

第一週：機器學習概觀

資料、模型與泛化

從「模型在學什麼」到「如何相信評估結果」。

什麼是機器學習？

模型利用資料中的經驗，改善某項任務的表現。

要素	垃圾郵件偵測
任務 T	判斷一封新郵件是否為垃圾郵件
經驗 E	使用者標記過的郵件與特徵
表現 P	在未見過郵件上的錯誤與漏判情形

儲存更多資料，不等於已經學會執行任務。

 **配套 Notebook：** `programs/notebooks/01_機器學習概觀.ipynb`。程式片段、實際圖表與表格可由此檔重現。

規則程式與資料學習

規則程式

資料 + 人寫規則



程式執行



預測結果

機器學習

資料 + 已知答案



訓練演算法



學到的模型

學到的模型再接收新資料，產生預測

當規則難以列完或經常改變時，資料學習可以減少人工維護。
訓練資料與評估方式，仍然需要人來設計。

機器學習系統的三個分類軸


分類軸	比較的是什麼？	例子
監督訊號	訓練時有哪些答案或回饋？	監督、非監督、半監督、自監督、強化
更新方式	是否能逐步吸收新資料？	批次、線上／增量
泛化方式	如何處理新樣本？	實例式、模型式

同一個系統可以同時是「監督式、批次、模型式」。

這些分類軸不是互斥的演算法清單。

監督式學習：迴歸與分類


迴歸



目標是連續數值，例如價格、溫度或需求量。

標籤的意義決定任務。數字編碼 0／1 不代表迴歸，邏輯斯迴歸通常用來分類。

分類



目標是離散類別，可分為二元或多類別任務。

樣本、特徵與目標

房屋樣本	面積（坪）	房齡（年）	區域	成交價（萬元）
A	20	5	北區	900
B	32	18	南區	1,150
C	25	10	北區	1,020

- 一列是一筆樣本。面積、房齡、區域是候選**特徵**。
- 成交價是**目標**，訓練時已知，推論時待預測。
- 樣本編號通常只供追蹤，不直接當作預測線索。


分類模型的樣本、特徵與目標

動物樣本	體重 (kg)	體長 (cm)	種類標籤
A	2.8	24	貓
B	18.0	52	狗
C	1.6	20	兔
D	4.1	29	貓

- 每一列是一筆**樣本**。體重與體長是**特徵**。
- 種類是**目標標籤**。貓／非貓是二元分類，貓／狗／兔是多類別分類。
- 表格特徵可嘗試 k 近鄰、邏輯斯迴歸、SVM 或隨機森林。原始影像通常需要 CNN 等模型學習視覺特徵。

非監督式學習


分群 (clustering)



找出特徵相似的樣本群組，群編號不是預先定義的人群標籤。

訓練資料沒有這次任務的目標標籤。t-SNE 圖上的距離與群形可能失真，不能單憑圖形斷定真實類別。

t-SNE 視覺化




將高維資料投影到二維，用來觀察結構與可能的群聚。

半監督式學習

- 少量樣本已有標籤，大量樣本還沒有標籤。
- 例如先用分群找出相似樣本，再將已確認的群標籤擴展給未標記樣本。
- 也可先用現有分類器產生**偽標籤**，再挑選高信心結果加入訓練。

風險：偽標籤可能出錯，錯誤還可能在後續訓練中被放大。

自監督式學習



先從未標記資料自動產生「輸入與目標」。圖 1-11 用遮罩影像當輸入，原始影像當目標，訓練模型復原被遮住的內容。

這個任務不需要人工逐張標記，但訓練時仍有明確目標。

遷移學習的做法

1. **先學通用表示**：在較大的來源資料集上預訓練模型。
2. **改成目標任務**：保留可重用的特徵擷取部分，替換或新增輸出層。
3. **用目標資料微調**：先凍結部分參數，再視資料量與評估結果逐步解凍。
4. **在目標分布上評估**：來源與目標差異太大時，可能出現負遷移。

教材範例：先學會復原寵物影像，再將模型改為寵物種類分類器，使用少量已標記影像微調。

強化學習：從互動回饋學策略



互動產生學習資料，策略影響後續取得的經驗

- 代理人觀察環境、採取行動，再取得新狀態與獎勵。
- 學習目標通常是提高**長期累積回饋**。
- 互動軌跡就是資料，也可能使用既有軌跡訓練。

批次學習與線上學習

	批次學習	線上／增量學習
更新	彙整資料後重新訓練	逐筆或小批次更新
適合情境	資料較穩定，可定期重訓	資料流、快速變化或記憶體有限
主要風險	更新延遲，模型逐漸過時	壞資料可能快速影響模型

「線上」不一定指連上網路或即時對外服務。
推論時即時回覆，也不代表模型正在即時學習。

實例式與模型式泛化

方法	新樣本如何得到答案？	需要注意
實例式	比較相似樣本，例如 k 個最近鄰居	距離定義、尺度、搜尋成本
模型式	把特徵代入已學到的函數	模型假設、參數、擬合程度

例如預測生活滿意度：

- 最近鄰：參考收入相近國家的生活滿意度。
- 線性模型：將收入代入一條已學好的直線。

 **配套實作：** `programs/notebooks/01_機器學習概觀.ipynb`。用同一份生活滿意度資料比較 k -NN 與線性模型，並延伸觀察梯度下降的學習率。

生活滿意度：先看資料代表什麼

國家	人均 GDP（美元）	生活滿意度
土耳其	28,384	5.5
匈牙利	31,008	5.6
法國	42,026	6.5
美國	60,236	6.9
紐西蘭	42,404	7.3
澳洲	48,698	7.3
丹麥	55,938	7.6


一筆資料是一個國家。國家層級關係不能直接推論個人因果。

線性模型的參數

$$\hat{y} = b + wx \qquad \hat{y} = b + \sum_{j=1}^d w_j x_j$$

- x 或 $\mathbf{x}$ ：輸入特徵。 $\hat{y}$ ：預測值。
- b ：截距。 w_j ：第 j 個特徵的權重。
- 一個特徵是簡單線性迴歸，多個特徵是多元線性迴歸。
- **訓練**：用資料找到參數。 **推論**：用已定參數產生答案。

一條線如何產生新預測？



教材模型： $\hat{y} = 3.75 + 6.78 \times 10^{-5}x$ 。

代入 $x = 33,442$ 美元，預測生活滿意度約 **6.02**。

Example 1-1：準備資料與散布圖

```
import matplotlib.pyplot as plt
import numpy as np
import pandas as pd
from sklearn.linear_model import LinearRegression

# Download and prepare the data
data_root = "https://github.com/ageron/data/raw/main/"
lifesat = pd.read_csv(data_root + "lifesat/lifesat.csv")
X = lifesat[["GDP per capita (USD)"]].values
y = lifesat[["Life satisfaction"]].values

# Visualize the data
lifesat.plot(kind="scatter", grid=True,
             x="GDP per capita (USD)", y="Life satisfaction")
plt.axis([23_500, 62_500, 4, 9])
plt.show()
```

`x` 是輸入特徵，`y` 是訓練時的目標。散布圖用來先檢查資料關係，不是模型的輸出。

Example 1-1：訓練與執行線性模型

```
model = LinearRegression()  
model.fit(X, y)  
X_new = [[33_442.8]] # GDP per capita in 2020  
print(model.predict(X_new)) # outputs [[6.01610329]]
```

程式片段	作用
<code>LinearRegression()</code>	選擇線性迴歸模型
<code>fit(X, y)</code>	由已知輸入與目標估計參數
<code>predict(X_new)</code>	將新樣本代入訓練完成的模型

輸出約為 **6.02**，與把 $x = 33,442$ 代入直線的結果一致。

先預測：改用三個最近鄰居，同一筆 GDP 的預測一定相同嗎？為什麼？


同一筆 GDP，線性模型與近鄰如何預測？

同一份國家資料：橫軸為人均 GDP（美元），縱軸為生活滿意度。星號是線性模型的新預測。

```
query = pd.DataFrame({  
    "GDP per capita (USD)": [33_442.8]})  
linear.predict(query), knn.predict(query)
```

直線使用全體資料估計參數；3-NN 平均三個近鄰的目標值。預測不同，不能只憑貼合圖選模型。

參考程式：`programs/notebooks/01_機器學習概觀.ipynb`




損失函數：把「擬合好不好」變成數字

$$e_i = \hat{y}_i - y_i$$

$$\text{MSE} = \frac{1}{m} \sum_{i=1}^m e_i^2$$

比較預測與真值的垂直差距。
平方可避免正負誤差互相抵銷。



ML 的主要挑戰

資料問題與模型問題都會影響泛化

接下來檢查「壞資料」與「壞模型」如何讓新樣本的預測失敗。


資料不足與不具代表性

狀況	例子	可能的改善方向
樣本太少	少量觀察不足以穩定估計關係	蒐集資料、簡化模型
抽樣偏差	只蒐集熱門網站上的商品評論	改善取樣與涵蓋範圍
分布改變	前一代相機影像用於新手機	建立接近使用情境的評估集

大量資料仍可能有系統性偏差。

先定義想泛化到的對象，再判斷資料是否足夠。

樣本範圍會改變我們看到的關係



補入較低與較高收入的國家後，原本的直線不再同樣合適。


外插到訓練範圍以外，尤其需要檢查模型假設。

資料品質與特徵工程

- **缺失值**：缺的是誰？為什麼缺？直接刪除會不會改變樣本？
- **離群值與量測錯誤**：先確認來源與單位，再決定處理方式。
- **不相關特徵**：模型可能學到偶然關係，例如名稱中的字母。
- **特徵工程**：挑選有用特徵、組合既有欄位，或補充新資料。

推論當下拿不到的欄位，即使與目標高度相關，也不能直接使用。

過度擬合：更貼近訓練資料，未必更能泛化



高次多項式緊貼各國的訓練資料，連偶然波動也當成規律。

它在訓練資料上表現很好，對未見國家的預測卻不可信。

 **配套實作：** `programs/notebooks/01_機器學習概觀.ipynb` （多項式、交叉驗證與正則化）

模型何時容易把雜訊當成規律？

容易發生的情況


- 模型相對於資料量與雜訊太複雜
- 訓練集太小，抽樣雜訊影響更大
- 不相關特徵讓模型找到偶然關係

教材提出的改善方向

- 選擇參數較少的模型、減少特徵，或限制模型
- 蒐集更多訓練資料
- 修正資料錯誤並處理不適當的離群值，以降低雜訊

關鍵不是一味降低訓練誤差，而是讓模型能預測未見樣本。

正則化：限制模型追隨資料的自由度



- 點線：只用圓點訓練的原模型；黑實線：加入方點後，用全部資料重新訓練。
- 藍虛線：只用圓點訓練，但加入**正則化**限制，斜率較小。
- 正則化模型對圓點的擬合稍差，對未見的方點卻較能泛化。

欠擬合與過度擬合的判讀

訓練誤差	驗證誤差	先檢查什麼？
高	高	特徵不足、模型太簡單、限制太強，或尚未收斂
低	高	過度擬合、資料分布不一致、切分問題
低	低	值得保留，仍需獨立測試與基準比較

「高」與「低」要相對於任務容許誤差及合理基準。
誤差落差是診斷線索，不能單憑一張表判定原因。

泛化與部署是不同的檢查面向

即使離線評估不錯，上線仍可能遇到：

- 新資料的格式、缺失率或分布改變。
- 推論速度、記憶體與維護成本無法接受。
- 真實標籤延遲到達，無法立即判斷表現。

測試集只能估計其代表情境下的表現。

模型上線後仍需監測與更新。

訓練、驗證與測試的分工



訓練集學參數，驗證集做選擇，測試集估計最終表現。

80／20 或 60／20／20 都是示例，比例取決於資料量與情境。

參數與超參數

	例子	主要如何決定？
模型參數	截距、權重、已學到的樹分割	訓練資料與學習演算法
超參數	正則化強度、鄰居數、樹最大深度	預先設定，再以驗證結果選擇
決策設定	分類閾值、可接受漏判率	任務代價與驗證資料

看過測試分數再調整設定，會讓測試集參與模型選擇。
即使沒有拿測試資料做梯度更新，也可能造成洩漏。

交叉驗證的基本概念


把開發資料分成 k 份，輪流保留一份做驗證。

- 每一折都重新訓練，再評估該折未參與訓練的資料。
- 比較各折分數與平均表現，減少依賴單一切分。
- 選完設定後，用全部開發資料重訓，再做最終測試。

交叉驗證不取代獨立測試集，也不能補救錯誤的切分單位。

 **配套實作：** `programs/notebooks/01_機器學習概觀.ipynb`。Notebook 將多項式複雜度、CV、L1／L2／ElasticNet 與早停放在同一條驗證流程中。

早停：訓練輪數也需要驗證



訓練損失繼續降低時，驗證損失可能已開始上升。
依驗證表現保留較好的模型狀態，不用測試集挑停止時間。

 **可執行範例：** `programs/notebooks/01_機器學習概觀.ipynb` (early stopping / best checkpoint)

分布不一致與切分單位

想預測的對象	合理的切分思考
同分布的新樣本	可考慮隨機切分
新學生／新病人／新裝置	依個體或群組切分，避免同人跨集合
未來一段時間	依時間切分，以過去預測未來
手機拍攝照片	驗證與測試應涵蓋實際手機情境

教材另留 **train-dev**：和訓練同來源但未參與訓練，
用來協助區分過度擬合與來源差異。

 **研究設計延伸**： `programs/notebooks/01_機器學習概觀.ipynb` 。可用 train-dev／data mismatch、群組切分與時間切分案例檢查評估設計。

第一週回顧與離堂題

- ML 的核心是用經驗改善任務表現，目標是**泛化**。
- 好資料要涵蓋預期使用對象，也要有可用的預測訊號。
- 正則化控制模型複雜度，強度需以驗證決定。
- 訓練、驗證、測試各自回答不同問題。

離堂題：某模型訓練表現很好、驗證表現很差，請提出兩種可能原因，以及各自需要補查的證據。