

第一週：機器學習概觀

資料、模型與泛化

從「模型在學什麼」到「如何相信評估結果」。

什麼是機器學習？

模型利用資料中的經驗，改善某項任務的表現。

要素	垃圾郵件偵測
任務 T	判斷一封新郵件是否為垃圾郵件
經驗 E	使用者標記過的郵件與特徵
表現 P	在未見過郵件上的錯誤與漏判情形

儲存更多資料，不等於已經學會執行任務。

規則程式與資料學習

規則程式

資料 + 人寫規則



程式執行



預測結果

機器學習

資料 + 已知答案



訓練演算法



學到的模型

學到的模型再接收新資料，產生預測

當規則難以列完或經常改變時，資料學習可以減少人工維護。
訓練資料與評估方式，仍然需要人來設計。

機器學習系統的三個分類軸

分類軸	比較的是什麼？	例子
監督訊號	訓練時有哪些答案或回饋？	監督、非監督、半監督、自監督、強化
更新方式	是否能逐步吸收新資料？	批次、線上／增量
泛化方式	如何處理新樣本？	實例式、模型式

同一個系統可以同時是「監督式、批次、模型式」。
這些分類軸不是互斥的演算法清單。

監督式學習：迴歸與分類

任務	輸入 x	目標 y	問題
迴歸	區域收入、房齡、人口	房價中位數	數值差多少？
二元分類	郵件文字與寄件資訊	垃圾／正常	屬於哪一類？
多類別分類	手寫數字影像	0 到 9	十類中是哪一類？

- **標籤的意義**決定任務，數字編碼 0／1 不代表迴歸。
- 邏輯斯迴歸雖然名字有「迴歸」，通常用來分類。

樣本、特徵與目標

房屋樣本	面積（坪）	房齡（年）	區域	成交價（萬元）
A	20	5	北區	900
B	32	18	南區	1,150
C	25	10	北區	1,020

- 一列是一筆樣本。面積、房齡、區域是候選**特徵**。
- 成交價是**目標**，訓練時已知，推論時待預測。
- 樣本編號通常只供追蹤，不直接當作預測線索。

非監督式學習

訓練資料沒有提供這次任務的目標標籤，模型尋找資料結構。

任務	用途	解讀限制
分群	找出行為相近的訪客	群編號不等於預先定義的人群
降維與視覺化	把高維資料投影到低維	圖上的距離可能失真
異常偵測	找出偏離常態的樣本	異常不必然是錯誤或詐欺
關聯規則	找出常一起出現的商品	共現不能直接解釋為因果

半監督、自監督與遷移學習

名稱	資料與訓練方式	例子
半監督	少量有標籤，加上大量無標籤資料	利用群結構或偽標籤輔助分類
自監督	從資料本身產生訓練目標	遮住影像區塊，再預測原內容
遷移學習	把既有任務學到的表示用於新任務	影像預訓練後再學寵物分類

自監督訓練有目標，只是不必逐筆請人標記。
偽標籤可能出錯，不能自動視為真實答案。

強化學習：從互動回饋學策略



互動產生學習資料，策略影響後續取得的經驗

- 代理人觀察環境、採取行動，再取得新狀態與獎勵。
- 學習目標通常是提高**長期累積回饋**。
- 互動軌跡就是資料，也可能使用既有軌跡訓練。

活動 A：先判斷任務，再選學習方式

兩人一組，每題說出「輸入、目標／回饋、學習方式」。

1. 預測房屋下個月的成交價。
2. 把未標記的顧客交易分成數種行為群。
3. 用少量已標記照片與大量未標記照片辨識動物。
4. 讓機器人嘗試移動，以到達終點取得獎勵。

加問：若只有未標記影像，能如何自己產生訓練目標？

批次學習與線上學習

	批次學習	線上／增量學習
更新	彙整資料後重新訓練	逐筆或小批次更新
適合情境	資料較穩定，可定期重訓	資料流、快速變化或記憶體有限
主要風險	更新延遲，模型逐漸過時	壞資料可能快速影響模型

「線上」不一定指連上網路或即時對外服務。
推論時即時回覆，也不代表模型正在即時學習。

實例式與模型式泛化

方法	新樣本如何得到答案？	需要注意
實例式	比較相似樣本，例如 k 個最近鄰居	距離定義、尺度、搜尋成本
模型式	把特徵代入已學到的函數	模型假設、參數、擬合程度

例如預測生活滿意度：

- 最近鄰：參考收入相近國家的生活滿意度。
- 線性模型：將收入代入一條已學好的直線。

生活滿意度：先看資料代表什麼

國家	人均 GDP（美元）	生活滿意度
土耳其	28,384	5.5
匈牙利	31,008	5.6
法國	42,026	6.5
美國	60,236	6.9
紐西蘭	42,404	7.3
澳洲	48,698	7.3
丹麥	55,938	7.6


一筆資料是一個國家。國家層級關係不能直接推論個人因果。

線性模型的參數

$$\hat{y} = b + wx \qquad \hat{y} = b + \sum_{j=1}^d w_j x_j$$

- x 或 $\mathbf{x}$ ：輸入特徵。 $\hat{y}$ ：預測值。
- b ：截距。 w_j ：第 j 個特徵的權重。
- 一個特徵是簡單線性迴歸，多個特徵是多元線性迴歸。
- **訓練**：用資料找到參數。 **推論**：用已定參數產生答案。

一條線如何產生新預測？



教材模型： $\hat{y} = 3.75 + 6.78 \times 10^{-5}x$ 。


代入 $x = 33,442$ 美元，預測生活滿意度約 **6.02**。

損失函數：把「擬合好不好」變成數字

$$e_i = \hat{y}_i - y_i$$

$$\text{MSE} = \frac{1}{m} \sum_{i=1}^m e_i^2$$

比較預測與真值的垂直差距。
平方可避免正負誤差互相抵銷。



梯度下降以 $\theta_{t+1} = \theta_t - \eta \nabla J(\theta_t)$ 反覆更新參數。
 η 是步長。訓練也可以用解析法求解。


資料不足與不具代表性

狀況	例子	可能的改善方向
樣本太少	少量觀察不足以穩定估計關係	蒐集資料、簡化模型
抽樣偏差	只蒐集熱門網站上的商品評論	改善取樣與涵蓋範圍
分布改變	舊相機影像用於新手機	建立接近使用情境的評估集

大量資料仍可能有系統性偏差。

先定義想泛化到的對象，再判斷資料是否足夠。

樣本範圍會改變我們看到的關係



補入較低與較高收入的國家後，原本的直線不再同樣合適。


外插到訓練範圍以外，尤其需要檢查模型假設。

資料品質與特徵工程

- **缺失值**：缺的是誰？為什麼缺？直接刪除會不會改變樣本？
- **離群值與量測錯誤**：先確認來源與單位，再決定處理方式。
- **不相關特徵**：模型可能學到偶然關係，例如名稱中的字母。
- **特徵工程**：挑選有用特徵、組合既有欄位，或補充新資料。

推論當下拿不到的欄位，即使與目標高度相關，也不能直接使用。

過度擬合：更貼近訓練資料，未必更能泛化



舊稿示例：藍點為訓練資料，綠點為測試資料。


二次模型與 50 次模型都能擬合曲線，高次模型更容易追隨噪音。

舊稿結果：訓練誤差與測試誤差

舊稿模型	訓練 RMSE	測試 RMSE
二次多項式	2.83	2.40
50 次多項式	2.70	7.24

- 50 次模型的訓練 RMSE 較低，測試 RMSE 卻明顯較高。
- 測試誤差偶爾比訓練誤差低，可能來自抽樣差異。
- 這是**舊稿報告的單次示例**，不代表任何模型的普遍排名。

正則化：限制模型追隨資料的自由度



教材以限制斜率示範：允許訓練誤差增加，換取較穩定的預測。
限制太強，也可能無法學到真正存在的關係。


L1 與 L2 正則化

$$J(\mathbf{w}, b) = \frac{1}{m} \sum_{i=1}^m (\hat{y}_i - y_i)^2 + \lambda \Omega(\mathbf{w})$$

方法	懲罰項 $\Omega(\mathbf{w})$	常見效果
Ridge／L2	$\sum_j w_j^2$	縮小係數，通常不直接變為 0
Lasso／L1	$\sum_j w_j $	部分係數可能變為 0，形成稀疏解
Elastic Net	L1 與 L2 的加權組合	結合兩類限制

$\lambda \geq 0$ 是超參數。此處通常不懲罰截距 b 。

正則化的幾何直覺



- 藍色等高線表示不同損失。
- 黃色區域是允許的係數範圍。
- L2 的限制邊界是圓。
- L1 的限制邊界有位於座標軸的角點，較容易出現零係數。

快算：不同係數如何受到懲罰？

假設兩個模型的 MSE 都是 2，特徵已採相同尺度：

模型	係數向量	L1 懲罰	L2 懲罰
A	(3, 0)	?	?
B	(1.5, 1.5)	?	?

以 $J = \text{MSE} + \lambda\Omega$ 、 $\lambda = 1$ 計算總目標。

兩種懲罰偏好的係數配置有什麼不同？

欠擬合與過度擬合的判讀

訓練誤差	驗證誤差	先檢查什麼？
高	高	特徵不足、模型太簡單、限制太強，或尚未收斂
低	高	過度擬合、資料分布不一致、切分問題
低	低	值得保留，仍需獨立測試與基準比較

「高」與「低」要相對於任務容許誤差及合理基準。
誤差落差是診斷線索，不能單憑一張表判定原因。

泛化與部署是不同的檢查面向

即使離線評估不錯，上線仍可能遇到：

- 新資料的格式、缺失率或分布改變。
- 推論速度、記憶體與維護成本無法接受。
- 真實標籤延遲到達，無法立即判斷表現。

測試集只能估計其代表情境下的表現。

模型上線後仍需監測與更新。

訓練、驗證與測試的分工



訓練集學參數，驗證集做選擇，測試集估計最終表現。

80／20 或 60／20／20 都是示例，比例取決於資料量與情境。

參數與超參數

	例子	主要如何決定？
模型參數	截距、權重、已學到的樹分割	訓練資料與學習演算法
超參數	正則化強度、鄰居數、樹最大深度	預先設定，再以驗證結果選擇
決策設定	分類閾值、可接受漏判率	任務代價與驗證資料

看過測試分數再調整設定，會讓測試集參與模型選擇。
即使沒有拿測試資料做梯度更新，也可能造成洩漏。


交叉驗證的基本概念

把開發資料分成 k 份，輪流保留一份做驗證。

- 每一折都重新訓練，再評估該折未參與訓練的資料。
- 比較各折分數與平均表現，減少依賴單一切分。
- 選完設定後，用全部開發資料重訓，再做最終測試。

交叉驗證不取代獨立測試集，也不能補救錯誤的切分單位。

早停：訓練輪數也需要驗證



訓練損失繼續降低時，驗證損失可能已開始上升。
依驗證表現保留較好的模型狀態，不用測試集挑停止時間。

分布不一致與切分單位

想預測的對象	合理的切分思考
同分布的新樣本	可考慮隨機切分
新學生／新病人／新裝置	依個體或群組切分，避免同人跨集合
未來一段時間	依時間切分，以過去預測未來
手機拍攝照片	驗證與測試應涵蓋實際手機情境

教材另留 **train-dev**：和訓練同來源但未參與訓練，
用來協助區分過度擬合與來源差異。

活動 B：設計一個可以相信的評估

有 200 位學生、每人 20 筆每週學習紀錄。

任務是預測「新入學學生」是否需要學習協助。

1. 一筆觀察與泛化對象分別是什麼？
2. 為何隨機把 4,000 列分成三份可能過度樂觀？
3. 如何切分訓練、驗證、測試？
4. 「學期結束後的總成績」可以當早期預警特徵嗎？

產出：一張資料切分圖，加上兩項可能的洩漏來源。

第一週回顧與離堂題

- ML 的核心是用經驗改善任務表現，目標是**泛化**。
- 好資料要涵蓋預期使用對象，也要有可用的預測訊號。
- 正則化控制模型複雜度，強度需以驗證決定。
- 訓練、驗證、測試各自回答不同問題。

離堂題：某模型訓練表現很好、驗證表現很差，請提出兩種可能原因，以及各自需要補查的證據。