

# 第一週：機器學習概觀

## 資料、模型與泛化

從「模型在學什麼」到「如何相信評估結果」。

# 什麼是機器學習？

---

模型利用資料中的經驗，改善某項任務的表現。

| 要素     | 垃圾郵件偵測          |
|--------|-----------------|
| 任務 $T$ | 判斷一封新郵件是否為垃圾郵件  |
| 經驗 $E$ | 使用者標記過的郵件與特徵    |
| 表現 $P$ | 在未見過郵件上的錯誤與漏判情形 |

儲存更多資料，不等於已經學會執行任務。

# 規則程式與資料學習

---

## 規則程式

資料 + 人寫規則



程式執行



預測結果

## 機器學習

資料 + 已知答案



訓練演算法



學到的模型

學到的模型再接收新資料，產生預測

當規則難以列完或經常改變時，資料學習可以減少人工維護。  
訓練資料與評估方式，仍然需要人來設計。


## 機器學習系統的三個分類軸

| 分類軸  | 比較的是什麼？      | 例子                |
|------|--------------|-------------------|
| 監督訊號 | 訓練時有哪些答案或回饋？ | 監督、非監督、半監督、自監督、強化 |
| 更新方式 | 是否能逐步吸收新資料？  | 批次、線上／增量          |
| 泛化方式 | 如何處理新樣本？     | 實例式、模型式           |

同一個系統可以同時是「監督式、批次、模型式」。  
這些分類軸不是互斥的演算法清單。

# 監督式學習：迴歸與分類


## 迴歸



目標是連續數值，例如價格、溫度或需求量。

**標籤的意義**決定任務。數字編碼 0/1 不代表迴歸，邏輯斯迴歸通常用來分類。

## 分類



目標是離散類別，可分為二元或多類別任務。

## 樣本、特徵與目標

| 房屋樣本 | 面積（坪） | 房齡（年） | 區域 | 成交價（萬元） |
|------|-------|-------|----|---------|
| A    | 20    | 5     | 北區 | 900     |
| B    | 32    | 18    | 南區 | 1,150   |
| C    | 25    | 10    | 北區 | 1,020   |

- 一列是一筆樣本。面積、房齡、區域是候選**特徵**。
- 成交價是**目標**，訓練時已知，推論時待預測。
- 樣本編號通常只供追蹤，不直接當作預測線索。


## 分類模型的樣本、特徵與目標

| 動物樣本 | 體重 (kg) | 體高 (cm) | 種類標籤 |
|------|---------|---------|------|
| A    | 2.8     | 24      | 貓    |
| B    | 18.0    | 52      | 狗    |
| C    | 1.6     | 20      | 兔    |
| D    | 4.1     | 29      | 貓    |

- 每一列是一筆**樣本**。體重與體高是**特徵**。
- 種類是**目標標籤**。貓／非貓是二元分類，貓／狗／兔是多類別分類。
- 表格特徵可嘗試  $k$  近鄰、邏輯斯迴歸、SVM 或隨機森林。原始影像通常需要 CNN 等模型學習視覺特徵。

# 非監督式學習


## 分群 (clustering)



找出特徵相似的樣本群組，群編號不是預先定義的人群標籤。

訓練資料沒有這次任務的目標標籤。t-SNE 圖上的距離與群形可能失真，不能單憑圖形斷定真實類別。

## t-SNE 視覺化



將高維資料投影到二維，用來觀察結構與可能的群聚。

## 半監督式學習


---

- 少量樣本已有標籤，大量樣本還沒有標籤。
- 例如先用分群找出相似樣本，再將已確認的群標籤擴展給未標記樣本。
- 也可先用現有分類器產生**偽標籤**，再挑選高信心結果加入訓練。

**風險**：偽標籤可能出錯，錯誤還可能在後續訓練中被放大。

# 自監督式學習

---



先從未標記資料自動產生「輸入與目標」。圖 1-11 用遮罩影像當輸入，原始影像當目標，訓練模型復原被遮住的內容。

這個任務不需要人工逐張標記，但訓練時仍有明確目標。

## 遷移學習的做法

---

1. **先學通用表示**：在較大的來源資料集上預訓練模型。
2. **改成目標任務**：保留可重用的特徵擷取部分，替換或新增輸出層。
3. **用目標資料微調**：先凍結部分參數，再視資料量與評估結果逐步解凍。
4. **在目標分布上評估**：來源與目標差異太大時，可能出現負遷移。

**教材範例**：先學會復原寵物影像，再將模型改為寵物種類分類器，使用少量已標記影像微調。

# 強化學習：從互動回饋學策略

---



互動產生學習資料，策略影響後續取得的經驗

- 代理人觀察環境、採取行動，再取得新狀態與獎勵。
- 學習目標通常是提高**長期累積回饋**。
- 互動軌跡就是資料，也可能使用既有軌跡訓練。

## 批次學習與線上學習

|      | 批次學習        | 線上／增量學習        |
|------|-------------|----------------|
| 更新   | 彙整資料後重新訓練   | 逐筆或小批次更新       |
| 適合情境 | 資料較穩定，可定期重訓 | 資料流、快速變化或記憶體有限 |
| 主要風險 | 更新延遲，模型逐漸過時 | 壞資料可能快速影響模型    |

「線上」不一定指連上網路或即時對外服務。  
推論時即時回覆，也不代表模型正在即時學習。

## 實例式與模型式泛化

| 方法  | 新樣本如何得到答案？          | 需要注意         |
|-----|---------------------|--------------|
| 實例式 | 比較相似樣本，例如 $k$ 個最近鄰居 | 距離定義、尺度、搜尋成本 |
| 模型式 | 把特徵代入已學到的函數         | 模型假設、參數、擬合程度 |

例如預測生活滿意度：

- 最近鄰：參考收入相近國家的生活滿意度。
- 線性模型：將收入代入一條已學好的直線。

## 生活滿意度：先看資料代表什麼

| 國家  | 人均 GDP（美元） | 生活滿意度 |
|-----|------------|-------|
| 土耳其 | 28,384     | 5.5   |
| 匈牙利 | 31,008     | 5.6   |
| 法國  | 42,026     | 6.5   |
| 美國  | 60,236     | 6.9   |
| 紐西蘭 | 42,404     | 7.3   |
| 澳洲  | 48,698     | 7.3   |
| 丹麥  | 55,938     | 7.6   |

一筆資料是一個國家。國家層級關係不能直接推論個人因果。


## 線性模型的參數

---

$$\hat{y} = b + wx \qquad \hat{y} = b + \sum_{j=1}^d w_j x_j$$

- $x$  或  $\mathbf{x}$ ：輸入特徵。  $\hat{y}$ ：預測值。
- $b$ ：截距。  $w_j$ ：第  $j$  個特徵的權重。
- 一個特徵是簡單線性迴歸，多個特徵是多元線性迴歸。
- **訓練**：用資料找到參數。 **推論**：用已定參數產生答案。

## 一條線如何產生新預測？



教材模型： $\hat{y} = 3.75 + 6.78 \times 10^{-5}x$ 。

代入  $x = 33,442$  美元，預測生活滿意度約 **6.02**。

## Example 1-1：準備資料與散布圖

```
import matplotlib.pyplot as plt
import numpy as np
import pandas as pd
from sklearn.linear_model import LinearRegression

# Download and prepare the data
data_root = "https://github.com/ageron/data/raw/main/"
lifesat = pd.read_csv(data_root + "lifesat/lifesat.csv")
X = lifesat[["GDP per capita (USD)"]].values
y = lifesat[["Life satisfaction"]].values

# Visualize the data
lifesat.plot(kind="scatter", grid=True,
              x="GDP per capita (USD)", y="Life satisfaction")
plt.axis([23_500, 62_500, 4, 9])
plt.show()
```

`x` 是輸入特徵，`y` 是訓練時的目標。散布圖用來先檢查資料關係，不是模型的輸出。

# Example 1-1：訓練與執行線性模型

```
# Select a linear model
model = LinearRegression()

# Train the model
model.fit(X, y)

# Make a prediction for Puerto Rico
X_new = [[33_442.8]] # GDP per capita in 2020
print(model.predict(X_new)) # outputs [[6.01610329]]
```

| 程式片段               | 作用            |
|--------------------|---------------|
| LinearRegression() | 選擇線性迴歸模型      |
| fit(X, y)          | 由已知輸入與目標估計參數  |
| predict(X_new)     | 將新樣本代入訓練完成的模型 |


輸出約為 **6.02**，與前頁把  $x = 33,442$  代入直線的結果一致。

# 損失函數：把「擬合好不好」變成數字

$$e_i = \hat{y}_i - y_i$$

$$\text{MSE} = \frac{1}{m} \sum_{i=1}^m e_i^2$$

比較預測與真值的垂直差距。  
平方可避免正負誤差互相抵銷。



梯度下降以  $\theta_{t+1} = \theta_t - \eta \nabla J(\theta_t)$  反覆更新參數。

$\eta$  是步長：太小收斂太慢，太大可能發散。訓練也可以用解析法求解。

# ML 的主要挑戰

資料問題與模型問題都會影響泛化

接下來檢查「壞資料」與「壞模型」如何讓新樣本的預測失敗。


## 資料不足與不具代表性

| 狀況   | 例子            | 可能的改善方向      |
|------|---------------|--------------|
| 樣本太少 | 少量觀察不足以穩定估計關係 | 蒐集資料、簡化模型    |
| 抽樣偏差 | 只蒐集熱門網站上的商品評論 | 改善取樣與涵蓋範圍    |
| 分布改變 | 舊相機影像用於新手機    | 建立接近使用情境的評估集 |

大量資料仍可能有系統性偏差。

先定義想泛化到的對象，再判斷資料是否足夠。

## 樣本範圍會改變我們看到的關係



補入較低與較高收入的國家後，原本的直線不再同樣合適。

**外插**到訓練範圍以外，尤其需要檢查模型假設。


## 資料品質與特徵工程

---

- **缺失值**：缺的是誰？為什麼缺？直接刪除會不會改變樣本？
- **離群值與量測錯誤**：先確認來源與單位，再決定處理方式。
- **不相關特徵**：模型可能學到偶然關係，例如名稱中的字母。
- **特徵工程**：挑選有用特徵、組合既有欄位，或補充新資料。

推論當下拿不到的欄位，即使與目標高度相關，也不能直接使用。

## 過度擬合：更貼近訓練資料，未必更能泛化



舊稿示例：藍點為訓練資料，綠點為測試資料。


二次模型與 50 次模型都能擬合曲線，高次模型更容易追隨噪音。

## 舊稿結果：訓練誤差與測試誤差

| 舊稿模型    | 訓練 RMSE | 測試 RMSE |
|---------|---------|---------|
| 二次多項式   | 2.83    | 2.40    |
| 50 次多項式 | 2.70    | 7.24    |

- 50 次模型的訓練 RMSE 較低，測試 RMSE 卻明顯較高。
- 測試誤差偶爾比訓練誤差低，可能來自抽樣差異。

# 正則化：限制模型追隨資料的自由度



- 圖 1-23 的高次多項式太複雜，把訓練資料中的隨機波動當成規律，因而發生過度擬合。
- **正則化**對模型加上限制，讓模型較簡單，並降低過度擬合的風險。
- 圖 1-24 中，正則化模型的斜率較小。它對圓點的擬合稍差，卻對未見過的方點預測得更好。
- 限制太強時，直線會趨近水平，模型反而可能欠擬合。

## 欠擬合與過度擬合的判讀

| 訓練誤差 | 驗證誤差 | 先檢查什麼？                |
|------|------|-----------------------|
| 高    | 高    | 特徵不足、模型太簡單、限制太強，或尚未收斂 |
| 低    | 高    | 過度擬合、資料分布不一致、切分問題     |
| 低    | 低    | 值得保留，仍需獨立測試與基準比較      |

「高」與「低」要相對於任務容許誤差及合理基準。  
誤差落差是診斷線索，不能單憑一張表判定原因。

## 泛化與部署是不同的檢查面向

---

即使離線評估不錯，上線仍可能遇到：

- 新資料的格式、缺失率或分布改變。
- 推論速度、記憶體與維護成本無法接受。
- 真實標籤延遲到達，無法立即判斷表現。

測試集只能估計其代表情境下的表現。

模型上線後仍需監測與更新。

## 訓練、驗證與測試的分工

---



**訓練集學參數，驗證集做選擇，測試集估計最終表現。**

80／20 或 60／20／20 都是示例，比例取決於資料量與情境。

## 參數與超參數

|      | 例子              | 主要如何決定？       |
|------|-----------------|---------------|
| 模型參數 | 截距、權重、已學到的樹分割   | 訓練資料與學習演算法    |
| 超參數  | 正則化強度、鄰居數、樹最大深度 | 預先設定，再以驗證結果選擇 |
| 決策設定 | 分類閾值、可接受漏判率     | 任務代價與驗證資料     |

看過測試分數再調整設定，會讓測試集參與模型選擇。  
即使沒有拿測試資料做梯度更新，也可能造成洩漏。

## 交叉驗證的基本概念


---

把開發資料分成  $k$  份，輪流保留一份做驗證。

- 每一折都重新訓練，再評估該折未參與訓練的資料。
- 比較各折分數與平均表現，減少依賴單一切分。
- 選完設定後，用全部開發資料重訓，再做最終測試。

**交叉驗證不取代獨立測試集，也不能補救錯誤的切分單位。**

## 早停：訓練輪數也需要驗證



訓練損失繼續降低時，驗證損失可能已開始上升。  
依驗證表現保留較好的模型狀態，不用測試集挑停止時間。

## 分布不一致與切分單位

| 想預測的對象      | 合理的切分思考          |
|-------------|------------------|
| 同分布的新樣本     | 可考慮隨機切分          |
| 新學生／新病人／新裝置 | 依個體或群組切分，避免同人跨集合 |
| 未來一段時間      | 依時間切分，以過去預測未來    |
| 手機拍攝照片      | 驗證與測試應涵蓋實際手機情境   |

教材另留 **train-dev**：和訓練同來源但未參與訓練，  
用來協助區分過度擬合與來源差異。

## 第一週回顧與離堂題

---

- ML 的核心是用經驗改善任務表現，目標是**泛化**。
- 好資料要涵蓋預期使用對象，也要有可用的預測訊號。
- 正則化控制模型複雜度，強度需以驗證決定。
- 訓練、驗證、測試各自回答不同問題。

**離堂題：**某模型訓練表現很好、驗證表現很差，請提出兩種可能原因，以及各自需要補查的證據。