

第一週：機器學習概觀

資料、模型與泛化

從「模型在學什麼」到「如何相信評估結果」。

什麼是機器學習？

模型利用資料中的經驗，改善某項任務的表現。

要素	垃圾郵件偵測
任務 T	判斷一封新郵件是否為垃圾郵件
經驗 E	使用者標記過的郵件與特徵
表現 P	在未見過郵件上的錯誤與漏判情形

儲存更多資料，不等於已經學會執行任務。

規則程式與資料學習

規則程式

資料 + 人寫規則



程式執行



預測結果

機器學習

資料 + 已知答案



訓練演算法



學到的模型

學到的模型再接收新資料，產生預測

當規則難以列完或經常改變時，資料學習可以減少人工維護。
訓練資料與評估方式，仍然需要人來設計。


機器學習系統的三個分類軸

分類軸	比較的是什麼？	例子
監督訊號	訓練時有哪些答案或回饋？	監督、非監督、半監督、自監督、強化
更新方式	是否能逐步吸收新資料？	批次、線上／增量
泛化方式	如何處理新樣本？	實例式、模型式

同一個系統可以同時是「監督式、批次、模型式」。
這些分類軸不是互斥的演算法清單。

監督式學習：迴歸與分類


迴歸



目標是連續數值，例如價格、溫度或需求量。

標籤的意義決定任務。數字編碼 0/1 不代表迴歸，邏輯斯迴歸通常用來分類。

分類



目標是離散類別，可分為二元或多類別任務。

樣本、特徵與目標

房屋樣本	面積（坪）	房齡（年）	區域	成交價（萬元）
A	20	5	北區	900
B	32	18	南區	1,150
C	25	10	北區	1,020

- 一列是一筆樣本。面積、房齡、區域是候選**特徵**。
- 成交價是**目標**，訓練時已知，推論時待預測。
- 樣本編號通常只供追蹤，不直接當作預測線索。


分類模型的樣本、特徵與目標

動物樣本	體重 (kg)	體高 (cm)	種類標籤
A	2.8	24	貓
B	18.0	52	狗
C	1.6	20	兔
D	4.1	29	貓

- 每一列是一筆**樣本**。體重與體高是**特徵**。
- 種類是**目標標籤**。貓／非貓是二元分類，貓／狗／兔是多類別分類。
- 表格特徵可嘗試 k 近鄰、邏輯斯迴歸、SVM 或隨機森林。原始影像通常需要 CNN 等模型學習視覺特徵。

非監督式學習


分群 (clustering)



找出特徵相似的樣本群組，群編號不是預先定義的人群標籤。

訓練資料沒有這次任務的目標標籤。t-SNE 圖上的距離與群形可能失真，不能單憑圖形斷定真實類別。

t-SNE 視覺化




將高維資料投影到二維，用來觀察結構與可能的群聚。

半監督式學習

- 少量樣本已有標籤，大量樣本還沒有標籤。
- 例如先用分群找出相似樣本，再將已確認的群標籤擴展給未標記樣本。
- 也可先用現有分類器產生**偽標籤**，再挑選高信心結果加入訓練。

風險：偽標籤可能出錯，錯誤還可能在後續訓練中被放大。

自監督式學習



先從未標記資料自動產生「輸入與目標」。圖 1-11 用遮罩影像當輸入，原始影像當目標，訓練模型復原被遮住的內容。

這個任務不需要人工逐張標記，但訓練時仍有明確目標。

遷移學習的做法

1. **先學通用表示**：在較大的來源資料集上預訓練模型。
2. **改成目標任務**：保留可重用的特徵擷取部分，替換或新增輸出層。
3. **用目標資料微調**：先凍結部分參數，再視資料量與評估結果逐步解凍。
4. **在目標分布上評估**：來源與目標差異太大時，可能出現負遷移。

教材範例：先學會復原寵物影像，再將模型改為寵物種類分類器，使用少量已標記影像微調。

強化學習：從互動回饋學策略



互動產生學習資料，策略影響後續取得的經驗

- 代理人觀察環境、採取行動，再取得新狀態與獎勵。
- 學習目標通常是提高**長期累積回饋**。
- 互動軌跡就是資料，也可能使用既有軌跡訓練。

批次學習與線上學習

	批次學習	線上／增量學習
更新	彙整資料後重新訓練	逐筆或小批次更新
適合情境	資料較穩定，可定期重訓	資料流、快速變化或記憶體有限
主要風險	更新延遲，模型逐漸過時	壞資料可能快速影響模型

「線上」不一定指連上網路或即時對外服務。
推論時即時回覆，也不代表模型正在即時學習。

實例式與模型式泛化

方法	新樣本如何得到答案？	需要注意
實例式	比較相似樣本，例如 k 個最近鄰居	距離定義、尺度、搜尋成本
模型式	把特徵代入已學到的函數	模型假設、參數、擬合程度

例如預測生活滿意度：

- 最近鄰：參考收入相近國家的生活滿意度。
- 線性模型：將收入代入一條已學好的直線。

 **配套實作：** `programs/notebooks/01_從資料到線性模型.ipynb`。用同一份生活滿意度資料比較 k -NN 與線性模型，並延伸觀察梯度下降的學習率。

生活滿意度：先看資料代表什麼

國家	人均 GDP（美元）	生活滿意度
土耳其	28,384	5.5
匈牙利	31,008	5.6
法國	42,026	6.5
美國	60,236	6.9
紐西蘭	42,404	7.3
澳洲	48,698	7.3
丹麥	55,938	7.6


一筆資料是一個國家。國家層級關係不能直接推論個人因果。

線性模型的參數

$$\hat{y} = b + wx \qquad \hat{y} = b + \sum_{j=1}^d w_j x_j$$

- x 或 $\mathbf{x}$ ：輸入特徵。 $\hat{y}$ ：預測值。
- b ：截距。 w_j ：第 j 個特徵的權重。
- 一個特徵是簡單線性迴歸，多個特徵是多元線性迴歸。
- **訓練**：用資料找到參數。 **推論**：用已定參數產生答案。

一條線如何產生新預測？



教材模型： $\hat{y} = 3.75 + 6.78 \times 10^{-5}x$ 。

代入 $x = 33,442$ 美元，預測生活滿意度約 **6.02**。

Example 1-1：準備資料與散布圖

```
import matplotlib.pyplot as plt
import numpy as np
import pandas as pd
from sklearn.linear_model import LinearRegression

# Download and prepare the data
data_root = "https://github.com/ageron/data/raw/main/"
lifesat = pd.read_csv(data_root + "lifesat/lifesat.csv")
X = lifesat[["GDP per capita (USD)"]].values
y = lifesat[["Life satisfaction"]].values

# Visualize the data
lifesat.plot(kind="scatter", grid=True,
              x="GDP per capita (USD)", y="Life satisfaction")
plt.axis([23_500, 62_500, 4, 9])
plt.show()
```

x 是輸入特徵，**y** 是訓練時的目標。散布圖用來先檢查資料關係，不是模型的輸出。

Example 1-1：訓練與執行線性模型

```
# Select a linear model
model = LinearRegression()

# Train the model
model.fit(X, y)

# Make a prediction for Puerto Rico
X_new = [[33_442.8]] # GDP per capita in 2020
print(model.predict(X_new)) # outputs [[6.01610329]]
```

程式片段	作用
LinearRegression()	選擇線性迴歸模型
fit(X, y)	由已知輸入與目標估計參數
predict(X_new)	將新樣本代入訓練完成的模型


輸出約為 **6.02**，與前頁把 $x = 33,442$ 代入直線的結果一致。

損失函數：把「擬合好不好」變成數字

$$e_i = \hat{y}_i - y_i$$

$$\text{MSE} = \frac{1}{m} \sum_{i=1}^m e_i^2$$

比較預測與真值的垂直差距。
平方可避免正負誤差互相抵銷。



ML 的主要挑戰

資料問題與模型問題都會影響泛化

接下來檢查「壞資料」與「壞模型」如何讓新樣本的預測失敗。


資料不足與不具代表性

狀況	例子	可能的改善方向
樣本太少	少量觀察不足以穩定估計關係	蒐集資料、簡化模型
抽樣偏差	只蒐集熱門網站上的商品評論	改善取樣與涵蓋範圍
分布改變	舊相機影像用於新手機	建立接近使用情境的評估集

大量資料仍可能有系統性偏差。

先定義想泛化到的對象，再判斷資料是否足夠。

樣本範圍會改變我們看到的關係



補入較低與較高收入的國家後，原本的直線不再同樣合適。


外插到訓練範圍以外，尤其需要檢查模型假設。

資料品質與特徵工程

- **缺失值**：缺的是誰？為什麼缺？直接刪除會不會改變樣本？
- **離群值與量測錯誤**：先確認來源與單位，再決定處理方式。
- **不相關特徵**：模型可能學到偶然關係，例如名稱中的字母。
- **特徵工程**：挑選有用特徵、組合既有欄位，或補充新資料。

推論當下拿不到的欄位，即使與目標高度相關，也不能直接使用。

過度擬合：更貼近訓練資料，未必更能泛化



高次多項式緊貼各國的訓練資料，連偶然波動也當成規律。
它在訓練資料上表現很好，對未見國家的預測卻不可信。

 **配套實作：** `programs/notebooks/02_驗證正則化與早停.ipynb`。用多項式模型、交叉驗證與正則化觀察「訓練更好、泛化更差」如何發生。

模型何時容易把雜訊當成規律？

容易發生的情況


- 模型相對於資料量與雜訊太複雜
- 訓練集太小，抽樣雜訊影響更大
- 不相關特徵讓模型找到偶然關係

教材提出的改善方向

- 選擇參數較少的模型、減少特徵，或限制模型
- 蒐集更多訓練資料
- 修正資料錯誤並處理不適當的離群值，以降低雜訊

關鍵不是一味降低訓練誤差，而是讓模型能預測未見樣本。

正則化：限制模型追隨資料的自由度



- 點線：只用圓點訓練的原模型；黑實線：加入方點後，用全部資料重新訓練。
- 藍虛線：只用圓點訓練，但加入**正則化**限制，斜率較小。
- 正則化模型對圓點的擬合稍差，對未見的方點卻較能泛化。

欠擬合與過度擬合的判讀

訓練誤差	驗證誤差	先檢查什麼？
高	高	特徵不足、模型太簡單、限制太強，或尚未收斂
低	高	過度擬合、資料分布不一致、切分問題
低	低	值得保留，仍需獨立測試與基準比較

「高」與「低」要相對於任務容許誤差及合理基準。
誤差落差是診斷線索，不能單憑一張表判定原因。

泛化與部署是不同的檢查面向

即使離線評估不錯，上線仍可能遇到：

- 新資料的格式、缺失率或分布改變。
- 推論速度、記憶體與維護成本無法接受。
- 真實標籤延遲到達，無法立即判斷表現。

測試集只能估計其代表情境下的表現。

模型上線後仍需監測與更新。

訓練、驗證與測試的分工



訓練集學參數，驗證集做選擇，測試集估計最終表現。

80／20 或 60／20／20 都是示例，比例取決於資料量與情境。

參數與超參數

	例子	主要如何決定？
模型參數	截距、權重、已學到的樹分割	訓練資料與學習演算法
超參數	正則化強度、鄰居數、樹最大深度	預先設定，再以驗證結果選擇
決策設定	分類閾值、可接受漏判率	任務代價與驗證資料

看過測試分數再調整設定，會讓測試集參與模型選擇。
即使沒有拿測試資料做梯度更新，也可能造成洩漏。

交叉驗證的基本概念


把開發資料分成 k 份，輪流保留一份做驗證。

- 每一折都重新訓練，再評估該折未參與訓練的資料。
- 比較各折分數與平均表現，減少依賴單一切分。
- 選完設定後，用全部開發資料重訓，再做最終測試。

交叉驗證不取代獨立測試集，也不能補救錯誤的切分單位。

 **配套實作：** `programs/notebooks/02_驗證正則化與早停.ipynb`。Notebook 將多項式複雜度、CV、L1／L2／ElasticNet 與早停放在同一條驗證流程中。

早停：訓練輪數也需要驗證



訓練損失繼續降低時，驗證損失可能已開始上升。

依驗證表現保留較好的模型狀態，不用測試集挑停止時間。

 **可執行範例：** `programs/notebooks/02_驗證正則化與早停.ipynb` 的 early stopping / best checkpoint 段落。

補充 02_Validation and Regularization s.9；對應主教材 Ch.1 模型選擇

分布不一致與切分單位

想預測的對象	合理的切分思考
同分布的新樣本	可考慮隨機切分
新學生／新病人／新裝置	依個體或群組切分，避免同人跨集合
未來一段時間	依時間切分，以過去預測未來
手機拍攝照片	驗證與測試應涵蓋實際手機情境

教材另留 **train-dev**：和訓練同來源但未參與訓練，
用來協助區分過度擬合與來源差異。

 **研究設計延伸**： `programs/notebooks/08_研究延伸與常見陷阱.ipynb`。可用 train-dev／data mismatch、群組切分與時間切分案例檢查評估設計。

第一週回顧與離堂題

- ML 的核心是用經驗改善任務表現，目標是**泛化**。
- 好資料要涵蓋預期使用對象，也要有可用的預測訊號。
- 正則化控制模型複雜度，強度需以驗證決定。
- 訓練、驗證、測試各自回答不同問題。

離堂題：某模型訓練表現很好、驗證表現很差，請提出兩種可能原因，以及各自需要補查的證據。