

第二週：端到端機器學習專案

以加州房價理解資料與迴歸

每一個前處理與評估決定，都會影響最終結論。

專案全貌



開發中的探索與調整可以迭代，最終測試須保留獨立性

資料探索產生假設，驗證資料比較方案，測試資料評估定案。

上線後的監測，決定何時需要重新蒐集資料與訓練。


 **配套 Notebook：** `programs/notebooks/02_端到端機器學習專案.ipynb`

程式實驗與實際輸出

```
train, test = housing_split()  
train.plot.scatter('longitude', 'latitude')
```

觀察：圖只使用訓練資料；地理位置與房價的關係需連同人口密度一起解讀。

參考程式：`programs/notebooks/02_端到端機器學習專案.ipynb`



問題定義：預測的是區域房價中位數

- **觀察單位**：加州的一個人口普查區域（block group）。
- **輸入**：區域人口、房齡、收入、地理位置等資料。
- **目標**：該區域的房價中位數，單位是美元。
- **任務**：監督式、多個輸入特徵、單一輸出目標的迴歸。

預測單一房屋售價，是另一個任務。

多個輸入特徵，也不等於多個輸出目標。

迴歸的評估指標

$$\text{MAE} = \frac{1}{m} \sum_i |\hat{y}_i - y_i| \quad \text{RMSE} = \sqrt{\frac{1}{m} \sum_i (\hat{y}_i - y_i)^2}$$

指標	直覺	單位
MAE	每筆絕對誤差的平均	與目標相同
MSE	平方後平均，較重視大誤差	目標單位的平方
RMSE	將 MSE 開根號	與目標相同

同一組樣本下 RMSE 不小於 MAE，但仍須依任務選指標。

指標之前，還有用途與假設

- 系統真正需要連續估價，還是低／中／高價位分類？
- 預測時能取得哪些欄位？資料何時更新？
- 高估與低估的代價是否相同？
- 是否需要對特定價位或地區維持基本表現？

如果使用方式不同，目標、指標與資料需求可能全部改變。

取得資料與保留可重現流程

- 記錄資料來源、版本、欄位定義及觀察時間。
- 保留原始資料，讓清理步驟可以重做。
- 筆記本依執行順序重新跑完，避免隱藏的舊變數狀態。
- 將下載、轉換與評估分開，保存切分規則與亂數種子。

本課堂先閱讀教材圖表，不要求在教室下載或安裝環境。

 **資料探索主線：** `programs/notebooks/02_端到端機器學習專案.ipynb`。從資料讀取、欄位檢查、分層切分到地理與相關分析都在此 Notebook。

20,640 個區域、10 個欄位

欄位	意義與型態
longitude、latitude	經度、緯度，數值座標
housing_median_age	房齡中位數，數值
total_rooms、total_bedrooms	房間總數、臥室總數，計數
population、households	人口、家戶數，計數
median_income	收入中位數，已縮放的數值
ocean_proximity	鄰海位置，類別
median_house_value	房價中位數，預測目標


原始 10 欄包含目標，因此此時有 9 個候選輸入欄位。

資料摘要透露的問題

- `total_bedrooms` 非空值 **20,433** 筆，缺少 **207** 筆。
- `ocean_proximity` 有五類，ISLAND 只有 **5** 筆。
- 房齡第 25、50、75 百分位分別是 **18、29、37 年**。
- 均值與標準差只能描述部分特性，仍需觀察完整分布。

對稀少類別做細分評估時，必須同時報告樣本數。

直方圖：偏態、尺度與截頂



橫軸是欄位值區間，縱軸是樣本數。觀察右長尾與上限堆積。

截頂標籤限制了能學到的事情

教材中的收入約以「萬美元」縮放，並設有上下限。

房齡與房價也有截頂，房價上限約 **50 萬美元**。

- 上限堆積不一定是自然形成的資料分布。
- 若真實用途要預測更高價格，需要更完整的標籤。
- 刪除截頂樣本會改變適用範圍，應明確說明。

先查資料生成方式，再解釋圖形。

在深入探索前保留測試集

教材示例保留 20% 作測試，其餘作開發資料：

$$20,640 \times 0.8 = 16,512 \quad 20,640 \times 0.2 = 4,128$$

- 切分需能重現，新增資料也不應讓舊樣本任意換組。
- 測試集在模型定案前保持隔離。
- 若任務要泛化到新地區，還需評估地理群組切分是否更合理。

分層抽樣保留重要群體比例

教材先將收入分成區間，再依收入層進行抽樣。


自編示例	全資料	希望在測試集中近似維持
低收入	30%	30%
中收入	50%	50%
高收入	20%	20%

分層能減少指定變數上的抽樣波動，不能消除所有偏差。

收入層僅供切分，完成後移除這個臨時欄位。

 **實作位置：** `programs/notebooks/02_端到端機器學習專案.ipynb`。這裡可直接比較隨機切分、收入分層與穩定 ID 切分的差異。

地理視覺化：同時閱讀位置、人口與價格



- 位置：經度與緯度。
- 色彩：房價中位數。
- 圓的大小：人口資訊。
- 透明度：幫助看出密集區。

沿海與都市的價格結構，值得進一步檢查。


相關係數：線性關係的摘要

特徵與房價的 Pearson r	教材結果（取三位小數）
median_income	0.688
total_rooms	0.137
housing_median_age	0.102
population	-0.020

r 介於 -1 與 1 ，描述線性關聯方向與強度。

r 接近 0 仍可能存在非線性關係，也不能用 r 判定因果。

散布圖補上相關係數看不到的細節




收入較高的區域，房價通常較高。

但也可看到：

- 相同收入下房價仍有差異。
- 頂部有截頂的水平線。
- 其他水平帶可能來自資料處理。

補充：Iris 散布矩陣的讀法



- 非對角：兩個特徵的散布圖。
- 對角：單一特徵的分布。
- 顏色：已知的鳶尾花類別。

花瓣特徵對類別分離可能有幫助。
圖上分得開，仍需要獨立評估。

特徵組合：總量與比例回答不同問題

$$\text{每戶房間數} = \frac{\text{total_rooms}}{\text{households}}$$

$$\text{臥室比例} = \frac{\text{total_bedrooms}}{\text{total_rooms}}$$

$$\text{每戶人口} = \frac{\text{population}}{\text{households}}$$

區域總量可能反映規模，比例則可能反映居住型態。

先處理零分母與缺失，再用驗證確認新特徵是否有幫助。

資料準備要能重複套用

把人工決定整理成清楚的轉換步驟：

- 缺失值與異常格式的處理。
- 類別編碼、數值縮放與特徵組合。
- 從訓練資料學到的統計量與字典。

訓練時學到什麼，預測時就使用同一份設定。

不能讓每一批新資料各自重算一套前處理規則。

缺失值：刪除或補值都有假設

方案	可能的代價
刪除缺失樣本	樣本變少，可能偏向容易量測的對象
刪除整個特徵	失去該欄位中的預測訊號
用訓練中位數補值	保留樣本，但不等於恢復真實值
保留缺失指示欄位	可表達「缺失」本身的資訊

補值的中位數只能從當次訓練資料估計。

驗證／測試資料只套用，不重新估計。

類別特徵：整數編碼不代表有大小

對沒有自然順序的 `ocean_proximity`，可採獨熱編碼：

類別（節錄）	INLAND	NEAR BAY	ISLAND
INLAND	1	0	0
NEAR BAY	0	1	0
ISLAND	0	0	1

將類別編成 0、1、2，可能讓部分模型誤以為存在順序或距離。
也要預先決定：推論時遇到未見過的類別怎麼辦？


特徵縮放與正則化不同

$$x_{\min\max} = \frac{x - x_{\min}}{x_{\max} - x_{\min}} \quad z = \frac{x - \mu}{\sigma}$$

方法	調整什麼？
Min-max 正規化	將訓練範圍映射到指定區間
標準化	依訓練均值、標準差調整尺度
正則化	在訓練目標或模型結構中加入限制

尺度會影響距離、梯度與係數懲罰。三者不能混用名稱。

分布轉換與新表示



對數轉換可壓縮右長尾，但必須處理零值與負值。

教材也介紹分位數、RBF 相似度與自訂轉換，是否有用要靠驗證。

Pipeline：把前處理與模型包成同一流程



不同型態走適合的轉換，再合併成模型輸入。
保存模型時，也必須保存補值、編碼與縮放設定。

 **模型開發主線：** `programs/notebooks/02_端到端機器學習專案.ipynb` (前處理、Pipeline、CV、搜尋與 final test)

fit、transform、predict 各自做什麼？

階段	訓練資料	驗證／測試／新資料
補值與縮放	<code>fit</code> 估計統計量，再 <code>transform</code>	僅 <code>transform</code>
類別編碼	<code>fit</code> 建立類別字典，再轉換	套用同一份字典
預測模型	<code>fit</code> 學習權重或規則	<code>predict</code> 產生預測

交叉驗證的每一折，都必須有自己重新擬合的完整流程。

基準模型：改善應該有比較對象

- MSE／RMSE 任務可用「總是預測訓練目標均值」作簡單基準。
- MAE 任務可用「總是預測訓練目標中位數」作簡單基準。
- 也可比較目前人工或既有系統的預測。

$$R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}$$

此式 $\bar{y}$ 是**評估集**的均值。 R^2 可以為負，且不是 RMSE。

訓練分數可能非常誤導

教材模型	訓練 RMSE (約)	10 折驗證平均 RMSE (約)
線性迴歸	68,973	70,003
決策樹	0	66,574
隨機森林	17,551	47,038

樹在訓練集零誤差，卻沒有零泛化誤差。

這些是教材在指定流程下的示例，不是普遍模型排名。

每一折都是一次完整的模型訓練

	只在開發資料內分析					獨立測試
第 1 折	驗證	訓練	訓練	訓練	訓練	不使用
第 2 折	訓練	驗證	訓練	訓練	訓練	不使用
第 3 折	訓練	訓練	驗證	訓練	訓練	不使用
第 4 折	訓練	訓練	訓練	驗證	訓練	不使用
第 5 折	訓練	訓練	訓練	訓練	驗證	不使用

每折重新估計：補值 + 編碼 + 縮放 + 模型

示意採 5 折，教材示例採 10 折。
報告平均值與各折波動，不能將折間標準差直接當信賴區間。

 **完整 CV 流程：** `programs/notebooks/02_端到端機器學習專案.ipynb` （每折重新 `fit` 整條 Pipeline）

常見洩漏：切分後仍可能發生

做法	洩漏了什麼？	修正方向
全資料補值後才切分	驗證／測試分布的統計量	在訓練流程內估計
先挑最相關特徵再做 CV	驗證標籤影響了特徵選擇	每折內選特徵
同人照片隨機分散各集合	個體資訊與近似重複樣本	按人或群組切分
多次看測試集調設定	測試結果引導模型選擇	保留真正未使用的最終評估

Pipeline 有助封裝前處理，不能自動修正錯誤的資料切分。

Fine-Tune Your Model：先固定評估規則

教材建議先快速比較多類模型，留下約 2-5 個有希望的候選，再開始細調。

名稱	何時決定	本章例子
模型參數	<code>fit()</code> 由訓練資料學得	樹的分割、葉節點預測值
超參數	訓練前由人或搜尋程序指定	<code>min_samples_leaf</code> 、 <code>max_features</code>

開發過程只使用訓練資料與其中的驗證折。

最終測試集不參與候選組合的挑選。

n-fold 交叉驗證如何支撐超參數搜尋

教材使用的 **k-fold** 也常被稱為 **n-fold**：n 代表切分的折數。

1. 將開發資料切成 n 個不重疊的折。
2. 每次保留一折驗證，其餘 n-1 折重新擬合完整 Pipeline。
3. 對每組超參數取得 n 個分數，比較平均與折間波動。

$$\bar{s} = \frac{1}{n} \sum_{j=1}^n s_j \quad N_{\text{fit}} = N_{\text{candidate}} \times n$$

教材的網格搜尋用 `cv=3`；前面比較單一模型時用 10 折。

Pipeline 的參數名稱可以一路往內指定

```
forest_pipe = Pipeline([
    ('preprocess', clone(preprocess)),
    ('model', clone(models['forest'])),
])
```

本課 Notebook 名稱	設定位置
preprocess__num__simpleimputer__strategy	數值分支的補值策略
model__max_features	森林每次分割考慮的特徵比例
model__min_samples_leaf	葉節點的最少樣本數

__ 依實際步驟名稱往內找。本課固定前處理，搜尋森林超參數。
教材的 preprocessing__geo__n_clusters 是另一條含地理群聚的管線。

GridSearchCV：列出所有候選組合

```
grid = GridSearchCV(  
    forest_pipe,  
    {'model__max_features': [.6, 1.0],  
     'model__min_samples_leaf': [1, 4]},  
    cv=folds, scoring='neg_root_mean_squared_error',  
    n_jobs=1,  
)  
grid.fit(X_train, y_train)
```

本課為 $2 \times 2 = 4$ 組候選，3 折共 $4 \times 3 = 12$ 次驗證用訓練。

預設 `refit=True` 另外以完整開發集擬合一次最佳設定。

教材的 15 組、45 次是較大的示例；本課縮小範圍便於 CPU 練習。

GridSearchCV：讀取最佳設定與各折結果

```
print(grid.best_params_)
cv_results = pd.DataFrame(grid.cv_results_)
cv_results['mean_RMSE'] = -cv_results['mean_test_score']
cv_results.sort_values('mean_RMSE').head()
```

- `split0_test_score` 等欄位是各折**驗證分數**。
- `mean_test_score` 越大越好；改為正 RMSE 後越小越好。
- `std_test_score` 是折間波動，不能直接當信賴區間。
- 比較 grid 與 random 的最佳 CV，才決定 `final_model`。

教材約 43,590 美元來自另一設定；本課以當次執行表格為準。

RandomizedSearchCV：用固定預算抽樣

```
random = RandomizedSearchCV(  
    forest_pipe,  
    {'model__max_features': [.5, .7, 1.0],  
     'model__min_samples_leaf': randint(1, 9)},  
    n_iter=4, cv=folds,  
    scoring='neg_root_mean_squared_error',  
    random_state=SEED, n_jobs=1,  
)  
random.fit(X_train, y_train)
```

本課 4 組候選 × 3 折 = 12 次驗證用訓練，另加一次 refit。

`randint(1, 9)` 包含 1、不包含 9；種子固定候選抽樣。

配套實作：`programs/notebooks/02_端到端機器學習專案.ipynb`

網格搜尋與隨機搜尋的選擇

問題特徵	網格搜尋	隨機搜尋
範圍小且候選明確	可窮舉全部組合	可能漏掉指定點
連續或取值很多	只會測試列出的點	可由機率分布取樣
加入影響很小的超參數	組合數成倍增加	總輪數仍由 <code>n_iter</code> 控制
計算預算	由網格大小決定	可直接設定抽樣輪數

若 6 個超參數各有 10 種值，網格搜尋會產生 10^6 組候選。
隨機搜尋則可依預算固定嘗試次數。

逐次減半：先用少量資源篩選候選

HalvingGridSearchCV 與 HalvingRandomSearchCV 將搜尋分成多輪：

1. 第一輪產生較多候選，只分配少量訓練資料或訓練輪數。
2. 保留表現較好的候選，下一輪給它們更多資源。
3. 最後少數候選才使用完整資源評估。

這種做法可節省時間，但早期少量資源的排名可能受抽樣波動影響。

搜尋完成後才建立定案模型

```
chosen_search = max(searches, key=lambda k: searches[k].best_score_)
final_model = searches[chosen_search].best_estimator_

feature_names = final_model["preprocess"].get_feature_names_out()
importances = final_model["model"].feature_importances_
```

- `refit=True` 是預設值。搜尋完成後，最佳 Pipeline 會用全部開發訓練資料再擬合。
- `best_estimator_` 包含前處理與模型，應當整體保存與部署。
- 取出最佳模型後，先做特徵重要性、錯誤樣本與群體切片分析，最後才使用測試集。

活動：用計算預算設計超參數搜尋

你準備搜尋：

- `n_clusters = [5, 10, 15, 20]`
- `max_features = [4, 6, 8]`
- `min_samples_leaf = [1, 2]`
- `cv = 5`，每次擬合約 18 秒

先算成本

1. 網格共有幾組候選？
2. 總共要執行幾次擬合？
3. 預估需要幾分鐘？

再做決策

限制在 **15 分鐘內**，你會如何修改？

寫下搜尋方法、`cv` / `n_iter` 與理由；並指出最終測試集何時才可使用。

錯誤分析：平均分數之外

- 依地區、價位、城鄉等切片，檢查誤差與樣本量。
- 查看大誤差樣本是否涉及截頂、缺失或未涵蓋情境。
- 特徵重要性提供模型使用資訊的線索，不能當作因果證據。
- 將改善假設交給驗證資料評估。

某一群體誤差很高，不應被整體平均掩蓋。

最終測試與不確定性

教材定案模型的測試 RMSE 約 **41,446 美元**。

教材 bootstrap 95% 信賴區間約 **39,521–43,702 美元**。

- 點估計不是保證值，結果取決於樣本與評估設計。
- 看完測試後再改模型，原測試就參與了開發。
- 測試表現較驗證好或壞，都不能靠反覆挑選結果解決。

部署、監測與維護

保存	監測	更新時機
模型、前處理、版本與切分規則	輸入格式、缺失率、分布與預測錯誤	資料或任務改變，表現不再符合要求

輸入漂移可能先於標籤到達而被觀察到。

但看到輸入改變，仍需後續真實結果確認預測表現是否下降。

 **部署練習**：先執行 `programs/notebooks/02_端到端機器學習專案.ipynb` 產生並保存模型，再由同一本的 `cloudpickle.load` 載入完整 Pipeline，核對同一批原始欄位的預測。

第二週回顧與課後整理

完成一頁房價預測設計，至少包含：

- 觀察單位、特徵、目標與資料限制。
- 一張分布或關係圖，以及它支持與不支持的解讀。
- 資料切分、Pipeline、基準與主要指標。
- 如何挑選設定、何時開啟最終測試。

下週把數值誤差改為分類錯誤，練習解釋不同分母與決策閾值。

Notebook 導讀：資料範圍與穩定切分

階段	預設 fast 模式	用途
EDA	16,512 筆 training	直方圖、散布圖、特徵假設
模型開發	其中分層抽 6,000 筆	三折 CV 與搜尋
最終測試	保留 4,128 筆	設定定案後評估



固定 seed 無法保證重新排序、追加資料後，舊樣本仍在同一集合。
穩定 ID 的 SHA-256 可固定成員歸屬，但不保證剛好 20% 或群組隔離。

Notebook 導讀：前處理分支與自訂轉換

分支	程式與解讀
一般數值	中位數補值 → StandardScaler
長尾數值	補值 → log1p → StandardScaler
比率特徵	補值 → RatioTransformer → StandardScaler
無序類別	眾數補值 → OneHotEncoder


`fit` 保存狀態，`transform` 套用狀態，`get_feature_names_out` 保留欄名。
本例分母為零時回傳 0，是明示的示範政策；未知類別採全零編碼。
保存時用 `cloudpickle` 一起保存模型與自訂類別，並記錄套件及資料版本。

Notebook 圖表：訓練誤差與特徵重要性



左：各折訓練與驗證 RMSE；右：森林使用的分裂重要度。
重要度受高基數與相關特徵影響，不能解讀為因果貢獻。

Notebook 圖表：殘差與最終測試



左：預測與真值偏離對角線；右：殘差採「預測減真實」。

Bootstrap 重抽固定模型的測試平方誤差，估計 RMSE 的抽樣區間。

它不包含重訓、搜尋、地理相依或未來漂移的全部不確定性。