

第二週：端到端機器學習專案

以加州房價理解資料與迴歸

每一個前處理與評估決定，都會影響最終結論。

專案全貌



開發中的探索與調整可以迭代，最終測試須保留獨立性

資料探索產生假設，驗證資料比較方案，測試資料評估定案。
上線後的監測，決定何時需要重新蒐集資料與訓練。

問題定義：預測的是區域房價中位數

- **觀察單位**：加州的一個人口普查區域（block group）。
- **輸入**：區域人口、房齡、收入、地理位置等資料。
- **目標**：該區域的房價中位數，單位是美元。
- **任務**：監督式、多個輸入特徵、單一輸出目標的迴歸。

預測單一房屋售價，是另一個任務。

多個輸入特徵，也不等於多個輸出目標。

迴歸的評估指標

$$\text{MAE} = \frac{1}{m} \sum_i |\hat{y}_i - y_i|$$

$$\text{RMSE} = \sqrt{\frac{1}{m} \sum_i (\hat{y}_i - y_i)^2}$$

指標	直覺	單位
MAE	每筆絕對誤差的平均	與目標相同
MSE	平方後平均，較重視大誤差	目標單位的平方
RMSE	將 MSE 開根號	與目標相同

同一組樣本下 RMSE 不小於 MAE，但仍須依任務選指標。

活動 C：平均誤差為零，預測就很好嗎？

四筆預測誤差為 -2 、 $+2$ 、 -2 、 $+2$ 萬美元。

1. 算出平均誤差、MAE、MSE、RMSE。
2. 最後一筆改成 $+10$ 萬美元，MAE 與 RMSE 各是多少？
3. 如果「非常大的估價誤差」特別昂貴，哪個指標更能反映？

先辨認單位，再計算。正負相抵與逐筆準確是不同的事情。

指標之前，還有用途與假設

- 系統真正需要連續估價，還是低／中／高價位分類？
- 預測時能取得哪些欄位？資料何時更新？
- 高估與低估的代價是否相同？
- 是否需要對特定價位或地區維持基本表現？

如果使用方式不同，目標、指標與資料需求可能全部改變。

取得資料與保留可重現流程

- 記錄資料來源、版本、欄位定義及觀察時間。
- 保留原始資料，讓清理步驟可以重做。
- 筆記本依執行順序重新跑完，避免隱藏的舊變數狀態。
- 將下載、轉換與評估分開，保存切分規則與亂數種子。

本課堂先閱讀教材圖表，不要求在教室下載或安裝環境。

20,640 個區域、10 個欄位

欄位	意義與型態
longitude、latitude	經度、緯度，數值座標
housing_median_age	房齡中位數，數值
total_rooms、total_bedrooms	房間總數、臥室總數，計數
population、households	人口、家戶數，計數
median_income	收入中位數，已縮放的數值
ocean_proximity	鄰海位置，類別
median_house_value	房價中位數，預測目標


原始 10 欄包含目標，因此此時有 9 個候選輸入欄位。

資料摘要透露的問題

- `total_bedrooms` 非空值 **20,433** 筆，缺少 **207** 筆。
- `ocean_proximity` 有五類，ISLAND 只有 **5** 筆。
- 房齡第 25、50、75 百分位分別是 **18、29、37** 年。
- 均值與標準差只能描述部分特性，仍需觀察完整分布。

對稀少類別做細分評估時，必須同時報告樣本數。

直方圖：偏態、尺度與截頂



橫軸是欄位值區間，縱軸是樣本數。觀察右長尾與上限堆積。

截頂標籤限制了能學到的事情

教材中的收入約以「萬美元」縮放，並設有上下限。
房齡與房價也有截頂，房價上限約 **50 萬美元**。

- 上限堆積不一定是自然形成的資料分布。
- 若真實用途要預測更高價格，需要更完整的標籤。
- 刪除截頂樣本會改變適用範圍，應明確說明。

先查資料生成方式，再解釋圖形。

在深入探索前保留測試集

教材示例保留 20% 作測試，其餘作開發資料：

$$20,640 \times 0.8 = 16,512 \quad 20,640 \times 0.2 = 4,128$$

- 切分需能重現，新增資料也不應讓舊樣本任意換組。
- 測試集在模型定案前保持隔離。
- 若任務要泛化到新地區，還需評估地理群組切分是否更合理。


分層抽樣保留重要群體比例

教材先將收入分成區間，再依收入層進行抽樣。

自編示例	全資料	希望在測試集中近似維持
低收入	30%	30%
中收入	50%	50%
高收入	20%	20%

分層能減少指定變數上的抽樣波動，不能消除所有偏差。
收入層僅供切分，完成後移除這個臨時欄位。

地理視覺化：同時閱讀位置、人口與價格



- 位置：經度與緯度。
- 色彩：房價中位數。
- 圓的大小：人口資訊。
- 透明度：幫助看出密集區。

沿海與都市的價格結構，值得進一步檢查。


相關係數：線性關係的摘要

特徵與房價的 Pearson r	教材結果（取三位小數）
median_income	0.688
total_rooms	0.137
housing_median_age	0.102
population	-0.020

r 介於 -1 與 1 ，描述線性關聯方向與強度。

r 接近 0 仍可能存在非線性關係，也不能用 r 判定因果。

散布圖補上相關係數看不到的細節




收入較高的區域，房價通常較高。

但也可看到：

- 相同收入下房價仍有差異。
- 頂部有截頂的水平線。
- 其他水平帶可能來自資料處理。

補充：Iris 散布矩陣的讀法



- 非對角：兩個特徵的散布圖。
- 對角：單一特徵的分布。
- 顏色：已知的鳶尾花類別。

花瓣特徵對類別分離可能有幫助。
圖上分得開，仍需要獨立評估。

特徵組合：總量與比例回答不同問題

$$\text{每戶房間數} = \frac{\text{total_rooms}}{\text{households}}$$

$$\text{臥室比例} = \frac{\text{total_bedrooms}}{\text{total_rooms}}$$

$$\text{每戶人口} = \frac{\text{population}}{\text{households}}$$

區域總量可能反映規模，比例則可能反映居住型態。

先處理零分母與缺失，再用驗證確認新特徵是否有幫助。

活動 D：從總量改成比例，結論會改變嗎？

區域	房間總數	家戶數	人口
A	6,000	1,000	3,000
B	3,000	300	900
C	4,000	0	1,200

1. 比較 A、B 的每戶房間數與每戶人口。
2. C 的比例應如何處理？還要查什麼？
3. 提出一個視覺化，檢查新特徵是否與房價有關。

資料準備要能重複套用

把人工決定整理成清楚的轉換步驟：

- 缺失值與異常格式的處理。
- 類別編碼、數值縮放與特徵組合。
- 從訓練資料學到的統計量與字典。

訓練時學到什麼，預測時就使用同一份設定。

不能讓每一批新資料各自重算一套前處理規則。

缺失值：刪除或補值都有假設

方案	可能的代價
刪除缺失樣本	樣本變少，可能偏向容易量測的對象
刪除整個特徵	失去該欄位中的預測訊號
用訓練中位數補值	保留樣本，但不等於恢復真實值
保留缺失指示欄位	可表達「缺失」本身的資訊

補值的中位數只能從當次訓練資料估計。

驗證／測試資料只套用，不重新估計。

類別特徵：整數編碼不代表有大小

對沒有自然順序的 `ocean_proximity`，可採獨熱編碼：

類別（節錄）	INLAND	NEAR BAY	ISLAND
INLAND	1	0	0
NEAR BAY	0	1	0
ISLAND	0	0	1

將類別編成 0、1、2，可能讓部分模型誤以為存在順序或距離。
也要預先決定：推論時遇到未見過的類別怎麼辦？


特徵縮放與正則化不同

$$x_{\min\max} = \frac{x - x_{\min}}{x_{\max} - x_{\min}} \quad z = \frac{x - \mu}{\sigma}$$

方法	調整什麼？
Min-max 正規化	將訓練範圍映射到指定區間
標準化	依訓練均值、標準差調整尺度
正則化	在訓練目標或模型結構中加入限制

尺度會影響距離、梯度與係數懲罰。三者不能混用名稱。

分布轉換與新表示



對數轉換可壓縮右長尾，但必須處理零值與負值。

教材也介紹分位數、RBF 相似度與自訂轉換，是否有用要靠驗證。

Pipeline：把前處理與模型包成同一流程



不同型態走適合的轉換，再合併成模型輸入。
保存模型時，也必須保存補值、編碼與縮放設定。

fit、transform、predict 各自做什麼？

階段	訓練資料	驗證／測試／新資料
補值與縮放	<code>fit</code> 估計統計量，再 <code>transform</code>	僅 <code>transform</code>
類別編碼	<code>fit</code> 建立類別字典，再轉換	套用同一份字典
預測模型	<code>fit</code> 學習權重或規則	<code>predict</code> 產生預測

交叉驗證的每一折，都必須有自己重新擬合的完整流程。

基準模型：改善應該有比較對象

- MSE／RMSE 任務可用「總是預測訓練目標均值」作簡單基準。
- MAE 任務可用「總是預測訓練目標中位數」作簡單基準。
- 也可比較目前人工或既有系統的預測。

$$R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}$$

此式 $\bar{y}$ 是**評估集**的均值。 R^2 可以為負，且不是 RMSE。

訓練分數可能非常誤導

教材模型	訓練 RMSE (約)	10 折驗證平均 RMSE (約)
線性迴歸	68,973	70,003
決策樹	0	66,574
隨機森林	17,551	47,038

樹在訓練集零誤差，卻沒有零泛化誤差。
這些是教材在指定流程下的示例，不是普遍模型排名。

每一折都是一次完整的模型訓練

	只在開發資料內分析					獨立測試
第 1 折	驗證	訓練	訓練	訓練	訓練	不使用
第 2 折	訓練	驗證	訓練	訓練	訓練	不使用
第 3 折	訓練	訓練	驗證	訓練	訓練	不使用
第 4 折	訓練	訓練	訓練	驗證	訓練	不使用
第 5 折	訓練	訓練	訓練	訓練	驗證	不使用

每折重新估計：補值 + 編碼 + 縮放 + 模型

示意採 5 折，教材示例採 10 折。
報告平均值與各折波動，不能將折間標準差直接當信賴區間。

常見洩漏：切分後仍可能發生

做法	洩漏了什麼？	修正方向
全資料補值後才切分	驗證／測試分布的統計量	在訓練流程內估計
先挑最相關特徵再做 CV	驗證標籤影響了特徵選擇	每折內選特徵
同人照片隨機分散各集合	個體資訊與近似重複樣本	按人或群組切分
多次看測試集調設定	測試結果引導模型選擇	保留真正未使用的最終評估

Pipeline 有助封裝前處理，不能自動修正錯誤的資料切分。

超參數搜尋：比較整個流程

方法	比較方式	適用情況
網格搜尋	列出候選組合，逐一做交叉驗證	組合不多，範圍明確
隨機搜尋	在指定範圍抽取固定數量組合	範圍大，計算預算有限

前處理設定也可以納入搜尋，例如地理特徵的群數。
教材示例有 **15 組候選 × 3 折 = 45 次** 驗證用訓練，
選定後通常還要再以全部開發資料重訓一次。

調參結果要連同評估方式閱讀

教材示例	驗證 RMSE (約)	評估方式
預設隨機森林	47,038	10 折平均
網格搜尋最佳候選	43,590	3 折平均

這些數字提示後者值得繼續檢查。
但折數與候選挑選過程不同，不能只用差值宣稱改善已被證實。
嚴謹比較可使用相同切分；搜尋後再以獨立測試評估定案系統。

錯誤分析：平均分數之外

- 依地區、價位、城鄉等切片，檢查誤差與樣本量。
- 查看大誤差樣本是否涉及截頂、缺失或未涵蓋情境。
- 特徵重要性提供模型使用資訊的線索，不能當作因果證據。
- 將改善假設交給驗證資料評估。

某一群體誤差很高，不應被整體平均掩蓋。

最終測試與不確定性

教材定案模型的測試 RMSE 約 **41,446 美元**。

教材 bootstrap 95% 信賴區間約 **39,521–43,702 美元**。

- 點估計不是保證值，結果取決於樣本與評估設計。
- 看完測試後再改模型，原測試就參與了開發。
- 測試表現較驗證好或壞，都不能靠反覆挑選結果解決。

部署、監測與維護

保存	監測	更新時機
模型、前處理、版本與切分規則	輸入格式、缺失率、分布與預測錯誤	資料或任務改變，表現不再符合要求

輸入漂移可能先於標籤到達而被觀察到。

但看到輸入改變，仍需後續真實結果確認預測表現是否下降。

活動 E：找出評估流程的問題

研究生的流程如下：

1. 全資料補中位數、標準化，再挑出最相關的五個特徵。
2. 隨機切分訓練與測試，對訓練資料進行交叉驗證。
3. 每試一組正則化強度，就看一次測試 RMSE。
4. 公布測試 RMSE 最低的那組模型。

任務：畫出修正版流程，並標出每個 `fit` 能看到的資料。

第二週回顧與課後整理

完成一頁房價預測設計，至少包含：

- 觀察單位、特徵、目標與資料限制。
- 一張分布或關係圖，以及它支持與不支持的解讀。
- 資料切分、Pipeline、基準與主要指標。
- 如何挑選設定、何時開啟最終測試。

下週把數值誤差改為分類錯誤，練習解釋不同分母與決策閾值。