

# 第二週：端到端機器學習專案

以加州房價理解資料與迴歸

每一個前處理與評估決定，都會影響最終結論。

# 專案全貌

---



開發中的探索與調整可以迭代，最終測試須保留獨立性

資料探索產生假設，驗證資料比較方案，測試資料評估定案。

上線後的監測，決定何時需要重新蒐集資料與訓練。

## 問題定義：預測的是區域房價中位數

---

- **觀察單位**：加州的一個人口普查區域（block group）。
- **輸入**：區域人口、房齡、收入、地理位置等資料。
- **目標**：該區域的房價中位數，單位是美元。
- **任務**：監督式、多個輸入特徵、單一輸出目標的迴歸。

預測單一房屋售價，是另一個任務。

多個輸入特徵，也不等於多個輸出目標。

# 迴歸的評估指標

$$\text{MAE} = \frac{1}{m} \sum_i |\hat{y}_i - y_i|$$

$$\text{RMSE} = \sqrt{\frac{1}{m} \sum_i (\hat{y}_i - y_i)^2}$$

| 指標   | 直覺           | 單位      |
|------|--------------|---------|
| MAE  | 每筆絕對誤差的平均    | 與目標相同   |
| MSE  | 平方後平均，較重視大誤差 | 目標單位的平方 |
| RMSE | 將 MSE 開根號    | 與目標相同   |

同一組樣本下 RMSE 不小於 MAE，但仍須依任務選指標。

## 指標之前，還有用途與假設

---

- 系統真正需要連續估價，還是低／中／高價位分類？
- 預測時能取得哪些欄位？資料何時更新？
- 高估與低估的代價是否相同？
- 是否需要對特定價位或地區維持基本表現？

如果使用方式不同，目標、指標與資料需求可能全部改變。

## 取得資料與保留可重現流程

---

- 記錄資料來源、版本、欄位定義及觀察時間。
- 保留原始資料，讓清理步驟可以重做。
- 筆記本依執行順序重新跑完，避免隱藏的舊變數狀態。
- 將下載、轉換與評估分開，保存切分規則與亂數種子。

本課堂先閱讀教材圖表，不要求在教室下載或安裝環境。

# 20,640 個區域、10 個欄位

| 欄位                         | 意義與型態        |
|----------------------------|--------------|
| longitude、latitude         | 經度、緯度，數值座標   |
| housing_median_age         | 房齡中位數，數值     |
| total_rooms、total_bedrooms | 房間總數、臥室總數，計數 |
| population、households      | 人口、家戶數，計數    |
| median_income              | 收入中位數，已縮放的數值 |
| ocean_proximity            | 鄰海位置，類別      |
| median_house_value         | 房價中位數，預測目標   |

原始 10 欄包含目標，因此此時有 9 個候選輸入欄位。

## 資料摘要透露的問題


---

- `total_bedrooms` 非空值 **20,433** 筆，缺少 **207** 筆。
- `ocean_proximity` 有五類，ISLAND 只有 **5** 筆。
- 房齡第 25、50、75 百分位分別是 **18、29、37** 年。
- 均值與標準差只能描述部分特性，仍需觀察完整分布。

對稀少類別做細分評估時，必須同時報告樣本數。



# 直方圖：偏態、尺度與截頂



橫軸是欄位值區間，縱軸是樣本數。觀察右長尾與上限堆積。

## 截頂標籤限制了能學到的事情

---

教材中的收入約以「萬美元」縮放，並設有上下限。  
房齡與房價也有截頂，房價上限約 **50 萬美元**。

- 上限堆積不一定是自然形成的資料分布。
- 若真實用途要預測更高價格，需要更完整的標籤。
- 刪除截頂樣本會改變適用範圍，應明確說明。

**先查資料生成方式，再解釋圖形。**

## 在深入探索前保留測試集

---

教材示例保留 20% 作測試，其餘作開發資料：

$$20,640 \times 0.8 = 16,512 \quad 20,640 \times 0.2 = 4,128$$

- 切分需能重現，新增資料也不應讓舊樣本任意換組。
- 測試集在模型定案前保持隔離。
- 若任務要泛化到新地區，還需評估地理群組切分是否更合理。

## 分層抽樣保留重要群體比例


教材先將收入分成區間，再依收入層進行抽樣。

| 自編示例 | 全資料 | 希望在測試集中近似維持 |
|------|-----|-------------|
| 低收入  | 30% | 30%         |
| 中收入  | 50% | 50%         |
| 高收入  | 20% | 20%         |

分層能減少指定變數上的抽樣波動，不能消除所有偏差。

收入層僅供切分，完成後移除這個臨時欄位。

## 地理視覺化：同時閱讀位置、人口與價格



- 位置：經度與緯度。
- 色彩：房價中位數。
- 圓的大小：人口資訊。
- 透明度：幫助看出密集區。

沿海與都市的價格結構，值得進一步檢查。


## 相關係數：線性關係的摘要

| 特徵與房價的 Pearson $r$ | 教材結果（取三位小數） |
|--------------------|-------------|
| median_income      | 0.688       |
| total_rooms        | 0.137       |
| housing_median_age | 0.102       |
| population         | -0.020      |

$r$  介於  $-1$  與  $1$ ，描述線性關聯方向與強度。

$r$  接近  $0$  仍可能存在非線性關係，也不能用  $r$  判定因果。

## 散布圖補上相關係數看不到的細節




收入較高的區域，房價通常較高。

但也可看到：

- 相同收入下房價仍有差異。
- 頂部有截頂的水平線。
- 其他水平帶可能來自資料處理。

## 補充：Iris 散布矩陣的讀法



- 非對角：兩個特徵的散布圖。
- 對角：單一特徵的分布。
- 顏色：已知的鳶尾花類別。

花瓣特徵對類別分離可能有幫助。  
圖上分得開，仍需要獨立評估。



## 特徵組合：總量與比例回答不同問題

---

$$\text{每戶房間數} = \frac{\text{total\_rooms}}{\text{households}}$$

$$\text{臥室比例} = \frac{\text{total\_bedrooms}}{\text{total\_rooms}}$$

$$\text{每戶人口} = \frac{\text{population}}{\text{households}}$$

區域總量可能反映規模，比例則可能反映居住型態。

先處理零分母與缺失，再用驗證確認新特徵是否有幫助。

## 資料準備要能重複套用

---

把人工決定整理成清楚的轉換步驟：

- 缺失值與異常格式的處理。
- 類別編碼、數值縮放與特徵組合。
- 從訓練資料學到的統計量與字典。

**訓練時學到什麼，預測時就使用同一份設定。**

不能讓每一批新資料各自重算一套前處理規則。

## 缺失值：刪除或補值都有假設

---

| 方案       | 可能的代價            |
|----------|------------------|
| 刪除缺失樣本   | 樣本變少，可能偏向容易量測的對象 |
| 刪除整個特徵   | 失去該欄位中的預測訊號      |
| 用訓練中位數補值 | 保留樣本，但不等於恢復真實值   |
| 保留缺失指示欄位 | 可表達「缺失」本身的資訊     |

補值的中位數只能從當次訓練資料估計。

驗證／測試資料只套用，不重新估計。

# 類別特徵：整數編碼不代表有大小

對沒有自然順序的 `ocean_proximity`，可採獨熱編碼：

| 類別（節錄）   | INLAND | NEAR BAY | ISLAND |
|----------|--------|----------|--------|
| INLAND   | 1      | 0        | 0      |
| NEAR BAY | 0      | 1        | 0      |
| ISLAND   | 0      | 0        | 1      |

將類別編成 0、1、2，可能讓部分模型誤以為存在順序或距離。  
也要預先決定：推論時遇到未見過的類別怎麼辦？


## 特徵縮放與正則化不同

$$x_{\min\max} = \frac{x - x_{\min}}{x_{\max} - x_{\min}} \quad z = \frac{x - \mu}{\sigma}$$

| 方法          | 調整什麼？           |
|-------------|-----------------|
| Min-max 正規化 | 將訓練範圍映射到指定區間    |
| 標準化         | 依訓練均值、標準差調整尺度   |
| 正則化         | 在訓練目標或模型結構中加入限制 |

尺度會影響距離、梯度與係數懲罰。三者不能混用名稱。

## 分布轉換與新表示



對數轉換可壓縮右長尾，但必須處理零值與負值。

教材也介紹分位數、RBF 相似度與自訂轉換，是否有用要靠驗證。

# Pipeline：把前處理與模型包成同一流程



不同型態走適合的轉換，再合併成模型輸入。  
保存模型時，也必須保存補值、編碼與縮放設定。

## fit、transform、predict 各自做什麼？

| 階段    | 訓練資料                                            | 驗證／測試／新資料                 |
|-------|-------------------------------------------------|---------------------------|
| 補值與縮放 | <code>fit</code> 估計統計量，再 <code>transform</code> | 僅 <code>transform</code>  |
| 類別編碼  | <code>fit</code> 建立類別字典，再轉換                     | 套用同一份字典                   |
| 預測模型  | <code>fit</code> 學習權重或規則                        | <code>predict</code> 產生預測 |

交叉驗證的每一折，都必須有自己重新擬合的完整流程。



## 基準模型：改善應該有比較對象

---

- MSE／RMSE 任務可用「總是預測訓練目標均值」作簡單基準。
- MAE 任務可用「總是預測訓練目標中位數」作簡單基準。
- 也可比較目前人工或既有系統的預測。

$$R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}$$

此式  $\bar{y}$  是**評估集**的均值。 $R^2$  可以為負，且不是 RMSE。

# 訓練分數可能非常誤導

| 教材模型 | 訓練 RMSE (約) | 10 折驗證平均 RMSE (約) |
|------|-------------|-------------------|
| 線性迴歸 | 68,973      | 70,003            |
| 決策樹  | 0           | 66,574            |
| 隨機森林 | 17,551      | 47,038            |

樹在訓練集零誤差，卻沒有零泛化誤差。  
這些是教材在指定流程下的示例，不是普遍模型排名。

# 每一折都是一次完整的模型訓練

|       | 只在開發資料內分析 |    |    |    |    | 獨立測試 |
|-------|-----------|----|----|----|----|------|
| 第 1 折 | 驗證        | 訓練 | 訓練 | 訓練 | 訓練 | 不使用  |
| 第 2 折 | 訓練        | 驗證 | 訓練 | 訓練 | 訓練 | 不使用  |
| 第 3 折 | 訓練        | 訓練 | 驗證 | 訓練 | 訓練 | 不使用  |
| 第 4 折 | 訓練        | 訓練 | 訓練 | 驗證 | 訓練 | 不使用  |
| 第 5 折 | 訓練        | 訓練 | 訓練 | 訓練 | 驗證 | 不使用  |

每折重新估計：補值 + 編碼 + 縮放 + 模型

示意採 5 折，教材示例採 10 折。  
報告平均值與各折波動，不能將折間標準差直接當信賴區間。

## 常見洩漏：切分後仍可能發生

| 做法           | 洩漏了什麼？      | 修正方向         |
|--------------|-------------|--------------|
| 全資料補值後才切分    | 驗證／測試分布的統計量 | 在訓練流程內估計     |
| 先挑最相關特徵再做 CV | 驗證標籤影響了特徵選擇 | 每折內選特徵       |
| 同人照片隨機分散各集合  | 個體資訊與近似重複樣本 | 按人或群組切分      |
| 多次看測試集調設定    | 測試結果引導模型選擇  | 保留真正未使用的最終評估 |

Pipeline 有助封裝前處理，不能自動修正錯誤的資料切分。

## 超參數搜尋：比較整個流程

| 方法   | 比較方式           | 適用情況       |
|------|----------------|------------|
| 網格搜尋 | 列出候選組合，逐一做交叉驗證 | 組合不多，範圍明確  |
| 隨機搜尋 | 在指定範圍抽取固定數量組合  | 範圍大，計算預算有限 |

前處理設定也可以納入搜尋，例如地理特徵的群數。  
教材示例有 **15 組候選 × 3 折 = 45 次** 驗證用訓練，  
選定後通常還要再以全部開發資料重訓一次。

## 調參結果要連同評估方式閱讀

| 教材示例     | 驗證 RMSE（約） | 評估方式   |
|----------|------------|--------|
| 預設隨機森林   | 47,038     | 10 折平均 |
| 網格搜尋最佳候選 | 43,590     | 3 折平均  |

這些數字提示後者值得繼續檢查。  
但折數與候選挑選過程不同，不能只用差值宣稱改善已被證實。  
嚴謹比較可使用相同切分；搜尋後再以獨立測試評估定案系統。

## 錯誤分析：平均分數之外

---

- 依地區、價位、城鄉等切片，檢查誤差與樣本量。
- 查看大誤差樣本是否涉及截頂、缺失或未涵蓋情境。
- 特徵重要性提供模型使用資訊的線索，不能當作因果證據。
- 將改善假設交給驗證資料評估。

某一群體誤差很高，不應被整體平均掩蓋。

## 最終測試與不確定性

---

教材定案模型的測試 RMSE 約 **41,446 美元**。

教材 bootstrap 95% 信賴區間約 **39,521–43,702 美元**。

- 點估計不是保證值，結果取決於樣本與評估設計。
- 看完測試後再改模型，原測試就參與了開發。
- 測試表現較驗證好或壞，都不能靠反覆挑選結果解決。



# 部署、監測與維護

| 保存             | 監測               | 更新時機             |
|----------------|------------------|------------------|
| 模型、前處理、版本與切分規則 | 輸入格式、缺失率、分布與預測錯誤 | 資料或任務改變，表現不再符合要求 |

輸入漂移可能先於標籤到達而被觀察到。  
但看到輸入改變，仍需後續真實結果確認預測表現是否下降。

## 第二週回顧與課後整理

---

完成一頁房價預測設計，至少包含：

- 觀察單位、特徵、目標與資料限制。
- 一張分布或關係圖，以及它支持與不支持的解讀。
- 資料切分、Pipeline、基準與主要指標。
- 如何挑選設定、何時開啟最終測試。

下週把數值誤差改為分類錯誤，練習解釋不同分母與決策閾值。