

第三週：分類與模型評估

混淆矩陣、決策閾值與錯誤分析

同一個模型，可以因為決策設定而產生不同的錯誤。

MNIST：影像也可以表示成特徵矩陣



- 70,000 張手寫數字影像。
- 每張 $28 \times 28 = 784$ 個像素。
- 一張影像是一筆樣本。
- 標籤為 0 到 9。
- 教材保留前 60,000 張訓練、後 10,000 張測試。



配套實作： `programs/notebooks/03_分類與模型評估.ipynb`

程式實驗與實際輸出

```
y_oof = cross_val_predict(clf, X, y, cv=3)  
ConfusionMatrixDisplay.from_predictions(y, y_oof)
```

觀察：折外預測產生的混淆矩陣可用於錯誤分析，最後測試集仍保留到決策完成後。

參考程式：`programs/notebooks/03_分類與模型評估.ipynb`



二元分類：先辨識「是不是 5」

$$y_i = \begin{cases} 1, & \text{影像是數字 5} \\ 0, & \text{影像不是數字 5} \end{cases}$$

- 正類（positive）是我們指定關注的事件。
- 負類（negative）包含其餘九個數字。
- 訓練資料提供真實標籤，模型對新影像輸出分數或類別。

正類不代表「好」，負類也不代表「壞」。


本週的二元混淆矩陣都採同一個正類定義。

補充：邏輯斯迴歸把分數轉為機率估計

$$z = b + \mathbf{w}^\top \mathbf{x}$$
$$\hat{p} = \sigma(z) = \frac{1}{1 + e^{-z}}$$

$\hat{p}$ 表示模型估計的正類機率。

當 $\hat{p} \geq t$ ，判為正類。




$t = 0.5$ 是常見起點，未必適合每種錯誤代價。



邏輯斯迴歸與多類別實作： `programs/notebooks/03_分類與模型評估.ipynb`

決策邊界：在特徵空間畫出判斷分界



舊稿使用 Iris 的兩個花瓣特徵，並篩成兩類。

- 點：樣本及其真實類別。
- 背景顏色：模型估計的機率。
- 色彩交界：特定閾值下的邊界。

訓練損失與分類正確率不同

二元交叉熵（此處使用自然對數）：

$$\ell(y, \hat{p}) = -[y \ln \hat{p} + (1 - y) \ln(1 - \hat{p})]$$

真實 $y = 1$	$\hat{p}$	閾值 0.5 下分類	損失（約）
樣本 A	0.9	正確	0.105
樣本 B	0.6	正確	0.511
樣本 C	0.1	錯誤	2.303

相同的分類結果，仍可能有不同的機率估計與損失。

用未參與訓練的預測評估

```
from sklearn.linear_model import SGDClassifier
from sklearn.model_selection import cross_val_predict

sgd_clf = SGDClassifier(random_state=42)
y_train_5 = (y_train == "5")
y_train_pred = cross_val_predict(
    sgd_clf, X_train, y_train_5, cv=3
)
```

- 每個 `y_train_pred[i]` 都來自**沒有用第 i 筆樣本訓練**的模型。
- 把折外預測（OOF）合併後，可計算混淆矩陣、precision、recall 與 F1。
- 調整模型或閾值後，仍需獨立的最終測試。

 **完整 MNIST 流程：** `programs/notebooks/03_分類與模型評估.ipynb`

類別不平衡：什麼都判成「不是 5」

教材訓練部分有 60,000 張影像，其中：

真實類別	筆數	比例
不是 5	54,579	90.965%
是 5	5,421	9.035%

若全部預測「不是 5」，accuracy 仍達 **90.965%**，
卻**一張 5 都找不到**。

混淆矩陣：列是真實，欄是預測

真實 \ 預測	負類：不是 5	正類：是 5
負類：不是 5	TN 真負例：正確排除	FP 偽正例：誤報
正類：是 5	FN 偽負例：漏判	TP 真正例：正確找到

- 第一個字母 T/F：這次預測是否正確。
- 第二個字母 P/N：**預測**為正類或負類。
- 各格合計等於評估樣本數，對角線是正確分類。

 **從矩陣到 ROC：** `programs/notebooks/03_分類與模型評估.ipynb`

教材的混淆矩陣

真實 \ 預測	不是 5	是 5	真實總數
不是 5	TN = 53,892	FP = 687	54,579
是 5	FN = 1,891	TP = 3,530	5,421
預測總數	55,783	4,217	60,000

$$\text{Accuracy} = \frac{TP + TN}{N} = \frac{57,422}{60,000} \approx 95.70\%$$

比全判負類的基準高，仍漏掉 1,891 張 5。

Precision 與 recall 的分母不同

$$\text{Precision} = \frac{TP}{TP + FP} = \frac{3,530}{4,217} \approx 83.71\%$$

在**所有被模型判成 5** 的影像中，有多少真的是 5？

$$\text{Recall} = \frac{TP}{TP + FN} = \frac{3,530}{5,421} \approx 65.12\%$$

在**所有真正的 5** 中，模型找回多少？

F1：精確率與召回率的調和平均

$$F_1 = \frac{2PR}{P + R} = \frac{2TP}{2TP + FP + FN} \approx 0.733$$

- 當 precision 或 recall 其中之一很低，F1 也會受到限制。
- F1 沒有直接使用 TN，不能完整表達排除負類的能力。
- F1 不會自動反映誤報與漏判的實際代價。

分母為零時，應說明處理規則，不能默認數值都有定義。

活動 F：從四格算出三個分數

真實 \ 預測	不是 5	是 5
不是 5	70	10
是 5	5	15

請算 accuracy、precision、recall，再說明：

85% accuracy 能不能證明模型已經足夠好？

決策閾值控制哪些樣本被判成正類


$$\hat{y} = 1[s(\mathbf{x}) \geq t]$$

- $s(\mathbf{x})$ 是模型分數，未必是機率。
- t 越高，被判成正類的樣本通常越少。
- 在固定資料與分數下，升高閾值使 recall 不增加。
- Precision 常會上升，**但不保證單調增加**。

閾值選擇是決策設計的一部分，應使用驗證資料。

 **閾值實作**： `programs/notebooks/03_分類與模型評估.ipynb` 。由 `decision_function` / 機率分數掃描 `threshold`，再重算混淆矩陣與指標。

圖上的閾值如何改變誤報與漏判？



將閾值往右移，部分原本判成正類的影像改判成負類。
其中可能同時包含被排除的誤報，以及新產生的漏判。

用八筆分數追蹤每一次決策

樣本	模型分數 s	真實 y (是 5=1)
A	0.95	1
B	0.85	0
C	0.80	1
D	0.70	1
E	0.60	0
F	0.40	0
G	0.30	1
H	0.10	0


共 4 個正類、4 個負類。採用 $s \geq t$ 判正類。

活動 G：閾值不同，混淆矩陣也不同

閾值 t	TP	FP	FN	TN	Precision	Recall
0.8	?	?	?	?	?	?
0.5	?	?	?	?	?	?
0.2	?	?	?	?	?	?

哪個設定漏判最少？哪個設定誤報最少？
如果漏判的代價較高，你會如何說明選擇？

教材的 precision/recall 與閾值曲線



教材把 precision 調到約 **90%** 時，recall 只剩約 **48%**。

「精確率很高」仍須交代找回多少正類，以及判出了多少筆。

ROC：真陽性率對偽陽性率

$$\begin{aligned} \text{TPR} &= \frac{TP}{TP + FN} = \text{Recall} \\ \text{FPR} &= \frac{FP}{FP + TN} = 1 - \underbrace{\frac{TN}{TN + FP}}_{\text{Specificity}} \end{aligned}$$

ROC 圖的橫軸是 FPR，縱軸是 TPR。

FPR 的分母是所有真負類，不是所有正類預測。

因此 FPR 不等於 $1 - \text{Precision}$ 。



PR / ROC / AUC： `programs/notebooks/03_分類與模型評估.ipynb`


畫 ROC：排序分數，再逐步降低閾值

① 分數由高到低，逐筆放寬門檻

正類 P：TP 增加 → TPR 上升 | 負類 N：FP 增加 → FPR 上升

樣本	分數	真實類別	座標變化	新座標
A	0.95	P	↑ 1/4	(0, 1/4)
B	0.85	N	→ 1/4	(1/4, 1/4)
C	0.80	P	↑ 1/4	(1/4, 2/4)
D	0.70	P	↑ 1/4	(1/4, 3/4)
E	0.60	N	→ 1/4	(2/4, 3/4)
F	0.40	N	→ 1/4	(3/4, 3/4)
G	0.30	P	↑ 1/4	(3/4, 4/4)
H	0.10	N	→ 1/4	(4/4, 4/4)

② 把每次的新座標連成階梯





FPR = FP / 4 (遇到負類向右)

從 $t > 0.95$ 的全判負類 (0,0) 出發；每納入一個正類就向上，每納入一個負類就向右，最後到全判正類 (1,1)。

概念參考：好豪筆記〈圖解 ROC 曲線〉；圖表為本課依八筆示例重繪。

八筆資料的 ROC 與 PR




橘點：TP 3、FP 2、FN 1、TN 2 (採 $s \geq 0.5$)

- 左下 (0, 0)：閾值高於所有分數，全部判負類。
- 左上 (0, 1)：所有正類都找到、沒有誤報，是理想位置。
- 右上 (1, 1)：閾值低於所有分數，全部判正類。
- 對角線 $y = x$ ：無排序能力模型的平均參考線；曲線越靠左上越好。

AUC 怎麼算：沿 FPR 把面積加起來

每遇到一個負類，FPR 增加 1/4；該橫向區段下方就是一塊面積



八筆示例的面積加總

每一帶寬度都是 1/4：

$$\text{AUC} = 1/4 \times (\textcolor{brown}{1/4} + \textcolor{brown}{3/4} + \textcolor{teal}{3/4} + \textcolor{teal}{1})$$

$$= 11/16$$

$$= 0.6875$$

垂直線段寬度為 0，不增加面積。

一般折線可用梯形公式：

$$\text{AUC} = \sum_i (\text{FPR}_i - \text{FPR}_{i-1}) \frac{\text{TPR}_i + \text{TPR}_{i-1}}{2}$$

本例是階梯線，四個寬度 1/4 的長方形相加，得到 **AUC = 0.6875**。

同一個 AUC，也能用正負配對驗算

正類樣本	分數	分數較低的負類	勝出配對
A	0.95	B、E、F、H	4
C	0.80	E、F、H	3
D	0.70	E、F、H	3
G	0.30	H	1
合計			11

八筆示例共有 $4 \times 4 = 16$ 個正負配對。

所以 $AUC = 11/16 = 0.6875$ ，與曲線下面積相同。

若正負樣本同分，該配對以 **0.5 次勝出** 計算。

AUC 不會告訴你應採哪個閾值，也不代表機率已校準。

PR 與 ROC 關注的比較對象

圖	橫軸／縱軸	主要閱讀問題
PR	Recall／Precision	找回更多正類時，正類預測有多可信？
ROC	FPR／TPR	增加負類誤報比例時，能找回多少正類？

當正類稀少，PR 常更直接呈現正類預測的可用性。

無辨識排序的 PR 參考水準取決於**正類盛行比例**，不固定是 0.5。

很小的 FPR，也可能帶來很多誤報


假設 10,000 筆資料中，只有 100 筆是正類。

某閾值的 $TPR = 90\%$ 、 $FPR = 1\%$ 。

結果	計算
TP	$100 \times 90\% = 90$
FP	$9,900 \times 1\% = 99$
Precision	$90 / (90 + 99) \approx 47.6\%$

召回率高、偽陽性率低，正類預測仍可能有一半左右是誤報。

教材的兩個分類器比較



在這組教材資料與流程下，隨機森林的 PR 曲線優於 SGD。

比較時仍要固定：

- 相同任務與正類定義。
- 相同資料切分與評估流程。
- 關心的 recall 或 precision 區域。

閾值選擇還要考慮處理成本

$$\text{錯誤總代價} = c_{FP} FP + c_{FN} FN$$

- c_{FP} ：每次誤報的代價，可能是人工檢查時間。
- c_{FN} ：每次漏判的代價，取決於任務後果。
- 可另設限制，例如每天最多處理 100 筆警示。

先在驗證資料比較可行操作點，設定確定後才做最終測試。

多類別分類：每張影像選一個數字

MNIST 完整任務有 10 個互斥類別。

- 有些模型原生支援多類別。
- 也可組合多個二元分類器。
- 輸出最高分數的**類別標籤**，不要混淆索引與標籤。

例：類別順序是「貓、狗、鳥」，分數最大的索引為 2，預測標籤是「鳥」，不是數字 2 這個語意。

一對其餘與一對一

策略	訓練內容	K 類的模型數	MNIST 十類
OvR	某一類對所有其他類	K	10
OvO	每兩個類別各訓練一個	$K(K - 1)/2$	45

- OvR 通常比較各類分數。
- OvO 通常整合兩兩分類結果，例如投票。
- 模型數較多，不一定代表總訓練時間按同樣比例增加。


補充：Softmax 與多類別目標

$$z_k = \mathbf{w}_k^\top \mathbf{x} + b_k \quad \hat{p}_k = \frac{e^{z_k}}{\sum_{j=1}^K e^{z_j}}$$

- 對每個類別產生一個分數，再轉成總和為 1 的機率估計。
- 互斥多類別通常選 $\arg \max_k \hat{p}_k$ 。
- 交叉熵可用獨熱標籤表示： $\ell = -\sum_k y_k \ln \hat{p}_k$ 。
- 許多實作接受整數類別標籤，不要求使用者手動做獨熱編碼。

 **Iris 多類別 / Softmax** : `programs/notebooks/03_分類與模型評估.ipynb`

多類別混淆矩陣



先看每類樣本量，再看各列流向哪些錯誤類別。

列正規化與欄正規化的分母

真實 \ 預測	A	B	C	真實總數
A	40	5	5	50
B	4	12	4	20
C	1	3	26	30


- 依列正規化：A 判成 A 為 $40/50 = 80\%$ ，是 A 的 recall。
- 依欄正規化：預測 A 中真 A 為 $40/45 \approx 88.9\%$ ，是 A 的 precision。
- 先去掉正確預測再正規化，分母變成**錯誤樣本數**。

多類別分數如何平均？

平均方式	計算概念	解讀
Macro	每類各算分數，再等權平均	每類同等重要
Weighted	依每類真實樣本量加權	大類別影響較大
Micro	合併各類 TP／FP／FN 再計算	由整體樣本決定

單標籤多類別、涵蓋全部類別時，micro F1 等於 accuracy。
Macro F1 要先算每類 F1，再平均，不是先平均 P／R 再算 F1。

錯誤案例檢查：3 與 5 為何混淆？



教材用真實類別與預測類別排列影像。

- 檢查書寫、位移與旋轉。
- 區分模糊標籤與模型錯誤。
- 提出特徵或前處理假設。
- 擴增資料只從訓練原圖產生。

完整錯誤分析： `programs/notebooks/03_分類與模型評估.ipynb`

多標籤分類：一筆樣本可以同時有多個答案


教材為數字影像建立兩個二元標籤：

數字	大數字 (7、8、9)	奇數
5	否	是
8	是	否
9	是	是

每個標籤可各自評估 precision、recall、F1。

這與「十個互斥數字中只能選一個」的多類別任務不同。

多輸出：一次預測多個目標



教材以雜訊影像作輸入、乾淨影像作目標，每個像素都是一個輸出。

- 若像素取離散灰階類別，可視為多輸出分類。
- 若直接預測連續強度，也可表述成多輸出迴歸。

活動 H：寫一份有決策依據的分類報告

使用前面的八筆示例。每次 FP 代價為 1，每次 FN 代價為 4。

1. 比較閾值 0.8、0.5、0.2 的總代價。
2. 若每批最多只能人工確認五筆正類預測，哪個設定可行？
3. 選閾值應用哪份資料？最終報告要保留哪些數字？
4. 若部署資料的正類比例下降，precision 可能如何改變？

產出：正類定義、混淆矩陣、閾值、指標與限制，各一句。

三週回顧：一份可信的機器學習報告

問題	報告至少要回答
資料代表誰？	觀察單位、時間、分布與限制
模型如何學？	特徵、目標、前處理與正則化
如何公平比較？	基準、訓練／驗證／測試與選擇程序
分數代表什麼？	分母、單位、閾值、錯誤與不確定性

後續依主教材 Ch.4 深入線性模型、梯度下降與正則化訓練。