

第三週：分類與模型評估

Logistic Regression、交叉熵、混淆矩陣與 ROC/AUC

同一個模型，可以因為決策設定而產生不同的錯誤。

MNIST：影像也可以表示成特徵矩陣



- 70,000 張手寫數字影像。
- 每張 $28 \times 28 = 784$ 個像素。
- 一張影像是一筆樣本。
- 標籤為 0 到 9。
- 教材保留前 60,000 張訓練、後 10,000 張測試。



配套實作： `programs/notebooks/03_分類與模型評估.ipynb`

程式實驗與實際輸出

```
y_oof = cross_val_predict(clf, X, y, cv=3)  
ConfusionMatrixDisplay.from_predictions(y, y_oof)
```

觀察：折外預測產生的混淆矩陣可用於錯誤分析，最後測試集仍保留到決策完成後。

參考程式：`programs/notebooks/03_分類與模型評估.ipynb`



分類問題：預測有限個類別

分類模型把特徵 $\mathbf{x}$ 對應到類別標籤，而不是任意連續數值。

$$f(\mathbf{x}) \longrightarrow \hat{y} \in \{0, 1, \dots, K - 1\}$$

任務	輸出例	本章案例
二元分類	是／否、0／1	影像是不是數字 5
多類別分類	K 個互斥類別	影像是 0 到 9 的哪個數字
多標籤分類	一筆可同時有多個標籤	大圖中是否同時出現 5 與 7

模型可以先輸出分數或機率，再依決策規則得到類別。

二元分類：先辨識「是不是 5」

$$y_i = \begin{cases} 1, & \text{影像是數字 5} \\ 0, & \text{影像不是數字 5} \end{cases}$$

- 正類（positive）是我們指定關注的事件。
- 負類（negative）包含其餘九個數字。
- 訓練資料提供真實標籤，模型對新影像輸出分數或機率。

正類不代表「好」，負類也不代表「壞」。

本週的二元混淆矩陣都採同一個正類定義。

線性組合：數值預測與分類分數

一筆資料有 n 個特徵， b 是截距， w_j 是第 j 個特徵的權重。

$$z = b + \sum_{j=1}^n w_j x_j = b + \mathbf{w}^\top \mathbf{x}$$

模型	如何使用線性組合 z	真實目標
線性迴歸	$\hat{y} = z$ ，直接預測數值	連續數值
二元 Logistic Regression	$\hat{p} = \sigma(z)$ ，估計正類機率	$y \in \{0, 1\}$

分類還要將機率與閾值 t 比較，才得到類別 $\hat{y}$ 。

$z = 2$ 是分數，不能直接解讀成 200% 的機率。


Logistic Regression (邏輯斯迴歸)

$$z = b + \mathbf{w}^\top \mathbf{x}$$

$$\hat{p} = P(y = 1 \mid \mathbf{x}) = \sigma(z) = \frac{1}{1 + e^{-z}}$$

$$\hat{y} = \begin{cases} 1, & \hat{p} \geq t \\ 0, & \hat{p} < t \end{cases}$$

$t = 0.5$ 是常見起點，實際值應依驗證資料與錯誤代價決定。



Odds、Logit 與線性分數

正類機率為 p ，負類機率為 $1 - p$ 。

$$\text{odds}(p) = \frac{p}{1 - p}$$


$$\text{logit}(p) = \ln \frac{p}{1 - p} = z$$

$$\sigma(\text{logit}(p)) = p$$

p	odds	logit(p)	解讀
0.20	0.25	-1.386	較偏向負類
0.50	1	0	兩類機率相同
0.80	4	1.386	較偏向正類

Logistic Regression 假設特徵的線性組合對應到 log-odds。

決策邊界：在特徵空間畫出判斷分界



此例使用 Iris 的兩個花瓣特徵，並只保留 setosa 與 versicolor 兩類。

- 點：樣本及其真實類別。
- 背景顏色：模型估計的機率。
- 色彩交界：特定閾值下的決策邊界。

為什麼不直接最佳化分類錯誤率？

分類錯誤率只看最後的 0/1 決策，忽略模型有多有信心。

真實 $y = 1$	預測機率 $\hat{p}$	閾值 0.5	錯誤率
樣本 A	0.99	正確	0
樣本 B	0.51	正確	0
樣本 C	0.49	錯誤	1

- 0/1 錯誤率對參數呈階梯狀，幾乎處處沒有可用梯度。
- 可微分的機率損失能表示「方向」與「修正幅度」。
- Accuracy 適合評估，Cross-Entropy（交叉熵）適合訓練機率分類器。

Information（資訊量）與 Entropy（熵）

事件 x 的機率越低，發生時提供的資訊量越大：

$$I(x) = -\log_2 p(x)$$

事件	發生機率	資訊量
A 通過考試	0.40	$-\log_2(0.40) = 1.322 \text{ bits}$
B 通過考試	0.99	$-\log_2(0.99) = 0.014 \text{ bits}$

Entropy（熵）是隨機變數資訊量的期望值：

$$H(X) = -\sum_k p_k \log_2 p_k$$

機率分布越平均，結果越難預測，Entropy（熵）越高。

Binary Entropy（二元熵）的數字計算

對二元事件，正類機率為 p ：

$$H(p) = -p \log_2 p - (1 - p) \log_2 (1 - p)$$

$$H(0.40) = -0.40 \log_2 (0.40) - 0.60 \log_2 (0.60) = 0.971$$

$$H(0.99) = -0.99 \log_2 (0.99) - 0.01 \log_2 (0.01) = 0.081$$

p	Entropy（熵）	意義
0 或 1	0	結果確定
0.40	0.971	兩種結果都可能出現
0.50	1	二元情況下最不確定

Cross-Entropy（交叉熵） 比較真實與預測

一筆樣本的真實 one-hot 標籤為 $\mathbf{y}$ ，模型預測為 $\hat{\mathbf{p}}$ ：

$$\ell(\mathbf{y}, \hat{\mathbf{p}}) = - \sum_{c=1}^C y_c \log \hat{p}_c$$

因為真實類別只有一個 $y_c = 1$ ：

$$\ell = -\log(\text{模型分配給真實類別的機率})$$

真實類別機率	交叉熵損失 $-\ln p$
0.9	0.105
0.6	0.511
0.1	2.303

模型若對錯誤答案非常有信心，Cross-Entropy（交叉熵）會給很大的懲罰。

Cross-Entropy（交叉熵）範例：逐筆計算

四筆資料的真實類別依序為「男生、女生、男生、其他」。下表只列真實類別的預測機率，使用 $\log_2$ ：

樣本	真實類別	Model 1 的 p_y	$-\log_2 p_y$	Model 2 的 p_y	$-\log_2 p_y$
1	男生	0.40	1.322	0.70	0.515
2	女生	0.40	1.322	0.80	0.322
3	男生	0.50	1.000	0.90	0.152
4	其他	0.10	3.322	0.30	1.737
總和			6.966		2.725
平均			1.741		0.681

兩個模型的分類正確率都是 $3/4 = 75\%$ ，Model 2 的 Cross-Entropy（交叉熵）較低。

二元 Cross-Entropy（交叉熵）與 Loss（損失）

二元分類中， $y \in \{0, 1\}$ 、 $p = \sigma(z)$ ：

$$\ell(y, p) = -[y \ln p + (1 - y) \ln(1 - p)]$$

$$\ell(y, p) = \begin{cases} -\ln p, & y = 1 \\ -\ln(1 - p), & y = 0 \end{cases}$$

資料集的平均成本函數（cost function）：

$$J(\mathbf{w}, b) = \frac{1}{n} \sum_{i=1}^n \ell(y_i, p_i)$$

Loss 指單筆或小批次損失，cost 常指整體平均；實務文件也常混用兩詞，閱讀時先確認公式的平均範圍。

Logistic Loss 的微分

$$z = b + \mathbf{w}^\top \mathbf{x}, \quad p = \sigma(z)$$

$$\frac{\partial p}{\partial z} = p(1 - p)$$

$$\frac{\partial \ell}{\partial p} = -\frac{y}{p} + \frac{1 - y}{1 - p}$$

套用連鎖律後，sigmoid 與對數項會化簡：

$$\frac{\partial \ell}{\partial z} = p - y$$

$$\frac{\partial \ell}{\partial w_j} = (p - y)x_j$$

$$\frac{\partial \ell}{\partial b} = p - y$$

預測機率高於真實標籤時，梯度把 z 往下調；低於真實標籤時，梯度把 z 往上調。

平均 Loss 的梯度與一次更新

令 $\mathbf{p} = (p_1, \dots, p_n)^\top$:

$$\nabla_{\mathbf{w}} J = \frac{1}{n} \mathbf{X}^\top (\mathbf{p} - \mathbf{y}), \quad \frac{\partial J}{\partial b} = \frac{1}{n} \sum_{i=1}^n (p_i - y_i)$$

梯度下降：

$$\mathbf{w} \leftarrow \mathbf{w} - \eta \nabla_{\mathbf{w}} J, \quad b \leftarrow b - \eta \frac{\partial J}{\partial b}$$

單筆例： $y = 1$ 、 $p = 0.8$ 、 $\mathbf{x} = (2, -1)$ 。

$$p - y = -0.2, \quad \nabla_{\mathbf{w}} \ell = (-0.4, 0.2), \quad \frac{\partial \ell}{\partial b} = -0.2$$

更新後此正類樣本的 z 會提高， $p = \sigma(z)$ 也會往 1 移動。

 **完整向量化實作：** `programs/notebooks/03_分類與模型評估.ipynb`

用未參與訓練的預測評估

```
from sklearn.linear_model import SGDClassifier
from sklearn.model_selection import cross_val_predict

sgd_clf = SGDClassifier(random_state=42)
y_train_5 = (y_train == "5")
y_train_pred = cross_val_predict(
    sgd_clf, X_train, y_train_5, cv=3
)
```

- 每個 `y_train_pred[i]` 都來自**沒有用第 i 筆樣本訓練**的模型。
- 把折外預測（OOF）合併後，可計算混淆矩陣、precision、recall 與 F1。
- 調整模型或閾值後，仍需獨立的最終測試。

 **完整 MNIST 流程：** `programs/notebooks/03_分類與模型評估.ipynb`

類別不平衡：什麼都判成「不是 5」

教材訓練部分有 60,000 張影像，其中：

真實類別	筆數	比例
不是 5	54,579	90.965%
是 5	5,421	9.035%

若全部預測「不是 5」，accuracy 仍達 **90.965%**，
卻**一張 5 都找不到**。

混淆矩陣：列是真實，欄是預測

真實 \ 預測	負類：不是 5	正類：是 5
負類：不是 5	TN 真負例：正確排除	FP 偽正例：誤報
正類：是 5	FN 偽負例：漏判	TP 真正例：正確找到

- 第一個字母 T／F：這次預測是否正確。
- 第二個字母 P／N：**預測**為正類或負類。
- 各格合計等於評估樣本數，對角線是正確分類。

 **從矩陣到 ROC：** `programs/notebooks/03_分類與模型評估.ipynb`

教材的混淆矩陣

真實 \ 預測	不是 5	是 5	真實總數
不是 5	TN = 53,892	FP = 687	54,579
是 5	FN = 1,891	TP = 3,530	5,421
預測總數	55,783	4,217	60,000

$$\text{Accuracy} = \frac{TP + TN}{N} = \frac{57,422}{60,000} \approx 95.70\%$$

比全判負類的基準高，仍漏掉 1,891 張 5。

Precision 與 recall 的分母不同

$$\text{Precision} = \frac{TP}{TP + FP} = \frac{3,530}{4,217} \approx 83.71\%$$

在**所有被模型判成 5** 的影像中，有多少真的是 5？

$$\text{Recall} = \frac{TP}{TP + FN} = \frac{3,530}{5,421} \approx 65.12\%$$

在**所有真正的 5** 中，模型找回多少？

F1：精確率與召回率的調和平均

$$F_1 = \frac{2PR}{P + R} = \frac{2TP}{2TP + FP + FN} \approx 0.733$$

- 當 precision 或 recall 其中之一很低，F1 也會受到限制。
- F1 沒有直接使用 TN，不能完整表達排除負類的能力。
- F1 不會自動反映誤報與漏判的實際代價。

分母為零時，應說明處理規則，不能默認數值都有定義。

混淆矩陣的完整指標公式

令 $P = TP + FN$ 、 $N = TN + FP$ 、總樣本數 $M = P + N$ 。

$$\text{Accuracy} = \frac{TP + TN}{M}$$

$$\text{Precision} = \frac{TP}{TP + FP}$$

$$\text{Recall} = \text{TPR} = \frac{TP}{TP + FN}$$

$$\text{Specificity} = \text{TNR} = \frac{TN}{TN + FP}$$

$$\text{FPR} = \frac{FP}{FP + TN} = 1 - \text{TNR}$$

$$F_1 = \frac{2TP}{2TP + FP + FN}$$

Precision 看「預測為正」那一欄；Recall 與 FPR 分別看真實正類、真實負類兩列。

四格數字的逐步計算

真實 \ 預測	不是 5	是 5
不是 5	70	10
是 5	5	15

因此 $TN = 70$ 、 $FP = 10$ 、 $FN = 5$ 、 $TP = 15$ ，總數 $M = 100$ 。

$$\text{Accuracy} = \frac{15 + 70}{100} = 0.85$$

$$\text{Precision} = \frac{15}{15 + 10} = 0.60$$

$$\text{Recall} = \frac{15}{15 + 5} = 0.75$$

$$F_1 = \frac{2 \times 15}{2 \times 15 + 10 + 5} = \frac{2}{3} \approx 0.667$$

全判負類的 Accuracy 已有 80%，所以 85% 仍不足以單獨證明模型可用。

決策閾值控制哪些樣本被判成正類


$$\hat{y} = 1[s(\mathbf{x}) \geq t]$$

- $s(\mathbf{x})$ 是模型分數，未必是機率。
- t 越高，被判成正類的樣本通常越少。
- 在固定資料與分數下，升高閾值使 recall 不增加。
- Precision 常會上升，**但不保證單調增加**。

閾值選擇是決策設計的一部分，應使用驗證資料。

 **閾值實作**： `programs/notebooks/03_分類與模型評估.ipynb` 由 `decision_function` / 機率分數掃描 `threshold`，再重算混淆矩陣與指標。

圖上的閾值如何改變誤報與漏判？



將閾值往右移，部分原本判成正類的影像改判成負類。
其中可能同時包含被排除的誤報，以及新產生的漏判。

用八筆分數追蹤每一次決策

樣本	模型分數 s	真實 y (是 $5=1$)
A	0.95	1
B	0.85	0
C	0.80	1
D	0.70	1
E	0.60	0
F	0.40	0
G	0.30	1
H	0.10	0

共 4 個正類、4 個負類。採用 $s \geq t$ 判正類。


三個閾值的混淆矩陣與指標

由前頁八筆分數逐筆計算：

閾值 t	TP	FP	FN	TN	Precision	Recall	F_1
0.8	2	1	2	3	$2/3 = 0.667$	$2/4 = 0.500$	$4/7 = 0.571$
0.5	3	2	1	2	$3/5 = 0.600$	$3/4 = 0.750$	$6/9 = 0.667$
0.2	4	3	0	1	$4/7 = 0.571$	$4/4 = 1.000$	$8/11 = 0.727$

- 三個閾值的 Accuracy 都是 $5/8 = 62.5\%$ ，錯誤型態卻不同。
- $t = 0.8$ 的誤報最少； $t = 0.2$ 沒有漏判。
- 閾值選擇還要考慮 FP、FN 的代價與人工處理容量。

教材的 precision/recall 與閾值曲線



教材把 precision 調到約 **90%** 時，recall 只剩約 **48%**。

「精確率很高」仍須交代找回多少正類，以及判出了多少筆。

ROC：真陽性率對偽陽性率

$$\text{TPR} = \frac{TP}{TP + FN} = \text{Recall}$$
$$\text{FPR} = \frac{FP}{FP + TN} = 1 - \underbrace{\frac{TN}{TN + FP}}_{\text{Specificity}}$$

ROC 圖的橫軸是 FPR，縱軸是 TPR。

FPR 的分母是所有真負類，不是所有正類預測。

因此 FPR 不等於 $1 - \text{Precision}$ 。



PR / ROC / AUC： `programs/notebooks/03_分類與模型評估.ipynb`


畫 ROC：排序分數，再逐步降低閾值

① 分數由高到低，逐筆放寬門檻

正類 P：TP 增加 → TPR 上升 | 負類 N：FP 增加 → FPR 上升

樣本	分數	真實類別	座標變化	新座標
A	0.95	P	↑ 1/4	(0, 1/4)
B	0.85	N	→ 1/4	(1/4, 1/4)
C	0.80	P	↑ 1/4	(1/4, 2/4)
D	0.70	P	↑ 1/4	(1/4, 3/4)
E	0.60	N	→ 1/4	(2/4, 3/4)
F	0.40	N	→ 1/4	(3/4, 3/4)
G	0.30	P	↑ 1/4	(3/4, 4/4)
H	0.10	N	→ 1/4	(4/4, 4/4)

② 把每次的新座標連成階梯




FPR = FP / 4 (遇到負類向右)

從 $t > 0.95$ 的全判負類 (0, 0) 出發；每納入一個正類就向上，每納入一個負類就向右，最後到全判正類 (1, 1)。

延伸閱讀：好豪筆記〈圖解 ROC 曲線〉；下圖使用八筆資料逐步計算。

八筆資料的 ROC 與 PR




橘點：TP 3、FP 2、FN 1、TN 2（採 $s \geq 0.5$ ）

- 左下 $(0, 0)$ ：閾值高於所有分數，全部判負類。
- 左上 $(0, 1)$ ：所有正類都找到、沒有誤報，是理想位置。
- 右上 $(1, 1)$ ：閾值低於所有分數，全部判正類。
- 對角線 $y = x$ ：無排序能力模型的平均參考線；曲線越靠左上越好。

AUC 怎麼算：沿 FPR 把面積加起來

每遇到一個負類，FPR 增加 1/4；該橫向區段下方就是一塊面積



八筆示例的面積加總

每一帶寬度都是 1/4：

$$\text{AUC} = 1/4 \times (1/4 + 3/4 + 3/4 + 1)$$

$$= 11/16$$

$$= 0.6875$$

垂直線段寬度為 0，不增加面積。

一般折線可用梯形公式：

$$\text{AUC} = \sum_i (\text{FPR}_i - \text{FPR}_{i-1}) \frac{\text{TPR}_i + \text{TPR}_{i-1}}{2}$$

本例是階梯線，四個寬度 1/4 的長方形相加，得到 **AUC = 0.6875**。

同一個 AUC，也能用正負配對驗算

正類樣本	分數	分數較低的負類	勝出配對
A	0.95	B、E、F、H	4
C	0.80	E、F、H	3
D	0.70	E、F、H	3
G	0.30	H	1
合計			11

八筆示例共有 $4 \times 4 = 16$ 個正負配對。

所以 $AUC = 11/16 = 0.6875$ ，與曲線下面積相同。

若正負樣本同分，該配對以 **0.5 次勝出** 計算。

AUC 不會告訴你應採哪個閾值，也不代表機率已校準。

PR 與 ROC 關注的比較對象

圖	橫軸／縱軸	主要閱讀問題
PR	Recall／Precision	找回更多正類時，正類預測有多可信？
ROC	FPR／TPR	增加負類誤報比例時，能找回多少正類？

當正類稀少，PR 常更直接呈現正類預測的可用性。

無辨識排序的 PR 參考水準取決於**正類盛行比例**，不固定是 0.5。


很小的 FPR，也可能帶來很多誤報

假設 10,000 筆資料中，只有 100 筆是正類。
某閾值的 $TPR = 90\%$ 、 $FPR = 1\%$ 。

結果	計算
TP	$100 \times 90\% = 90$
FP	$9,900 \times 1\% = 99$
Precision	$90 / (90 + 99) \approx 47.6\%$

召回率高、偽陽性率低，正類預測仍可能有一半左右是誤報。

教材的兩個分類器比較



在這組教材資料與流程下，隨機森林的 PR 曲線優於 SGD。

比較時仍要固定：

- 相同任務與正類定義。
- 相同資料切分與評估流程。
- 關心的 recall 或 precision 區域。

閾值選擇還要考慮處理成本

$$\text{錯誤總代價} = c_{FP} FP + c_{FN} FN$$

- c_{FP} ：每次誤報的代價，可能是人工檢查時間。
- c_{FN} ：每次漏判的代價，取決於任務後果。
- 可另設限制，例如每天最多處理 100 筆警示。

先在驗證資料比較可行操作點，設定確定後才做最終測試。

多類別分類：每張影像選一個數字

MNIST 完整任務有 10 個互斥類別。

- 有些模型原生支援多類別。
- 也可組合多個二元分類器。
- 輸出最高分數的**類別標籤**，不要混淆索引與標籤。

例：類別順序是「貓、狗、鳥」，分數最大的索引為 2，預測標籤是「鳥」，不是數字 2 這個語意。

一對其餘與一對一

策略	訓練內容	K 類的模型數	MNIST 十類
OvR	某一類對所有其他類	K	10
OvO	每兩個類別各訓練一個	$K(K - 1)/2$	45

- OvR 通常比較各類分數。
- OvO 通常整合兩兩分類結果，例如投票。
- 模型數較多，不一定代表總訓練時間按同樣比例增加。


補充：Softmax 與多類別目標

$$z_k = \mathbf{w}_k^\top \mathbf{x} + b_k \quad \hat{p}_k = \frac{e^{z_k}}{\sum_{j=1}^K e^{z_j}}$$

- 對每個類別產生一個分數，再轉成總和為 1 的機率估計。
- 互斥多類別通常選 $\arg \max_k \hat{p}_k$ 。
- 交叉熵可用獨熱標籤表示： $\ell = -\sum_k y_k \ln \hat{p}_k$ 。
- 許多實作接受整數類別標籤，不要求使用者手動做獨熱編碼。

 **Iris 多類別／Softmax**： `programs/notebooks/03_分類與模型評估.ipynb`

多類別混淆矩陣



先看每類樣本量，再看各列流向哪些錯誤類別。

Notebook 另比較像素除以 255 與加入 StandardScaler 的 OOF 結果。

列正規化與欄正規化的分母

真實 \ 預測	A	B	C	真實總數
A	40	5	5	50
B	4	12	4	20
C	1	3	26	30


- 依列正規化：A 判成 A 為 $40/50 = 80\%$ ，是 A 的 recall。
- 依欄正規化：預測 A 中真 A 為 $40/45 \approx 88.9\%$ ，是 A 的 precision。
- 先去掉正確預測再正規化，分母變成**錯誤樣本數**。

多類別分數如何平均？

平均方式	計算概念	解讀
Macro	每類各算分數，再等權平均	每類同等重要
Weighted	依每類真實樣本量加權	大類別影響較大
Micro	合併各類 TP／FP／FN 再計算	由整體樣本決定

單標籤多類別、涵蓋全部類別時，micro F1 等於 accuracy。
Macro F1 要先算每類 F1，再平均，不是先平均 P／R 再算 F1。

錯誤案例檢查：3 與 5 為何混淆？



教材用真實類別與預測類別排列影像。

- 檢查書寫、位移與旋轉。
- 區分模糊標籤與模型錯誤。
- 提出特徵或前處理假設。
- 擴增資料只從訓練原圖產生。

完整錯誤分析： `programs/notebooks/03_分類與模型評估.ipynb`

多標籤分類：一筆樣本可以同時有多個答案


教材為數字影像建立兩個二元標籤：

數字	大數字 (7、8、9)	奇數
5	否	是
8	是	否
9	是	是

每個標籤可各自評估 precision、recall、F1。

這與「十個互斥數字中只能選一個」的多類別任務不同。

多輸出：一次預測多個目標



教材以雜訊影像作輸入、乾淨影像作目標，每個像素都是一個輸出。

- 若像素取離散灰階類別，可視為多輸出分類。
- 若直接預測連續強度，也可表述成多輸出迴歸。

活動 H：寫一份有決策依據的分類報告

使用前面的八筆示例。每次 FP 代價為 1，每次 FN 代價為 4。

1. 比較閾值 0.8、0.5、0.2 的總代價。
2. 若每批最多只能人工確認五筆正類預測，哪個設定可行？
3. 選閾值應用哪份資料？最終報告要保留哪些數字？
4. 若部署資料的正類比例下降，precision 可能如何改變？

產出：正類定義、混淆矩陣、閾值、指標與限制，各一句。

三週回顧：一份可信的機器學習報告

問題	報告至少要回答
資料代表誰？	觀察單位、時間、分布與限制
模型如何學？	特徵、目標、前處理與正則化
如何公平比較？	基準、訓練／驗證／測試與選擇程序
分數代表什麼？	分母、單位、閾值、錯誤與不確定性

後續依主教材 Ch.4 深入線性模型、梯度下降與正則化訓練。

Notebook 導讀：Iris 的訓練損失與梯度

二元 Iris 先切分，再以 training 的均值、標準差縮放花瓣長與寬。

$$z_i = b + \mathbf{w}^\top \mathbf{x}_i, \quad p_i = \sigma(z_i), \quad \ell_i = \text{logaddexp}(0, z_i) - y_i z_i$$

```
error = p - y
w -= eta * (X.T @ error) / len(X)
b -= eta * error.mean()
```

同一批更新前參數先算完 error，再同步更新。平均 loss 與 accuracy 分開觀察。

`logaddexp` 穩定計算 $\ln(1 + e^z)$ ；完整梯度推導見第 05 章。

Notebook 導讀：AP 與驗證閾值

$$AP = \sum_k (R_k - R_{k-1}) P_k$$

沿 recall 增加的順序加總；AP 的階梯加權不同於 PR 點的梯形面積。

fast 模式	筆數	決策
fit	9,000	三折 OOF 比較 SGD／森林，選較高 AP
validation	3,000	precision ≥ 0.90 中取 recall 最大的閾值
locked test	10,000	固定模型與閾值後才評估

`precision_recall_curve` 最後一點沒有 threshold；程式須用 `p[:-1]` 對齊。

Notebook 導讀：Softmax 與 OvR 的輸出

實作	機率／分數如何取得？	決策
手寫 OvR	各類獨立的 decision score	最大分數的類別
手寫 OvO	兩兩分類器各投一票	多數票；平手規則需明示
三類 LogisticRegression	聯合 Softmax 機率，列和為 1	最大機率的類別

$$p_c = \frac{\exp(z_c - a)}{\sum_j \exp(z_j - a)}, \quad a = \max_j z_j$$

Notebook 驗算穩定 Softmax 與 `predict_proba` 相同，並用 `classes_` 將索引轉回標籤。
Iris 是小型機制示範；100% accuracy 不代表所有花種與環境都適用。