

線性模型與最佳化

第 4 週 | 從閉式解走到梯度下降與多項式模型

後續八週課程 | 每週 180 分鐘（含兩次 10 分鐘休息）

今天要能做的三件事

1. 用矩陣表示預測與平方誤差。
2. 手算一次梯度更新，判讀學習率與縮放的影響。
3. 用學習曲線區分欠擬合、過擬合與資料不足。


 **配套 Notebook：** [04_線性模型與最佳化.ipynb](#)。程式片段、實際圖表與表格可由此檔重現。

程式實驗與實際輸出

```
theta -= eta * gradient  
# 比較 eta=0.02、0.30、1.05
```

觀察：學習率過小收斂慢，適中可收斂，過大會讓損失發散。

[開啟完整 Notebook](#)



三小時的工作節奏

時段	任務
0-50 分	線性模型、閉式解與數值求解
50-60 分	休息
60-120 分	梯度下降、學習率與批次
120-130 分	休息
130-180 分	多項式、學習曲線與診斷練習

參數、特徵與預測：先把形狀寫對

一筆資料有 n 個特徵， $x_0 = 1$ 表示截距。

$$\hat{y} = \theta_0 + \sum_{j=1}^n \theta_j x_j = \boldsymbol{\theta}^T \mathbf{x}$$

教材特例：生活滿意度 $= \theta_0 + \theta_1 \times$ 人均 GDP。

$X \in \mathbb{R}^{m \times (n+1)}$ 、 $\boldsymbol{\theta} \in \mathbb{R}^{n+1}$ 、 $\hat{\mathbf{y}} = X\boldsymbol{\theta} \in \mathbb{R}^m$ 。


訓練目標：讓所有殘差的平方平均最小

$$J(\theta) = \text{MSE} = \frac{1}{m} \sum_{i=1}^m (\theta^T x^{(i)} - y^{(i)})^2$$

$$J(\theta) = \frac{1}{m} \|X\theta - y\|_2^2$$

殘差有正有負；平方使它們不互相抵銷，也會放大極端誤差。

教材例子：帶有雜訊的直線資料



資料生成規則是 $y = 4 + 3x + \text{noise}$ ；觀測點不會全部落在真實直線上。


從「梯度為零」得到正規方程

$$X^T(X\hat{\theta} - y) = 0$$

$$\hat{\theta} = (X^T X)^{-1} X^T y$$

只有在 X 的欄彼此線性獨立時，這個反矩陣才存在。

估計直線與資料生成直線不是同一條



教材估計截距約 3.691、斜率約 3.330；有限樣本與雜訊會造成差異。

SVD 與偽反矩陣：處理共線與非方陣

$$X = U\Sigma V^T, \quad X^+ = V\Sigma^+ U^T$$
$$\hat{\theta} = X^+ y$$

把非零奇異值取倒數，近零值按數值容忍度處理。偽反矩陣可給出最小範數的最小平方解。

程式：避免自己計算反矩陣

```
import numpy as np
from sklearn.linear_model import LinearRegression
X = np.array([[0.], [1.], [2.]])
y = np.array([1., 3., 5.])
model = LinearRegression().fit(X, y)
print(model.intercept_, model.coef_) # 1, [2]
print(model.predict([[3.]])         # [7]
```

計算成本要同時看樣本數與特徵數

工作	主要影響	實務判斷
形成與求解正規方程	約 $O(mn^2 + n^3)$	特徵很多時昂貴
SVD 最小平方	常見稠密情況約 $O(mn^2)$ ($m \geq n$)	數值穩健，仍受維度影響
對新資料預測	約 $O(mn)$	與訓練方法無關

手算：三個點能決定哪一條線？


資料為 $(0, 1), (1, 3), (2, 5)$ 。

1. 寫出含截距的 X 與 y 。
2. 試算 $\theta = (1, 2)$ 與 $(0, 2)$ 的 MSE。
3. 若新增特徵 $x_2 = 2x_1$ ，還能唯一決定兩個斜率嗎？

休息 10 分鐘


離開座位、休息眼睛。回來後先用一句話回答上一段的核心問題。

梯度下降：根據目前斜率移動參數




參數位置決定損失；梯度指出上升最快方向，更新走向反方向。

學習率太小：方向對，卻走得很慢




每一步的改善很有限；固定迭代次數下，可能還沒有接近最低點。

學習率太大：可能越走越遠




跨過谷底並不必然失敗；振盪幅度持續增大才是發散的重要訊號。

一般損失曲面可能有局部低點與平臺



線性迴歸的 MSE 是凸函數；不要把本圖的非凸困難直接套到線性 MSE。

特徵尺度不同，會把等高線拉長



標準化常使更新路徑更有效率；縮放參數只從訓練資料估計。

一個偏導數：只看第 j 個參數

$$\frac{\partial J}{\partial \theta_j} = \frac{2}{m} \sum_{i=1}^m (\theta^T x^{(i)} - y^{(i)}) x_j^{(i)}$$

「殘差 $\times$ 對應特徵」告訴我們該參數如何影響損失。截距使用 $x_0 = 1$ 。

把所有偏導數組成一次更新

$$\nabla_{\theta} J = \frac{2}{m} X^T (X\theta - y)$$

$$\theta_{t+1} = \theta_t - \eta \nabla_{\theta} J(\theta_t)$$


所有參數要使用「同一個舊參數向量」計算梯度後再同步更新。

手算一次更新，檢查損失是否下降

令 $X = \begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix}$ 、 $y = (1, 3)^T$ 、 $\theta = (0, 0)^T$ 。


1. 計算殘差與梯度。
2. 設 $\eta = 0.1$ ，更新參數。
3. 比較更新前、後的 MSE。

同一資料，不同學習率的更新軌跡



比較左、中、右的收斂速度與穩定性；一次走得遠不等於更快收斂。

隨機梯度：以一筆資料估計下降方向




每步便宜、帶有雜訊；即使接近最低點，固定學習率仍可能持續晃動。

SGD 的學習率可逐步衰減

$$g_t = 2x^{(i)}(x^{(i)T}\theta_t - y^{(i)}), \quad \eta_t = \frac{t_0}{t + t_1}$$


先用較大步伐探索，後期用較小步伐穩定參數。每個 epoch 重新打亂資料，避免固定排序偏差。

SGD 的前幾步：單筆改善不等於整體改善



看整體損失趨勢，不要求每一步對全部樣本都變好。

Batch、SGD 與 Mini-batch 的路徑比較



Mini-batch 在梯度雜訊與硬體效率間折衷；批次大小也會影響合適的學習率。

休息 10 分鐘

離開座位、休息眼睛。回來後先用一句話回答上一段的核心問題。

表 4-1：資料規模與可用訓練方式

方法	大樣本 m	記憶體外	高維 n
正規方程	快	不適合	慢
SVD	快	不適合	慢
Batch GD	慢	不適合	快
SGD	快	可	快
Mini-batch GD	快	可	快


表 4-1：超參數、縮放與實作

方法	超參數數量	需要縮放	教材對應類別
正規方程	0	否	自行求解
SVD	0	否	LinearRegression
Batch GD	2	是	自行迭代
SGD	至少 2	是	SGDRegressor
Mini-batch GD	至少 2	是	自行迭代

fit、partial_fit 與 epoch 的差別


- `fit`：按估計器的訓練流程執行；不要假定重複呼叫會保留狀態。
- `partial_fit`：使用這次提供的資料繼續增量更新。
- `epoch`：走過訓練集一次；`iteration`：可能指一步或一次批次。
- 資料太大時，把縮放與分批讀取一起規劃。

資料是彎曲的，直線可能系統性失準



先考慮模型表達能力；把學習率調得更細，無法讓直線變成拋物線。

多項式迴歸：先轉換特徵，再用線性模型



加入 x^2 後， $\hat{y} = \theta_0 + \theta_1 x + \theta_2 x^2$ 仍對參數呈線性。


多項式特徵也包含交互作用

兩個特徵做二次展開： $[x_1, x_2, x_1^2, x_1x_2, x_2^2]$ 。

```
from sklearn.pipeline import make_pipeline
from sklearn.preprocessing import PolynomialFeatures, StandardScaler
poly = make_pipeline(PolynomialFeatures(2, include_bias=False),
                     StandardScaler(), LinearRegression())
```


維度與次數增加時，組合數成長很快。

模型階數：太簡單與太靈活的兩端




高次模型可緊貼訓練點，卻可能在點與點之間劇烈波動。

學習曲線：訓練與驗證誤差都偏高




增加資料後仍停在相近高誤差：先檢查欠擬合，而非只蒐集更多資料。

學習曲線：訓練很好，驗證落後



兩曲線有明顯差距時，可考慮更多資料、正則化或降低模型複雜度。

偏差與變異：重複抽樣後會看到什麼？



偏差關於平均預測偏離；變異關於不同訓練集的預測波動。

診斷工作單：下一步該改什麼？

A：訓練 RMSE=8、驗證=8.5，資料增加後都不改善。

B：訓練 RMSE=1、驗證=9；加資料後差距縮小。

各提出一個主要假設、一個驗證方法與一個調整；不要只寫「調參」。

離堂檢核與課後延伸

1. 為什麼共線時不能直接反轉 $X^T X$ ？
2. 梯度與學習率各負責什麼？
3. 多項式迴歸為何仍叫線性模型？

課後：主教材 Ch.4 練習 1–6；延伸比較 SVD 與 SGD 的適用情境。