

線性模型與最佳化

第 4 週 | 從閉式解走到梯度下降與多項式模型

今天要能做的三件事

1. 從平方損失的偏微分，推導線性迴歸的閉式解。
2. 用矩陣表示多元迴歸，手算梯度更新並判讀學習率。
3. 用學習曲線區分欠擬合、過擬合與資料不足。


 **配套 Notebook**： `programs/notebooks/04_線性模型與最佳化.ipynb` 。程式片段、實際圖表與表格可由此檔重現。

程式實驗與實際輸出

```
theta -= eta * gradient  
# 比較 eta=0.02、0.30、1.05
```

觀察：學習率過小收斂慢，適中可收斂，過大會讓損失發散。

參考程式：`programs/notebooks/04_線性模型與最佳化.ipynb`



本章概念如何串起來？

問題	方法與檢核
如何表示預測與誤差？	線性模型、殘差與平方損失
如何找到較佳參數？	閉式解、梯度、學習率與批次更新
如何判讀學習結果？	多項式特徵、學習曲線與偏差／變異診斷

同一條主線：定義目標函數、求解參數，再以未見資料檢查泛化。

簡單線性迴歸：一個特徵預測一個數值

$$\hat{y}_i = b + wx_i$$

- x_i ：第 i 筆資料的特徵； y_i ：觀察到的真實值。
- $\hat{y}_i$ ：模型預測； b ：截距； w ：斜率。
- x 增加 1 單位，模型的預測值改變 w 單位。

教材例子：生活滿意度 $= b + w \times$ 人均 GDP。

訓練時資料固定，調整 b, w 以改善預測。

數學符號：樣本、特徵與參數

符號	本章約定
$m, i = 1, \dots, m$	樣本數與樣本索引
$n, j = 1, \dots, n$	特徵數與特徵索引； x_{ij} 是第 i 筆的第 j 個特徵
$y_i, \hat{y}_i$	真實值與預測值；粗體 $\mathbf{y}, \hat{\mathbf{y}}$ 集合所有樣本
b, w_j	截距與第 j 個特徵的權重；單一特徵時簡寫為 w
$\theta_0 = b, \theta_j = w_j$	$\boldsymbol{\theta} = (b, w_1, \dots, w_n)^\top$ 是參數向量
k, η	第 k 次更新與學習率； $\boldsymbol{\theta}^{(k)}$ 的上標不是次方

帶帽的 $\hat{\boldsymbol{\theta}}$ 表示求得的最小平方解。

多元線性迴歸：特徵加權與矩陣表示

$$\hat{y}_i = b + \sum_{j=1}^n w_j x_{ij} = \tilde{\mathbf{x}}_i^\top \boldsymbol{\theta}, \quad \tilde{\mathbf{x}}_i = (1, x_{i1}, \dots, x_{in})^\top$$

$$X = \begin{bmatrix} 1 & x_{11} & \cdots & x_{1n} \\ \vdots & \vdots & & \vdots \\ 1 & x_{m1} & \cdots & x_{mn} \end{bmatrix}, \quad \hat{\mathbf{y}} = X\boldsymbol{\theta}$$

X 為 $m \times (n + 1)$ ， $\boldsymbol{\theta}$ 為 $(n + 1) \times 1$ ， $\hat{\mathbf{y}}$ 為 $m \times 1$ 。

每列是一筆樣本；首欄的 1 配合截距。多元迴歸以多個特徵預測**一個目標**。

訓練目標：讓所有殘差的平方平均最小


$$r_i = \hat{y}_i - y_i, \quad J(\boldsymbol{\theta}) = \text{MSE} = \frac{1}{m} \sum_{i=1}^m r_i^2$$

$$J(\boldsymbol{\theta}) = \frac{1}{m} \|X\boldsymbol{\theta} - \mathbf{y}\|_2^2$$

殘差有正有負；平方使它們不互相抵銷，也會放大極端誤差。

本章殘差採「預測減真實」； $\text{SSE} = mJ$ ，且 J **沒有乘** $1/2$ 。

教材例子：帶有雜訊的直線資料



資料生成規則是 $y = 4 + 3x + \text{noise}$ ；觀測點不會全部落在真實直線上。

導數與偏導數：參數改變時，損失怎麼變？

$$f'(a) = \lim_{h \rightarrow 0} \frac{f(a+h) - f(a)}{h}$$

導數描述局部斜率。 $J(b, w)$ 有兩個參數，偏微分時固定另一個參數。

平方的微分要乘上內部函數的導數，這是**連鎖律**：

$$\frac{d}{du} [g(u)]^2 = 2g(u)g'(u)$$

例： $f(u) = (u - 3)^2$ ，則 $f'(u) = 2(u - 3)$ ，所以 $f'(1) = -4$ 。

平方損失的偏微分：截距與斜率

簡單迴歸中， $r_i = b + wx_i - y_i$ ， $J(b, w) = \frac{1}{m} \sum_i r_i^2$ 。

$$\frac{\partial J}{\partial b} = \frac{1}{m} \sum_{i=1}^m 2r_i \frac{\partial r_i}{\partial b} = \frac{2}{m} \sum_{i=1}^m r_i$$
$$\frac{\partial J}{\partial w} = \frac{1}{m} \sum_{i=1}^m 2r_i \frac{\partial r_i}{\partial w} = \frac{2}{m} \sum_{i=1}^m r_i x_i$$

因為 $\frac{\partial r_i}{\partial b} = 1$ ，而 $\frac{\partial r_i}{\partial w} = x_i$ 。

檢查： $r_i > 0$ 表示高估還是低估？這一筆對截距梯度貢獻什麼符號？

簡單迴歸的閉式解：偏導數設為零

定義 $\bar{x} = \frac{1}{m} \sum_i x_i$ 、 $\bar{y} = \frac{1}{m} \sum_i y_i$ 。

$$0 = \sum_i (\hat{b} + \hat{w}x_i - y_i) \implies \hat{b} = \bar{y} - \hat{w}\bar{x}$$

代回斜率條件 $\sum_i x_i(\hat{b} + \hat{w}x_i - y_i) = 0$ ：

$$0 = \hat{w} \sum_i (x_i - \bar{x})^2 - \sum_i (x_i - \bar{x})(y_i - \bar{y})$$

$$\boxed{\hat{w} = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sum_i (x_i - \bar{x})^2}}, \quad \boxed{\hat{b} = \bar{y} - \hat{w}\bar{x}}$$

x_i 必須有變化，分母才大於零；配適直線通過 $(\bar{x}, \bar{y})$ 。

多元迴歸的偏導數：每個權重各算一次

$$r_i = b + \sum_{j=1}^n w_j x_{ij} - y_i, \quad \frac{\partial r_i}{\partial w_j} = x_{ij}$$

$$\frac{\partial J}{\partial w_j} = \frac{1}{m} \sum_{i=1}^m 2r_i \frac{\partial r_i}{\partial w_j} = \frac{2}{m} \sum_{i=1}^m r_i x_{ij}$$

截距令 $x_{i0} = 1$ 、 $\theta_0 = b$ ；其餘 $\theta_j = w_j$ 。

把所有偏導數排成向量，就是梯度 $\nabla_{\theta} J$ 。

多元迴歸的平方損失與梯度

$$\begin{aligned} J(\boldsymbol{\theta}) &= \frac{1}{m} (\mathbf{X}\boldsymbol{\theta} - \mathbf{y})^\top (\mathbf{X}\boldsymbol{\theta} - \mathbf{y}) \\ &= \frac{1}{m} \left(\boldsymbol{\theta}^\top \mathbf{X}^\top \mathbf{X} \boldsymbol{\theta} - 2\boldsymbol{\theta}^\top \mathbf{X}^\top \mathbf{y} + \mathbf{y}^\top \mathbf{y} \right) \end{aligned}$$

$\mathbf{X}^\top \mathbf{X}$ 是對稱矩陣；三項對參數微分分別為：

$$\nabla_{\boldsymbol{\theta}} J = \frac{1}{m} (2\mathbf{X}^\top \mathbf{X} \boldsymbol{\theta} - 2\mathbf{X}^\top \mathbf{y} + \mathbf{0}) = \frac{2}{m} \mathbf{X}^\top (\mathbf{X}\boldsymbol{\theta} - \mathbf{y})$$

第 j 個分量正是上一頁的 $\frac{2}{m} \sum_i r_i x_{ij}$ 。

從「梯度為零」得到正規方程

$$\nabla J(\hat{\boldsymbol{\theta}}) = \mathbf{0} \implies X^\top (X\hat{\boldsymbol{\theta}} - \mathbf{y}) = \mathbf{0}$$


$$\boxed{X^\top X\hat{\boldsymbol{\theta}} = X^\top \mathbf{y}}$$

若 X 的欄彼此線性獨立，可寫成：

$$\hat{\boldsymbol{\theta}} = (X^\top X)^{-1} X^\top \mathbf{y}$$

線性迴歸的 MSE 為凸函數；滿欄秩時，最小平方解唯一。

估計直線與資料生成直線不是同一條



教材估計截距約 3.691、斜率約 3.330；有限樣本與雜訊會造成差異。

SVD 與偽反矩陣：處理共線與非方陣

$$X = U\Sigma V^{\top}, \quad X^+ = V\Sigma^+ U^{\top}$$
$$\hat{\boldsymbol{\theta}} = X^+ \mathbf{y}$$

把非零奇異值取倒數，近零值按數值容忍度處理。偽反矩陣可給出最小範數的最小平方解。

程式：避免自己計算反矩陣

```
import numpy as np
from sklearn.linear_model import LinearRegression
X = np.array([[0.], [1.], [2.]])
y = np.array([1., 3., 5.])
model = LinearRegression().fit(X, y)
print(model.intercept_, model.coef_) # 1, [2]
print(model.predict([[3.]])         # [7]
```

延伸閱讀：計算成本與資料維度

工作	主要影響	實務判斷
形成與求解正規方程	約 $O(mn^2 + n^3)$	特徵很多時昂貴
SVD 最小平方	常見稠密情況約 $O(mn^2)$ ($m \geq n$)	數值穩健，仍受維度影響
對新資料預測	約 $O(mn)$	與訓練方法無關

手算：三個點能決定哪一條線？

資料為 $(0, 1), (1, 3), (2, 5)$ 。


1. 寫出含截距的 X 與 $\mathbf{y}$ ，用閉式解算 $\hat{b}, \hat{w}$ 。
2. 試算 $\boldsymbol{\theta} = (1, 2)^\top$ 與 $(0, 2)^\top$ 的 MSE。
3. 若新增特徵 $x_2 = 2x_1$ ，還能唯一決定兩個斜率嗎？

閉式解與梯度下降如何銜接？

給定三筆資料 $(x, y) = (0, 1), (1, 3), (2, 5)$ ：

- 最小平方解為 $\hat{y} = 1 + 2x$ ，三筆殘差都是 0，所以 MSE 為 0。
- 若新增 $x_2 = 2x_1$ ，則只可確定 $w_1 + 2w_2 = 2$ ；係數不唯一。
- 梯度下降可找使 MSE 下降的參數；有完全共線特徵時，也不會憑空產生唯一係數。

梯度下降：根據目前斜率移動參數



參數位置決定損失；梯度指出上升最快方向，更新走向反方向。

梯度更新：同一組更新前參數，同步調整

第 k 步先算殘差 $r_i^{(k)} = b^{(k)} + w^{(k)}x_i - y_i$ ：


$$b^{(k+1)} = b^{(k)} - \eta \frac{2}{m} \sum_i r_i^{(k)}$$
$$w^{(k+1)} = w^{(k)} - \eta \frac{2}{m} \sum_i r_i^{(k)} x_i$$

多元迴歸將所有參數合併成一次向量更新：

$$\boldsymbol{\theta}^{(k+1)} = \boldsymbol{\theta}^{(k)} - \eta \frac{2}{m} X^\top (X\boldsymbol{\theta}^{(k)} - \mathbf{y})$$


梯度決定局部方向與斜率， $\eta > 0$ 控制步幅；本式每步使用全部訓練資料。

學習率太小：方向對，卻走得很慢




每一步的改善很有限；固定迭代次數下，可能還沒有接近最低點。

學習率太大：可能越走越遠




跨過谷底並不必然失敗；振盪幅度持續增大才是發散的重要訊號。

一般損失曲面可能有局部低點與平臺



線性迴歸的 MSE 是凸函數；不要把本圖的非凸困難直接套到線性 MSE。

特徵尺度不同，會把等高線拉長



標準化常使更新路徑更有效率；縮放參數只從訓練資料估計。

手算一次更新，檢查損失是否下降

令 $X = \begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix}$ 、 $\mathbf{y} = (1, 3)^\top$ 、 $\boldsymbol{\theta}^{(0)} = (0, 0)^\top$ 。

1. 計算殘差與梯度。
2. 設 $\eta = 0.1$ ，更新參數。
3. 比較更新前、後的 MSE。

繳交：殘差、梯度、新參數、兩次 MSE，並說明更新方向。

手算解答：從殘差到新的預測


$$\mathbf{r}^{(0)} = X\boldsymbol{\theta}^{(0)} - \mathbf{y} = \begin{bmatrix} -1 \\ -3 \end{bmatrix}, \quad \nabla J(\boldsymbol{\theta}^{(0)}) = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} -1 \\ -3 \end{bmatrix} = \begin{bmatrix} -4 \\ -3 \end{bmatrix}$$

$$\boldsymbol{\theta}^{(1)} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} - 0.1 \begin{bmatrix} -4 \\ -3 \end{bmatrix} = \begin{bmatrix} 0.4 \\ 0.3 \end{bmatrix}, \quad \hat{\mathbf{y}}^{(1)} = \begin{bmatrix} 0.4 \\ 0.7 \end{bmatrix}$$

$$J(\boldsymbol{\theta}^{(0)}) = \frac{1 + 9}{2} = 5, \quad J(\boldsymbol{\theta}^{(1)}) = \frac{(-0.6)^2 + (-2.3)^2}{2} = 2.825$$


這一步損失下降；梯度尚未為零，仍可繼續更新。

同一資料，不同學習率的更新軌跡



比較左、中、右的收斂速度與穩定性；一次走得遠不等於更快收斂。

隨機梯度：以一筆資料估計下降方向



每步便宜、帶有雜訊；即使接近最低點，固定學習率仍可能持續晃動。


SGD 的學習率可逐步衰減

$$\mathbf{g}^{(k)} = 2\tilde{\mathbf{x}}_{i_k} \left(\tilde{\mathbf{x}}_{i_k}^\top \boldsymbol{\theta}^{(k)} - y_{i_k} \right), \quad \eta_k = \frac{a}{k + c}$$

i_k 是這一步選到的樣本， k 是累計更新次數； $a, c > 0$ 控制衰減。


先用較大步伐探索，後期用較小步伐穩定參數。每個 epoch 重新打亂資料，避免固定排序偏差。

SGD 的前幾步：單筆改善不等於整體改善



看整體損失趨勢，不要求每一步對全部樣本都變好。

Batch、SGD 與 Mini-batch 的路徑比較



Mini-batch 在梯度雜訊與硬體效率間折衷；批次大小也會影響合適的學習率。

Batch、SGD、Mini-batch 怎麼選？

三者都沿同一個訓練目標更新參數，差別在每次估計梯度使用的樣本數：

方法	單次梯度資料	常見取捨
Batch	全部樣本	方向穩定，但單次更新較慢
SGD	一筆樣本	更新頻繁，梯度雜訊較大
Mini-batch	一小批樣本	計算效率與梯度穩定度折衷

比較時先固定資料切分、特徵縮放與評估指標。

表 4-1：資料規模與可用訓練方式

方法	大樣本 m	記憶體外	高維 n
正規方程	快	不適合	慢
SVD	快	不適合	慢
Batch GD	慢	不適合	快
SGD	快	可	快
Mini-batch GD	快	可	快


表 4-1：超參數、縮放與實作

方法	超參數數量	需要縮放	教材對應類別
正規方程	0	否	自行求解
SVD	0	否	LinearRegression
Batch GD	2	是	自行迭代
SGD	至少 2	是	SGDRegressor
Mini-batch GD	至少 2	是	自行迭代

fit、partial_fit 與 epoch 的差別


- `fit`：按估計器的訓練流程執行；不要假定重複呼叫會保留狀態。
- `partial_fit`：使用這次提供的資料繼續增量更新。
- `epoch`：走過訓練集一次；`iteration`：可能指一步或一次批次。
- 資料太大時，把縮放與分批讀取一起規劃。

資料是彎曲的，直線可能系統性失準



先考慮模型表達能力；把學習率調得更細，無法讓直線變成拋物線。

多項式迴歸：先轉換特徵，再用線性模型



加入 x^2 後， $\hat{y} = b + w_1x + w_2x^2$ 仍對參數呈線性。


多項式特徵也包含交互作用

兩個特徵做二次展開： $[x_1, x_2, x_1^2, x_1x_2, x_2^2]$ 。

```
from sklearn.pipeline import make_pipeline
from sklearn.preprocessing import PolynomialFeatures, StandardScaler
poly = make_pipeline(PolynomialFeatures(2, include_bias=False),
                     StandardScaler(), LinearRegression())
```


維度與次數增加時，組合數成長很快。

模型階數：太簡單與太靈活的兩端




高次模型可緊貼訓練點，卻可能在點與點之間劇烈波動。

學習曲線：訓練與驗證誤差都偏高




增加資料後仍停在相近高誤差：先檢查欠擬合，而非只蒐集更多資料。

學習曲線：訓練很好，驗證落後



兩曲線有明顯差距時，可考慮更多資料、正則化或降低模型複雜度。

偏差與變異：重複抽樣後會看到什麼？



偏差關於平均預測偏離；變異關於不同訓練集的預測波動。

診斷工作單：下一步該改什麼？

A：訓練 RMSE=8、驗證=8.5，資料增加後都不改善。

B：訓練 RMSE=1、驗證=9；加資料後差距縮小。

各提出一個主要假設、一個驗證方法與一個調整；不要只寫「調參」。

離堂檢核與課後延伸

1. MSE 的偏導數中， $2/m$ 與 x_{ij} 各從哪裡來？
2. 閉式解與梯度下降求解什麼目標？共線時解是否唯一？
3. 梯度與學習率各負責什麼？多項式迴歸為何仍是線性模型？

課後：主教材 Ch.4 練習 1-6；延伸比較 SVD 與 SGD 的適用情境。

下一個進度： 05_正則化與機率分類

延伸閱讀：閉式解中的置中求和

利用 $\sum_i x_i = m\bar{x}$ 、 $\sum_i y_i = m\bar{y}$ ：

$$\sum_i (x_i - \bar{x})(y_i - \bar{y}) = \sum_i x_i y_i - \bar{x} \sum_i y_i - \bar{y} \sum_i x_i + m\bar{x}\bar{y}$$

$$= \sum_i x_i y_i - m\bar{x}\bar{y}$$

$$\sum_i (x_i - \bar{x})^2 = \sum_i x_i^2 - 2\bar{x} \sum_i x_i + m\bar{x}^2$$

$$= \sum_i x_i^2 - m\bar{x}^2$$

因此 $\hat{w} = \frac{\sum_i x_i y_i - m\bar{x}\bar{y}}{\sum_i x_i^2 - m\bar{x}^2}$ ，等於課堂上的置中形式。

延伸閱讀：負梯度方向的一階近似

令目前梯度 $\mathbf{g} = \nabla J(\boldsymbol{\theta}) \neq \mathbf{0}$ 。

小幅改變參數 $\Delta\boldsymbol{\theta}$ 時：

$$J(\boldsymbol{\theta} + \Delta\boldsymbol{\theta}) \approx J(\boldsymbol{\theta}) + \mathbf{g}^\top \Delta\boldsymbol{\theta}$$

選擇 $\Delta\boldsymbol{\theta} = -\eta\mathbf{g}$ 、 $\eta > 0$ ，則：

$$J(\boldsymbol{\theta} - \eta\mathbf{g}) \approx J(\boldsymbol{\theta}) - \eta\mathbf{g}^\top \mathbf{g} = J(\boldsymbol{\theta}) - \eta\|\mathbf{g}\|_2^2$$

梯度非零且步長足夠小時，損失會下降；步長太大時，不能靠這個近似保證。

Notebook 導讀：解析梯度與有限差分


對每個參數小幅往左右移，近似該方向的偏導數：

$$g_j \approx \frac{J(\boldsymbol{\theta} + h\mathbf{e}_j) - J(\boldsymbol{\theta} - h\mathbf{e}_j)}{2h}$$

- 用來驗算 $\frac{2}{m} X^\top (X\boldsymbol{\theta} - y)$ ；不取代連鎖律推導。
- h 太大近似不準，太小會受到浮點相消影響。
- Notebook 同時比較逐欄梯度、矩陣梯度與同步更新。


共線時檢查矩陣秩與條件數；浮點反矩陣不一定拋出例外，不能用「沒報錯」證明可逆。

Notebook 圖表：更新次數與 epoch



左：每次更新後的整體 MSE；右：參數路徑。每步使用的樣本量不同。
一次 epoch 看完一輪資料； `partial_fit` 每次只處理傳入那一塊。
Notebook 另保留 epoch 結尾圖，不能把兩種橫軸當相同運算成本。

Notebook 圖表：重複抽樣的偏差與變異



固定生成函數與雜訊，重抽 100 組訓練集；實線是平均預測，色帶是 ± 1 標準差。

$$\mathbb{E}[(\hat{f}(x) - y)^2] = \text{Bias}(x)^2 + \text{Var}(\hat{f}(x)) + \sigma^2$$