

正則化與機率分類

第 5 週 | 控制模型複雜度，理解機率、損失與決策

後續八週課程 | 每週 180 分鐘（含兩次 10 分鐘休息）

本週任務與節奏

前 37 分：Ridge、Lasso、Elastic Net。刪除「手算懲罰」頁後，釋出的 13 分鐘可作後續討論或彈性調整。

休息後 60 分：早停、Logistic 與二元交叉熵。

第二次休息後 50 分：Softmax、多類別與選模實作。

成果：能說明正則化如何改變目標，以及機率如何轉成決策。


 **配套 Notebook**： `programs/notebooks/05_正則化與機率分類.ipynb`。程式片段、實際圖表與表格可由此檔重現。

程式實驗與實際輸出

```
for alpha in alphas:  
    Ridge(alpha=alpha).fit(X, y)
```

觀察：正則化強度改變係數大小；比較前要固定資料切分與特徵縮放流程。

參考程式：`programs/notebooks/05_正則化與機率分類.ipynb`



正則化：把參數大小也放入訓練目標

$$J(\theta) = \text{資料誤差} + \lambda \text{參數懲罰}$$

- 犧牲一點訓練擬合，限制不穩定的係數。
- 通常不懲罰截距；先縮放特徵，讓懲罰可比較。
- 強度由驗證集或交叉驗證選擇。

L1 與 L2 正則化


$$J(\mathbf{w}, b) = \frac{1}{m} \sum_{i=1}^m (\hat{y}_i - y_i)^2 + \lambda \Omega(\mathbf{w})$$

方法	懲罰項 $\Omega(\mathbf{w})$	常見效果
Ridge／L2	$\sum_j w_j^2$	縮小係數，通常不直接變為 0
Lasso／L1	$\sum_j w_j $	部分係數可能變為 0，形成稀疏解
Elastic Net	L1 與 L2 的加權組合	結合兩類限制

$\lambda \geq 0$ 是超參數。此處通常不懲罰截距 b 。

重複標記：本頁由第一週原頁移入，與本檔既有 Ridge／Lasso／Elastic Net 說明重複，待課程整理時決定刪除。

正則化的幾何直覺



- 藍色等高線表示不同損失。
- 黃色區域是允許的係數範圍。
- L2 的限制邊界是圓。
- L1 的限制邊界有位於座標軸的角點，較容易出現零係數。

重複標記：本頁由第一週原頁移入，與後面的 Ch.4 圖 4-20 幾何說明重複，待課程整理時決定刪除。


Ridge：平方懲罰讓係數平滑縮小

$$J_{\text{ridge}} = \text{MSE}(\theta) + \frac{\alpha}{m} \sum_{j=1}^n \theta_j^2$$

$$\hat{\theta} = (X^T X + \alpha A)^{-1} X^T y, \quad A = \text{diag}(0, 1, \dots, 1)$$

$\alpha = 0$ 回到無正則化；越大通常縮得越多。

Ridge 的強度如何改變直線與曲線？




比較左右兩組圖：正則化既能約束原始線性係數，也能約束多項式係數。

Lasso：絕對值懲罰可以產生零係數

$$J_{\text{lasso}} = \text{MSE}(\theta) + 2\alpha \sum_{j=1}^n |\theta_j|$$


可得到稀疏參數；但高度相關特徵間，選擇結果可能不穩定。

Lasso 在多項式模型中壓掉部分項



觀察模型變簡單的方式：可能使部分係數精確變成 0。

L1 與 L2 的幾何：角點與圓滑邊界



L1 邊界在座標軸有角點，較容易使最優解落在某些係數為零的位置。

零點不可微，仍可使用次梯度

$$g_j = \frac{\partial \text{MSE}}{\partial \theta_j} + 2\alpha s_j, \quad s_j \in \begin{cases} \{1\} & \theta_j > 0 \\ [-1, 1] & \theta_j = 0 \\ \{-1\} & \theta_j < 0 \end{cases}$$

在零點選 $s_j = 0$ 是合法代表；實際 Lasso 求解器也可用座標下降等方法。截距不加此項。

Elastic Net：同時限制 L1 與 L2

$$J = \text{MSE} + \lambda_1 \|w\|_1 + \lambda_2 \|w\|_2^2$$

λ_1 控制稀疏傾向， λ_2 提供平滑收縮。混合比例 r 越大，越偏向 Lasso。

同叫 alpha，目標函數尺度可能不同

教材式 4-13： $\text{MSE} + 2r\alpha\|w\|_1 + \frac{(1-r)\alpha}{m}\|w\|_2^2$ 。

scikit-learn ElasticNet： $\frac{\text{MSE}}{2} + \alpha r\|w\|_1 + \frac{\alpha(1-r)}{2}\|w\|_2^2$ 。

兩式的 L2 樣本數係數不同；實作與調參以使用的 API 目標為準，不能直接照搬同一個 α 。


Ridge、Lasso、Elastic Net 如何選？

方法	主要效果	先考慮的情境
Ridge	收縮，通常不產生零係數	多個特徵共同提供訊息
Lasso	稀疏化	需要少數特徵，並檢查穩定性
Elastic Net	L1 與 L2 混合	特徵相關、又想保留稀疏性

休息 10 分鐘

離開座位、休息眼睛。回來後先用一句話回答上一段的核心問題。

早停：保留驗證表現最好的參數



訓練誤差繼續下降，不代表泛化繼續改善；測試集不可用來決定停止點。

早停需要「監看、耐心、保存、回復」

1. 每個 epoch 記錄訓練損失與驗證指標。
2. 指標需超過最小改善量；連續若干次未改善才停止。
3. 保存最佳參數，最後回復最佳版本。


`deepcopy` 可保存已學參數；`clone` 主要複製估計器設定。

Logistic：先算分數，再轉成正類機率

$$z = \theta^T x, \quad \hat{p} = \sigma(z) = \frac{1}{1 + e^{-z}}$$
$$\hat{y} = \begin{cases} 1 & \hat{p} \geq 0.5 \\ 0 & \hat{p} < 0.5 \end{cases}$$

預測機率是連續值；類別是套用閾值後的決策。

Sigmoid 把任意實數映射到 0 與 1 之間



$z = 0$ 對應 0.5；分數往正方向移動，正類估計機率上升。

二元交叉熵：自信地答錯，代價很高

$$c(\theta) = \begin{cases} -\log \hat{p} & y = 1 \\ -\log(1 - \hat{p}) & y = 0 \end{cases}$$

$$J = -\frac{1}{m} \sum_i [y^{(i)} \log \hat{p}^{(i)} + (1 - y^{(i)}) \log(1 - \hat{p}^{(i)})]$$


Logistic 梯度：形式像殘差，但預測已轉機率

$$\frac{\partial J}{\partial \theta_j} = \frac{1}{m} \sum_i (\sigma(\theta^T x^{(i)}) - y^{(i)}) x_j^{(i)}$$

$$\nabla J = \frac{1}{m} X^T (\hat{p} - y)$$


單純 Logistic 的交叉熵是凸的；線性可分且無正則化時，有限的最優參數未必存在。

Iris 案例：定義正類，才能解讀機率




教材以 *Iris virginica* 為正類；不是直接把花種編號當連續數字迴歸。

一個特徵的機率曲線與 0.5 決策界線



閾值改變會改變類別判定；模型的機率曲線本身未必改變。

兩個特徵的線性決策邊界



Logistic 對原始特徵的分數是線性的；加入非線性特徵後可得到彎曲邊界。

機率不是最後決策：比較兩個閾值

四筆真值為 $[1, 0, 1, 0]$ ，正類機率為 $[.8, .6, .4, .1]$ 。

1. 閾值 0.5 與 0.3 時，各算 TP、FP、FN、TN。
2. 需要減少漏報時會考慮哪個閾值？
3. 為什麼不能只看 accuracy？

休息 10 分鐘

離開座位、休息眼睛。回來後先用一句話回答上一段的核心問題。

Softmax：每一類先得到自己的分數

$$s_k(x) = \theta_k^T x, \quad \hat{p}_k = \frac{\exp(s_k)}{\sum_{j=1}^K \exp(s_j)}$$

$$\hat{y} = \arg \max_k \hat{p}_k = \arg \max_k s_k$$

適用於互斥類別；同一筆可同時多標籤時，改用各標籤的 Sigmoid。

穩定的 Softmax：先減掉最大分數

$$\hat{p}_k = \frac{e^{s_k - c}}{\sum_j e^{s_j - c}}, \quad c = \max_j s_j$$

分數 $[1000, 1001, 1002]$ 與 $[-2, -1, 0]$ 的 Softmax 相同。


直接計算大數的指數可能溢位；減常數不改變機率比。

多類別交叉熵：看正確類別拿到多少機率

$$J = -\frac{1}{m} \sum_i \sum_{k=1}^K y_k^{(i)} \log \hat{p}_k^{(i)}$$
$$\nabla_{\theta_k} J = \frac{1}{m} \sum_i (\hat{p}_k^{(i)} - y_k^{(i)}) x^{(i)}$$

one-hot 真值只有正確類別是 1；其他是 0。

Softmax 的三類決策區域



各區域選擇最高分數的類別；邊界上兩類分數相等，第三類仍可能更高。

用 Pipeline 選正則化強度

```
from sklearn.pipeline import make_pipeline
from sklearn.preprocessing import StandardScaler
from sklearn.linear_model import LogisticRegression
from sklearn.model_selection import GridSearchCV
pipe = make_pipeline(StandardScaler(),
                     LogisticRegression(max_iter=2000))
search = GridSearchCV(pipe, {"logisticregression__C":
                             [0.01, 0.1, 1, 10]}, cv=5)
search.fit(X_train, y_train)
```

把分數、機率、類別與評估分開

層次	輸出	回答的問題
分數	decision_function	相對偏向哪一類？
機率	predict_proba	模型估計的類別機率？
類別	predict 或自訂閾值	現在要採取什麼決策？
評估	log loss／混淆矩陣等	機率品質與決策效果如何？

綜合實作：三類分類的完整流程

使用已有的 Iris 或其他小型分類資料。

1. 固定一次訓練／測試切分。
2. 在 Pipeline 內標準化，用 CV 比較四個 C。
3. 提交最佳 C、CV 指標、測試混淆矩陣與兩筆機率。
4. 離線替代：手算分數 $[0, 1, 2]$ 的 Softmax 與類別 2 的損失。

離堂檢核：三個常見誤解

- 係數小，不等於特徵沒有因果作用。
- 驗證集用來選 C 或早停後，就不是最終測試集。
- Softmax 機率加總為 1，不表示機率已經校準。

課後：Ch.4 練習 7-12；比較同一資料上 Ridge、Lasso 與 Elastic Net 的係數。