

正則化與機率分類

第 5 週 | 控制模型複雜度，理解機率、損失與決策

後續八週課程 | 每週 180 分鐘（含兩次 10 分鐘休息）

本週任務與節奏

前 50 分：Ridge、Lasso、Elastic Net，含 13 分鐘比較與討論。

休息後 60 分：早停、Logistic、交叉熵梯度推導與手算。

第二次休息後 50 分：Softmax、多類別與選模實作。

成果：能說明正則化、推導 $\hat{p}_i - y_i$ 的來源，區分訓練與決策。


 **配套 Notebook**： `programs/notebooks/05_正則化與機率分類.ipynb`。程式片段、實際圖表與表格可由此檔重現。

程式實驗與實際輸出

```
for alpha in alphas:  
    Ridge(alpha=alpha).fit(X, y)
```

觀察：正則化強度改變係數大小；比較前要固定資料切分與特徵縮放流程。

參考程式：`programs/notebooks/05_正則化與機率分類.ipynb`



正則化：把參數大小也放入訓練目標

$$J(\theta) = \text{資料誤差} + \lambda \text{參數懲罰}$$

- 犧牲一點訓練擬合，限制不穩定的係數。
- 通常不懲罰截距；先縮放特徵，讓懲罰可比較。
- 強度由驗證集或交叉驗證選擇。

L1 與 L2 正則化


$$J(\mathbf{w}, b) = \frac{1}{m} \sum_{i=1}^m (\hat{y}_i - y_i)^2 + \lambda \Omega(\mathbf{w})$$

方法	懲罰項 $\Omega(\mathbf{w})$	常見效果
Ridge／L2	$\sum_j w_j^2$	縮小係數，通常不直接變為 0
Lasso／L1	$\sum_j w_j $	部分係數可能變為 0，形成稀疏解
Elastic Net	L1 與 L2 的加權組合	結合兩類限制

$\lambda \geq 0$ 是超參數。此處通常不懲罰截距 b 。

重複標記：本頁由第一週原頁移入，與本檔既有 Ridge／Lasso／Elastic Net 說明重複，待課程整理時決定刪除。

正則化的幾何直覺



- 藍色等高線表示不同損失。
- 黃色區域是允許的係數範圍。
- L2 的限制邊界是圓。
- L1 的限制邊界有位於座標軸的角點，較容易出現零係數。

重複標記：本頁由第一週原頁移入，與後面的 Ch.4 圖 4-20 幾何說明重複，待課程整理時決定刪除。


Ridge：平方懲罰讓係數平滑縮小

$$J_{\text{ridge}} = \text{MSE}(\boldsymbol{\theta}) + \frac{\alpha}{m} \sum_{j=1}^n \theta_j^2$$

$$\hat{\boldsymbol{\theta}} = (X^\top X + \alpha A)^{-1} X^\top \mathbf{y}, \quad A = \text{diag}(0, 1, \dots, 1)$$

$\alpha = 0$ 回到無正則化；越大通常縮得越多。

Ridge 的強度如何改變直線與曲線？




比較左右兩組圖：正則化既能約束原始線性係數，也能約束多項式係數。

Lasso：絕對值懲罰可以產生零係數

$$J_{\text{lasso}} = \text{MSE}(\boldsymbol{\theta}) + 2\alpha \sum_{j=1}^n |\theta_j|$$


可得到稀疏參數；但高度相關特徵間，選擇結果可能不穩定。

Lasso 在多項式模型中壓掉部分項



觀察模型變簡單的方式：可能使部分係數精確變成 0。

L1 與 L2 的幾何：角點與圓滑邊界



L1 邊界在座標軸有角點，較容易使最優解落在某些係數為零的位置。

零點不可微，仍可使用次梯度

$$g_j = \frac{\partial \text{MSE}}{\partial \theta_j} + 2\alpha s_j, \quad s_j \in \begin{cases} \{1\} & \theta_j > 0 \\ [-1, 1] & \theta_j = 0 \\ \{-1\} & \theta_j < 0 \end{cases}$$

在零點選 $s_j = 0$ 是合法代表；實際 Lasso 求解器也可用座標下降等方法。截距不加此項。

Elastic Net：同時限制 L1 與 L2

$$J = \text{MSE} + \lambda_1 \|\mathbf{w}\|_1 + \lambda_2 \|\mathbf{w}\|_2^2$$

λ_1 控制稀疏傾向， λ_2 提供平滑收縮。混合比例 r 越大，越偏向 Lasso。

同叫 alpha，目標函數尺度可能不同

教材式 4-13： $\text{MSE} + 2r\alpha\|\mathbf{w}\|_1 + \frac{(1-r)\alpha}{m}\|\mathbf{w}\|_2^2$ 。

scikit-learn ElasticNet： $\frac{\text{MSE}}{2} + \alpha r\|\mathbf{w}\|_1 + \frac{\alpha(1-r)}{2}\|\mathbf{w}\|_2^2$ 。

兩式的 L2 樣本數係數不同；實作與調參以使用的 API 目標為準，不能直接照搬同一個 α 。


Ridge、Lasso、Elastic Net 如何選？

方法	主要效果	先考慮的情境
Ridge	收縮，通常不產生零係數	多個特徵共同提供訊息
Lasso	稀疏化	需要少數特徵，並檢查穩定性
Elastic Net	L1 與 L2 混合	特徵相關、又想保留稀疏性

休息 10 分鐘

離開座位、休息眼睛。回來後先用一句話回答上一段的核心問題。

早停：保留驗證表現最好的參數



訓練誤差繼續下降，不代表泛化繼續改善；測試集不可用來決定停止點。

早停需要「監看、耐心、保存、回復」

1. 每個 epoch 記錄訓練損失與驗證指標。
2. 指標需超過最小改善量；連續若干次未改善才停止。
3. 保存最佳參數，最後回復最佳版本。

`deepcopy` 可保存已學參數；`clone` 主要複製估計器設定。

Logistic：先算分數，再轉成正類機率

沿用第 04 章： $\boldsymbol{\theta} = (b, w_1, \dots, w_n)^\top$ ， $\tilde{\mathbf{x}}_i = (1, x_{i1}, \dots, x_{in})^\top$ 。


$$z_i = b + \sum_{j=1}^n w_j x_{ij} = \tilde{\mathbf{x}}_i^\top \boldsymbol{\theta}, \quad \hat{p}_i = \sigma(z_i) = \frac{1}{1 + e^{-z_i}}$$

$$\hat{y}_i = \begin{cases} 1 & \hat{p}_i \geq t \\ 0 & \hat{p}_i < t \end{cases}$$

i 表示樣本， j 表示特徵。 $\hat{p}_i$ 是正類機率估計， t 是決策閾值。

接下來先推導**無正則化**的訓練損失，最後才用閾值判類別。

Sigmoid 把任意實數映射到 0 與 1 之間



$z = 0$ 對應 0.5；分數往正方向移動，正類估計機率上升。

Sigmoid 的導數：外層與內層分開算

$$\begin{aligned}\sigma'(z) &= \frac{d}{dz}(1 + e^{-z})^{-1} \\ &= -(1 + e^{-z})^{-2}(-e^{-z}) \\ &= \frac{e^{-z}}{(1 + e^{-z})^2} = \sigma(z)(1 - \sigma(z))\end{aligned}$$

所以 $\frac{\partial \hat{p}_i}{\partial z_i} = \hat{p}_i(1 - \hat{p}_i)$ 。

檢查： $z_i = 0$ 時， $\hat{p}_i = 0.5$ ，導數為 0.25。

Bernoulli 概似：真實類別得到多少機率？

對二元標籤 $y_i \in \{0, 1\}$ ：

$$P(y_i \mid \mathbf{x}_i; \boldsymbol{\theta}) = \hat{p}_i^{y_i} (1 - \hat{p}_i)^{1-y_i}$$

在樣本條件獨立的假設下，整份資料的概似為各筆相乘：

$$L(\boldsymbol{\theta}) = \prod_{i=1}^m \hat{p}_i^{y_i} (1 - \hat{p}_i)^{1-y_i}$$

最大化 L 等同最小化 $-\frac{1}{m} \ln L$ ；取對數可將乘積變成加總。

二元交叉熵：每筆損失與整體平均

$$\ell_i = -[y_i \ln \hat{p}_i + (1 - y_i) \ln(1 - \hat{p}_i)]$$

$$J(\boldsymbol{\theta}) = -\frac{1}{m} \ln L(\boldsymbol{\theta}) = \frac{1}{m} \sum_{i=1}^m \ell_i$$

真實標籤	每筆損失	答對且機率高時
$y_i = 1$	$-\ln \hat{p}_i$	$\hat{p}_i$ 接近 1，損失接近 0
$y_i = 0$	$-\ln(1 - \hat{p}_i)$	$\hat{p}_i$ 接近 0，損失接近 0

使用自然對數； $y_i = 1$ 時， $\hat{p}_i = 0.9$ 的損失約 0.105。

交叉熵先對預測機率微分

把 y_i 視為常數，分開微分兩個對數項：

$$\begin{aligned}\frac{\partial \ell_i}{\partial \hat{p}_i} &= -\frac{y_i}{\hat{p}_i} - (1 - y_i) \frac{-1}{1 - \hat{p}_i} \\ &= -\frac{y_i}{\hat{p}_i} + \frac{1 - y_i}{1 - \hat{p}_i} \\ &= \frac{\hat{p}_i - y_i}{\hat{p}_i(1 - \hat{p}_i)}\end{aligned}$$

第二項的內部函數 $1 - \hat{p}_i$ 微分會帶出負號。

連鎖律：機率梯度如何變成分數梯度？

$$\begin{aligned}\frac{\partial \ell_i}{\partial z_i} &= \frac{\partial \ell_i}{\partial \hat{p}_i} \frac{\partial \hat{p}_i}{\partial z_i} \\ &= \frac{\hat{p}_i - y_i}{\hat{p}_i(1 - \hat{p}_i)} \hat{p}_i(1 - \hat{p}_i) \\ &= \boxed{\hat{p}_i - y_i}\end{aligned}$$

這個化簡來自 **sigmoid 與二元交叉熵的組合**。

若 $y_i = 1$ 、 $\hat{p}_i < 1$ ，分數梯度為負，下降更新會傾向提高該筆分數。

Logistic 梯度：形式像殘差，但預測已轉機率

$$\frac{\partial \ell_i}{\partial w_j} = \frac{\partial \ell_i}{\partial z_i} \frac{\partial z_i}{\partial w_j} = (\hat{p}_i - y_i) x_{ij}$$
$$\frac{\partial J}{\partial b} = \frac{1}{m} \sum_i (\hat{p}_i - y_i), \quad \nabla_{\theta} J = \frac{1}{m} X^{\top} (\hat{\mathbf{p}} - \mathbf{y})$$

單純 Logistic 的交叉熵是凸的；線性可分且無正則化時，有限的最優參數未必存在。

梯度下降：同樣的更新規則，不同的損失

先用舊參數算 $\hat{\mathbf{p}}^{(k)} = \sigma(X\boldsymbol{\theta}^{(k)})$ ，再同步更新：

$$\boldsymbol{\theta}^{(k+1)} = \boldsymbol{\theta}^{(k)} - \eta \frac{1}{m} X^\top (\hat{\mathbf{p}}^{(k)} - \mathbf{y})$$

模型與訓練目標	梯度
線性迴歸搭配 MSE	$\frac{2}{m} X^\top (\hat{\mathbf{y}} - \mathbf{y})$
Logistic 搭配交叉熵	$\frac{1}{m} X^\top (\hat{\mathbf{p}} - \mathbf{y})$

以上皆未加正則化；閾值 t 不參與這兩個訓練梯度。

手算 Logistic 的第一次更新

$$X = \begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 0 \\ 1 \end{bmatrix}, \quad \boldsymbol{\theta}^{(0)} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

1. 算出分數、機率與 $\hat{\mathbf{p}}^{(0)} - \mathbf{y}$ 。
2. 使用 $\eta = 1$ ，求梯度與新參數。
3. 比較更新前後的平均交叉熵；再用 $t = 0.5$ 比較 accuracy。

提交：一組更新計算，以及「損失和 accuracy 是否一起改變」的說明。

手算解答：損失下降，accuracy 可以不變


$$\hat{\mathbf{p}}^{(0)} - \mathbf{y} = \begin{bmatrix} 0.5 \\ -0.5 \end{bmatrix}, \quad \nabla J = \frac{1}{2} \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 0.5 \\ -0.5 \end{bmatrix} = \begin{bmatrix} 0 \\ -0.25 \end{bmatrix}$$

$$\boldsymbol{\theta}^{(1)} = \begin{bmatrix} 0 \\ 0.25 \end{bmatrix}, \quad \hat{\mathbf{p}}^{(1)} = \begin{bmatrix} 0.5 \\ \sigma(0.25) \end{bmatrix} \approx \begin{bmatrix} 0.5 \\ 0.56218 \end{bmatrix}$$

$$J^{(0)} = \ln 2 \approx 0.69315, \quad J^{(1)} = \frac{\ln 2 + \ln(1 + e^{-0.25})}{2} \approx 0.63454$$


$t = 0.5$ 時，兩次皆預測 $(1, 1)^\top$ ，accuracy 都是 50%。

Iris 案例：定義正類，才能解讀機率




教材以 *Iris virginica* 為正類；不是直接把花種編號當連續數字迴歸。

一個特徵的機率曲線與 0.5 決策界線



閾值改變會改變類別判定；模型的機率曲線本身未必改變。

兩個特徵的線性決策邊界



Logistic 對原始特徵的分數是線性的；加入非線性特徵後可得到彎曲邊界。

機率不是最後決策：比較兩個閾值

四筆真值為 $[1, 0, 1, 0]$ ，正類機率為 $[.8, .6, .4, .1]$ 。

1. 閾值 0.5 與 0.3 時，各算 TP、FP、FN、TN。
2. 需要減少漏報時會考慮哪個閾值？
3. 為什麼不能只看 accuracy？

休息 10 分鐘

離開座位、休息眼睛。回來後先用一句話回答上一段的核心問題。

Softmax：每一類先得到自己的分數

$$z_{ic} = \tilde{\mathbf{x}}_i^\top \boldsymbol{\theta}_c, \quad \hat{p}_{ic} = \frac{\exp(z_{ic})}{\sum_{r=1}^K \exp(z_{ir})}$$
$$\hat{y}_i = \arg \max_c \hat{p}_{ic} = \arg \max_c z_{ic}$$

$c = 1, \dots, K$ 表示類別；每個類別各有一組參數 $\boldsymbol{\theta}_c$ 。

適用於互斥類別；同一筆可同時多標籤時，改用各標籤的 Sigmoid。

穩定的 Softmax：先減掉最大分數

$$\hat{p}_{ic} = \frac{e^{z_{ic} - a_i}}{\sum_{r=1}^K e^{z_{ir} - a_i}}, \quad a_i = \max_r z_{ir}$$

分數 $[1000, 1001, 1002]$ 與 $[-2, -1, 0]$ 的 Softmax 相同。


直接計算大數的指數可能溢位；減常數不改變機率比。

多類別交叉熵：看正確類別拿到多少機率

$$J = -\frac{1}{m} \sum_{i=1}^m \sum_{c=1}^K y_{ic} \ln \hat{p}_{ic}$$
$$\nabla_{\theta_c} J = \frac{1}{m} \sum_{i=1}^m (\hat{p}_{ic} - y_{ic}) \tilde{\mathbf{x}}_i$$

one-hot 真值只有正確類別是 1；其他是 0。

Softmax 的三類決策區域



各區域選擇最高分數的類別；邊界上兩類分數相等，第三類仍可能更高。

用 Pipeline 選正則化強度

```
from sklearn.pipeline import make_pipeline
from sklearn.preprocessing import StandardScaler
from sklearn.linear_model import LogisticRegression
from sklearn.model_selection import GridSearchCV
pipe = make_pipeline(StandardScaler(),
                     LogisticRegression(max_iter=2000))
search = GridSearchCV(pipe, {"logisticregression__C":
                             [0.01, 0.1, 1, 10]}, cv=5)
search.fit(X_train, y_train)
```

把分數、機率、類別與評估分開

層次	輸出	回答的問題
分數	decision_function	相對偏向哪一類？
機率	predict_proba	模型估計的類別機率？
類別	predict 或自訂閾值	現在要採取什麼決策？
評估	log loss／混淆矩陣等	機率品質與決策效果如何？

綜合實作：三類分類的完整流程

使用已有的 Iris 或其他小型分類資料。

1. 固定一次訓練／測試切分。
2. 在 Pipeline 內標準化，用 CV 比較四個 C。
3. 提交最佳 C、CV 指標、測試混淆矩陣與兩筆機率。
4. 離線替代：手算分數 $[0, 1, 2]$ 的 Softmax 與類別 2 的損失。

離堂檢核：梯度、決策與泛化

- 係數小，不等於特徵沒有因果作用。
- 驗證集用來選 C 或早停後，就不是最終測試集。
- Softmax 機率加總為 1，不表示機率已經校準。
- 交叉熵下降，accuracy 不一定同時上升。

課後：Ch.4 練習 7-12；比較同一資料上 Ridge、Lasso 與 Elastic Net 的係數。

Notebook 導讀：懲罰、早停與評估範圍

實驗	要檢查的證據
Ridge／Lasso 與幾何	同資料改 α ；範數限制與預測曲線分開讀
早停	訓練／驗證曲線、最佳 epoch、還原後損失
Sigmoid 與交叉熵	解析梯度＝中心差分；兩筆例子的 loss 下降
Iris 邊界／Softmax	全資料圖只說明幾何；正式成效另做 CV／test

手算懲罰： $(2, 0)$ 與 $(1, 1)$ 的 L1 都是 2；L2 平方分別為 4、2。

早停與調 C 都使用驗證資訊，驗證集不能再當最終測試集。