

決策樹與SVM補充

第 6 週 | 從可解釋的分割規則，走到模型邊界比較

學習重點與成果

- 走訪決策樹、機率與不純度。
- CART、正則化與迴歸樹。
- 穩定性、SVM 補充與模型比較。

能交付：一條預測路徑、一個分割計算，以及有理由的模型選擇。


 **配套 Notebook**： `programs/notebooks/06_決策樹與SVM補充.ipynb` 。程式片段、實際圖表與表格可由此檔重現。

程式實驗與實際輸出


```
DecisionTreeClassifier(max_depth=depth,  
                        random_state=42).fit(X, y)
```

觀察：限制樹深會平滑決策邊界；是否改善泛化仍要看驗證結果。

參考程式：[programs/notebooks/06_決策樹與SVM補充.ipynb](#)



從根節點走到葉節點：Iris 決策樹




每次只回答一個特徵閾值問題；最終葉節點提供類別分布。

讀懂節點上的四種資訊

- 規則：例如花瓣長度是否小於等於 2.45 cm。
- `samples`：到達此節點的訓練樣本數。
- `value`：各類別的計數或比例，依顯示工具而異。
- `gini`：混雜程度；0 表示節點內只有一類。

樹把空間切成一塊一塊的區域



第一次分割作用於全區域；後續分割只作用於相應子區域。

葉節點的機率來自到達此處的樣本

若葉節點有 $[0, 49, 5]$ 共 54 筆，則

$$\hat{p} = (0, 49/54, 5/54) \approx (0, .907, .093)$$

輸出最多的類別；機率是區域內的訓練頻率估計，並非個體的確定性。

特徵型態與樹的資料準備

特徵型態	分割方式與準備
連續值	比較數值閾值；通常不需標準化
有序類別	編碼須保留原有順序，例如低、中、高
無序類別	通常先 one-hot；任意整數大小會引入假順序

scikit-learn 的一般決策樹不直接分割字串類別。部分設定支援缺失值，需確認模型與設定。

Gini：隨機抽兩個標籤會多常不同？

$$G_i = 1 - \sum_{k=1}^K p_{i,k}^2$$

二元節點各一半時 $G = 0.5$ ；單一類別時 $G = 0$ 。

三類均等時 $G = 2/3$ ，因此 Gini 的最大值不固定為 0.5。

Entropy：標籤越難猜，資訊量越大

$$H_i = - \sum_{k:p_{i,k}>0} p_{i,k} \log_2 p_{i,k}$$

約定 $0 \log 0 = 0$ 。二元各一半時是 1 bit；單一類別是 0。

Gini 與 Entropy 常給出相近分割，但不保證完全相同。

手算：哪個節點比較純？

A 節點標籤數 $[4, 0]$ ，B 為 $[2, 2]$ ，C 為 $[3, 1]$ 。

1. 各算 Gini 與 Entropy。
2. 用一句話解釋「純度」與「預測是否正確」的差別。

建立一棵可閱讀的樹

```
from sklearn.tree import DecisionTreeClassifier, export_text
tree = DecisionTreeClassifier(max_depth=2, random_state=42)
tree.fit(X_train, y_train)
print(export_text(tree, feature_names=feature_names))
proba = tree.predict_proba(X_test[:2])
```

先限制深度方便閱讀；正式選擇仍要比較驗證表現。

分割計算：加權不純度

母節點有 8 正例、8 負例，Gini 不純度為 $1 - (8/16)^2 - (8/16)^2 = 0.5$ 。

若切成左節點 (6, 2)、右節點 (2, 6)：

- 每個子節點 Gini 都是 $1 - (6/8)^2 - (2/8)^2 = 0.375$ 。
- 加權子節點不純度是 $(8/16)0.375 + (8/16)0.375 = 0.375$ 。
- 不純度下降 $0.5 - 0.375 = 0.125$ ；要與其他候選切點比較，不能只看單側。

CART：挑選加權子節點不純度最小的分割

$$J(k, t_k) = \frac{m_L}{m} G_L + \frac{m_R}{m} G_R$$

在候選特徵 k 與閾值 t_k 中選最小值，再遞迴處理子節點。

這是貪婪的二元分割；每步最佳不代表整棵樹全域最佳。

資訊增益與決策樹演算法

$$IG = H(\text{父}) - \sum_c \frac{m_c}{m} H(c)$$

演算法	典型分割準則	需分清楚
ID3	資訊增益	偏好取值很多的屬性
C4.5	增益比，校正分支資訊量	擴充 ID3，能處理連續屬性
CART	分類不純度或迴歸誤差	二元分割；不等於只准用 Gini

`criterion="entropy"` 仍是 sklearn 的 CART 型二元樹，不會變成 ID3。

訓練成本與預測成本

- 平衡樹深度約為 $\log_2 m$ ，單筆預測約比較這麼多次。
 - 教材估計訓練成本約 $O(nm \log m)$ ， m 為樣本數、 n 為特徵數。
 - 若樹極不平衡，預測需走過實際深度，不能一律套用對數時間。
- 一百萬筆資料的平衡樹約深 20 層；限制深度與候選特徵也能減少成本。

選讀 | 手刻決策樹的遞迴流程

1. 檢查停止條件：標籤已純、到達深度上限或樣本太少。
2. 枚舉候選特徵與閾值，計算左右節點的加權不純度。
3. 保存最佳分割，分別對左右子集呼叫同一訓練程序。
4. 葉節點保存類別統計；預測時依規則逐層走訪。

可追讀 `03_Decision_Tree_from_scratch.py` 的 `fit`、`find_best_split`、`_get_prediction`，對照圖 5-1。

算一次分割，不能只比較左右平均

父節點有 $[4, 4]$ ，共 8 筆。

方案 A：左 $[3, 0]$ ，右 $[1, 4]$ 。

方案 B：左 $[2, 2]$ ，右 $[2, 2]$ 。

計算兩方案加權 Gini 與相對父節點的下降量。

選讀 | 80 筆資料的分割比較

父節點 [40,40] 。A 分成 [30,10] 、 [10,30] ； B 分成 [20,40] 、 [20,0] 。

指標	A	B
加權 Gini	0.375	0.3333
加權 Entropy	0.8113	0.6887
資訊增益	0.1887	0.3113

兩種準則都偏好 B 。 B 的左右權重為 60/80 、 20/80 ，不能各取一半 。

限制樹的成長：先控制葉節點有多少證據


參數	作用	加強正則化的方向
max_depth	最大深度	調小
min_samples_split	允許分割的最少樣本數	調大
min_samples_leaf	葉節點最少樣本數	調大
max_leaf_nodes	葉節點數上限	調小

其他停止條件與剪枝

設定	控制的內容
min_weight_fraction_leaf	葉節點最少權重占比
min_impurity_decrease	分割帶來的最小加權不純度下降
max_features	每次候選特徵數
ccp_alpha	後剪枝的成本複雜度強度；越大通常樹越小

預剪枝在生長時停止分割；後剪枝先長樹再移除子樹。兩者都要由訓練集內的驗證選擇。

正則化前後：彎月資料的邊界



增加葉節點最少樣本數，可以減少為個別樣本切出的細碎區域。


迴歸樹：葉節點改成輸出數值平均

$$\hat{y}_{\text{node}} = \frac{1}{m_{\text{node}}} \sum_{i \in \text{node}} y^{(i)}$$

在平方誤差目標下，葉內平均值最小化該葉的總平方殘差。

輸出通常是分段常數；不會自然外插出向上延伸的直線。

讀迴歸樹：追蹤規則與葉內平均




每個葉節點顯示預測平均值及其平方誤差；不再顯示類別 Gini。

CART 迴歸目標：比較子節點的加權 MSE


$$J(k, t_k) = \frac{m_L}{m} \text{MSE}_L + \frac{m_R}{m} \text{MSE}_R$$
$$\text{MSE}_{\text{node}} = \frac{1}{m_{\text{node}}} \sum_{i \in \text{node}} (y^{(i)} - \hat{y}_{\text{node}})^2$$

增加深度：階梯更細，表達能力更強



深度增加可降低訓練誤差，也可能開始追逐雜訊。

迴歸樹也需要正則化



限制最小葉樣本數，能減少尖銳、短促的階梯。

迴歸葉節點：為什麼預測平均值？

同一葉中的目標是 `[1, 2, 6]`。

比較預測 2、3、4 的 MSE，找出最佳值。

再討論：如果損失改成絕對誤差，最佳常數會改成什麼？


迴歸樹的葉節點為何用平均值？

葉節點含目標值 2, 4, 9，若以常數 c 預測並最小化平方誤差：

$$L(c) = (2 - c)^2 + (4 - c)^2 + (9 - c)^2$$


令導數 $L'(c) = 6c - 30 = 0$ ，得 $c = 5$ 。平均值最小化葉內平方誤差；若改用絕對誤差，最佳常數通常是中位數 4。

座標軸方向會影響樹的複雜度



樹的分割通常平行於特徵軸；旋轉資料後，原本簡單的斜線可能需很多階梯。

PCA 旋轉後，樹可能更容易分割



縮放與旋轉不同：單調縮放通常保持排序，旋轉會改變分割方向。

相同資料重訓，也可能得到不同的樹




圖 5-9 使用相同資料重訓，隨機選擇可能改變規則；資料小幅變動也會放大差異。
固定 `random_state` 有助重現；下一週以多棵不同的樹降低變異。

補充 SVM：用間隔比較不同的分隔面

$$f(x) = w^T x + b, \quad \hat{y} = \text{sign}(f(x))$$

線性可分時，將邊界兩側最近點的函數間隔規範為 ± 1 ，兩條支持超平面距離為 $2/\|w\|$ 。

補充 SVM：軟間隔與 hinge loss

$$\min_{w,b} \frac{1}{2} \|w\|^2 + C \sum_i \max(0, 1 - y^{(i)} f(x^{(i)}))$$

C 越大，越重視違反間隔的代價；越小，越容許違反以換取較大間隔。

特徵尺度會改變距離與懲罰，通常要先標準化。

補充 SVM：分對仍可能有損失

令 $u = yf(x)$ ，hinge loss 為 $\max(0, 1 - u)$ ，標籤 $y \in \{-1, +1\}$ 。

u	預測與位置	損失
1.5	分對且超過間隔	0
0.4	分對但位於間隔內	0.6
-0.5	分錯	1.5

軟間隔以鬆弛變數 $\xi_i \geq 0$ 表示違反程度： $y_i f(x_i) \geq 1 - \xi_i$ 。

補充 SVM：原始問題與對偶的關係

硬間隔： $\min \frac{1}{2} \|w\|^2$ ，限制 $y_i(w^T x_i + b) \geq 1$ 。

對偶： $\max_a \sum_i a_i - \frac{1}{2} \sum_{i,j} a_i a_j y_i y_j K(x_i, x_j)$ 。

限制 $a_i \geq 0$, $\sum_i a_i y_i = 0$ ；軟間隔再加 $a_i \leq C$ 。

線性模型先用 $K(x_i, x_j) = x_i^T x_j$ ；後面再以核函數替換內積。支持向量對應非零對偶係數。

選讀 | SVM 對偶如何得到預測函數

$$w = \sum_i a_i y_i x_i, \quad f(x) = \sum_i a_i y_i K(x_i, x) + b$$

由拉格朗日函數對 w, b 的一階條件，得到第一式與 $\sum_i a_i y_i = 0$ 。

只有非零 a_i 的支持向量參與預測；核技巧就在這個內積位置代入 K 。

軟間隔中， $0 < a_i < C$ 的點位於間隔邊界，可用來求 $b = y_i - \sum_j a_j y_j K(x_j, x_i)$ 。

補充 SVM：核函數與 RBF 的 gamma

$$K(x, z) = \phi(x)^T \phi(z), \quad K_{\text{RBF}}(x, z) = e^{-\gamma \|x - z\|^2}$$

核技巧以相似度取代顯式高維展開。γ 越大，單點影響越局部，邊界可能更細碎。

補充 SVM：多項式特徵與核技巧

對二維輸入，令 $\phi(x) = (x_1^2, \sqrt{2}x_1x_2, x_2^2)$ ，則

$$\phi(x)^T \phi(z) = (x^T z)^2$$

$(1, 1)$ 轉成 $(1, \sqrt{2}, 1)$ 。XOR 可用 $x_1^2 + x_2^2 - 2x_1x_2 = 0.5$ 分隔。

- 顯式展開： `PolynomialFeatures` 後接 `LinearSVC`。
- 核方法： `SVC(kernel="poly")`，直接算相似度。

展開方式、縮放與懲罰不同時，兩段程式不保證得到相同模型。

補充 SVM：多類別與模型比較

策略	K 類需訓練的二元模型數	整合方式
OvR，一對其餘	K	比較各類分數
OvO，一對一	$K(K - 1)/2$	成對比較後投票

SVC 採 OvO 訓練；`decision_function_shape="ovr"` 是分數輸出格式。

SVM 與 Logistic 都可能受離群點影響，須比較縮放、正則化與驗證結果。

選讀 | SVM 的次梯度與核參數實驗

$$J = \frac{\lambda}{2} \|w\|^2 + \frac{1}{m} \sum_i \max(0, 1 - y_i f_i)$$

$$\nabla_w J = \lambda w - \frac{1}{m} \sum_{y_i f_i < 1} y_i x_i, \quad \partial_b J = -\frac{1}{m} \sum_{y_i f_i < 1} y_i$$

在折內標準化後，比較 `SVC(C=c, gamma=g)` 的 `c=[0.1,1,10]`、`g=[0.1,1,10]`。核的 `degree` 屬於 `SVC` 或 `PolynomialFeatures`，不是 `LinearSVC` 的參數。

三種分類模型的比較

模型	典型邊界	重要檢查
Logistic	線性分數＋機率	正則化、校準、閾值
SVM（補充）	線性或核邊界	縮放、C、gamma；分數不等於機率
決策樹	軸平行分區	深度、葉樣本數、穩定性

比較實作：同一切分，兩種模型

使用同一份訓練與測試資料。

1. CV 比較樹深度 [2,4,8,None] 。
2. 比較標準化 Logistic；八週版再加入標準化 SVM 。
3. 除指標外，報告模型規則、錯誤案例與訓練時間。
4. 離線：解釋斜向邊界為何可能讓淺樹吃虧。

離堂檢核與作業

1. CART 為何要依樣本數加權？
2. 為什麼葉節點很純，仍可能測試表現差？
3. 哪一種資料改動可能明顯改變樹的規則？

課後：Ch.5 練習 1-7；進階以多個抽樣子集比較樹的穩定性。

Notebook 導讀：樹的幾何與 SVM 驗算

內容	可執行的檢查
CART	枚舉閾值、加權 Gini、遞迴停止及走訪預測
迴歸樹	節點平均、階梯曲線與葉樣本限制
旋轉／PCA	比較座標與邊界；PCA 不保證使樹更簡單
SVM	支持向量核加權 = decision_function；hinge 次梯度

幾何示意可使用全部訓練樣本；模型比較使用同一切分與 CV。
固定示範設定的 test 數字不能拿來反覆選最佳深度或 gamma。