

決策樹與支援向量機

第 6 週 | 從可解釋的分割規則，走到最大間隔與非線性核方法


學習重點與成果

- 走訪決策樹、機率與不純度。
- CART、正則化與迴歸樹。
- 決策樹的穩定性與模型比較。
- SVM 的最大間隔、軟間隔、對偶問題與核方法。

能交付：一條預測路徑、一個分割計算，以及有理由的模型選擇。

 **配套 Notebook**： `programs/notebooks/06_決策樹與SVM補充.ipynb` 。程式片段、實際圖表與表格可由此檔重現。

從根節點走到葉節點：Iris 決策樹




每次只回答一個特徵閾值問題；最終葉節點提供類別分布。

讀懂節點上的四種資訊

- 規則：例如花瓣長度是否小於等於 2.45 cm。
- `samples`：到達此節點的訓練樣本數。
- `value`：各類別的計數或比例，依顯示工具而異。
- `gini`：混雜程度；0 表示節點內只有一類。

樹把空間切成一塊一塊的區域



第一次分割作用於全區域；後續分割只作用於相應子區域。

葉節點的機率來自到達此處的樣本

若葉節點有 $[0, 49, 5]$ 共 54 筆，則

$$\hat{p} = (0, 49/54, 5/54) \approx (0, .907, .093)$$

輸出最多的類別；機率是區域內的訓練頻率估計，並非個體的確定性。

特徵型態與樹的資料準備

特徵型態	分割方式與準備
連續值	比較數值閾值；通常不需標準化
有序類別	編碼須保留原有順序，例如低、中、高
無序類別	通常先 one-hot；任意整數大小會引入假順序

scikit-learn 的一般決策樹不直接分割字串類別。部分設定支援缺失值，需確認模型與設定。

Gini：隨機抽兩個標籤會多常不同？

$$G_i = 1 - \sum_{k=1}^K p_{i,k}^2$$

二元節點各一半時 $G = 0.5$ ；單一類別時 $G = 0$ 。

三類均等時 $G = 2/3$ ，因此 Gini 的最大值不固定為 0.5。

Entropy：標籤越難猜，資訊量越大

$$H_i = - \sum_{k:p_{i,k}>0} p_{i,k} \log_2 p_{i,k}$$

約定 $0 \log 0 = 0$ 。二元各一半時是 1 bit；單一類別是 0。

Gini 與 Entropy 常給出相近分割，但不保證完全相同。

手算：哪個節點比較純？

A 節點標籤數 $[4, 0]$ ，B 為 $[2, 2]$ ，C 為 $[3, 1]$ 。

1. 各算 Gini 與 Entropy。
2. 用一句話解釋「純度」與「預測是否正確」的差別。

建立一棵可閱讀的樹

```
from sklearn.tree import DecisionTreeClassifier, export_text
tree = DecisionTreeClassifier(max_depth=2, random_state=42)
tree.fit(X_train, y_train)
print(export_text(tree, feature_names=feature_names))
proba = tree.predict_proba(X_test[:2])
```

先限制深度方便閱讀；正式選擇仍要比較驗證表現。

分割計算：加權不純度

母節點有 8 正例、8 負例，Gini 不純度為 $1 - (8/16)^2 - (8/16)^2 = 0.5$ 。

若切成左節點 (6, 2)、右節點 (2, 6)：

- 每個子節點 Gini 都是 $1 - (6/8)^2 - (2/8)^2 = 0.375$ 。
- 加權子節點不純度是 $(8/16)0.375 + (8/16)0.375 = 0.375$ 。
- 不純度下降 $0.5 - 0.375 = 0.125$ ；要與其他候選切點比較，不能只看單側。

CART：挑選加權子節點不純度最小的分割

$$J(k, t_k) = \frac{m_L}{m} G_L + \frac{m_R}{m} G_R$$

在候選特徵 k 與閾值 t_k 中選最小值，再遞迴處理子節點。

這是貪婪的二元分割；每步最佳不代表整棵樹全域最佳。

資訊增益與決策樹演算法

$$IG = H(\text{父}) - \sum_c \frac{m_c}{m} H(c)$$

演算法	典型分割準則	需分清楚
ID3	資訊增益	偏好取值很多的屬性
C4.5	增益比，校正分支資訊量	擴充 ID3，能處理連續屬性
CART	分類不純度或迴歸誤差	二元分割；不等於只准用 Gini

`criterion="entropy"` 仍是 sklearn 的 CART 型二元樹，不會變成 ID3。

訓練成本與預測成本

- 平衡樹深度約為 $\log_2 m$ ，單筆預測約比較這麼多次。
 - 教材估計訓練成本約 $O(nm \log m)$ ， m 為樣本數、 n 為特徵數。
 - 若樹極不平衡，預測需走過實際深度，不能一律套用對數時間。
- 一百萬筆資料的平衡樹約深 20 層；限制深度與候選特徵也能減少成本。

選讀 | 手刻決策樹的遞迴流程

1. 檢查停止條件：標籤已純、到達深度上限或樣本太少。
2. 枚舉候選特徵與閾值，計算左右節點的加權不純度。
3. 保存最佳分割，分別對左右子集呼叫同一訓練程序。
4. 葉節點保存類別統計；預測時依規則逐層走訪。

可追讀 `03_Decision_Tree_from_scratch.py` 的 `fit`、`find_best_split`、`_get_prediction`，對照圖 5-1。

算一次分割，不能只比較左右平均

父節點有 $[4, 4]$ ，共 8 筆。

方案 A：左 $[3, 0]$ ，右 $[1, 4]$ 。

方案 B：左 $[2, 2]$ ，右 $[2, 2]$ 。

計算兩方案加權 Gini 與相對父節點的下降量。

選讀 | 80 筆資料的分割比較

父節點 [40,40] 。A 分成 [30,10] 、 [10,30] ；B 分成 [20,40] 、 [20,0] 。

指標	A	B
加權 Gini	0.375	0.3333
加權 Entropy	0.8113	0.6887
資訊增益	0.1887	0.3113

兩種準則都偏好 B 。B 的左右權重為 60/80 、 20/80 ，不能各取一半 。

限制樹的成長：先控制葉節點有多少證據

參數	作用	加強正則化的方向
max_depth	最大深度	調小
min_samples_split	允許分割的最少樣本數	調大
min_samples_leaf	葉節點最少樣本數	調大
max_leaf_nodes	葉節點數上限	調小


其他停止條件與剪枝

設定	控制的內容
min_weight_fraction_leaf	葉節點最少權重占比
min_impurity_decrease	分割帶來的最小加權不純度下降
max_features	每次候選特徵數
ccp_alpha	後剪枝的成本複雜度強度；越大通常樹越小

預剪枝在生長時停止分割；後剪枝先長樹再移除子樹。兩者都要由訓練集內的驗證選擇。


先預測：增加 `min_samples_leaf` 後，細碎區域與訓練 accuracy 會怎麼變？測試 accuracy 是否一定提高？

比較葉節點限制前後的彎月邊界



教材圖：增加葉節點最少樣本數，減少細碎區域。

Notebook 圖：同一切分，比較無限制與 `min_samples_leaf=20`。



點與背景色分別表示訓練標籤與模型預測；兩軸是合成特徵。限制後訓練 accuracy 較低，本次測試 accuracy 較高，不能只憑邊界較簡單宣稱泛化改善。

參考程式：`programs/notebooks/06_決策樹與SVM補充.ipynb`


迴歸樹：葉節點改成輸出數值平均

$$\hat{y}_{\text{node}} = \frac{1}{m_{\text{node}}} \sum_{i \in \text{node}} y^{(i)}$$

在平方誤差目標下，葉內平均值最小化該葉的總平方殘差。

輸出通常是分段常數；不會自然外插出向上延伸的直線。

讀迴歸樹：追蹤規則與葉內平均




每個葉節點顯示預測平均值及其平方誤差；不再顯示類別 Gini。

CART 迴歸目標：比較子節點的加權 MSE


$$J(k, t_k) = \frac{m_L}{m} \text{MSE}_L + \frac{m_R}{m} \text{MSE}_R$$
$$\text{MSE}_{\text{node}} = \frac{1}{m_{\text{node}}} \sum_{i \in \text{node}} (y^{(i)} - \hat{y}_{\text{node}})^2$$

增加深度：階梯更細，表達能力更強



深度增加可降低訓練誤差，也可能開始追逐雜訊。

迴歸樹也需要正則化



限制最小葉樣本數，能減少尖銳、短促的階梯。

迴歸葉節點：為什麼預測平均值？

同一葉中的目標是 $[1, 2, 6]$ 。

比較預測 2、3、4 的 MSE，找出最佳值。

再討論：如果損失改成絕對誤差，最佳常數會改成什麼？


迴歸樹的葉節點為何用平均值？

葉節點含目標值 2, 4, 9，若以常數 c 預測並最小化平方誤差：

$$L(c) = (2 - c)^2 + (4 - c)^2 + (9 - c)^2$$


令導數 $L'(c) = 6c - 30 = 0$ ，得 $c = 5$ 。平均值最小化葉內平方誤差；若改用絕對誤差，最佳常數通常是中位數 4。

座標軸方向會影響樹的複雜度



樹的分割通常平行於特徵軸；旋轉資料後，原本簡單的斜線可能需很多階梯。

PCA 旋轉後，樹可能更容易分割



縮放與旋轉不同：單調縮放通常保持排序，旋轉會改變分割方向。

相同資料重訓，也可能得到不同的樹




圖 5-9 使用相同資料重訓，隨機選擇可能改變規則；資料小幅變動也會放大差異。
固定 `random_state` 有助重現；下一週以多棵不同的樹降低變異。

第二部分：支援向量機

SVM 是本週的正式教材。學習路徑由幾何直覺進入最佳化，再延伸至非線性核方法。

1. 超平面、距離與最大間隔。
2. 軟間隔、hinge loss 與懲罰權重 C 。
3. 對偶問題、支持向量與核函數。

超平面與特徵空間

輸入 $x \in \mathbb{R}^d$ ，線性分類邊界為

$$\mathcal{P} = \{x : w^T x + b = 0\}, \quad \hat{y} = \text{sign}(w^T x + b)$$

- w 是超平面的法向量。
- $d = 2$ 時邊界是直線， $d = 3$ 時是平面， $d > 3$ 時稱為超平面。
- 核 SVM 把 x 映射為 $\phi(x)$ ，再於高維或無限維特徵空間尋找超平面。

hyperplane 是邊界，feature space 是映射後的空間。「hyper space」不是本單元的標準術語。

函數間隔與幾何間隔

對標籤 $y_i \in \{-1, +1\}$ 與分數 $f(x) = w^T x + b$:

$$\text{函數間隔} = y_i f(x_i), \quad \text{幾何間隔} = \frac{y_i f(x_i)}{\|w\|}$$

點 x 到決策邊界的距離為

$$\text{dist}(x, \mathcal{P}) = \frac{|w^T x + b|}{\|w\|}$$

同時將 (w, b) 乘上正常數不會改變邊界，卻會改變函數間隔。除以 $\|w\|$ 後才得到不受縮放影響的幾何距離。

硬間隔 SVM 的目標函數

線性可分時，將最近點規範為 $y_i f(x_i) = 1$ ：

$$\min_{w,b} \frac{1}{2} \|w\|^2 \quad \text{subject to} \quad y_i(w^T x_i + b) \geq 1$$

兩條間隔邊界是 $w^T x + b = +1$ 與 -1 ，它們之間的寬度為

$$\frac{2}{\|w\|}$$

因此最小化 $\|w\|^2$ 等價於最大化間隔。達到等式的訓練點是支持向量。

軟間隔：允許可控制的違規

$$\min_{w,b,\xi} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^m \xi_i$$

$$\text{subject to } y_i(w^T \phi(x_i) + b) \geq 1 - \xi_i, \quad \xi_i \geq 0$$

ξ_i 記錄第 i 點跨入間隔或跨過決策邊界的程度。 C 權衡間隔寬度與違規懲罰。

消去 ξ_i 後，目標可寫成 hinge loss 形式：

$$\min_{w,b} \frac{1}{2} \|w\|^2 + C \sum_i \max(0, 1 - y_i f(x_i))$$

懲罰權重 C 如何改變模型

C	正則化力量	間隔與違規	常見風險
小	強	傾向較寬間隔，容許較多違規	過度平滑、欠擬合
大	弱	更重視單點懲罰，傾向縮窄間隔	邊界對雜訊敏感、過擬合

- C 是全局懲罰尺度，不是單純的「準確率旋鈕」。
- `class_weight` 改變各類別的相對懲罰，`sample_weight` 可改變單筆樣本的相對懲罰。
- 特徵尺度會改變距離與 $\|w\|$ ，SVM 通常要在 Pipeline 內標準化。

Hinge loss：分對仍可能有損失

令 $u = yf(x)$ ，hinge loss 為 $\ell(u) = \max(0, 1 - u)$ 。

u	預測與位置	$\ell(u)$	ξ
1.5	分對且超過間隔	0	0
1.0	位於間隔邊界	0	0
0.4	分對但位於間隔內	0.6	0.6
0	位於決策邊界	1	1
-0.5	分錯	1.5	1.5

分類錯誤只看 $u < 0$ ，hinge 還懲罰 $0 < u < 1$ 的「分對但不夠安全」樣本。

從原始問題建立拉格朗日函數

令 $\phi_i = \phi(x_i)$ ，並對軟間隔的兩組限制引入 $\alpha_i \geq 0$ 與 $\mu_i \geq 0$ ：

$$\begin{aligned} L(w, b, \xi, \alpha, \mu) = & \frac{1}{2} \|w\|^2 + C \sum_i \xi_i \\ & - \sum_i \alpha_i [y_i(w^T \phi_i + b) - 1 + \xi_i] - \sum_i \mu_i \xi_i \end{aligned}$$

原始問題對 (w, b, ξ) 最小化。對偶問題改為對 (α, μ) 最大化可保證的下界。

一階條件消去 w 、 b 與 ξ

$$\frac{\partial L}{\partial w} = 0 \quad \Rightarrow \quad w = \sum_i \alpha_i y_i \phi(x_i)$$

$$\frac{\partial L}{\partial b} = 0 \quad \Rightarrow \quad \sum_i \alpha_i y_i = 0$$

$$\frac{\partial L}{\partial \xi_i} = 0 \quad \Rightarrow \quad C - \alpha_i - \mu_i = 0 \quad \Rightarrow \quad 0 \leq \alpha_i \leq C$$

最後一個上界是軟間隔與硬間隔對偶問題的關鍵差異。

SVM 的對偶問題

$$\begin{aligned} \max_{\alpha} \quad & \sum_i \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j K(x_i, x_j) \\ \text{subject to} \quad & 0 \leq \alpha_i \leq C, \quad \sum_i \alpha_i y_i = 0 \end{aligned}$$

對偶二次項矩陣 Q 的元素為 $Q_{ij} = y_i y_j K(x_i, x_j)$ 。對偶目標只通過內積比較樣本，所以可將 $\phi(x_i)^T \phi(x_j)$ 直接替換為 $K(x_i, x_j)$ ，不必顯式建立高維特徵。

KKT 條件解釋哪些點會支撐邊界

α_i	典型位置	對預測的影響
0	間隔外， $y_i f_i > 1$	不出現在核展開中
$0 < \alpha_i < C$	間隔邊界， $y_i f_i = 1$	支持向量，可用來求 b
$\alpha_i = C$	可能位於間隔內或分類錯誤	支持向量，違規懲罰已達上界

$$f(x) = \sum_{i \in SV} \alpha_i y_i K(x_i, x) + b$$

只有 $\alpha_i > 0$ 的支持向量出現在 `decision_function` ◦ `dual_coef_` 儲存的是含標籤符號的對偶係數。

特徵映射與核技巧

$$\phi : \mathcal{X} \rightarrow \mathcal{H}, \quad K(x, z) = \langle \phi(x), \phi(z) \rangle_{\mathcal{H}}$$

在特徵空間 $\mathcal{H}$ 中使用線性超平面，映回原始輸入空間後可形成非線性邊界。

對有限訓練集，Gram 矩陣 $G_{ij} = K(x_i, x_j)$ 應為對稱半正定，才能對應內積幾何與凸對偶問題。

核技巧的重點是直接計算 $K(x, z)$ ，而不是先建立巨大的 $\phi(x)$ 。

多項式核的空間轉換影片

原始 PPTX 第 25 頁嵌入的 HD 影片：

SVM with polynomial kernel visualization (HD)

觀看時請記錄：

1. 原始二維資料為什麼無法用直線分開？
2. 新特徵 $z = x^2 + y^2$ 如何將資料抬到三維？
3. 三維平面映回二維後，邊界變成什麼形狀？

SVC 內建的四種核函數

kernel	$K(x, z)$	主要參數	典型用法
linear	$x^T z$	C	高維稀疏特徵、可解釋權重
poly	$(\gamma x^T z + r)^d$	C, γ, d, r	指定階數的特徵交互
rbf	$e^{-\gamma x - z ^2}$	C, γ	一般非線性邊界，常作為起點
sigmoid	$\tanh(\gamma x^T z + r)$	C, γ, r	類似神經元激活，須特別驗證參數

scikit-learn 以 `degree=d`、`coef0=r` 與 `gamma= $\gamma$` 命名公式中的參數。

自訂與預計算核的延伸

核函數	公式或用法	適合情境
Laplacian	$e^{-\gamma x-z _1}$	希望使用 L1 差異，對特徵差異的反應與 RBF 不同
χ^2	$e^{-\gamma \sum_j (x_j - z_j)^2 / (x_j + z_j)}$	非負的頻數或直方圖特徵
cosine	$x^T z / (x z)$	方向比長度更重要的特徵
precomputed	直接提供 Gram 矩陣	已有可驗證的相似度或領域核

`svc` 可接受 callable 或 `kernel="precomputed"`。自訂核必須對訓練與測試使用一致的 Gram 定義。

多項式特徵與核技巧

對二維輸入，令 $\phi(x) = (x_1^2, \sqrt{2}x_1x_2, x_2^2)$ ，則

$$\phi(x)^T \phi(z) = (x^T z)^2$$

$(1, 1)$ 轉成 $(1, \sqrt{2}, 1)$ 。對 XOR 四點，可在特徵空間使用

$$-x_1^2 + 2x_1x_2 - x_2^2 + 0.5 = 0$$

分開兩類。顯式展開可用 `PolynomialFeatures` 後接線性 SVM，核方法則使用 `SVC(kernel="poly")`。


RBF 核的 γ 決定影響範圍

$$K_{\text{RBF}}(x, z) = \exp(-\gamma \|x - z\|^2), \quad \gamma = \frac{1}{2\sigma^2}$$

- γ 小：相似度隨距離下降較慢，單點影響範圍較大，邊界通常較平滑。
- γ 大：只有很靠近的點仍相似，邊界可能變得細碎。
- `gamma="scale"` 使用 $1/(d \text{Var}(X))$ ，仍要與 C 一起經交叉驗證比較。

特徵未縮放時，大數值特徵會主導 $\|x - z\|^2$ ，讓 γ 難以解釋。

C 與 γ 需要一起觀察



這次固定切分中， $(\gamma, C) = (5, 100)$ 產生較細碎的邊界，測試正確率反而低於 $(5, 1)$ 。單次測試分數只能解讀這次實驗，調參應改用訓練折內交叉驗證。

程式實作：核函數、 C 與 γ

```
from sklearn.pipeline import make_pipeline
from sklearn.preprocessing import StandardScaler
from sklearn.svm import SVC

linear = make_pipeline(StandardScaler(), SVC(kernel="linear", C=1))
poly = make_pipeline(StandardScaler(), SVC(kernel="poly", degree=3,
                                             gamma="scale", coef0=1, C=1))
rbf = make_pipeline(StandardScaler(), SVC(kernel="rbf", gamma=0.5, C=1))
sigmoid = make_pipeline(StandardScaler(), SVC(kernel="sigmoid",
                                                gamma="scale", coef0=0, C=1))
```

以同一份交叉驗證切分比較模型，並在折內完成 `StandardScaler.fit`。多項式與 RBF 的邊界實驗已收錄在現有程式。

多類別、分數與計算限制

主題	SVC 的行為	教學重點
多類別	內部訓練 OvO，共 $K(K - 1)/2$ 個二元模型	<code>decision_function_shape="ovr"</code> 只改變輸出形式
分數	<code>decision_function</code> 與超平面距離成比例	分數不等於機率
規模	核 SVC 的 fit 時間至少隨樣本數二次成長	大樣本先考慮 <code>LinearSVC</code> 、SGD 或核近似

SVM 並非天生不受離群點影響。 C 、核參數、縮放與權重都會改變邊界。

選讀 | 線性 SVM 的次梯度

$$J = \frac{\lambda}{2} \|w\|^2 + \frac{1}{m} \sum_i \max(0, 1 - y_i f_i)$$

$$\partial_w J = \lambda w - \frac{1}{m} \sum_{y_i f_i < 1} y_i x_i, \quad \partial_b J = -\frac{1}{m} \sum_{y_i f_i < 1} y_i$$

- $y_i f_i > 1$ 的點只留下正則化梯度。
- $y_i f_i < 1$ 的點會推動 w, b 改變邊界。
- $y_i f_i = 1$ 處不可微，但可使用合法次梯度。

這是 plain hinge 的教學版。LinearSVC 的預設損失為 `squared_hinge`，與本頁更新式不完全相同。

三種分類模型的比較

模型	典型邊界	重要檢查
Logistic	線性分數與機率	正則化、校準、閾值
SVM	原始空間的線性邊界，或核所得的非線性邊界	縮放、 C 、核參數，分數不等於機率
決策樹	軸平行分區	深度、葉樣本數、穩定性

比較實作：同一切分，三種模型

使用同一份彎月資料與同一組交叉驗證切分。

1. 比較樹深度 `[2,4,8,None]`。
2. 比較 Pipeline 內標準化的 Logistic 與 RBF SVM。
3. 對 RBF SVM 比較 $C \in \{0.1, 1, 10\}$ 與 $\gamma \in \{0.1, 1, 10\}$ 。
4. 報告 CV 平均、標準差、訓練時間與一組錯誤案例。

離堂檢核與作業

1. 為什麼決策樹的子節點不純度要依樣本數加權？
2. 請分別說明函數間隔與幾何間隔。
3. C 從 1 增至 100 時，模型在懲罰什麼？為什麼不保證測試分數變好？
4. 對偶問題為什麼使核技巧成為可能？
5. RBF 核的 γ 過大時，決策邊界會出現什麼風險？

課後：完成本章 Notebook 的樹深度與 SVM 參數比較，附上一張邊界圖與一段不超過 150 字的證據解釋。

Notebook 導讀：樹的幾何與 SVM 驗算

內容	可執行的檢查
CART	枚舉閾值、加權 Gini、遞迴停止及走訪預測
迴歸樹	節點平均、階梯曲線與葉樣本限制
旋轉／PCA	比較座標與邊界，PCA 不保證使樹更簡單
SVM	間隔寬度、hinge loss、 C/γ 邊界、核加權與 <code>decision_function</code>

幾何示意可使用全部訓練樣本。模型比較使用同一切分與 CV，不使用固定 test 數字反覆選參數。

SVM 主要來源與延伸閱讀

- Cortes, C., & Vapnik, V. (1995). *Support-Vector Networks*. Machine Learning, 20, 273–297. [DOI](#)
- scikit-learn, [Support Vector Machines: mathematical formulation and kernels](#)
- scikit-learn, [SVC API](#)
- Udi Aharoni, [SVM with polynomial kernel visualization \(HD\)](#)
- 原始教學素材：`source_pptx/03_SVM_DecisionTree_RandomForest.pptx`，第 2–29 頁。