

決策樹與SVM補充

第 6 週 | 從可解釋的分割規則，走到模型邊界比較

後續八週課程 | 每週 180 分鐘（含兩次 10 分鐘休息）

本週成果與三段安排


0–50 分：走訪決策樹、機率與不純度。

60–120 分：CART、正則化與迴歸樹。

130–180 分：穩定性、SVM 補充與模型比較。

能交付：一條預測路徑、一個分割計算，以及有理由的模型選擇。

從根節點走到葉節點：Iris 決策樹




每次只回答一個特徵閾值問題；最終葉節點提供類別分布。

讀懂節點上的四種資訊

- 規則：例如花瓣長度是否小於等於 2.45 cm。
- `samples`：到達此節點的訓練樣本數。
- `value`：各類別的計數或比例，依顯示工具而異。
- `gini`：混雜程度；0 表示節點內只有一類。

樹把空間切成一塊一塊的區域



第一次分割作用於全區域；後續分割只作用於相應子區域。

葉節點的機率來自到達此處的樣本

若葉節點有 $[0, 49, 5]$ 共 54 筆，則

$$\hat{p} = (0, 49/54, 5/54) \approx (0, .907, .093)$$

輸出最多的類別；機率是區域內的訓練頻率估計，並非個體的確定性。

Gini：隨機抽兩個標籤會多常不同？

$$G_i = 1 - \sum_{k=1}^K p_{i,k}^2$$

二元節點各一半時 $G = 0.5$ ；單一類別時 $G = 0$ 。

三類均等時 $G = 2/3$ ，因此 Gini 的最大值不固定為 0.5。

Entropy：標籤越難猜，資訊量越大

$$H_i = - \sum_{k:p_{i,k}>0} p_{i,k} \log_2 p_{i,k}$$

約定 $0 \log 0 = 0$ 。二元各一半時是 1 bit；單一類別是 0。

Gini 與 Entropy 常給出相近分割，但不保證完全相同。

手算：哪個節點比較純？

A 節點標籤數 $[4, 0]$ ，B 為 $[2, 2]$ ，C 為 $[3, 1]$ 。

1. 各算 Gini 與 Entropy。
2. 用一句話解釋「純度」與「預測是否正確」的差別。

建立一棵可閱讀的樹

```
from sklearn.tree import DecisionTreeClassifier, export_text
tree = DecisionTreeClassifier(max_depth=2, random_state=42)
tree.fit(X_train, y_train)
print(export_text(tree, feature_names=feature_names))
proba = tree.predict_proba(X_test[:2])
```

先限制深度方便閱讀；正式選擇仍要比較驗證表現。

休息 10 分鐘

離開座位、休息眼睛。回來後先用一句話回答上一段的核心問題。

CART：挑選加權子節點不純度最小的分割

$$J(k, t_k) = \frac{m_L}{m} G_L + \frac{m_R}{m} G_R$$

在候選特徵 k 與閾值 t_k 中選最小值，再遞迴處理子節點。

這是貪婪的二元分割；每步最佳不代表整棵樹全域最佳。

算一次分割，不能只比較左右平均

父節點有 $[4, 4]$ ，共 8 筆。

方案 A：左 $[3, 0]$ ，右 $[1, 4]$ 。

方案 B：左 $[2, 2]$ ，右 $[2, 2]$ 。

計算兩方案加權 Gini 與相對父節點的下降量。


限制樹的成長：先控制葉節點有多少證據

參數	作用	加強正則化的方向
max_depth	最大深度	調小
min_samples_split	允許分割的最少樣本數	調大
min_samples_leaf	葉節點最少樣本數	調大
max_leaf_nodes	葉節點數上限	調小

其他停止條件與剪枝

設定	控制的內容
min_weight_fraction_leaf	葉節點最少權重占比
min_impurity_decrease	分割帶來的最小加權不純度下降
max_features	每次候選特徵數
ccp_alpha	成本複雜度剪枝強度；越大通常樹越小

正則化前後：彎月資料的邊界



增加葉節點最少樣本數，可以減少為個別樣本切出的細碎區域。


迴歸樹：葉節點改成輸出數值平均

$$\hat{y}_{\text{node}} = \frac{1}{m_{\text{node}}} \sum_{i \in \text{node}} y^{(i)}$$

在平方誤差目標下，葉內平均值最小化該葉的總平方殘差。

輸出通常是分段常數；不會自然外插出向上延伸的直線。

讀迴歸樹：追蹤規則與葉內平均




每個葉節點顯示預測平均值及其平方誤差；不再顯示類別 Gini。

CART 迴歸目標：比較子節點的加權 MSE


$$J(k, t_k) = \frac{m_L}{m} \text{MSE}_L + \frac{m_R}{m} \text{MSE}_R$$
$$\text{MSE}_{\text{node}} = \frac{1}{m_{\text{node}}} \sum_{i \in \text{node}} (y^{(i)} - \hat{y}_{\text{node}})^2$$

增加深度：階梯更細，表達能力更強



深度增加可降低訓練誤差，也可能開始追逐雜訊。

迴歸樹也需要正則化



限制最小葉樣本數，能減少尖銳、短促的階梯。

迴歸葉節點：為什麼預測平均值？

同一葉中的目標是 $[1, 2, 6]$ 。


比較預測 2、3、4 的 MSE，找出最佳值。

再討論：如果損失改成絕對誤差，最佳常數會改成什麼？

休息 10 分鐘


離開座位、休息眼睛。回來後先用一句話回答上一段的核心問題。

座標軸方向會影響樹的複雜度




樹的分割通常平行於特徵軸；旋轉資料後，原本簡單的斜線可能需很多階梯。

PCA 旋轉後，樹可能更容易分割



縮放與旋轉不同：單調縮放通常保持排序，旋轉會改變分割方向。

小幅改動訓練資料，樹可能換一套規則



單棵樹具有高變異傾向；下一週用多棵不同的樹降低不穩定性。

補充 SVM：用間隔比較不同的分隔面

$$f(x) = w^T x + b, \quad \hat{y} = \text{sign}(f(x))$$

線性可分時，將邊界兩側最近點的函數間隔規範為 ± 1 ，兩條支持超平面距離為 $2/\|w\|$ 。

補充 SVM：軟間隔與 hinge loss

$$\min_{w,b} \frac{1}{2} \|w\|^2 + C \sum_i \max(0, 1 - y^{(i)} f(x^{(i)}))$$

C 越大，越重視違反間隔的代價；越小，越容許違反以換取較大間隔。

特徵尺度會改變距離與懲罰，通常要先標準化。

補充 SVM：核函數與 RBF 的 gamma

$$K(x, z) = \phi(x)^T \phi(z), \quad K_{\text{RBF}}(x, z) = e^{-\gamma \|x - z\|^2}$$

核技巧以相似度取代顯式高維展開。 γ 越大，單點影響越局部，邊界可能更細碎。

補充 SVM：原始問題與對偶的關係

硬間隔： $\min \frac{1}{2} \|w\|^2$ ，限制 $y_i(w^T x_i + b) \geq 1$ 。

對偶： $\max_a \sum_i a_i - \frac{1}{2} \sum_{i,j} a_i a_j y_i y_j K(x_i, x_j)$ 。

限制 $a_i \geq 0$, $\sum_i a_i y_i = 0$ ；軟間隔再加 $a_i \leq C$ 。

支持向量對應非零對偶係數；可延伸 OvR／OvO 處理多類別。

三種分類模型的比較

模型	典型邊界	重要檢查
Logistic	線性分數＋機率	正則化、校準、閾值
SVM（補充）	線性或核邊界	縮放、C、gamma；分數不等於機率
決策樹	軸平行分區	深度、葉樣本數、穩定性

比較實作：同一切分，兩種模型

使用同一份訓練與測試資料。

1. CV 比較樹深度 [2,4,8,None] 。
2. 比較標準化 Logistic；八週版再加入標準化 SVM 。
3. 除指標外，報告模型規則、錯誤案例與訓練時間 。
4. 離線：解釋斜向邊界為何可能讓淺樹吃虧 。

離堂檢核與作業

1. CART 為何要依樣本數加權？
2. 為什麼葉節點很純，仍可能測試表現差？
3. 哪一種資料改動可能明顯改變樹的規則？

課後：Ch.5 練習 1-7；進階以多個抽樣子集比較樹的穩定性。