

集成學習與隨機森林

第 7 週 | 多個模型如何互補，以及何時只是重複同一種錯誤

課堂主線 180 分鐘（含兩次 10 分鐘休息）；「選讀」頁安排課後或替換同段內容

本週節奏與成果

0–50 分：投票、Bagging、OOB、隨機森林。

60–120 分：AdaBoost 與 Gradient Boosting。

130–180 分：Histogram Boosting、Stacking 與比較實作。

成果：能區分平行抽樣、逐步修正與第二層學習。


 **配套 Notebook**： `programs/notebooks/07_集成學習與隨機森林.ipynb`。程式片段、實際圖表與表格可由此檔重現。

程式實驗與實際輸出


```
residual = y - model.predict(X)
next_tree.fit(X, residual)
```

觀察：平方損失下，每一棵新樹擬合目前殘差，集成預測逐步修正。

參考程式：`programs/notebooks/07_集成學習與隨機森林.ipynb`




投票分類器：不同模型提供不同觀點



同一份訓練資料可交給不同演算法；有差異的錯誤才可能互補。

硬投票：每個模型先投一個類別




多數決易理解，但不使用模型對類別的信心差異。

軟投票：先平均機率，再選最大值

$$\hat{p}_k(x) = \frac{\sum_j w_j \hat{p}_{j,k}(x)}{\sum_j w_j}, \quad \hat{y} = \arg \max_k \hat{p}_k(x)$$

需要各模型提供可比較的類別機率；過度自信的模型可能扭曲平均。

大數法則的前提：錯誤不能完全同步



許多略優於隨機的判斷可累積優勢；高度相關的模型會限制集成收益。

同樣三個模型，硬投票與軟投票會相同嗎？

正類機率依序為 $[0.51, 0.51, 0.01]$ 。


1. 等權硬投票的預測是什麼？
2. 等權軟投票的預測是什麼？
3. 若第三個模型嚴重失準，平均機率可能有什麼問題？

投票分類器的機率條件

```
from sklearn.ensemble import VotingClassifier
vote = VotingClassifier(
    estimators=[("lr", lr_pipeline), ("rf", forest),
                ("svc", svc_pipeline)], voting="soft")
vote.fit(X_train, y_train)
pred = vote.predict(X_test)
```


lr_pipeline 、 svc_pipeline 含折內縮放；SVC 需先設 probability=True 。硬投票可改 voting="hard" 。

Bagging：每個模型用不同抽樣資料訓練



有放回抽樣稱 Bagging；無放回抽樣稱 Pasting。最終做分類投票或迴歸平均。

很多棵不同的樹，邊界通常更平滑



集成主要降低變異；如果每棵樹的錯誤幾乎一樣，改善有限。

袋外 OOB：這棵樹沒看過哪些樣本？

$$P(\text{某樣本未被抽到}) = \left(1 - \frac{1}{m}\right)^m \approx e^{-1} \approx 0.368$$

每筆資料只由「沒有抽到它」的樹預測，形成 OOB 評估。

OOB 可輔助驗證；若反覆據此調參，仍需獨立最終測試。

Bagging 與 OOB 的實作對照

```
from sklearn.ensemble import BaggingClassifier
from sklearn.tree import DecisionTreeClassifier
bag = BaggingClassifier(DecisionTreeClassifier(),
                        n_estimators=200, bootstrap=True, oob_score=True,
                        random_state=42)
bag.fit(X_train, y_train)
print(bag.oob_score_)
```

`bootstrap=False` 改為 Pasting，此時停用 OOB。基模型可輸出機率時，sklearn Bagging 平均機率再選類別。

資料與特徵，都可以隨機抽樣

做法	樣本	特徵
Bagging／Pasting	抽部分樣本	可用全部
Random subspaces	全部樣本	抽部分特徵
Random patches	抽部分樣本	抽部分特徵
Random forest	通常 bootstrap	每個分割點抽候選特徵

Random Forest 與 Extra Trees 的差別

- 隨機森林：每個節點只在部分候選特徵中找最佳分割。
- Extra Trees：額外隨機化候選切割閾值。
- 額外隨機化可能降低相關性，也可能增加偏差。
- **Boosting 是另一種集成策略**，不是隨機森林的別名。

森林的隨機性與重要度計算


`RandomForestClassifier(n_estimators=200, max_features="sqrt", random_state=42)` 在每個節點抽候選特徵。

特徵 k 的貢獻：累加使用它的節點之

$$\frac{m_t}{m} \left(I_t - \frac{m_L}{m_t} I_L - \frac{m_R}{m_t} I_R \right)$$

森林再彙整各樹結果並正規化，得到 `feature_importances_`。一般森林與 Extra Trees 的 bootstrap 預設也不同，比較時應寫明設定。

特徵重要度：哪些像素參與較多有效分割？



不純度重要度可做探索；高基數特徵或相關特徵會影響其解讀。

休息 10 分鐘

離開座位、休息眼睛。回來後先用一句話回答上一段的核心問題。


Boosting：新模型接著處理前面的不足

AdaBoost：提高難分樣本的相對權重。

Gradient Boosting：朝目前損失的負梯度方向加入新模型。


訓練具有先後依賴；這與可平行訓練的 Bagging 不同。

AdaBoost 的權重更新流程



先訓練、再計算加權錯誤、調整樣本權重，重複得到多個加權模型。

後續分類器更注意先前的難分樣本



教材用 RBF-SVM 展示權重效果；實務入門常用淺決策樹。

AdaBoost：加權錯誤率與模型權重

$$r_j = \frac{\sum_i w_i \mathbf{1}[\hat{y}_j^{(i)} \neq y^{(i)}]}{\sum_i w_i}, \quad \alpha_j = \eta \log \frac{1 - r_j}{r_j}$$

這裡是教材的二元「只增加錯分權重」寫法； $r_j < 0.5$ 時模型權重為正。

AdaBoost：更新樣本權重，再做加權投票

$$w_i \leftarrow \begin{cases} w_i & \hat{y}_j^{(i)} = y^{(i)} \\ w_i e^{\alpha_j} & \hat{y}_j^{(i)} \neq y^{(i)} \end{cases}, \quad w_i \leftarrow \frac{w_i}{\sum_l w_l}$$
$$\hat{y}(x) = \arg \max_k \sum_j \alpha_j \mathbf{1}[\hat{y}_j(x) = k]$$

手算 AdaBoost 的第一輪

四筆資料初始權重皆為 $1/4$ ，第一個模型只錯一筆， $\eta = 1$ 。

1. 算 r 、 α 。
2. 更新並正規化後，錯分與正確樣本權重各多少？
3. 若錯誤標籤一直被加權，可能發生什麼事？

選讀 | 手刻 AdaBoost 為何多了二分之一

舊程式採 $y, h(x) \in \{-1, +1\}$ 的對稱更新：

$$a = \frac{1}{2} \log \frac{1-r}{r}, \quad w'_i \propto w_i e^{-ay_i h(x_i)}$$

答對乘 e^{-a} ，答錯乘 e^a ，錯／對權重比增為 e^{2a} 。


教材只放大錯分者，令 $\alpha = 2a$ ，因此正規化後權重相同。前頁 $r = 1/4$ 時，兩種寫法都得到錯分者 $1/2$ 、其餘各 $1/6$ 。

Gradient Boosting：平方損失時學殘差

$$F_0(x) = \bar{y}, \quad r_i = y_i - F_{t-1}(x_i), \quad F_t(x) = F_{t-1}(x) + \eta h_t(x)$$


新樹 h_t 擬合殘差。一般損失則擬合負梯度，不一定等於 $y - \hat{y}$ 。

逐棵加入：左邊學殘差，右邊累加預測




從第一列往下看：每一輪針對剩餘誤差，修正目前集成。

圖 6-9 放大：第 1 輪殘差與累加




第一棵樹直接擬合目標，建立初始集成。

圖 6-9 放大：第 2 輪殘差與累加




第二棵樹擬合第一棵留下的殘差，再加回原預測。

圖 6-9 放大：第 3 輪殘差與累加



第三棵樹再修正剩餘殘差；模型逐步改善但仍需驗證。

學習率較小，通常需要更多棵樹



樹數與 learning_rate 要一起調整；更多樹並非永遠更好。

Boosting 的停止條件與隨機化

- `n_estimators`：最多加入幾個模型。
- `learning_rate`：每個新模型的影響幅度。
- `n_iter_no_change`：驗證指標無改善的容忍次數。
- `subsample < 1`：每輪只用部分訓練樣本，形成隨機梯度提升。

休息 10 分鐘

離開座位、休息眼睛。回來後先用一句話回答上一段的核心問題。

Histogram Gradient Boosting：先把連續值分箱

把連續特徵轉成有限分箱，再從箱邊界找分割，減少候選切點。

適合較大表格資料；可處理缺失值，類別特徵要明確指定或提供正確資料型態。


未知類別、資料洩漏與驗證切分仍需處理。

GBRT 與 HGB 的參數不能直接互抄

控制項目	GradientBoostingRegressor	HistGradientBoostingRegressor
最多輪數	<code>n_estimators</code>	<code>max_iter</code>
早停開關	設 <code>n_iter_no_change</code>	<code>early_stopping=True</code>
每輪樣本抽樣	<code>subsample</code>	無相同的參數
分箱	無此步驟	<code>max_bins</code> ，會損失數值精度


類別與缺失值處理也不同。XGBoost、LightGBM、CatBoost 與 YDF 留作課後比較，先用相同切分與指標建立基準。

Stacking：讓第二層模型學會如何組合




第一層輸出成為第二層特徵；blender 可學到不同模型的適用情況。

用折外預測建立第二層訓練資料



每列的基模型預測，都來自未看過該列標籤的折內模型；用這些預測訓練 blender。

多層 Stacking：多個 blender 還可再組合



本圖展示推論時的三層組合；增加層數也增加訓練成本、延遲與洩漏控制的難度。

Stacking 洩漏：看似完美的訓練特徵

錯誤流程：基模型先 fit 全訓練集，再用它對同一批資料的預測訓練 blender。

高容量基模型可能記住答案；第二層學到的組合方式無法泛化。

正確流程：折外預測（OOF）或獨立保留集。

Stacking 的訓練與推論介面

```
from sklearn.ensemble import StackingClassifier
stack = StackingClassifier(
    estimators=[("lr", lr_pipeline), ("rf", forest)],
    final_estimator=LogisticRegression(), cv=5)
stack.fit(X_train, y_train)
pred = stack.predict(X_test)
```

`cv=5` 用來建立第二層的折外特徵；仍需外層驗證評估整個模型。推論使用在完整訓練集重訓的基模型，再交由第二層組合。

表 6-1：投票方法的適用條件與案例

方法	教材使用條件	教材案例
Hard voting	類別較平衡；模型強且多樣	垃圾郵件、情緒、疾病分類
Soft voting	機率模型；信心資訊有價值	醫療診斷、信用風險、假新聞

表 6-1：抽樣集成的適用條件與案例

方法	教材使用條件	教材案例
Bagging	結構或半結構資料；高變異模型	金融風險、電商推薦
Pasting	結構或半結構資料；希望增加多樣性	顧客分群、蛋白質分類

表 6-1：隨機樹的適用條件與案例

方法	教材使用條件	教材案例
Random forest	高維結構資料；可能有雜訊特徵	顧客流失、基因資料、詐欺偵測
Extra Trees	大型多特徵資料；重視速度與降低變異	即時詐欺偵測、感測資料分析

表 6-1：Boosting 的適用條件與案例

方法	教材使用條件	教材案例
AdaBoost	中小型、低雜訊；弱學習器如樹樁	信用評分、異常偵測、預測維護
Gradient Boosting	中大型表格；願意投入調參	房價、風險評估、需求預測

表 6-1：HGB 與 Stacking 的條件與案例

方法	教材使用條件	教材案例
Histogram GB	大型表格；重視速度與規模	點擊率、排序、廣告競價
Stacking	複雜高維；組合多樣模型	推薦、自動駕駛決策、競賽

綜合比較：單樹、森林與提升樹

固定資料切分與評估指標，比較：

1. 單棵淺樹。
2. 隨機森林（例如 200 棵）。
3. Gradient Boosting 或 Histogram GB。

提交訓練／CV 表現、運行時間與錯誤案例；離線組畫出三種訓練流程並說明資料角色。

離堂檢核：辨認三種「下一個模型」

- Bagging：下一個模型用另一份抽樣資料。
- Boosting：下一個模型根據目前錯誤或梯度訓練。
- Stacking：第二層模型學習組合折外預測。

課後：Ch.6 練習 1-9；用錯誤重疊率解釋投票是否有效。