

# 集成學習與隨機森林

第 7 週 | 多個模型如何互補，以及何時只是重複同一種錯誤

後續八週課程 | 每週 180 分鐘（含兩次 10 分鐘休息）

## 本週節奏與成果

---


0–50 分：投票、Bagging、OOB、隨機森林。

60–120 分：AdaBoost 與 Gradient Boosting。

130–180 分：Histogram Boosting、Stacking 與比較實作。


成果：能區分平行抽樣、逐步修正與第二層學習。

## 投票分類器：不同模型提供不同觀點



同一份訓練資料可交給不同演算法；有差異的錯誤才可能互補。

## 硬投票：每個模型先投一個類別



多數決易理解，但不使用模型對類別的信心差異。


## 軟投票：先平均機率，再選最大值

---

$$\hat{p}_k(x) = \frac{\sum_j w_j \hat{p}_{j,k}(x)}{\sum_j w_j}, \quad \hat{y} = \arg \max_k \hat{p}_k(x)$$

需要各模型提供可比較的類別機率；過度自信的模型可能扭曲平均。

## 大數法則的前提：錯誤不能完全同步



許多略優於隨機的判斷可累積優勢；高度相關的模型會限制集成收益。


## 同樣三個模型，硬投票與軟投票會相同嗎？

---

正類機率依序為  $[0.51, 0.51, 0.01]$ 。


1. 等權硬投票的預測是什麼？
2. 等權軟投票的預測是什麼？
3. 若第三個模型嚴重失準，平均機率可能有什麼問題？

## Bagging：每個模型用不同抽樣資料訓練



有放回抽樣稱 Bagging；無放回抽樣稱 Pasting。最終做分類投票或迴歸平均。

## 很多棵不同的樹，邊界通常更平滑



集成主要降低變異；如果每棵樹的錯誤幾乎一樣，改善有限。

## 袋外 OOB：這棵樹沒看過哪些樣本？

---

$$P(\text{某樣本未被抽到}) = \left(1 - \frac{1}{m}\right)^m \approx e^{-1} \approx 0.368$$

每筆資料只由「沒有抽到它」的樹預測，形成 OOB 評估。

OOB 可輔助驗證；若反覆據此調參，仍需獨立最終測試。

## 資料與特徵，都可以隨機抽樣

---

| 做法               | 樣本           | 特徵         |
|------------------|--------------|------------|
| Bagging／Pasting  | 抽部分樣本        | 可用全部       |
| Random subspaces | 全部樣本         | 抽部分特徵      |
| Random patches   | 抽部分樣本        | 抽部分特徵      |
| Random forest    | 通常 bootstrap | 每個分割點抽候選特徵 |


## Random Forest 與 Extra Trees 的差別

---

- 隨機森林：每個節點只在部分候選特徵中找最佳分割。
- Extra Trees：額外隨機化候選切割閾值。
- 額外隨機化可能降低相關性，也可能增加偏差。
- **Boosting 是另一種集成策略**，不是隨機森林的別名。

## 特徵重要度：哪些像素參與較多有效分割？

---



不純度重要度可做探索；高基數特徵或相關特徵會影響其解讀。

## 休息 10 分鐘

---

離開座位、休息眼睛。回來後先用一句話回答上一段的核心問題。

## Boosting：新模型接著處理前面的不足


---

AdaBoost：提高難分樣本的相對權重。

Gradient Boosting：朝目前損失的負梯度方向加入新模型。


訓練具有先後依賴；這與可平行訓練的 Bagging 不同。

# AdaBoost 的權重更新流程



先訓練、再計算加權錯誤、調整樣本權重，重複得到多個加權模型。

## 後續分類器更注意先前的難分樣本



教材用 RBF-SVM 展示權重效果；實務入門常用淺決策樹。

## AdaBoost：加權錯誤率與模型權重

---

$$r_j = \frac{\sum_i w_i \mathbf{1}[\hat{y}_j^{(i)} \neq y^{(i)}]}{\sum_i w_i}, \quad \alpha_j = \eta \log \frac{1 - r_j}{r_j}$$

這裡是教材的二元「只增加錯分權重」寫法； $r_j < 0.5$  時模型權重為正。

## AdaBoost：更新樣本權重，再做加權投票

---

$$w_i \leftarrow \begin{cases} w_i & \hat{y}_j^{(i)} = y^{(i)} \\ w_i e^{\alpha_j} & \hat{y}_j^{(i)} \neq y^{(i)} \end{cases}, \quad w_i \leftarrow \frac{w_i}{\sum_l w_l}$$
$$\hat{y}(x) = \arg \max_k \sum_j \alpha_j \mathbf{1}[\hat{y}_j(x) = k]$$

## 手算 AdaBoost 的第一輪

---

四筆資料初始權重皆為  $1/4$ ，第一個模型只錯一筆， $\eta = 1$ 。

1. 算  $r$ 、 $\alpha$ 。
2. 更新並正規化後，錯分與正確樣本權重各多少？
3. 若錯誤標籤一直被加權，可能發生什麼事？


## Gradient Boosting：平方損失時學殘差

---

$$F_0(x) = \bar{y}, \quad r_i = y_i - F_{t-1}(x_i), \quad F_t(x) = F_{t-1}(x) + \eta h_t(x)$$


新樹  $h_t$  擬合殘差。一般損失則擬合負梯度，不一定等於  $y - \hat{y}$ 。

## 逐棵加入：左邊學殘差，右邊累加預測




從第一列往下看：每一輪針對剩餘誤差，修正目前集成。

## 圖 6-9 放大：第 1 輪殘差與累加




第一棵樹直接擬合目標，建立初始集成。

## 圖 6-9 放大：第 2 輪殘差與累加




第二棵樹擬合第一棵留下的殘差，再加回原預測。

## 圖 6-9 放大：第 3 輪殘差與累加



第三棵樹再修正剩餘殘差；模型逐步改善但仍需驗證。

## 學習率較小，通常需要更多棵樹



樹數與 learning\_rate 要一起調整；更多樹並非永遠更好。

## Boosting 的停止條件與隨機化

---

- `n_estimators`：最多加入幾個模型。
- `learning_rate`：每個新模型的影響幅度。
- `n_iter_no_change`：驗證指標無改善的容忍次數。
- `subsample < 1`：每輪只用部分訓練樣本，形成隨機梯度提升。

## 休息 10 分鐘

---

離開座位、休息眼睛。回來後先用一句話回答上一段的核心問題。

## Histogram Gradient Boosting：先把連續值分箱


---

把連續特徵轉成有限分箱，再從箱邊界找分割，減少候選切點。

適合較大表格資料；可處理缺失值，類別特徵要明確指定或提供正確資料型態。


未知類別、資料洩漏與驗證切分仍需處理。

# Stacking：讓第二層模型學會如何組合




第一層輸出成為第二層特徵；blender 可學到不同模型的適用情況。

## 用折外預測建立第二層訓練資料



每列的基模型預測，都來自未看過該列標籤的折內模型；用這些預測訓練 blender。

## 多層 Stacking：多個 blender 還可再組合



本圖展示推論時的三層組合；增加層數也增加訓練成本、延遲與洩漏控制的難度。

## Stacking 洩漏：看似完美的訓練特徵

---

錯誤流程：基模型先 fit 全訓練集，再用它對同一批資料的預測訓練 blender。

高容量基模型可能記住答案；第二層學到的組合方式無法泛化。

正確流程：折外預測（OOF）或獨立保留集。

表 6-1：投票方法的適用條件與案例

| 方法          | 教材使用條件       | 教材案例          |
|-------------|--------------|---------------|
| Hard voting | 類別較平衡；模型強且多樣 | 垃圾郵件、情緒、疾病分類  |
| Soft voting | 機率模型；信心資訊有價值 | 醫療診斷、信用風險、假新聞 |

表 6-1：抽樣集成的適用條件與案例

| 方法      | 教材使用條件           | 教材案例       |
|---------|------------------|------------|
| Bagging | 結構或半結構資料；高變異模型   | 金融風險、電商推薦  |
| Pasting | 結構或半結構資料；希望增加多樣性 | 顧客分群、蛋白質分類 |

表 6-1：隨機樹的適用條件與案例

| 方法            | 教材使用條件            | 教材案例           |
|---------------|-------------------|----------------|
| Random forest | 高維結構資料；可能有雜訊特徵    | 顧客流失、基因資料、詐欺偵測 |
| Extra Trees   | 大型多特徵資料；重視速度與降低變異 | 即時詐欺偵測、感測資料分析  |

表 6-1：Boosting 的適用條件與案例

| 方法                | 教材使用條件          | 教材案例           |
|-------------------|-----------------|----------------|
| AdaBoost          | 中小型、低雜訊；弱學習器如樹樁 | 信用評分、異常偵測、預測維護 |
| Gradient Boosting | 中大型表格；願意投入調參    | 房價、風險評估、需求預測   |

表 6-1：HGB 與 Stacking 的條件與案例

| 方法           | 教材使用條件       | 教材案例         |
|--------------|--------------|--------------|
| Histogram GB | 大型表格；重視速度與規模 | 點擊率、排序、廣告競價  |
| Stacking     | 複雜高維；組合多樣模型  | 推薦、自動駕駛決策、競賽 |

## 綜合比較：單樹、森林與提升樹

---

固定資料切分與評估指標，比較：

1. 單棵淺樹。
2. 隨機森林（例如 200 棵）。
3. Gradient Boosting 或 Histogram GB。

提交訓練／CV 表現、運行時間與錯誤案例；離線組畫出三種訓練流程並說明資料角色。

## 離堂檢核：辨認三種「下一個模型」

---

- Bagging：下一個模型用另一份抽樣資料。
- Boosting：下一個模型根據目前錯誤或梯度訓練。
- Stacking：第二層模型學習組合折外預測。

課後：Ch.6 練習 1-9；用錯誤重疊率解釋投票是否有效。