

降維與資料表示

第 8 週 | 壓縮什麼、保留什麼，以及圖形能說明什麼

課堂主線 180 分鐘（含兩次 10 分鐘休息）；「選讀」頁安排課後或替換同段內容

本週成果與三段安排

0–50 分：維度災難、投影、PCA 幾何。

60–120 分：矩陣推導、保留維度、壓縮與實作。

130–180 分：隨機投影、流形方法與結果解讀。

成果：能做 PCA、解釋變異比例，並辨識視覺化的限制。


 **配套 Notebook**： [08_降維與資料表示.ipynb](#)。程式片段、實際圖表與表格可由此檔重現。

程式實驗與實際輸出


```
Z = pca.fit_transform(X_train)
X_hat = pca.inverse_transform(Z)
```

觀察：降維保留主要變異，同時造成重建誤差；維度選擇要連回下游任務。

[開啟完整 Notebook](#)



維度增加：大部分空間可能靠近邊界



高維空間的距離與密度直覺，不能直接沿用二維經驗。

維度災難帶來三個問題

- 要維持相似的資料密度，所需樣本可能大幅增加。
- 距離變得較不具區辨力，近鄰與分群更難。
- 特徵過多增加計算、雜訊與過擬合風險。

降維可能幫助，但也可能丟掉預測所需訊息。

高維空間靠近邊界的機率


在 $[0, 1]^n$ 均勻抽一個點，離任一邊界小於 δ 的機率為

$$P = 1 - (1 - 2\delta)^n, \quad 0 < \delta < \frac{1}{2}$$

令 $\delta = 0.001$ ：二維約 0.4%；一萬維已超過 99.999999%。


這是均勻分布的幾何示例。真實資料若集中在低維結構附近，所需樣本量可能小得多。

投影：資料是否接近某個低維子空間？




把三維點投影到平面；若偏離平面的變化很小，損失可能有限。

在投影平面建立新的座標




主成分通常是原始特徵的線性組合，不等同刪掉幾個原始欄位。

Swiss roll : 彎曲流形無法靠平面直接攤開




資料內在可能接近二維，但嵌在三維且彎曲；線性投影會重疊。

攤開流形：保留局部鄰近關係




流形學習假設資料集中在低維結構附近；真實資料未必符合。

降維之後，分類邊界不一定更簡單



某些目標在流形座標容易分，其他目標卻可能更難；要看任務。

PCA：選擇投影後變異最大的方向



第一主成分保留最多變異；後續方向與前面正交，再保留剩餘變異。

PCA 的兩個等價觀點

1. 在正交線性投影中，最大化保留的變異。
2. 在固定維度下，最小化平方重建誤差。

先中心化資料；標準化是否適合，要依單位與任務判斷。

變異大不代表對標籤更有預測力。

先猜方向，再計算

資料點為 $(-2, -2)$, $(-1, -1)$, $(1, 1)$, $(2, 2)$ 。

1. 哪條線能完整保留資料？
2. 投影到 x 軸與投影到對角線，哪個重建誤差小？
3. 若只留下「最大變異」，是否一定保留分類訊息？

休息 10 分鐘

離開座位、休息眼睛。回來後先用一句話回答上一段的核心問題。

PCA 的 SVD 寫法與矩陣形狀

$$X_c = X - \mathbf{1}\mu^T = U\Sigma V^T$$

V 的欄為主成分方向。令 $W_d = [v_1, \dots, v_d] \in \mathbb{R}^{n \times d}$ 。

$$Z = X_c W_d \in \mathbb{R}^{m \times d}$$

從共變異矩陣推導第一主成分

$$C = \frac{1}{m-1} X_c^T X_c, \quad \max_{\|w\|=1} w^T C w$$

$$\mathcal{L}(w, \lambda) = w^T C w - \lambda(w^T w - 1) \Rightarrow Cw = \lambda w$$

選最大特徵值對應的單位特徵向量；後續方向依特徵值排序。

共變異特徵值與奇異值的關係

$$X_c = U\Sigma V^T, \quad C = \frac{X_c^T X_c}{m-1} = V \frac{\Sigma^T \Sigma}{m-1} V^T$$

所以 $\lambda_j = s_j^2/(m-1)$ ，資料矩陣的奇異值為 $s_j = \sqrt{(m-1)\lambda_j}$ 。

對非零 s_j ， $u_j = X_c v_j / s_j$ 。只取 $\sqrt{\lambda_j}$ 會讓 U 的欄長度不對。

SVD 可分解一般矩陣；要用它求 PCA 主成分，先中心化資料。

手算例：同一條線的共變異矩陣

前段四點已中心化， $C = \frac{10}{3} \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}$ 。

特徵值為 $20/3$ 與 0 ；第一方向為 $(1, 1)^T / \sqrt{2}$ 。

第一主成分保留 100% 變異；主成分符號反轉不改變子空間。

選讀 | 手刻 PCA 與函式庫的比較

```
Xc = X - X.mean(axis=0)
eigenvalues, V = np.linalg.eigh(np.cov(Xc, rowvar=False))
order = np.argsort(eigenvalues)[::-1]
W = V[:, order[:2]]
Z = Xc @ W
U, s, Vt = np.linalg.svd(Xc, full_matrices=False)
```

兩邊需使用相同的中心化／標準化資料；比較解釋變異與重建誤差。符號翻轉、重複特徵值造成的旋轉不代表算錯。

選讀 | 原課程的 3×2 矩陣 SVD 手算

$$A = \begin{pmatrix} -1 & 1 \\ 0 & -1 \\ 1 & 1 \end{pmatrix}, \quad A^T A = \begin{pmatrix} 2 & 0 \\ 0 & 3 \end{pmatrix}$$

按奇異值遞減排序，精簡分解 $A = U\Sigma V^T$ 可取

$$U = \begin{pmatrix} 1/\sqrt{3} & -1/\sqrt{2} \\ -1/\sqrt{3} & 0 \\ 1/\sqrt{3} & 1/\sqrt{2} \end{pmatrix}, \quad \Sigma = \begin{pmatrix} \sqrt{3} & 0 \\ 0 & \sqrt{2} \end{pmatrix}, \quad V^T = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$$


檢查 $U^T U = V^T V = I_2$ ，再乘回 A 。一般矩陣的 SVD 不要求先中心化；用於 PCA 時才先中心化。

解釋變異比例與保留維度

$$\rho_j = \frac{\lambda_j}{\sum_l \lambda_l}, \quad d = \min \left\{ q : \sum_{j=1}^q \rho_j \geq \tau \right\}$$

例如 $\tau = 0.95$ 保留 95% 變異；它不是保證保留 95% 分類正確率。

用累積曲線選 d：壓縮與保真之間的折衷



教材 MNIST 例子約需 154 個維度保留 95% 變異；數字會隨資料與前處理而變。

PCA 程式：先切分，再學投影

```
from sklearn.decomposition import PCA
pca = PCA(n_components=0.95, svd_solver="full")
Z_train = pca.fit_transform(X_train)
Z_test = pca.transform(X_test)
X_rebuilt = pca.inverse_transform(Z_test)
print(pca.n_components_)
print(pca.explained_variance_ratio_.sum())
```


逆投影：重建時要把平均值加回去

$$\hat{X} = ZW_d^T + \mathbf{1}\mu^T$$

教材式 7-3 的簡寫 $X_{\text{recovered}} = X_{d\text{-proj}}W_d^T$ ，對應中心化座標。

丟掉的維度通常無法完整找回；inverse transform 不代表無損。

圖像壓縮：重建仍像數字，但細節已減少



同時看圖與量化重建 MSE；下游辨識表現也要單獨評估。

PCA 的計算選項

方法	適合情境	代價或條件
完整 SVD PCA	中小型資料、精確分解	需儲存主要矩陣
Randomized PCA	只需少量主成分	近似解，設定 random_state
Incremental PCA	資料無法一次放入記憶體	分批 partial_fit；批次需夠大
memmap	磁碟映射大陣列	降低一次載入需求，仍有 I/O 成本

選讀 | 分批 PCA 的訓練與固定投影

```
from sklearn.decomposition import IncrementalPCA
ipca = IncrementalPCA(n_components=20)
for X_batch in training_batches:
    ipca.partial_fit(X_batch)
Z_train = ipca.transform(X_train)
Z_test = ipca.transform(X_test)
```

先完成各批次擬合，再統一轉換。批次數量須足夠支持保留維度；更新投影後，下游模型也須重訓。

PCA 維度與分類器一起驗證

```
from sklearn.pipeline import Pipeline
from sklearn.model_selection import GridSearchCV
from sklearn.linear_model import LogisticRegression
pipe = Pipeline([("pca", PCA()),
                  ("clf", LogisticRegression(max_iter=1000))])
search = GridSearchCV(pipe, {"pca__n_components": [2, 10, 30]},
                      cv=3, scoring="accuracy")
search.fit(X_train, y_train)
```

以 digits 的 64 維像素為例。比較未降維基準；每個驗證折重新 fit PCA，避免投影偷看驗證集。

實作：壓縮率與辨識品質是否一起變好？

對已備妥的 digits 資料，比較 2、10、30 個主成分。

記錄：變異比例、重建 MSE、分類 CV 指標、運行時間。

離線：若特徵值是 `[8, 1.5, 0.5]`，保留 90% 至少需要幾維？

休息 10 分鐘

離開座位、休息眼睛。回來後先用一句話回答上一段的核心問題。

隨機投影：不用先找到主方向

$$Z = XP, \quad P_{ij} \sim \mathcal{N}(0, 1/d)$$

用隨機矩陣近似保留有限點集間的距離，計算便宜；不以最大化變異為目標。

Johnson–Lindenstrauss 維度界線

$$d \geq \frac{4 \log m}{\varepsilon^2/2 - \varepsilon^3/3}, \quad 0 < \varepsilon < 1$$

以足夠高的目標維度，讓平方距離大致維持在原距離的 $(1 \pm \varepsilon)$ 範圍。

這是保守理論界，不保證比原始維度更小；不是「任何高維都可壓成 2D」。


稀疏隨機投影：大部分矩陣元素為零

令非零機率為 r ，非零元素取 $\pm 1/\sqrt{dr}$ ，各占 $r/2$ 。

可減少儲存與乘法成本；教材常用 $r = 1/\sqrt{n}$ 。

偽反矩陣可做近似重建，但投影已丟失資訊，不能期待還原全部細節。

LLE：用鄰居重建每個點，再保持重建關係



先找局部鄰域權重，再尋找能維持這些權重的低維座標。

LLE 第一步：找到局部重建權重

$$\min_W \sum_i \left\| x_i - \sum_j w_{ij} x_j \right\|^2$$

限制：不是鄰居則 $w_{ij} = 0$ ；每列 $\sum_j w_{ij} = 1$ 。


權重描述局部幾何；鄰居數太少或太多都可能破壞結構。

LLE 第二步：保持權重，移動低維座標

$$\min_Z \sum_i \left\| z_i - \sum_j w_{ij} z_j \right\|^2$$

需加中心化與尺度限制，例如 $Z^T \mathbf{1} = 0$ 、 $Z^T Z = I$ ，排除全部點縮成零的退化解。

同一資料用不同降維方法，圖形可能很不同



MDS 著重距離；Isomap 著重沿流形的路徑距離；t-SNE 強調局部鄰近。

其他方法與解讀界線

方法	保留／使用的資訊	注意
MDS	點間距離	大樣本成本高
Isomap	近鄰圖的最短路徑距離	鄰居圖錯接會失真
t-SNE	局部相似度	群間距離與群大小不宜直接解釋
LDA	標籤導向可分性	監督式降維，需防標籤洩漏

LDA：使用標籤選擇投影方向

Fisher 的方向以類別中心的分離，對照類內的散布：

$$\max_w \frac{w^T S_B w}{w^T S_W w}$$

S_B 是類間散布， S_W 是類內散布。若有 K 類、 n 個特徵，最多取得 $\min(n, K - 1)$ 個判別維度。

PCA 最大化整體變異，並不要求高斯分布；LDA 的高斯生成分類解釋另假設類內高斯及共用共變異。

補充 t-SNE：相似度不是原始距離的等比例縮圖

$$\text{KL}(P\|Q) = \sum_{i \neq j} p_{ij} \log \frac{p_{ij}}{q_{ij}}$$

高維相似度以局部尺度建立；低維使用厚尾分布。Perplexity 調整有效鄰域尺度。

不同隨機種子與設定可能得到不同圖；UMAP 可作課後比較，不以單張圖確認真實群數。

選讀 | t-SNE 相似度與困惑度

$$p_{j|i} = \frac{e^{-\|x_i - x_j\|^2 / (2\sigma_i^2)}}{\sum_{k \neq i} e^{-\|x_i - x_k\|^2 / (2\sigma_i^2)}}, \quad p_{ij} = \frac{p_{j|i} + p_{i|j}}{2m}$$
$$q_{ij} = \frac{(1 + \|z_i - z_j\|^2)^{-1}}{\sum_{k \neq l} (1 + \|z_k - z_l\|^2)^{-1}}$$

$\text{Perp}(P_i) = 2^{-\sum_j p_{j|i} \log_2 p_{j|i}}$ 控制有效鄰域尺度，再調整 σ_i 使其接近設定值。

高斯用來定義局部相似度，不表示整份資料必須服從高斯分布。

PCA、LLE 與 t-SNE 的實驗安排

- 壓縮／預測：用 PCA 的變異、重建誤差與下游驗證指標。
- 流形：Swiss roll 比較 LLE 的不同 `n_neighbors`，觀察錯接與局部重建。
- 視覺化：MNIST 子集先 PCA 到 50 維，再 t-SNE 到 2 維；比較種子與困惑度。

先 PCA 可減少 t-SNE 輸入成本，代價是先丟掉一些資訊。計時需包含兩步，不能保證固定加速倍數。

離堂檢核與作業

1. PCA 是選原始欄位，還是建立新座標？
2. 為什麼重建時要加回平均值？
3. t-SNE 上兩群相距兩倍，能否說原始距離也兩倍？

課後：Ch.7 練習 1-10；對同一資料呈現壓縮、視覺化與預測三種評估。