

分群與表示應用

第 9 週 | K-means、群數判斷、影像量化與少量標註

學習重點與成果

- 分群任務、K-means 目標與更新。
- 初始化、群數、輪廓係數與失敗案例。
- 影像分割、半監督學習與標註策略。

成果：能解釋群的意義、提出選 k 的證據與限制。


 **配套 Notebook**： `programs/notebooks/09_分群與表示應用.ipynb` 。程式片段、實際圖表與表格可由此檔重現。

程式實驗與實際輸出


```
km = KMeans(n_clusters=k, n_init=10)
score = silhouette_score(X, km.fit_predict(X))
```

觀察：inertia 會隨 k 下降，輪廓分數提供另一個群內緊密與群間分離的角度。

參考程式：`programs/notebooks/09_分群與表示應用.ipynb`



沒有標籤時，資料自己呈現什麼結構？




分類用已知答案學習；分群先依特徵相似性找結構，群編號不是已知類別。

分群可用於哪些任務？

- 探索顧客、文件或行為的相似群體。
- 推薦同群使用者偏好的內容，或縮小相似影像的搜尋候選集。
- 影像顏色量化與資料摘要。
- 建立距離型特徵，供後續分類或迴歸。
- 挑選代表樣本標註，協助半監督學習。


推薦與搜尋還需要排序與成效驗證；距離所有中心都遠，可作異常候選訊號。

K-means：把點指派給最近的中心



先指定 k ；模型交替估計中心位置與樣本所屬群。

最近中心形成 Voronoi 分區



邊界由等距位置決定；中心的改變會改變整個分區。

目標函數：最小化群內平方距離

$$I = \sum_{i=1}^m \|x_i - \mu_{c_i}\|^2$$

c_i 是第 i 筆的群編號； μ_{c_i} 是該群中心。


K-means 的慣性（inertia）越小，表示同一個 k 下群內更緊密。

兩步交替：指派與更新

$$c_i \leftarrow \arg \min_j \|x_i - \mu_j\|^2$$
$$\mu_j \leftarrow \frac{1}{|C_j|} \sum_{i \in C_j} x_i$$

直到指派或中心移動足夠小；空群需由實作重新初始化等策略處理。

觀察迭代：中心移動，群邊界跟著改變



每步固定另一部分再改善目標；可收斂到局部解，不保證全域最佳。

手算一維 K-means 的兩步

資料 $[0, 1, 4, 5]$ ，初始中心 $[0, 4]$ 。

1. 指派各點到最近中心。
2. 更新兩個平均中心。
3. 算更新前、後的 inertia，再看是否還會改群。

群編號沒有天然大小與固定語義

同一個合理分群，某次叫群 0，另一次可能叫群 2。

比較兩次分群時，不能直接把群編號當真實標籤計算 accuracy。

有外部標籤時，可用對編號置換不敏感的指標，例如 ARI；外部標籤仍不等於唯一正確分群。

K-means 的群號、距離與分數

```
from sklearn.cluster import KMeans
km = KMeans(n_clusters=5, n_init=10, random_state=42)
labels = km.fit_predict(X_train)
new_labels = km.predict(X_new)
distances = km.transform(X_new)
```

`labels_` 是訓練群號；`cluster_centers_` 是中心；`inertia_` 是訓練平方距離和。 `score(X)` 回傳負 inertia，並非分類 accuracy。


K-means 一輪更新的兩個步驟

給定中心 c_1, c_2 ，先把每筆資料指派到最近中心，再以群內平均更新中心：

$$a_i = \arg \min_k \|x_i - c_k\|^2, \quad c_k = \frac{1}{|C_k|} \sum_{i \in C_k} x_i$$

指派步驟固定中心，更新步驟固定群號；兩步都不增加群內平方和，但結果仍可能依初始化而不同。

不同初始化，可能得到不同局部解



重複啟動並比較 inertia；固定 random_state 方便重現。

K-means++ 與多次初始化

K-means++ 讓後續初始中心傾向遠離已選中心，降低一開始擠在一起的風險。

`n_init` 控制重跑次數；教學明確寫出數值，避免依賴版本預設。

```
from sklearn.cluster import KMeans
KMeans(n_clusters=5, init="k-means++",
       n_init=10, random_state=42)
```

K-means++ 的抽樣機率

先均勻隨機選第一個中心。令 D_i 為第 i 點到最近已選中心的距離：

$$P(\text{選第 } i \text{ 點}) = \frac{D_i^2}{\sum_j D_j^2}$$


例如距離為 `[0, 1, 3]`，抽樣機率為 `[0, 0.1, 0.9]`；較遠的点較容易入選，但不是每次都選最遠者。

先備中心可直接交給 `init=centers, n_init=1`；一般 K-means++ 仍可配多次重啟。

加速方式：避開多餘距離，或改用小批次


- Elkan：利用三角不等式與距離界線，減少重算；不保證每份資料都更快。
- MiniBatchKMeans：每次用小批次更新中心。
- 分批方法更省記憶體與時間，但 inertia 可能稍差。
- Lloyd 每輪約需 $O(mkn)$ ；總成本還乘上迭代與重啟次數。
- 資料超過記憶體時可分批 `partial_fit`；需自行安排初始化與批次。

k 選錯：可能切碎一群，或合併不同群




左圖 $k=3$ 合併了部分結構；右圖 $k=8$ 切出更多小群。先問切法是否符合分析任務。

肘部法：找 inertia 改善開始遞減的位置



inertia 隨 k 增加而下降；肘部可能不明顯，也可能不只一個，不能只選最小 inertia。

平均輪廓分數：把群內與群外距離一起比較



此圖最高值在 $k=4$ ；它與 inertia 的肘部可能給出不同線索，下一頁拆解計算公式。

輪廓係數：群內近，群外遠


$$s_i = \frac{b_i - a_i}{\max(a_i, b_i)}$$

a_i ：與同群其他點的平均距離。

b_i ：到每個其他群的平均距離中，最小的一個。

越接近 1 通常越清楚；接近 0 在邊界；負值可能指派不佳。

輪廓圖：不要只看整體平均




每群的寬度、負值與大小不均也值得檢查；虛線是整體平均參考。

手算輪廓係數，並質疑平均值

某點 $a = 2, b = 5$ ；另一點 $a = 4, b = 3$ 。

1. 各算輪廓係數。
2. 若平均很高但少數群很多負值，能直接宣布分群成功嗎？
3. 若一群只有一個樣本，為何需特別處理？

K-means 的限制：橢圓、密度與群大小差異



K-means 偏好近似等向、相近尺度的群；複雜形狀不宜硬套最近中心。

縮放之前，先定義什麼叫「相似」

收入、年齡、次數的單位不同，歐氏距離可能被大尺度欄位主導。

標準化是一個選擇；若某欄本來就應更重要，可以明確設定權重並驗證。

分群結果是「特徵、距離、演算法、超參數」共同決定的。

選群數：輪廓係數的意義

對單筆樣本， a 是同群平均距離， b 是最近其他群的平均距離：

$$s = \frac{b - a}{\max(a, b)}$$

例如 $a = 2, b = 5$ ，則 $s = (5 - 2)/5 = 0.6$ 。接近 1 表示更靠近本群；接近 0 表示位於邊界。
群數選擇仍需結合任務意義與群大小。

用 K-means 做顏色量化與影像分割



把每個像素的 RGB 當三維點，以群中心顏色取代原色；少量顏色能形成簡化影像。

顏色、語意與實例分割

任務	一個區域的意義	例子
顏色分割	類似顏色	瓢蟲的紅色、葉片的綠色
語意分割	同一物件類型	所有行人像素同屬「行人」
實例分割	同一個物件	行人 A、行人 B 分開標記

RGB K-means 只做顏色分組。小物件即使顏色醒目，也可能因像素太少被併入其他顏色群。

影像轉換的陣列形狀

```
# image: (height, width, 3), 數值尺度需一致
pixels = image.reshape(-1, 3)
km = KMeans(n_clusters=8, n_init=10, random_state=42)
labels = km.fit_predict(pixels)
segmented = km.cluster_centers_[labels].reshape(image.shape)
```

群中心代表典型顏色；此流程未利用像素位置與空間連續性。

把距離轉成新的特徵表示

$$\phi(x) = [\|x - \mu_1\|, \dots, \|x - \mu_k\|]$$

`KMeans.transform(X)` 得到每筆對各中心的距離；可交給後續監督模型。

中心也屬於學到的前處理，必須只從訓練資料建立。


只有 50 個標籤：先標哪些資料？

直接使用前 50 筆有標籤資料作基準；公平比較時也可重複隨機抽樣 50 筆。

另一個方法：先把未標註訓練集分成 50 群，每群選最靠近中心的樣本交由人標註。

群數不需要等於類別數；一個數字類別可能有多種書寫樣貌。

代表樣本：每群挑一張最接近中心的圖



人類只標這些代表樣本；群中心本身是平均向量，未必是一張真實圖。

代表樣本與標籤傳播的陣列操作

```
dist = km.fit_transform(X_unlabeled_train)
representative_idx = dist.argmin(axis=0)
# 逐張人工標註代表樣本，取得 y_representative
pseudo_y = y_representative[km.labels_]
own_dist = dist[np.arange(len(dist)), km.labels_]
```

每群依 `own_dist` 的中位數保留較近的一半，重新訓練分類器。群號不是類別答案，不可直接當成 `y`。

教材少量標註實驗：每一步改變了什麼？

策略	教材測試 accuracy	解讀
前 50 筆有標籤	75.8%	少標籤基準
50 個代表樣本	83.4%	標註選樣策略
傳播給全群	86.9%	增加偽標籤訓練資料
只傳播給較近的一半	88.4%	降低遠端錯誤傳播

標籤傳播需要「群內標籤一致」的假設

若某群混合不同真實類別，代表樣本的標籤可能傳錯整群。

可只使用靠近中心的樣本，或保留人工複核的不確定區域。

教材的 98.9% 是保留下來的「偽標籤正確率」，不是分類器測試 accuracy；真實無標籤資料無法直接知道此值。

LabelPropagation / LabelSpreading 使用相似圖；SelfTrainingClassifier 則反覆加入高信心偽標籤。

主動學習：讓模型提出下一筆標註需求

1. 使用目前標籤訓練模型。
2. 從未標註資料找出不確定、分歧或資訊量高的樣本。
3. 交由人類標註，再重新訓練。
4. 記錄標註成本與獨立驗證的改善。

實作與報告：群數不是一個神奇答案

對小型資料比較 $k=2$ 到 8，畫 inertia 與 silhouette。

挑兩個候選 k ，逐群報告大小、中心、代表樣本與可能意義。

離線組：對「收入×購買次數」的顧客群提出縮放與命名方案，列出不能推論的事情。

離堂檢核與下週預告

1. k 增加時 inertia 下降，為何還不能直接選最大 k ？
2. 輪廓係數的 b 是哪個距離？
3. 顏色分群為何不等於物件辨識？

下週：DBSCAN 處理不規則形狀；GMM 提供機率密度。課後：Ch.8 練習 1–5。

Notebook 導讀：從群中心走到標註策略

輸出	要解釋的現象
Lloyd 迭代、不同初始中心與 k	inertia 下降仍可能停在局部解
每群輪廓圖	平均以外的負值與群大小
50 張代表數字與部分傳播	標記預算、群內一致性、可信範圍
距離特徵 Pipeline、標註候選索引	每折重 fit；測試集不參與挑選

Notebook 使用內建 digits／flower 與合成資料。

顏色量化不等於語意分割；單次代表樣本結果不保證優於隨機標記。