

# 密度分群與機率模型

第 10 週 | DBSCAN、Gaussian Mixture、EM 與異常偵測

課堂主線 180 分鐘（含兩次 10 分鐘休息）；「選讀」頁安排課後或替換同段內容

## 本週成果與三段安排

---

0–50 分：密度鄰域、DBSCAN 與其他分群方法。

60–120 分：GMM、EM 與機率密度。

130–180 分：異常偵測、AIC／BIC、模型比較。

成果：能分清楚群機率、密度、異常分數與判定閾值。


 **配套 Notebook**： `programs/notebooks/10_密度分群與機率模型.ipynb` 。程式片段、實際圖表與表格可由此檔重現。

# 程式實驗與實際輸出

```
gmm = GaussianMixture(n_components=3)  
gmm.fit(X)
```

**觀察：** GMM 以機率描述橢圓形群集；共變異限制會改變模型自由度與邊界。

參考程式：`programs/notebooks/10_密度分群與機率模型.ipynb`



## DBSCAN：密集區域透過核心點連成一群

---

$\epsilon$  鄰域：距離不超過  $\epsilon$  的所有點。

- 核心點：鄰域樣本數（包含自己）至少 `min_samples`。
- 邊界點：不是核心，但位於某個核心點的鄰域。
- 雜訊點：不是核心，且不在任何核心點的鄰域。


## DBSCAN 的擴張與邊界點

---

1. 核心點連到鄰域內的其他核心點，持續向外擴張。
2. 鄰域中的非核心點加入群中，但不由它繼續擴張。
3. 最終不屬於任何核心鄰域的點，才標為雜訊 `-1`。

邊界點不能把兩個核心群串起來。若同時接近兩群，歸屬可能受走訪順序影響；最早暫標為雜訊的點，也可能稍後成為邊界點。

## 改變 $\text{eps}$ ：同一資料會從破碎變成連續



$\text{eps}$  太小可能切出大量小群與雜訊；太大可能把原本分開的群合併。

## 讀取 DBSCAN 結果

---

```
from sklearn.cluster import DBSCAN
db = DBSCAN(eps=0.2, min_samples=5).fit(X)
labels = db.labels_ # -1 表示雜訊
core_indices = db.core_sample_indices_
core_points = db.components_
```

先決定距離與特徵尺度，再選 eps；不同尺度不能共用同一數值。

## 手算鄰域：誰是核心，誰是雜訊？

---

一維點 `[0, .1, .2, .4, 2.0]`，`eps=.21`、`min_samples=3`。

1. 列出每點鄰域數（包含自己）。
2. 判定核心、邊界與雜訊。
3. 如果 `min_samples` 增加為 4，結果如何？



## DBSCAN 沒有原生 predict，延伸要另訂規則


---

`fit_predict` 是對參與分群的資料給群號。

新點可用核心點訓練近鄰分類器，但那是額外的分類規則。

只用近鄰會把很遠的點也分到某群；需要最大距離拒絕機制。

## 新點的延伸分類：距離過遠應拒絕



圖中的分類邊界來自後加的近鄰模型，不是 DBSCAN 自己的 predict。

## 密度與階層方法：結構假設不同

---

| 方法            | 主要概念       | 限制                     |
|---------------|------------|------------------------|
| DBSCAN        | 核心點連接、辨識雜訊 | 密度差異與高維距離；鄰域儲存最差可達平方規模 |
| HDBSCAN       | 考慮多尺度密度結構  | 仍需設定與評估                |
| Agglomerative | 由小群逐步合併    | 連結方式與距離影響結果            |
| BIRCH         | 壓縮群摘要形成樹   | 適合大資料，仍受維度影響           |

## 階層式分群補充：連結方式決定合併順序

---

Single linkage：兩群最近點的距離，容易形成鏈狀。

Complete linkage：兩群最遠點距離，偏向緊密群。

Average linkage：跨群點對距離的平均。

Ward：選增加群內平方誤差最少的合併，搭配歐氏幾何。

## 樹狀圖的合併高度與切群

以一維 `[0,1,4,6]` 、single linkage 為例：

| 合併            | 高度（距離） | 剩餘群數 |
|---------------|--------|------|
| 0 與 1         | 1      | 3    |
| 4 與 6         | 2      | 2    |
| {0,1} 與 {4,6} | 3      | 1    |

在高度 2 與 3 之間切開得到兩群。凝聚式由單點往上合併，分裂式由全集往下拆分；樹狀圖高度代表合併準則，不是節點深度。

## Mean-shift、代表點與相似圖分群

---

| 方法                   | 做法           | 需注意                 |
|----------------------|--------------|---------------------|
| Mean-shift           | 移動視窗到局部高密度位置 | bandwidth影響大；大資料成本高 |
| Affinity propagation | 訊息交換選代表樣本    | 不先指定k，但仍有偏好等參數      |
| Spectral clustering  | 相似圖降維後再分群    | 圖與相似度設定、樣本規模        |

## 休息 10 分鐘

---

離開座位、休息眼睛。回來後先用一句話回答上一段的核心問題。

## GMM：先選一個成分，再從該高斯分布取樣

---

$$P(z = j) = \pi_j, \quad x \mid z = j \sim \mathcal{N}(\mu_j, \Sigma_j)$$

$$p(x) = \sum_{j=1}^k \pi_j \mathcal{N}(x \mid \mu_j, \Sigma_j), \quad \sum_j \pi_j = 1$$

每個成分有權重、中心與共變異；群可以是不同方向、大小的橢圓。



## 多變量高斯：平均與共變異各控制什麼？


---

$$\mathcal{N}(x \mid \mu, \Sigma) = \frac{\exp[-\frac{1}{2}(x - \mu)^T \Sigma^{-1}(x - \mu)]}{(2\pi)^{n/2} |\Sigma|^{1/2}}$$

$\mu$  控制中心； $\Sigma$  控制各方向的寬度與相關性。

完整共變異須可逆；實務加小的對角正則項避免退化。

## GMM 同時給群邊界與密度等高線



橢圓形密度符合此合成資料；這是模型假設適合資料的例子。

## EM 的 E-step：每個成分分擔多少責任？

---

$$r_{ij} = P(z_i = j \mid x_i) = \frac{\pi_j \mathcal{N}(x_i \mid \mu_j, \Sigma_j)}{\sum_l \pi_l \mathcal{N}(x_i \mid \mu_l, \Sigma_l)}$$

每列責任值加總為 1；點可部分屬於多個成分，稱為軟指派。

## EM 的 M-step：用責任值重新估計參數

---

$$N_j = \sum_i r_{ij}, \quad \pi_j = \frac{N_j}{m}, \quad \mu_j = \frac{\sum_i r_{ij} x_i}{N_j}$$
$$\Sigma_j = \frac{1}{N_j} \sum_i r_{ij} (x_i - \mu_j)(x_i - \mu_j)^T$$

高責任值的樣本對該成分影響較大；反覆 E、M 直到收斂。

## K-means 與 GMM 的更新差異

| 比較 | K-means     | GMM 的 EM          |
|----|-------------|-------------------|
| 指派 | 最近中心，一筆一群   | 後驗責任值，總和為 1       |
| 更新 | 群內平均        | 責任值加權的平均、共變異、混合權重 |
| 目標 | 降低平方距離      | 提高資料對數似然          |
| 形狀 | 歐氏幾何的最近中心區域 | 可學橢圓、方向與寬度        |

在等權重、同球形共變異且變異趨近零的特定極限下，GMM 指派趨近最近中心；兩者並非任意設定都等價。

## 手算軟指派與更新

---

E-step：兩成分權重皆 .5，某點的密度為 .2 與 .05；責任值各多少？

M-step：資料  $[0, 2]$ ，成分 A 的責任值  $[.8, .2]$ 。計算  $N_A$ 、新權重、平均與變異。

## 收斂不等於找到全域最優

---

EM 可卡在不好的局部解；使用多次初始化並比較最終似然。

```
from sklearn.mixture import GaussianMixture
gm = GaussianMixture(n_components=3, n_init=10,
                     covariance_type="full", random_state=42)
gm.fit(X_train)
print(gm.converged_, gm.n_iter_)
```

## 選讀 | 手刻 EM 的數值穩定性

---

先在 log 空間計算  $a_{ij} = \log \pi_j + \log \mathcal{N}(x_i \mid \mu_j, \Sigma_j)$ ：

$$\log p(x_i) = \log \text{sumexp}_j(a_{ij}), \quad r_{ij} = e^{a_{ij} - \log \text{sumexp}_l(a_{il})}$$


- 先算極小密度再取 log，可能早已下溢，事後加小常數無法恢復資訊。
- M-step 檢查  $N_j$  是否接近零，共變異加對角正則項。
- 理想 EM 不降低似然；明顯下降需查數值、目標或實作。



## 限制共變異：容量與成本的折衷

| covariance_type | 可表示的形狀     | 共變異參數數量           |
|-----------------|------------|-------------------|
| full            | 每群任意橢圓     | 每群 $n(n + 1)/2$   |
| tied            | 所有群共用同一橢圓  | 全部共用 $n(n + 1)/2$ |
| diag            | 每群軸平行橢圓    | 每群 $n$            |
| spherical       | 每群球形、大小可不同 | 每群 1              |

## tied 與 spherical：限制形狀會改變結果



不同共變異假設讓模型更簡單；是否值得，要看擬合與驗證證據。

## 休息 10 分鐘

---

離開座位、休息眼睛。回來後先用一句話回答上一段的核心問題。


## 機率、密度與生成：三個 API 回答不同問題

---

- `predict_proba(X)`：每筆屬於各成分の後驗機率。
- `score_samples(X)`：每筆的對數機率密度。
- `sample(n)`：從學到的混合分布生成新樣本。

密度可大於 1；區域機率需要對該區域積分，不能把密度當成單點機率。

## 低密度異常：先估分數，再選閾值



教材用第 2 百分位作閾值，約標出 2% 的訓練樣本；這不是偵測成功率。

## 異常閾值如何決定？

---

```
log_density = gm.score_samples(X_train)
threshold = np.percentile(log_density, 2)
flag = gm.score_samples(X_new) < threshold
```

比例應由可接受誤報、漏報與可複核量決定；用有標註驗證資料校準更有依據。


## 離群偵測與新穎偵測的資料假設

---

| 任務                       | 訓練資料         | 要判斷什麼         |
|--------------------------|--------------|---------------|
| 離群偵測 (outlier detection) | 可能混入少量異常     | 找出偏離主要模式的樣本   |
| 新穎偵測 (novelty detection) | 假設主要是乾淨的正常資料 | 新資料是否偏離已知正常分布 |

GMM 會嘗試解釋所有訓練資料；污染過多時，可能把異常學成正常成分。低密度只是模型的異常訊號，仍要複核。

# Likelihood：固定資料，比較不同參數



機率密度是固定參數看  $x$ ；似然是固定已觀測  $x$  看參數，後者不必對參數積分為 1。



## 最大似然與 MAP：從乘積改成對數和

---

$$\ell(\theta) = \sum_i \log p(x_i \mid \theta), \quad \hat{\theta}_{\text{MLE}} = \arg \max_{\theta} \ell(\theta)$$

MAP 再加入先驗：最大化  $\ell(\theta) + \log p(\theta)$ 。

對數是單調的，最大化位置不變；也能避免許多小數連乘下溢。

## AIC 與 BIC：擬合收益要付出複雜度代價

---

$$\text{AIC} = 2p - 2 \log \hat{\mathcal{L}}, \quad \text{BIC} = p \log m - 2 \log \hat{\mathcal{L}}$$

$p$  是自由參數數量， $m$  是樣本數；同一資料與可比較模型之間越小越好。

不要用 K-means 的 inertia 直接選橢圓 GMM。

## GMM 的自由參數如何計數

---

$k$  個成分、每筆  $n$  維資料：平均值有  $kn$  個參數，混合權重有  $k - 1$  個自由度。

$$p_{\text{full}} = kn + (k - 1) + k \frac{n(n + 1)}{2}$$

二維、三成分、full 共變異： $p = 6 + 2 + 9 = 17$ 。

`gm.aic(X)`、`gm.bic(X)` 需在相同資料與特徵尺度比較。完整共變異每輪成本約  $O(kmn^2 + kn^3)$ ，高維時可考慮 diag 或 PCA。

## 數例：比較兩個 GMM 的複雜度代價

---


同樣  $m = 100$ ：A 有  $p = 5, \ell = -100$ ；B 有  $p = 8, \ell = -96$ 。

AIC：A=210、B=208，偏好 B。

BIC：A $\approx$ 223.03、B $\approx$ 228.84，偏好 A。

準則可能不一致；BIC 在此對參數增加的懲罰更大。

## 同時搜尋成分數與共變異假設



圖例展示不同  $k$  的準則；真正比較時也可納入 `covariance_type`。

## Bayesian GMM：給成分上限，讓權重收縮


---

`BayesianGaussianMixture` 可使不必要成分的權重接近零。

`n_components` 是上限；先驗、初始化與資料仍會影響有效成分數。

它不保證自動找到唯一、真實的群數。

## 彎月資料：多個高斯也可能切出很多小橢圓



密度估計可以有用途，但得到八個成分不代表資料語義上有八群。

## 異常與新穎偵測方法概覽

| 方法                        | 主要訊號      | 假設或注意         |
|---------------------------|-----------|---------------|
| EllipticEnvelope／Fast-MCD | 穩健橢圓範圍    | 正常資料近單一高斯     |
| Isolation Forest          | 較少分割即可隔離  | 適合比較稀有、容易隔離的點 |
| LOF                       | 相對鄰居的局部密度 | 新資料用途需正確模式    |
| One-class SVM             | 學正常資料的邊界  | 縮放、核與超參數影響大   |



## 用重建誤差找異常：接回上一週的 PCA

---

$$e_i = \frac{1}{n} \|x_i - \text{inverse\_transform}(\text{transform}(x_i))\|^2$$

在正常資料表示下難以重建的點，可能有較高誤差。

先用訓練／驗證資料設定閾值；正常但罕見的樣本也可能被標出。

## 選模工作單：形狀、機率與用途一起決定

---

A：兩條彎月且有少數孤立點。

B：方向不同的橢圓群，需要每點的群機率。

C：高維表格資料，要篩出待人工複核的少數樣本。

各選一個起點、兩個超參數或假設檢查，以及一個失敗風險。

## 離堂檢核與作業

---

1. 邊界點可以把兩個核心群串成一群嗎？
2. 責任值與機率密度有何差別？
3. 設定 2% 閾值，是否代表能抓到 98% 異常？

課後：Ch.8 練習 6-13；比較 K-means、DBSCAN 與 GMM 的失敗案例。