

密度分群與機率模型

第 10 週 | DBSCAN、Gaussian Mixture、EM 與異常偵測

學習重點與成果

- 密度鄰域、DBSCAN 與其他分群方法。
- GMM、EM 與機率密度。
- 異常偵測、AIC／BIC、模型比較。

成果：能分清楚群機率、密度、異常分數與判定閾值。

 **配套 Notebook**： `programs/notebooks/10_密度分群與機率模型.ipynb` 。程式片段、實際圖表與表格可由此檔重現。

DBSCAN：密集區域透過核心點連成一群

ϵ 鄰域：距離不超過 ϵ 的所有點。


- 核心點：鄰域樣本數（包含自己）至少 `min_samples`。
- 邊界點：不是核心，但位於某個核心點的鄰域。
- 雜訊點：不是核心，且不在任何核心點的鄰域。

DBSCAN 的擴張與邊界點

1. 核心點連到鄰域內的其他核心點，持續向外擴張。
2. 鄰域中的非核心點加入群中，但不由它繼續擴張。
3. 最終不屬於任何核心鄰域的點，才標為雜訊 -1。

邊界點不能把兩個核心群串起來。若同時接近兩群，歸屬可能受走訪順序影響；最早暫標為雜訊的點，也可能稍後成為邊界點。

改變 eps ：同一資料會從破碎變成連續



eps 太小可能切出大量小群與雜訊；太大可能把原本分開的群合併。

讀取 DBSCAN 結果

```
from sklearn.cluster import DBSCAN
db = DBSCAN(eps=0.2, min_samples=5).fit(X)
labels = db.labels_ # -1 表示雜訊
core_indices = db.core_sample_indices_
core_points = db.components_
```

先決定距離與特徵尺度，再選 eps；不同尺度不能共用同一數值。

手算鄰域：誰是核心，誰是雜訊？

一維點 `[0, .1, .2, .4, 2.0]`，`eps=.21`、`min_samples=3`。

1. 列出每點鄰域數（包含自己）。
2. 判定核心、邊界與雜訊。
3. 如果 `min_samples` 增加為 4，結果如何？


DBSCAN 沒有原生 predict，延伸要另訂規則

`fit_predict` 是對參與分群的資料給群號。

新點可用核心點訓練近鄰分類器，但那是額外的分類規則。

只用近鄰會把很遠的點也分到某群；需要最大距離拒絕機制。

新點的延伸分類：距離過遠應拒絕



圖中的分類邊界來自後加的近鄰模型，不是 DBSCAN 自己的 predict。

密度與階層方法：結構假設不同

方法	主要概念	限制
DBSCAN	核心點連接、辨識雜訊	密度差異與高維距離；鄰域儲存最差可達平方規模
HDBSCAN	考慮多尺度密度結構	仍需設定與評估
Agglomerative	由小群逐步合併	連結方式與距離影響結果
BIRCH	壓縮群摘要形成樹	適合大資料，仍受維度影響

階層式分群補充：連結方式決定合併順序

Single linkage：兩群最近點的距離，容易形成鏈狀。

Complete linkage：兩群最遠點距離，偏向緊密群。

Average linkage：跨群點對距離的平均。

Ward：選增加群內平方誤差最少的合併，搭配歐氏幾何。

樹狀圖的合併高度與切群

以一維 `[0,1,4,6]` 、single linkage 為例：

合併	高度（距離）	剩餘群數
0 與 1	1	3
4 與 6	2	2
{0,1} 與 {4,6}	3	1

在高度 2 與 3 之間切開得到兩群。凝聚式由單點往上合併，分裂式由全集往下拆分；樹狀圖高度代表合併準則，不是節點深度。

Mean-shift、代表點與相似圖分群

方法	做法	需注意
Mean-shift	移動視窗到局部高密度位置	bandwidth影響大；大資料成本高
Affinity propagation	訊息交換選代表樣本	不先指定k，但仍有偏好等參數
Spectral clustering	相似圖降維後再分群	圖與相似度設定、樣本規模

DBSCAN：核心點、邊界點與雜訊

設定半徑 ε 與 `min_samples` 後：

- 核心點的 ε 鄰域內達到最少樣本數。
- 邊界點本身未達門檻，但落在某核心點的鄰域中。
- 既不是核心點也無法由核心點連到的樣本，標為雜訊。

調大 ε 可能合併群，調高 `min_samples` 可能增加雜訊；要一起檢查縮放與距離定義。

GMM：先選一個成分，再從該高斯分布取樣

$$P(z = j) = \pi_j, \quad x \mid z = j \sim \mathcal{N}(\mu_j, \Sigma_j)$$

$$p(x) = \sum_{j=1}^k \pi_j \mathcal{N}(x \mid \mu_j, \Sigma_j), \quad \sum_j \pi_j = 1$$

每個成分有權重、中心與共變異；群可以是不同方向、大小的橢圓。


多變量高斯：平均與共變異各控制什麼？

$$\mathcal{N}(x \mid \mu, \Sigma) = \frac{\exp[-\frac{1}{2}(x - \mu)^T \Sigma^{-1}(x - \mu)]}{(2\pi)^{n/2} |\Sigma|^{1/2}}$$

μ 控制中心； Σ 控制各方向的寬度與相關性。

完整共變異須可逆；實務加小的對角正則項避免退化。

GMM 同時給群邊界與密度等高線



橢圓形密度符合此合成資料；這是模型假設適合資料的例子。

EM 的 E-step：每個成分分擔多少責任？

$$r_{ij} = P(z_i = j \mid x_i) = \frac{\pi_j \mathcal{N}(x_i \mid \mu_j, \Sigma_j)}{\sum_l \pi_l \mathcal{N}(x_i \mid \mu_l, \Sigma_l)}$$

每列責任值加總為 1；點可部分屬於多個成分，稱為軟指派。

EM 的 M-step：用責任值重新估計參數

$$N_j = \sum_i r_{ij}, \quad \pi_j = \frac{N_j}{m}, \quad \mu_j = \frac{\sum_i r_{ij} x_i}{N_j}$$
$$\Sigma_j = \frac{1}{N_j} \sum_i r_{ij} (x_i - \mu_j)(x_i - \mu_j)^T$$

高責任值的樣本對該成分影響較大；反覆 E、M 直到收斂。

K-means 與 GMM 的更新差異

比較	K-means	GMM 的 EM
指派	最近中心，一筆一群	後驗責任值，總和為 1
更新	群內平均	責任值加權的平均、共變異、混合權重
目標	降低平方距離	提高資料對數似然
形狀	歐氏幾何的最近中心區域	可學橢圓、方向與寬度

在等權重、同球形共變異且變異趨近零的特定極限下，GMM 指派趨近最近中心；兩者並非任意設定都等價。

手算軟指派與更新

E-step：兩成分權重皆 .5，某點的密度為 .2 與 .05；責任值各多少？

M-step：資料 $[0, 2]$ ，成分 A 的責任值 $[.8, .2]$ 。計算 N_A 、新權重、平均與變異。

收斂不等於找到全域最優

EM 可卡在不好的局部解；使用多次初始化並比較最終似然。

```
from sklearn.mixture import GaussianMixture
gm = GaussianMixture(n_components=3, n_init=10,
                     covariance_type="full", random_state=42)
gm.fit(X_train)
print(gm.converged_, gm.n_iter_)
```

選讀 | 手刻 EM 的數值穩定性

先在 $\log$ 空間計算 $a_{ij} = \log \pi_j + \log \mathcal{N}(x_i \mid \mu_j, \Sigma_j)$ ：


$$\log p(x_i) = \log \text{sumexp}_j(a_{ij}), \quad r_{ij} = e^{a_{ij} - \log \text{sumexp}_l(a_{il})}$$

- 先算極小密度再取 $\log$ ，可能早已下溢，事後加小常數無法恢復資訊。
- M-step 檢查 N_j 是否接近零，共變異加對角正則項。
- 理想 EM 不降低似然；明顯下降需查數值、目標或實作。

限制共變異：容量與成本的折衷

covariance_type	可表示的形狀	共變異參數數量
full	每群任意橢圓	每群 $n(n + 1)/2$
tied	所有群共用同一橢圓	全部共用 $n(n + 1)/2$
diag	每群軸平行橢圓	每群 n
spherical	每群球形、大小可不同	每群 1

tied 與 spherical：限制形狀會改變結果



不同共變異假設讓模型更簡單；是否值得，要看擬合與驗證證據。

從橢圓方向檢查 GMM 的形狀假設


對 700 個二維合成點，固定三個成分，使用 `full` 共變異擬合。

```
gm = GaussianMixture(n_components=3,  
    covariance_type="full", n_init=10,  
    random_state=42).fit(G)
```

兩軸為合成特徵。點色是最大責任值的成分，紅線示範各成分的共變異形狀，灰線是混合密度等高線。

若改成 `diag`，哪些傾斜形狀無法保留？自由度較多是否就應直接選 `full`？

參考程式：`programs/notebooks/10_密度分群與機率模型.ipynb`




機率、密度與生成：三個 API 回答不同問題

- `predict_proba(X)`：每筆屬於各成分の後驗機率。
- `score_samples(X)`：每筆的對數機率密度。
- `sample(n)`：從學到的混合分布生成新樣本。

密度可大於 1；區域機率需要對該區域積分，不能把密度當成單點機率。

低密度異常：先估分數，再選閾值



教材用第 2 百分位作閾值，約標出 2% 的訓練樣本；這不是偵測成功率。

異常閾值如何決定？

```
log_density = gm.score_samples(X_train)
threshold = np.percentile(log_density, 2)
flag = gm.score_samples(X_new) < threshold
```


比例應由可接受誤報、漏報與可複核量決定；用有標註驗證資料校準更有依據。

離群偵測與新穎偵測的資料假設

任務	訓練資料	要判斷什麼
離群偵測 (outlier detection)	可能混入少量異常	找出偏離主要模式的樣本
新穎偵測 (novelty detection)	假設主要是乾淨的正常資料	新資料是否偏離已知正常分布

GMM 會嘗試解釋所有訓練資料；污染過多時，可能把異常學成正常成分。低密度只是模型的異常訊號，仍要複核。

Likelihood：固定資料，比較不同參數



機率密度是固定參數看 x ；似然是固定已觀測 x 看參數，後者不必對參數積分為 1。

最大似然與 MAP：從乘積改成對數和

$$\ell(\theta) = \sum_i \log p(x_i \mid \theta), \quad \hat{\theta}_{\text{MLE}} = \arg \max_{\theta} \ell(\theta)$$

MAP 再加入先驗：最大化 $\ell(\theta) + \log p(\theta)$ 。

對數是單調的，最大化位置不變；也能避免許多小數連乘下溢。

AIC 與 BIC：擬合收益要付出複雜度代價

$$\text{AIC} = 2p - 2 \log \hat{\mathcal{L}}, \quad \text{BIC} = p \log m - 2 \log \hat{\mathcal{L}}$$

p 是自由參數數量， m 是樣本數；同一資料與可比較模型之間越小越好。

不要用 K-means 的 inertia 直接選橢圓 GMM。

GMM 的自由參數如何計數

k 個成分、每筆 n 維資料：平均值有 kn 個參數，混合權重有 $k - 1$ 個自由度。

$$p_{\text{full}} = kn + (k - 1) + k \frac{n(n + 1)}{2}$$

二維、三成分、full 共變異： $p = 6 + 2 + 9 = 17$ 。

`gm.aic(X)`、`gm.bic(X)` 需在相同資料與特徵尺度比較。完整共變異每輪成本約 $O(kmn^2 + kn^3)$ ，高維時可考慮 diag 或 PCA。

數例：比較兩個 GMM 的複雜度代價


同樣 $m = 100$ ：A 有 $p = 5, \ell = -100$ ；B 有 $p = 8, \ell = -96$ 。

AIC：A=210、B=208，偏好 B。

BIC：A $\approx$ 223.03、B $\approx$ 228.84，偏好 A。

準則可能不一致；BIC 在此對參數增加的懲罰更大。

同時搜尋成分數與共變異假設



圖例展示不同 k 的準則；真正比較時也可納入 `covariance_type`。


Bayesian GMM：給成分上限，讓權重收縮

`BayesianGaussianMixture` 可使不必要成分的權重接近零。

`n_components` 是上限；先驗、初始化與資料仍會影響有效成分數。

它不保證自動找到唯一、真實的群數。

彎月資料：多個高斯也可能切出很多小橢圓



密度估計可以有用途，但得到八個成分不代表資料語義上有八群。

異常與新穎偵測方法概覽

方法	主要訊號	假設或注意
EllipticEnvelope／Fast-MCD	穩健橢圓範圍	正常資料近單一高斯
Isolation Forest	較少分割即可隔離	適合比較稀有、容易隔離的點
LOF	相對鄰居的局部密度	新資料用途需正確模式
One-class SVM	學正常資料的邊界	縮放、核與超參數影響大

用重建誤差找異常：接回上一週的 PCA

$$e_i = \frac{1}{n} \|x_i - \text{inverse_transform}(\text{transform}(x_i))\|^2$$

在正常資料表示下難以重建的點，可能有較高誤差。

先用訓練／驗證資料設定閾值；正常但罕見的樣本也可能被標出。

選模工作單：形狀、機率與用途一起決定

A：兩條彎月且有少數孤立點。

B：方向不同的橢圓群，需要每點的群機率。

C：高維表格資料，要篩出待人工複核的少數樣本。

各選一個起點、兩個超參數或假設檢查，以及一個失敗風險。

離堂檢核與作業

1. 邊界點可以把兩個核心群串成一群嗎？
2. 責任值與機率密度有何差別？
3. 設定 2% 閾值，是否代表能抓到 98% 異常？

課後：Ch.8 練習 6-13；比較 K-means、DBSCAN 與 GMM 的失敗案例。

Notebook 導讀：生成、選模與異常分數

程式輸出	判讀重點
DBSCAN 延伸分區與拒絕區	外加規則，不是原生 predict
共變異等高線、EM 軌跡	形狀假設；收斂仍可能是局部解
似然／先驗曲線與 AIC／BIC	固定資料比較參數，並支付複雜度代價
階層樹、彎月 GMM、新穎偵測	成分不等於語意群；校準與測試分開

Notebook 的尾端 2% 是異常標記示範，不是模型正確率。

PCA 範例的保留正常資料用於校準；獨立測試另以合成例示範。