

深層神經網路訓練

梯度穩定與遷移學習

書本第 11 章（上） | 含第 10 章必要的 PyTorch 銜接

180 分鐘，含兩次 10 分鐘休息

本次成果與節奏

- **0-50 分**：讀懂 PyTorch 訓練步驟，解釋梯度與初始化。
- **60-120 分**：比較激活函數，手算 BatchNorm 與 LayerNorm。
- **130-180 分**：梯度裁剪、遷移學習與實驗設計。

成果：能指出訓練流程的錯誤，並用證據選擇改善方法。

「選讀」頁可課後閱讀，或替換同段講解。程式以讀碼為主。


 **配套 Notebook**： `programs/notebooks/12_深層神經網路訓練_梯度與遷移.ipynb` 。程式片段、實際圖表與表格可由此檔重現。

程式實驗與實際輸出

```
clipped = g * min(1, max_norm / norm(g))
```

觀察：13 的梯度範數裁剪為 5；圖顯示多層小導數連乘會快速縮小反向訊號。

參考程式：`programs/notebooks/12_深層神經網路訓練_梯度與遷移.ipynb`



課程位置：ANN、PyTorch 與深層訓練

書本章節	問題	本課銜接
Ch.9 人工神經網路	網路如何表示函數、計算梯度？	已有 11_人工神經網路入門.md
Ch.10 PyTorch	如何建立模型、迭代訓練與評估？	先補本章範例需要的操作
Ch.11 深層訓練	加深以後，如何穩定、加速與泛化？	本份及下一份的主線

前一份的激活、Dropout 等選讀是預告；本次補上原理與操作。

PyTorch 銜接：資料形狀與角色

本章沿用 Fashion MNIST：28×28 灰階影像、10 個互斥類別。

物件	形狀／型態	角色
<code>X_batch</code>	<code>[B, 1, 28, 28]</code> 浮點數	前處理後的影像
<code>y_batch</code>	<code>[B]</code> ， <code>torch.long</code>	0-9 的類別索引
<code>model(X_batch)</code>	<code>[B, 10]</code> 浮點數	未正規化的 logits
<code>DataLoader</code>	逐批回傳 <code>(X_batch, y_batch)</code>	訓練可打散，驗證固定

訓練集學參數，驗證集選設定，測試集留到最後。

PyTorch 銜接：最小分類模型

```
import torch
from torch import nn

device = torch.device("cpu") # 讀碼與小型示範可用 CPU
model = nn.Sequential(
    nn.Flatten(), nn.Linear(784, 100), nn.ReLU(),
    nn.Linear(100, 10)
).to(device)
loss_fn = nn.CrossEntropyLoss()
optimizer = torch.optim.SGD(model.parameters(), lr=0.01)
```

CrossEntropyLoss 直接接 logits，模型末端不另加 Softmax。

選讀 | Keras 舊例：輸出與損失要一起看

Keras 原 Notebook

(`programs/upstream/MachineLearning2025/06_neural_nets_with_keras.ipynb`)：搜尋 `sparse_categorical_crossentropy`。

```
# 原碼摘錄：最後一層 (cell 43) 與訓練設定 (cell 54)
keras.layers.Dense(10, activation="softmax")
model.compile(loss="sparse_categorical_crossentropy",
              optimizer="sgd", metrics=["accuracy"])
```

舊例輸出機率配對交叉熵；本課 PyTorch 輸出 logits 配對 `CrossEntropyLoss`。

換框架時，要連同輸出層、損失函數與標籤格式一起檢查。

PyTorch 銜接：一次批次更新

```
model.train()
for X_batch, y_batch in train_loader:
    X_batch = X_batch.to(device)
    y_batch = y_batch.to(device)
    optimizer.zero_grad(set_to_none=True)
    logits = model(X_batch)
    loss = loss_fn(logits, y_batch)
    loss.backward()
    optimizer.step()
```

`backward()` 計算並累積梯度，`step()` 才更新參數。

PyTorch 銜接：驗證與訓練模式

```
model.eval()
loss_sum, n = 0.0, 0
with torch.no_grad():
    for X_batch, y_batch in valid_loader:
        X_batch, y_batch = X_batch.to(device), y_batch.to(device)
        loss = loss_fn(model(X_batch), y_batch)
        loss_sum += loss.item() * len(y_batch)
        n += len(y_batch)
val_loss = loss_sum / n
```

`eval()` 切換 BN／Dropout 行為，`no_grad()` 關閉梯度紀錄。

讀碼檢核：哪一步需要修正？

1. 在 `CrossEntropyLoss` 前先做 `Softmax`。
 2. 每批只呼叫 `backward()`，整堂課都沒清除梯度。
 3. 用 `no_grad()` 驗證，卻忘記 `model.eval()`。
 4. 每個 epoch 用測試 accuracy 決定是否換模型。
- 兩人一組，各選一項說明「會發生什麼」及「如何改」。

選讀 | 手刻 MLP：前向、反向與參數更新

開啟手刻 MNIST 原程式

(`programs/upstream/MachineLearning2025/06_ANN_from_Scratch_MNIST.py`) : `train()` , L265–276 。

```
# 原碼摘錄；上方已完成forward()與backward()  
model.weight_h -= learning_rate * d_loss__d_w_h  
model.bias_h -= learning_rate * d_loss__d_b_h  
model.weight_out -= learning_rate * d_loss__d_w_out  
model.bias_out -= learning_rate * d_loss__d_b_out
```

四行就是基本 SGD 更新，對照本課的 `optimizer.step()` 。


原模型採 Sigmoid+平方損失，不能只換成 Softmax 卻沿用原反向公式。

深層網路的四個訓練困難

- **梯度不穩定**：前面層學不到，或參數更新突然失控。
- **標註資料不足**：大模型很快記住少量訓練樣本。
- **訓練太慢**：有梯度，卻需要很多次更新。
- **泛化不足**：訓練誤差下降，驗證誤差反而上升。

先判斷問題類型，再選方法；同一現象可能有多種原因。

圖 11-1：Sigmoid 飽和與小梯度



輸入落在曲線兩端時，輸出幾乎不變，導數接近 0。

梯度為何會消失或爆炸？

$$\delta^{(l)} = \left(\delta^{(l+1)} W^{(l+1)T} \right) \odot \phi'_l(Z^{(l)})$$

反向傳播跨越多層時，反覆乘上權重與激活導數。

僅看十層 Sigmoid 導數的上界： $(1/4)^{10} \approx 9.54 \times 10^{-7}$ 。

這個數字示範縮小效應。完整梯度還取決於權重、分支與資料。

表 11-1：初始化尺度與激活函數

fan_{in} 是輸入數， fan_{out} 是輸出數。

初始化	書中配對	常態分布的變異數 σ^2
Glorot/Xavier	線性、tanh、sigmoid、softmax	$2/(\text{fan}_{in} + \text{fan}_{out})$
He/Kaiming	ReLU 及書中列出的變體	$2/\text{fan}_{in}$
LeCun	SELU	$1/\text{fan}_{in}$

若用均勻分布 $U(-r, r)$ ，則 $r = \sqrt{3\sigma^2}$ 。

初始化手算：100 個輸入、50 個輸出

方法	σ^2	標準差 σ
Glorot	$2/(100 + 50)$	?
He	$2/100$	?
LeCun	$1/100$	?

如果把同一個隨機值填滿整層權重，是否已經打破對稱？

PyTorch：隱藏層與輸出層分開初始化

```
# 沿用前面的784→100→10模型
nn.init.kaiming_normal_(model[1].weight, nonlinearity="relu")
nn.init.zeros_(model[1].bias)
nn.init.xavier_normal_(model[3].weight)
nn.init.zeros_(model[3].bias)
```

隱藏層接 ReLU，輸出層提供 logits，兩者的角色不同。

不要在每個 epoch 重做初始化，否則會清除已學到的參數。

選讀 | 手刻 MLP 的初始化尺度

原程式的 `__init__` (`programs/upstream/MachineLearning2025/06_ANN_from_Scratch_MNIST.py`) : L94-102。

```
# 原碼摘錄：scale是標準差
rng = np.random.RandomState(random_seed)
self.weight_h = rng.normal(
    loc=0.0, scale=0.1, size=(num_hidden, num_features))
self.bias_h = np.zeros(num_hidden)
```

原模型 784 個輸入、50 個隱藏單元，固定 $\sigma = 0.1$ 。


Glorot 對此層給 $\sigma = \sqrt{2/(784 + 50)} \approx 0.049$ 。

兩者不同：初始化尺度應連同激活函數、層寬與深度比較。

休息 10 分鐘

回來後討論：換成 ReLU，是否就不會遇到梯度問題？

圖 11-2：Leaky ReLU 保留負半軸斜率



$\text{LeakyReLU}(z) = \max(\alpha z, z)$ ，通常 $0 < \alpha < 1$ 。

ReLU 變體與初始化配對


激活	負半軸怎麼處理？	PyTorch
ReLU	設為 0	<code>nn.ReLU()</code>
Leaky ReLU	固定斜率 α	<code>nn.LeakyReLU(0.2)</code>
PReLU	斜率也是待學參數	<code>nn.PReLU()</code>
RReLU	訓練時抽樣斜率，推論固定	<code>nn.RReLU()</code>

Leaky ReLU 的 He 變異數可調為 $2/[(1 + \alpha^2)\text{fan}_{in}]$ 。

原程式：Leaky ReLU 與導數

(`programs/upstream/MachineLearning2025/06_Activation_functions.py`) (L30–34)，比較 `alpha=0.05` 與本頁的 `0.2`。

圖 11-3：ELU 與 SELU




ELU 允許負值並逐漸飽和；SELU 再調整整體尺度。

SELU 自我正規化的條件

- 使用連續堆疊的全連接隱藏層，並採用 SELU。
- 輸入先標準化，隱藏權重使用 **LeCun normal**。
- 避免任意混入 BN、LN 或一般 Dropout 後仍宣稱自我正規化。
- 需要 Dropout 時，搭配保留分布特性的 `nn.AlphaDropout`。

這是一組有條件的設計，不能只把 ReLU 名稱改成 SELU。

圖 11-4：平滑激活函數的差異



比較負半軸、零點附近與大正值區域；曲線不同會改變梯度。

GELU、SiLU、Mish 與 ReLU²

函數	定義	實作／提醒
GELU	$z\Phi(z)$	<code>nn.GELU()</code> ， Φ 為標準常態 CDF
SiLU／Swish ($\beta = 1$)	$z\sigma(z)$	<code>nn.SiLU()</code>
Mish	$z \tanh(\log(1 + e^z))$	<code>nn.Mish()</code>
ReLU ²	$\max(0, z)^2$	正值越大，導數也越大

比較驗證表現與運算成本；較平滑不等於一定較準。

選讀 | 激活函數：把公式對到原始碼

開啟激活函數原程式（`programs/upstream/MachineLearning2025/06_Activation_functions.py`）：
L42–66，假設已匯入 NumPy 與 `erf`。

```
# 原碼摘錄，保留原函數之間的呼叫關係
def gelu(x):
    return 0.5 * x * (1 + erf(x / np.sqrt(2)))
def swish(x):
    return x * sigmoid(x)
def mish(x):
    return x * tanh(softplus(x))
```

對照同檔的導數，在 $x = -2, 0, 2$ 判斷哪些位置仍能傳遞梯度。

選讀 | SwiGLU 的形狀與門控

將線性層輸出分成兩半，逐元素相乘：

$$z = [z_1, z_2], \quad h = (z_1 \sigma(z_1)) \odot z_2$$

```
import torch.nn.functional as F
projection = nn.Linear(100, 200)
z1, z2 = projection(x).chunk(2, dim=-1) # x: [B,100]
h = F.silu(z1) * z2                      # h: [B,100]
```

前層輸出要加倍，分割後才得到需要的 100 維表示。

BatchNorm：先算批次統計，再學尺度

對一個特徵，批次內有 m 筆值：

$$\mu_B = \frac{1}{m} \sum_i x_i, \quad \sigma_B^2 = \frac{1}{m} \sum_i (x_i - \mu_B)^2$$

$$\hat{x}_i = \frac{x_i - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}}, \quad z_i = \gamma \hat{x}_i + \beta$$

μ_B, σ_B^2 來自本批資料； γ, β 透過梯度學習。

BatchNorm 手算：四筆資料的一個特徵

本批輸入 $[2, 4, 4, 6]$ ，先忽略很小的 ϵ 。

1. 算出平均數與變異數，分母使用 4。
2. 計算四個標準化值。
3. 令 $\gamma = 2, \beta = 1$ ，計算最終輸出。

這四個值是「四筆樣本的同一直徵」，每一列代表一個人。

BatchNorm 的訓練與推論

狀態	正規化統計來源	是否更新移動統計？
<code>model.train()</code>	當前批次	是
<code>model.eval()</code>	已保存的 running mean / variance	否

PyTorch 的 BN momentum m 表示新資料權重：

$$\mu_{run,new} = (1 - m)\mu_{run,old} + m\mu_B$$

小批次的統計可能不穩定；`eval()` 不會刪除已學到的 γ, β 。

PyTorch : Linear 、 BatchNorm 、 ReLU

```
model_bn = nn.Sequential(  
    nn.Flatten(),  
    nn.Linear(784, 100, bias=False),  
    nn.BatchNorm1d(100),  
    nn.ReLU(),  
    nn.Linear(100, 10)  
) .to(device)
```

本例在激活前放 BN，線性層省略重複偏置。輸入先完成前處理。

BN 的統計軸：向量與影像

輸入	模組	每組統計涵蓋哪些值？
[B,C]	BatchNorm1d(C)	同一特徵的 B 筆樣本
[B,C,L]	BatchNorm1d(C)	同一通道的 $B \times L$ 個值
[B,C,H,W]	BatchNorm2d(C)	同一通道的 $B \times H \times W$ 個值

BN 的可學參數是每通道一個 γ 與一個 β 。

影像不必先攤平才能使用正規化，模組要配合資料形狀。

LayerNorm：每筆資料自己算統計

對一筆樣本的特徵向量 $h = [h_1, \dots, h_d]$ ：

$$\mu = \frac{1}{d} \sum_j h_j, \quad \sigma^2 = \frac{1}{d} \sum_j (h_j - \mu)^2$$

$$\text{LN}(h)_j = \gamma_j \frac{h_j - \mu}{\sqrt{\sigma^2 + \epsilon}} + \beta_j$$

`nn.LayerNorm(d)` 正規化最後一個維度，訓練與推論都用本筆統計。

LayerNorm 手算：一筆資料的四個特徵

Attention 舊稿的例子： $h = [2, 4, 4, 6]$ 。

$\mu = 4$ ， $\sigma^2 = 2$ ，初始 $\gamma_j = 1, \beta_j = 0$ ：

$$\text{LN}(h) \approx [-1.4142, 0, 0, 1.4142]$$

與剛才 BN 使用相同數字，但這次是一筆樣本的四個特徵。

若批次裡加入另一筆樣本，這筆的 LN 結果會改變嗎？

BatchNorm 與 LayerNorm 比較

比較項目	BN (以 [B,D] 為例)	LN (以 LayerNorm(D) 為例)
統計方向	每一欄跨樣本	每一列跨特徵
依賴其他樣本	訓練時會	不會
推論統計	通常用移動估計	即時計算
小批次限制	統計可能不穩定	不依賴批次大小
常見情境	CNN／批次訓練	序列、Transformer等

兩者都可學縮放和平移，需依架構與資料驗證選擇。

休息 10 分鐘

回來後思考：如果梯度已經非常大，應在訓練的哪一步處理？

梯度裁剪：限制一次更新的梯度

按範數裁剪：

$$g_{clip} = g \min \left(1, \frac{c}{\|g\|_2} \right)$$

例如 $g = [3, 4]$ 、 $c = 1$ ，範數為 5，裁剪後為 $[0.6, 0.8]$ 。

按值裁剪至 $[-1, 1]$ 則得到 $[1, 1]$ ，可能改變方向。


裁剪抑制過大梯度，不能把消失的梯度放大回來。

梯度裁剪放在 backward 與 step 之間

```
optimizer.zero_grad(set_to_none=True)
logits = model(X_batch)
loss = loss_fn(logits, y_batch)
loss.backward()
grad_norm = nn.utils.clip_grad_norm_(
    model.parameters(), max_norm=1.0)
optimizer.step()
```

回傳值可記錄裁剪前的總範數；頻繁裁剪時仍需檢查學習率與資料。

圖 11-5：重用已學到的特徵



重用較底層的代表，替換符合新任務的輸出層，再逐步微調。

遷移學習：凍結與解凍的順序

階段	重用層	新輸出層	原因
先學新任務	凍結	訓練	避免隨機輸出層破壞原特徵
局部微調	解凍靠近輸出的部分	訓練	讓高階特徵適應新資料
再評估	視資料量與驗證結果解凍更多	訓練	兼顧適應能力與過擬合

解凍時通常降低學習率，並確認 optimizer 包含新解凍的參數。

書中範例：Fashion MNIST 的任務 A 與 B

任務	可用資料	輸出
A：先學 8 類服飾	不含 T-shirt/top 與 Pullover	8 個 logits
B：區分 T-shirt 與 Pullover	只有 20 張有標註影像	1 個 logit

從 A 複製隱藏層，在 B 換成二元分類輸出。

B 的損失使用 `BCEWithLogitsLoss`，標籤需轉成 0／1 浮點數。

PyTorch：複製骨幹，先只訓練新頭

```
import copy
backbone = copy.deepcopy(model_A[:-1])
for p in backbone.parameters():
    p.requires_grad_(False)
model_B = nn.Sequential(backbone, nn.Linear(100, 1)).to(device)
loss_B = nn.BCEWithLogitsLoss()
optimizer_B = torch.optim.AdamW(
    model_B[1].parameters(), lr=1e-3, weight_decay=1e-4)
# 批次內：logits_B = model_B(X_batch).squeeze(-1)
# loss = loss_B(logits_B, y_binary.float())
```

用深複製保護任務 A 的參數；本例骨幹不含 BN／Dropout。

PyTorch：解凍後建立分組學習率

```
for p in model_B[0].parameters():  
    p.requires_grad_(True)  
optimizer_B = torch.optim.AdamW([  
    {"params": model_B[0].parameters(), "lr": 1e-5},  
    {"params": model_B[1].parameters(), "lr": 1e-4},  
], weight_decay=1e-4)
```

本例讓骨幹慢慢調整，新頭較快適應；數值仍要用驗證集選擇。

重建 optimizer 會重設其內部狀態，這是新的微調階段。

書中成效：為何 92.5% 不能直接當保證？


教材展示任務 B 從 **71.6%** 提升至 **92.5%**。

但作者隨後明說：他嘗試了許多設定，刻意挑出改善大的案例。

改變類別或隨機種子後，改善可能縮小、消失，甚至反轉。

課堂比較應固定切分、報告多次結果，並保留從零訓練的基準。


舊稿補充：圖片描述的預訓練 Encoder



先重用 CNN 的影像表示，再讓 Decoder 學習文字描述。

凍結特徵擷取器與微調部分層，是兩個可分別比較的策略。

圖 11-6：無監督預訓練的想法



圖示為早期逐層預訓練；今日也可先整體訓練表示，再接上任務輸出。

輔助任務與自監督預訓練

想做文章分類，但標註很少，可以先用大量文本練習填空：

「這件外套非常____，適合冬天穿。」

遮住的原字由資料本身提供答案，模型先學語言表示。

之後替換任務輸出，用分類標註微調。預訓練與新任務越相關，越值得比較。

小組設計：只有少量服飾標註時

已有相關的預訓練分類器，每組設計三種比較：

1. 小網路從零訓練。
2. 凍結預訓練骨幹，只訓練新頭。
3. 在第二組基礎上解凍，使用較小學習率。

提交：固定切分、各組可訓練參數、比較指標與失敗判準。

離線組：用矩陣形狀和訓練步驟說明三種策略，不需執行訓練。

離堂檢核：方法與問題要配對

1. He 初始化主要想維持什麼？能否保證整段訓練穩定？
2. 為何同一組 $[2, 4, 4, 6]$ 可以是 BN 或 LN 的例子？
3. 凍結參數與呼叫 `eval()` 有何不同？
4. 裁剪梯度為何要放在 `backward()` 之後？

課後：書本第 11 章練習 1-4；下一份接續最佳化與正則化。