

深層神經網路訓練

最佳化與正則化

書本第 11 章（下） | 學得更快，也要泛化得更好

學習重點與成果

- Momentum、Nesterov、AdaGrad、RMSProp 與 Adam。
- AdamW、方法比較、學習率排程與診斷。
- 正則化、Dropout、完整實驗設計。

成果：能手算參數更新、標出 scheduler 的位置，並規劃公平比較。

「選讀」頁提供進階推導與實作補充。範例數據會標明是否為教材結果。


 **配套 Notebook**： `programs/notebooks/13_深層神經網路訓練_最佳化與正則化.ipynb`。
本檔提供公式驗算、機制實驗與結果圖；框架片段及完整模型案例另依頁面說明閱讀。

程式實驗與實際輸出

```
velocity = beta * velocity + gradient  
theta -= eta * velocity
```

觀察：在狹長損失面上，Momentum 累積一致方向的更新，減少淺方向的緩慢移動。

參考程式：`programs/notebooks/13_深層神經網路訓練_最佳化與正則化.ipynb`



梯度、最佳化器與排程的分工

- `loss.backward()`：目前參數該往哪個方向調整？
- `optimizer.step()`：結合梯度與歷史狀態，實際調整多少？
- `scheduler.step()`：下一個階段使用什麼學習率？
- 驗證與早停：目前模型是否值得繼續訓練？

同樣的梯度，換一個 `optimizer`，更新量可能不同。

Momentum：累積前幾步的方向

令 $g_t = \nabla_{\theta} L(\theta_t)$ ， $v_0 = 0$ ：

$$v_t = \beta v_{t-1} - \eta g_t, \quad \theta_{t+1} = \theta_t + v_t$$

持續同向的梯度會累積；來回變動的部分可互相抵銷。

β 越大，歷史影響越久，也可能跨過最低點後持續震盪。


Momentum 手算：連續兩次相同梯度

設 $\theta_0 = 1$ ， $v_0 = 0$ ， $\eta = 0.1$ ， $\beta = 0.9$ ，兩步梯度均為 2。

步驟	速度 v	更新後的 θ
第 1 步	$0.9 \times 0 - 0.1 \times 2 = -0.2$	0.8
第 2 步	?	?

若使用沒有 Momentum 的 SGD，兩步後參數是多少？

圖 11-7：Nesterov 提前看動量方向



概念上先看 $\theta_t + \beta v_{t-1}$ 附近的坡度，再修正更新。

Nesterov 的更新式與 PyTorch


$$v_t = \beta v_{t-1} - \eta \nabla L(\theta_t + \beta v_{t-1})$$

$$\theta_{t+1} = \theta_t + v_t$$

```
optimizer = torch.optim.SGD(  
    model.parameters(), lr=0.01,  
    momentum=0.9, nesterov=True)
```

使用內建 optimizer 即可，不需手動把模型參數先挪到「前看點」。

圖 11-8：AdaGrad 對各方向調整步幅



累積梯度較大的座標，後續更新會縮得更多，讓路徑改變。

AdaGrad：累積梯度平方

$$s_t = s_{t-1} + g_t^2, \quad \theta_{t+1} = \theta_t - \eta \frac{g_t}{\sqrt{s_t} + \epsilon}$$

平方、開根號與除法都逐座標進行。

若第一步 $g = [1, 10]$ ， $s_0 = 0$ 、 $\eta = 0.1$ ，忽略 ϵ ：

$s_1 = [1, 100]$ ，兩個座標的更新量都約為 -0.1 。

累積量不斷增加，後期可能縮得太小而停滯。

RMSProp：保留較近的梯度尺度

$$s_t = \alpha s_{t-1} + (1 - \alpha) g_t^2$$

$$\theta_{t+1} = \theta_t - \eta \frac{g_t}{\sqrt{s_t} + \epsilon}$$

用指數移動平均，減少早期的大梯度永久壓低後續步幅。

```
torch.optim.RMSprop(model.parameters(), lr=0.001, alpha=0.9)
```

Adam：一階矩與二階原點矩

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t$$

$$s_t = \beta_2 s_{t-1} + (1 - \beta_2) g_t^2$$

m_t 追蹤梯度方向， s_t 追蹤梯度平方的尺度。

兩者從 0 開始，需要偏差修正，避免早期估計偏向 0。

二階原點矩是 $E[g^2]$ ，不等於中心化變異數 $E[(g - E[g])^2]$ 。

Adam：偏差修正與更新

$$\hat{m}_t = \frac{m_t}{1 - \beta_1^t}, \quad \hat{s}_t = \frac{s_t}{1 - \beta_2^t}$$
$$\theta_{t+1} = \theta_t - \eta \frac{\hat{m}_t}{\sqrt{\hat{s}_t} + \epsilon}$$

```
optimizer = torch.optim.Adam(  
    model.parameters(), lr=1e-3, betas=(0.9, 0.999))
```

「自適應」仍需要選擇全域學習率，並查看驗證結果。

Adam 手算：第一步為何需要修正？

設 $g_1 = 2$ ， $m_0 = s_0 = 0$ ， $\beta_1 = 0.9$ ， $\beta_2 = 0.999$ 。

1. 求 m_1 與 s_1 。
2. 求 $\hat{m}_1$ 與 $\hat{s}_1$ 。
3. $\eta = 0.001$ ，忽略極小的 ϵ ，參數改變多少？

最後說明：梯度為 2，為什麼更新量不直接等於 -0.002 ？

Adam 的 L2 懲罰等於 weight decay 嗎？

在普通 SGD 中，將 $\lambda \|w\|_2^2 / 2$ 加入損失，與更新時的權重衰減可對應；在 Adam 中，L2 梯度會進入自適應動量統計，兩者一般不等價。

AdamW 將 weight decay 與梯度更新解耦。比較實驗時要明確記錄優化器、衰減係數及哪些參數不受衰減。

Adam 的變體：改動了哪個部分？

方法	主要改動	適合檢查的問題
AdaMax	以衰減後的最大絕對梯度縮放	Adam 不穩定時的比較選項
NAdam	結合 Adam 與 Nesterov 想法	更新方向與收斂速度
AdamW	將權重衰減與梯度自適應分開	模型泛化與權重控制

三者都需要用同一資料切分與預算比較，沒有通用第一名。

AdamW：分開處理權重衰減

將 Adam 更新方向記為 u_t ：

$$\theta_{t+1} = (1 - \eta\lambda)\theta_t - \eta u_t$$

衰減直接縮小權重，不進入一階、二階矩的梯度估計。

對一般 SGD（無動量），加入 $\frac{\lambda}{2}\|\theta\|^2$ 可得到相同形式。

對 Adam，將 $\lambda\theta$ 加入梯度會連帶影響自適應尺度，因此不同。

表 11-2：最佳化器比較（1/2）

方法	書中收斂速度評等	書中收斂品質評等
SGD	低	高
SGD+Momentum	中	高
SGD+Nesterov	中	高
AdaGrad	中	低，可能太早停滯

這是作者的質性摘要，沒有共同資料集上的時間或分數單位。

表 11-2：最佳化器比較（2/2）

方法	書中收斂速度評等	書中收斂品質評等
RMSProp	中	中或高
Adam	中	中或高
AdaMax	中	中或高
NAdam	中	中或高
AdamW	中	中或高

課堂比較還要記錄實際時間、驗證損失與多次實驗變異。

選讀 | 二階資訊與稀疏模型


Hessian 描述損失曲率， n 個參數的完整矩陣有 n^2 個元素。

一百萬參數若以 float32 儲存完整 Hessian，僅矩陣就約 **4 TB**。

- 近似曲率方法如 Shampoo，試圖降低直接處理完整矩陣的成本。
- L1 懲罰與剪枝可促進稀疏，但零值多不保證一般硬體推論更快。

需要另測記憶體、支援的運算與端到端延遲。

圖 11-9：固定學習率的取捨



太小前進慢，太大可能震盪或發散；接近好解後通常需要更細的步幅。

指數衰減：每輪乘上一個比例


$$\eta_t = \eta_0 \gamma^t$$

$\eta_0 = 0.01, \gamma = 0.9$ ，十次衰減後約為 0.00349。

```
scheduler = torch.optim.lr_scheduler.ExponentialLR(  
    optimizer, gamma=0.9)  
# 每個 epoch 完成 optimizer 更新後，再 scheduler.step()
```

衰減太快，仍可能在學好之前就讓步幅過小。

圖 11-10：餘弦退火



$$\eta_t = \eta_{\min} + \frac{\eta_{\max} - \eta_{\min}}{2} \left[1 + \cos \left(\frac{t\pi}{T_{\max}} \right) \right]$$

從高學習率平滑降至低學習率，需要先指定排程長度。

依表現降學習率：ReduceLROnPlateau

```
scheduler = torch.optim.lr_scheduler.ReduceLROnPlateau(  
    optimizer, mode="min", patience=2, factor=0.5)  
# 每輪先訓練，再計算完整驗證損失 val_loss  
scheduler.step(val_loss)
```

驗證損失停滯一段時間，才降低學習率；監控 accuracy 則用 `mode="max"`。


降低學習率不等於早停，可以先繼續觀察是否改善。

Warmup：開始幾輪逐步提高學習率

```
optimizer = torch.optim.AdamW(model.parameters(), lr=1e-3)
warmup = torch.optim.lr_scheduler.LinearLR(
    optimizer, start_factor=0.1, end_factor=1.0, total_iters=3)
cosine = torch.optim.lr_scheduler.CosineAnnealingLR(
    optimizer, T_max=17, eta_min=1e-5)
scheduler = torch.optim.lr_scheduler.SequentialLR(
    optimizer, schedulers=[warmup, cosine], milestones=[3])
```

20 輪示例：先暖身 3 輪，再接 17 輪餘弦排程，每輪訓練後 `step()`。

圖 11-11：餘弦退火與暖重啟



學習率週期性回升，再重新下降；可讓後面的週期逐漸加長。

「重啟」指學習率排程，通常保留模型權重。

1cycle：在訓練預算內先升後降

```
scheduler = torch.optim.lr_scheduler.OneCycleLR(  
    optimizer, max_lr=1e-3, epochs=20,  
    steps_per_epoch=len(train_loader), pct_start=0.3)  
# 每批 loss.backward() 之後：  
optimizer.step()  
scheduler.step()
```

每批更新後呼叫一次；`max_lr` 是峰值，不是每一步都使用的值。

總更新步數要與實際訓練一致，避免少跑或多跑排程。

Scheduler 呼叫時機總表

排程	本課呼叫頻率	傳入的資訊
ExponentialLR	每 epoch 訓練後	<code>step()</code>
CosineAnnealingLR	每 epoch 訓練後	<code>step()</code> ； T_max 同單位
LinearLR／SequentialLR	每 epoch 訓練後	<code>step()</code>
CosineAnnealingWarmRestarts	本例每 epoch 後	<code>step()</code> ；週期同單位
ReduceLROnPlateau	完成驗證後	<code>step(val_loss)</code>
OneCycleLR	每個 optimizer 更新後	<code>step()</code>

選讀 | mini-batch 的排程計數

延伸練習：在本章 Notebook 比較 full-batch、mini-batch 與帶動量的更新軌跡。

```
# 錯誤寫法：每輪都從 iteration=0 開始
eta = learning_schedule(iteration)
# 教學修正版：放在原本epoch內的mini-batch迴圈
step = epoch * n_batches_per_epoch + iteration
eta = learning_schedule(step)
gradients = 2 / len(xi) * xi.T @ (xi @ theta - yi)
theta = theta - eta * gradients
```

原排程是 $200 / (t + 1000)$ 。用累積步數，才不會每輪回到初始學習率。

診斷活動：排程為什麼失去作用？

A：設定 `T_max=20`，想每輪下降一次，實際卻每批都呼叫。

B：OneCycle 設定每輪 100 步，但每個 epoch 只 `step()` 一次。

C：每個 epoch 都重新建立 optimizer，Momentum 一直沒累積。

D：用驗證 accuracy，卻把 Plateau 的 `mode` 設為 `min`。

提交：各挑兩項，說明應改的位置與預期改善。

訓練損失降、驗證損失升：怎麼診斷？

這是可能過度擬合的訊號，先檢查：

1. 訓練與驗證資料是否正確切分，前處理是否只在訓練資料上擬合？
2. 兩者的損失計算與 `train()` / `eval()` 模式是否一致？
3. 是否可用早停、正則化或更多適當資料改善驗證表現？

不要以測試集反覆挑選訓練設定。

正則化：用驗證集判斷是否改善泛化

- 早停：保留驗證表現較好的訓練版本。
- L1／L2／weight decay：限制參數大小或促進稀疏。
- Dropout：訓練時擾動隱藏表示，減少過度依賴少數特徵。
- 資料擴增：提供合理變化，維持任務標籤的意義。

先排除切分錯誤、前處理不一致與標籤問題，再調整正則化強度。

L1、L2 與手動加入懲罰

$$L_{total} = L_{data} + \lambda_1 \sum_j |w_j| + \frac{\lambda_2}{2} \sum_j w_j^2$$

L1 促進稀疏，L2 限制權重尺度。懲罰哪些參數需明確指定。

```
# 示範只懲罰Sequential內Linear層的權重
weights = [m.weight for m in model.modules()
            if isinstance(m, nn.Linear)]
l2 = sum(w.square().sum() for w in weights)
loss = loss_fn(logits, y_batch) + 0.5 * 1e-4 * l2
```

延伸練習：比較 Lasso/Ridge 的係數如何隨 `alpha` 改變。

AdamW 分組：只衰減本例的線性權重

```
linear_weights = [m.weight for m in model.modules()
                  if isinstance(m, nn.Linear)]
weight_ids = {id(p) for p in linear_weights}
other_params = [p for p in model.parameters()
                if id(p) not in weight_ids]
optimizer = torch.optim.AdamW([
    {"params": linear_weights, "weight_decay": 1e-4},
    {"params": other_params, "weight_decay": 0.0},
], lr=1e-3)
```

本例是沒有共享權重的 MLP；BN／LN 參數與偏置落在第二組。

早停與最佳參數回復

每輪完整驗證後，改善才保存。停止後回到最佳版本。

```
import copy
# epoch迴圈之前: best_loss, stale = float("inf"), 0
if val_loss < best_loss:
    best_loss, stale = val_loss, 0
    best_state = copy.deepcopy(model.state_dict())
else:
    stale += 1
# stale達耐心值時結束epoch迴圈
# 訓練結束: model.load_state_dict(best_state)
```

要續訓時，另保存 optimizer、scheduler、epoch 與前處理設定。

選讀 | 早停：保存後要回復哪一版？

延伸練習：在本章 Notebook 執行多項式迴歸的早停實驗，找出最佳驗證 epoch。

程式位置	實際行為	讀碼時要注意的觀念
cell 3-4	用名為 test 的資料挑最佳 epoch	這份資料實際扮演驗證集
cell 4	<code>best_model = deepcopy(lin_reg)</code>	已保存當時最佳參數
cell 5	用 <code>lin_reg.predict(...)</code>	仍是最後一輪模型
cell 7	重訓到 <code>best_epoch+1</code>	不保證重現已保存的參數

應直接用已保存的 `best_model`；最終測試另留未參與選模的資料。


選讀 | Keras callback：停止與回復最佳權重

Keras 範例：比較 `ModelCheckpoint` 與 `EarlyStopping(restore_best_weights=True)` 的行為。

```
# 程式片段：model 與 checkpoint_cb 已在前面建立
early_stopping_cb = keras.callbacks.EarlyStopping(
    patience=10, restore_best_weights=True)
history = model.fit(X_train, y_train, epochs=100,
                    validation_data=(X_valid, y_valid),
                    callbacks=[checkpoint_cb, early_stopping_cb])
```

`patience` 決定等待多久，`restore_best_weights` 決定結束時回復哪一版。

圖 11-12：Dropout 的隨機遮罩



每次訓練前向暫時遮掉一部分激活，下次可能換成另一組。

Dropout 手算：為什麼要除以保留率？

$$\tilde{a} = \frac{r \odot a}{1 - p}, \quad r_j \sim \text{Bernoulli}(1 - p)$$

$a = [2, 4, 6, 8]$ ， $p = 0.5$ ，這次遮罩 $r = [1, 0, 1, 0]$ 。

1. 計算訓練時的輸出。
2. 一般 `eval()` 時輸出是什麼？
3. 解釋為何 $E[\tilde{a}_j] = a_j$ 。

PyTorch : Dropout 與評估公平性

```
model_drop = nn.Sequential(  
    nn.Flatten(), nn.Linear(784, 100), nn.ReLU(),  
    nn.Dropout(p=0.2), nn.Linear(100, 10)  
).to(device)
```

- 訓練用 `train()`，一般驗證用 `eval()` 與 `no_grad()`。
- 比較 train／validation loss 時，兩邊都可另用 `eval` 模式重算。
- Dropout 過強可能欠擬合，比例需驗證。

MC Dropout：保留遮罩，多次預測

普通推論關閉 Dropout；MC Dropout 讓 Dropout 保持隨機，平均多次機率。

$$\bar{p}_k = \frac{1}{T} \sum_{t=1}^T p_k^{(t)}$$

例如某類三次得到 $[0.2, 0.5, 0.8]$ ，平均為 0.5，變動很大。

先將每次 logits 轉成機率，再平均；平均 logits 通常不等價。

選讀 | MC Dropout 只打開需要的層

```
model_drop.eval()
for module in model_drop.modules():
    if isinstance(module, nn.Dropout):
        module.train()
with torch.no_grad():
    probs = torch.stack([
        model_drop(X_new).softmax(dim=-1) for _ in range(30)])
mean_p = probs.mean(dim=0)
std_p = probs.std(dim=0, unbiased=False)
model_drop.eval() # 使用完回復一般推論
```

Max-norm：限制每個神經元的權重範數

更新參數後，對每個神經元的輸入權重向量做：

$$w \leftarrow w \min \left(1, \frac{r}{\|w\|_2} \right)$$

$w = [3, 4]$ 、上限 $r = 2$ ，調整後是 $[1.2, 1.6]$ 。

Max-norm 限制**權重**，梯度裁剪限制**梯度**，插入位置不同。

選讀 | 只對 Linear 權重施加 Max-norm

```
# 緊接optimizer.step()之後
with torch.no_grad():
    for layer in model.modules():
        if isinstance(layer, nn.Linear):
            w = layer.weight
            norms = w.norm(dim=1, keepdim=True)
            scale = (2.0 / norms.clamp_min(1e-8)).clamp(max=1.0)
            w.mul_(scale)
```

每一列對應一個輸出神經元，不對一維的 BN/LN 參數套用此程式。

資料擴增要保留標籤意義

變化	可考慮的任務	應先檢查的風險
小幅平移、裁切	物件分類	關鍵物件是否被切掉？
左右翻轉	部分自然影像	文字、左右方向是否影響標籤？
亮度、對比變化	光照可能改變的影像	是否破壞顏色判別資訊？
小角度旋轉	容許姿態改變的物件	旋轉是否改變類別？

先切分原始樣本，再只對訓練集擴增，避免近乎相同影像跨集合。

表 11-3：深層網路的起始設定

項目	書中建議起點
權重初始化	He
激活	較淺用 ReLU，較深可比較 Swish
正規化	淺層可不用，深層可比較 BN／LN
正則化	早停，需要時加 weight decay
Optimizer	Nesterov SGD 或 AdamW
學習率排程	依驗證表現調整或 1cycle

綜合實驗：每次只回答一個比較問題

固定 Fashion MNIST 的切分、前處理、epoch 上限與記錄方式。

比較	保持相同	主要觀察
SGD+Nesterov vs AdamW	網路、資料、搜尋預算	驗證損失與實際時間
固定學習率 vs 1cycle	optimizer與網路	到達相近驗證表現的時間
無 Dropout vs 有 Dropout	其餘已選定設定	泛化差距與收斂變化

各 optimizer 可在相同預算內各自選學習率，避免只給某組有利設定。

實驗提交與離線替代

提交一張結果表與兩張曲線，至少包含：

- 設定、隨機種子、資料切分與前處理。
- 每輪 train/validation loss、學習率與時間。
- 最佳驗證版本、錯誤案例、改善與未改善的解釋。

沒有環境：提交訓練迴圈流程，標出清梯度、裁剪、更新、排程及驗證位置。

驗收看比較是否公平、證據能否支持結論，不以達到特定分數評分。

選讀 | Keras 的 TensorBoard 訓練紀錄

延伸練習：在本章 Notebook 對照訓練紀錄欄位，確認每次實驗有獨立的 run 名稱與目錄。

```
# 程式片段：model、資料與 checkpoint_cb 均已備妥
run_logdir = get_run_logdir()
tensorboard_cb = keras.callbacks.TensorBoard(run_logdir)
history = model.fit(X_train, y_train, epochs=30,
                    validation_data=(X_valid, y_valid),
                    callbacks=[checkpoint_cb, tensorboard_cb])
```

每次實驗分開目錄；先記錄設定，再比較 loss、val_loss 與訓練時間。

課後延伸：書中 CIFAR10 深層網路實驗

第 11 章練習 8：用 20 個隱藏層、每層 100 個單元觀察訓練困難。

1. He+SiLU，搭配 NAdam 與早停，重新搜尋學習率。
2. 加 BN 比較，再以符合條件的 SELU+LeCun normal 比較。
3. 嘗試 AlphaDropout、MC Dropout 與 1cycle，分開記錄影響。

CIFAR10 為 32×32 彩色影像，攤平是 3,072 維，輸出 10 個 logits。

選讀 | 強化學習 PDF：Q-table 與神經網路

表示方法	如何得到各動作的 Q 值？	與本章的關係
Q-table	依離散狀態查表，每個狀態保存動作值	表格更新不用反向傳播
神經網路近似	輸入狀態特徵，由網路輸出動作值	訓練會用到梯度與 optimizer

Q-table 適合離散狀態；DQN 則以神經網路近似動作價值。

狀態空間很大時可考慮函數近似；DQN 還需要本章以外的訓練設計。

離堂檢核：以證據選方法

1. Adam 為何仍需要調整學習率？
2. Dropout 開啟時的 train loss，為何不宜直接和 eval loss 比？
3. Gradient clipping 與 Max-norm 分別在哪個位置執行？
4. 為何只展示一次最好成績，不能證明新方法比較好？

課後：第 11 章練習 5–7，並選練習 8 的一組變因設計實驗。

Notebook 導讀：可執行的機制與驗收

程式比較	讀取證據
GD、Momentum、Nesterov、AdaGrad、RMSProp、Adam	同一起點的路徑與損失
固定、指數、餘弦、暖身、重啟、1cycle	每次更新的學習率與損失
Dropout／MC、Max-norm	遮罩、輸出分布、投影後範數
早停與記錄	驗證選擇、回復快照、CSV 訓練曲線

二次函數實驗不等於完整深層網路排名。框架呼叫時機以原讀碼頁對照；CIFAR10、TensorBoard 與 Q-network 是延伸案例，不宣稱已完整訓練。