

卷積神經網路：影像特徵與架構

卷積、池化與深層視覺模型

書本第 12 章

建議 180 分鐘，含活動與休息

學習成果與課堂安排

- 0–50 分：卷積與張量尺寸，手算一個濾波器。
- 60–110 分：池化、CNN 與資料增強。
- 120–180 分：經典架構比較、殘差連接與讀碼。

成果：能算輸出尺寸與參數量，說明 CNN 如何利用影像的空間結構。

 **配套 Notebook**：[14_卷積神經網路_影像特徵與架構.ipynb](#)。程式片段、實際圖表與表格
可由此檔重現。

程式實驗與實際輸出

```
Y[i, j] = sum(X[i:i+2, j:j+2] * K)
```

觀察：程式輸出與投影片手算相同：[[0, -1], [-1, 1]]。

[開啟完整 Notebook](#)

input			kernel		output	
1	2	0	1	0	0	-1
0	1	3	0	-1	-1	1
2	1	0				

影像分類的輸入與輸出

輸入是一批影像，輸出是每張影像的類別分數。

物件	PyTorch 常見形狀
灰階影像	[B, 1, H, W]
RGB 影像	[B, 3, H, W]
十類分類 logits	[B, 10]

空間相鄰的像素往往有關，直接攤平會丟掉這項結構提示。

MLP 與 CNN 的銜接

MachineLearning2025：手刻 MNIST MLP

- 找到輸入攤平與第一個全連接層。
- MLP 的不同像素位置各有權重；CNN 讓同一濾波器掃過各位置。
- 原程式用手刻反向傳播；本章用 PyTorch autograd。

討論：邊緣從影像左側移到右側時，哪些參數可以共用？


視覺皮質帶來的設計啟發

視覺皮質中的神經元可能對局部區域與特定圖樣產生反應。

CNN 借用局部連接與分層表示的想法，但不等於完整模擬生物視覺。

較低層常回應邊緣或紋理，較高層可組合成任務相關的複雜特徵。

局部感受野



單一輸出位置先看輸入的一小塊；堆疊多層後，可整合更大範圍。


參數共用的效果

假設輸入為 $32 \times 32 \times 3$ ，輸出有 16 個通道。

第一層設計	含偏置的參數量
全連接到 16 個神經元	$(32 \times 32 \times 3 + 1) \times 16 = 49,168$
16 個 3×3 卷積核	$(3 \times 3 \times 3 + 1) \times 16 = 448$

兩者輸出結構不同；此處比較參數共用，不宣稱功能等價。

濾波器與特徵圖



同一張影像可經不同濾波器產生不同回應；訓練會學出濾波器權重。

卷積手算：一個位置

輸入小區塊與濾波器：

$$X = \begin{bmatrix} 1 & 2 & 0 \\ 0 & 1 & 3 \\ 2 & 1 & 0 \end{bmatrix}, \quad K = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix}$$

左上角輸出： $1 \times 1 + 2 \times 0 + 0 \times 0 + 1 \times (-1) = 0$ 。


移動一步，右上角是多少？此例 stride=1、無 padding、bias=0。

卷積手算：完整輸出

$$Y = \begin{bmatrix} 0 & -1 \\ -1 & 1 \end{bmatrix}$$

- 同一組 K 在四個位置重複使用。
- 加上 bias 時，每個輸出位置加同一個通道偏置。
- ReLU 會把負值設為 0，得到不同的特徵表示。

Padding 保留邊界附近的資訊



補零讓濾波器能處理邊界，也能控制輸出大小。補零不會創造新的觀測資訊。

輸出尺寸公式


$$H_{out} = \left\lfloor \frac{H + 2P - D(K - 1) - 1}{S} \right\rfloor + 1$$

K : kernel size , S : stride , P : padding , D : dilation 。

例： $H = 32, K = 3, S = 2, P = 1, D = 1$ ，輸出高度為 16 。

寬度同樣計算；輸出通道數由濾波器個數決定。

多個通道如何合成輸出



每個輸出通道的卷積核都跨越所有輸入通道，先加總再加偏置。

Conv2d 的形狀檢查

```
import torch
from torch import nn
X = torch.randn(8, 3, 32, 32)
conv = nn.Conv2d(3, 16, kernel_size=3, stride=2, padding=1)
Y = conv(X)
print(Y.shape) # 預期 torch.Size([8, 16, 16, 16])
print(conv.weight.shape) # 預期 [16, 3, 3, 3]
```

第一個 16 是輸出通道；batch 大小不影響參數量。

作者程式：Cells 20-43

讀碼練習：影像軸的順序


資料常見 `[B, H, W, C]`；Conv2d 需要 `[B, C, H, W]`。

```
X_nchw = X_nhwc.permute(0, 3, 1, 2)
```

`reshape` 改變形狀卻不等於交換軸。

請用一個 2×3 的小矩陣說明 `reshape` 與 `transpose` 的差別。

Max pooling



每個小區域取最大值，縮小空間尺寸；一般不含可學習參數。

池化與平移的關係

操作	作用	代價
Max pooling	保留局部最強回應	細節與位置資訊減少
Average pooling	整合區域平均回應	尖銳特徵可能被稀釋
Global average pooling	每通道壓成一個值	難保留精確座標

小幅平移可能得到相近結果；CNN 不保證對所有平移完全不變。


Pooling 的 PyTorch 實作

```
X = torch.randn(8, 16, 32, 32)
local = nn.MaxPool2d(kernel_size=2, stride=2)(X)
global_avg = nn.AdaptiveAvgPool2d(1)(X)
print(local.shape)          # 預期 [8,16,16,16]
print(global_avg.shape)    # 預期 [8,16,1,1]
```

兩者保留通道數，改變的是空間尺寸。

作者程式：[Cells 44-61](#)（教學改寫）

分類 CNN 的典型組成



卷積與池化抽取特徵，最後把特徵轉成類別 logits。

小型 CNN：先追蹤每一層尺寸

```
model = nn.Sequential(  
    nn.Conv2d(1, 16, 3, padding=1), nn.ReLU(),  
    nn.MaxPool2d(2),  
    nn.Conv2d(16, 32, 3, padding=1), nn.ReLU(),  
    nn.AdaptiveAvgPool2d(1), nn.Flatten(),  
    nn.Linear(32, 10))  
logits = model(torch.randn(4, 1, 28, 28))
```

尺寸依序為 28×28 、 14×14 、 14×14 、 1×1 ；logits 為 [4,10]。

作者程式：Cell 64（簡化改寫）

分類損失與評估

```
loss_fn = nn.CrossEntropyLoss()  
loss = loss_fn(logits, y.long())
```

- logits 不先經過 Softmax；此損失內部完成所需計算。
- `y` 是 `[B]` 的類別整數，不是 `[B,10]` 的機率。
- 評估使用 `model.eval()` 與 `torch.no_grad()`。
- 同時看混淆矩陣，檢查哪些類別容易混淆。


LeNet-5 與 AlexNet

模型	主要教學重點
LeNet-5	小影像、卷積與下採樣交替
AlexNet	更大影像、ReLU、Dropout、資料增強

架構表要一起讀輸入尺寸、通道數、kernel 與 stride。

層數增加只是其中一項變化，不能把效果全歸因於「更深」。

資料增強改變訓練影像




裁切、翻轉或顏色變化應保留標籤語意；驗證與測試採固定前處理。

增強的標籤檢查

任務	水平翻轉通常可行？
貓狗分類	通常可，但要看資料
文字或數字辨識	可能改變字形與答案
物件定位	可以，但框座標也要變

活動：為醫學左右側判讀設計增強規則，說明哪些變換需排除。

Inception 的平行分支



不同卷積核與池化分支擷取不同尺度； 1×1 卷積可先調整通道數。


1×1 卷積的計算量例子

在同一空間尺寸上，把 256 通道變成 128 通道：

作法（忽略 bias）	每位置乘加項數
直接 3×3 卷積	$3 \times 3 \times 256 \times 128 = 294,912$
1×1 降至 32，再 3×3	$256 \times 32 + 3 \times 3 \times 32 \times 128 = 45,056$

瓶頸層降低成本，也限制中間表示的寬度。

Residual learning



殘差分支學 $F(x)$ ，輸出為 $x + F(x)$ ，讓訊息和梯度能沿捷徑傳遞。

殘差相加的尺寸條件

- 高度、寬度與通道數都要一致才能逐元素相加。
- stride 改變尺寸時，捷徑也要配合下採樣。
- 通道不同時，可用 1×1 projection。

讀碼：作者 `ResidualUnit` 的使用方式何時會進入 projection 分支？


殘差連接：一般化的尺寸判斷

```
# __init__ 內的捷徑分支；主分支須產生同樣的輸出尺寸
if stride != 1 or in_channels != out_channels:
    skip = nn.Conv2d(in_channels, out_channels, 1,
                     stride=stride, bias=False)
else:
    skip = nn.Identity()
# forward: return torch.relu(main(X) + skip(X))
```

比原範例多檢查通道數，避免把類別移用到其他架構時相加失敗。

作者程式：Cell 74（教學改寫）

Depthwise separable convolution



先逐通道做空間卷積，再用 1×1 卷積混合通道；兩部分分工。


一般卷積與可分離卷積

忽略 bias， $K = 3, C_{in} = 32, C_{out} = 64$ 。

作法	參數量
一般卷積	$3^2 \times 32 \times 64 = 18,432$
Depthwise + pointwise	$3^2 \times 32 + 32 \times 64 = 2,336$

參數較少不代表所有硬體都同倍加速，仍須量測延遲。

Squeeze-and-Excitation



用全域資訊估計每個通道的重要程度，再調整特徵圖的強弱。

其他 CNN 架構的設計焦點

架構	重點
VGG	重複小卷積核，架構規律但模型可能很大
DenseNet	連接先前多層特徵，增加特徵重用
MobileNet／EfficientNet	考慮運算、寬度、深度與解析度
ConvNeXt	以現代訓練與架構設計改良CNN

課堂活動：小影像分類設計

20 分鐘，兩人一組。

1. 寫出輸入、兩個卷積層與分類頭的形狀。
2. 算第一層參數量，提出一個合理資料增強。
3. 指定基準模型與評估資料切分。
4. 交付一張尺寸表與一項可能失敗的情況。

離堂檢核

1. 為何輸出通道數不等於輸入 RGB 的 3？
2. 32×32 輸入、 3×3 kernel、stride=2、padding=1，輸出多大？
3. 殘差相加時，哪些軸必須一致？
4. 池化對分類與定位有何不同影響？

課後程式與延伸閱讀

- 作者第 12 章 [Notebook](#)：先執行 Setup，再定位本課指定區段。
- 舊稿 `07_Convolutional Neural Networks.pptx`：卷積、池化、ResNet、資料增強。
- [本地手刻 MLP](#)：比較全連接與卷積。

程式連結固定於教材核對的版本；執行前確認資料、套件與運算資源。