

電腦視覺：遷移學習與偵測分割

預訓練、定位、偵測、追蹤與分割

書本第 12 章

學習重點與成果

- 模型選擇、記憶體與預訓練。
- 定位、IoU、偵測與 mAP。
- 追蹤、分割與實作設計。

成果：能依輸出需求選任務，設計公平的模型比較。


 **配套 Notebook**： `programs/notebooks/15_電腦視覺_遷移學習與偵測分割.ipynb`。本檔提供公式驗算、機制實驗與結果圖；框架片段及完整模型案例另依頁面說明閱讀。

程式實驗與實際輸出

```
for i in argsort(scores)[::-1]:  
    if all(iou(boxes[i], boxes[j]) < .5 for j in keep): keep.append(i)
```

觀察：NMS 保留高分框並移除與它高度重疊的候選；閾值本身是任務設定。

參考程式：[programs/notebooks/15_電腦視覺_遷移學習與偵測分割.ipynb](#)



影像任務的輸出差異

任務	模型要輸出什麼
分類	整張圖的類別
分類與定位	類別與一個框
物件偵測	多個框、類別、信心分數
物件追蹤	跨影格維持物件ID
語意分割	每個像素的類別

模型選擇的比較表

條件	應比較的項目
行動裝置	延遲、模型大小、耗電
少量標註	預訓練是否適合目標領域
大量小物件	解析度與特徵圖細節
批次服務	吞吐量與峰值記憶體

TorchVision 的架構與權重結果會隨版本更新，課堂不把表格當作最新排行榜。

推論與訓練的記憶體

- 權重以外，還有中間 activation、梯度與 optimizer 狀態。
- 訓練通常需保留反向傳播所需的中間量。
- 輸入解析度、batch size 與特徵通道數都影響記憶體。
- 可逆網路 RevNet 嘗試重建部分 activation，以額外運算換空間。

預訓練模型與前處理成對使用

```
import torchvision
weights = torchvision.models.ConvNeXt_Base_Weights.IMAGENET1K_V1
model = torchvision.models.convnext_base(weights=weights)
preprocess = weights.transforms()
model.eval()
X = preprocess(images) # images : 已載入且格式符合前處理的影像
```

尺寸、裁切與標準化須符合權重設定；不要套用另一模型的平均值。

預訓練類別與目標類別

```
class_names = weights.meta["categories"]
```

- ImageNet 的標籤集合不會自動等於本次課程的類別。
- 預測「最像哪個既有類別」不代表模型能辨認新的類別。
- 修改分類頭後，至少要訓練新分類頭。

遷移學習：凍結主幹與更換分類頭

```
for p in model.parameters():  
    p.requires_grad = False  
in_features = model.classifier[2].in_features  
model.classifier[2] = nn.Linear(in_features, 102)  
optimizer = torch.optim.AdamW(  
    model.classifier[2].parameters(), lr=1e-3)
```

使用已匯入的 `torch.nn` ；此例對應 Flowers102。先訓練分類頭，再評估是否解凍部分主幹。

凍結參數與 train／eval

`requires_grad=False` 只停止該參數的梯度計算。

- `train()`／`eval()` 控制 Dropout 與 BatchNorm 的行為。
- 主幹若含 BatchNorm，凍結權重後仍可能更新 running statistics。
- 微調時分開決定：哪些參數更新？哪些模組採推論行為？

驗證集用於調整策略，測試集留到最後一次評估。

定位需要額外的監督訊號

同一主幹可以接兩個頭：分類 logits 與四個框座標。

$$L = L_{class} + \lambda L_{box}$$

先約定框格式，例如 $(x_{min}, y_{min}, x_{max}, y_{max})$ 。

框的單位可為像素或正規化座標，預測、標註與評估必須一致。

IoU：框的交集與聯集



IoU 衡量預測框與真實框重疊程度；類別答對仍可能定位不準。

IoU 手算

兩框面積各為 100，交集面積為 60。

$$IoU = \frac{60}{100 + 100 - 60} = \frac{3}{7} \approx 0.429$$

若評估要求 $IoU \geq 0.5$ ，這個框符合定位條件嗎？

答案：不符合。實際偵測還需要類別正確與一對一配對。


滑動視窗的重複運算

在不同位置與尺度裁切影像，再逐一分類，會重複計算大量重疊區域。

全卷積網路讓整張圖共享特徵計算。

偵測器還必須學會框的位置與大小，不能只把分類結果貼在視窗中心。

全卷積網路處理不同尺寸



把全連接運算轉成等效卷積後，可在較大輸入上得到空間分布的輸出。

YOLO 的偵測流程

- 單次前向傳播產生一批候選框、類別與分數。
- 依實作進行信心篩選與重複框處理。
- 常見 NMS 保留高分框，移除高度重疊的同類候選。

YOLO 有多代架構；本頁聚焦單階段偵測的共同資料流與輸出語意。

NMS 手算

同一類別的框 A、B、C，分數為 0.9、0.8、0.7。

框對	IoU
A、B	0.8
A、C	0.1

設 NMS 閾值 0.5：先保留 A，再移除 B，保留 C。

擁擠場景中，兩個不同物件也可能高度重疊。

Precision、Recall 與 AP

- 先固定 IoU 閾值與配對規則。
- 降低信心門檻，通常會收進更多預測。
- Precision 看預測中有多少正確，Recall 看真物件找回多少。
- AP 概括一個類別的 precision-recall 曲線。

同一個真物件的重複框不能各算一次正確偵測。

mAP 的定義要寫清楚

指標寫法	比較範圍
AP@0.5	IoU=0.5 下某類別的 AP
mAP@0.5	在類別間平均
mAP@0.5:0.95	再跨一組 IoU 閾值平均

報告時同時列資料集、類別集合、IoU 範圍與評估程式。

偵測程式導讀

作者 Notebook：Object Detection (`12_deep_computer_vision_with_cnns.ipynb`)

定位 Cells 125–131：模型載入、影像輸入、結果解讀。

讀碼任務：找出框座標、類別 ID 與信心分數，說明各自對應什麼。

完整推論需下載套件與權重；課堂可先閱讀輸出結構。

物件追蹤與身分切換

偵測回答「這一影格有哪些物件」，追蹤還要把不同影格的物件配對。

常用線索：運動預測、框重疊、外觀特徵。

遮擋或相似外觀可能造成 ID switch。

活動：兩人交錯行走時，僅用最近中心距離會出現什麼問題？

語意分割的像素標籤




輸出是一張類別圖；同一類的不同個體，在語意分割中可能共用標籤。

語意、實例與全景分割

任務	人物 A 與人物 B	背景區域
語意分割	同為「人」	像素類別
實例分割	各自有 ID	常只處理物件
全景分割	各自有 ID	也有完整區域類別


先依標註需求選任務，才選模型與指標。

轉置卷積與上採樣



轉置卷積可以學習放大特徵圖；它不是一般卷積的數學反函數。

跳接保留細節



高層語意與低層空間資訊一起使用，有助於恢復邊界與細小區域。

其他卷積層的用途

類型	主要用途
Conv1d	時間或一維訊號
Conv3d	影片、體積資料
Dilated convolution	增加感受野而不直接下採樣
Grouped convolution	控制通道之間的連接

維度選擇依資料結構，不只依資料是否能轉成矩陣。

課堂活動：校園垃圾辨識

練習：分類、偵測或分割，哪個才符合需求？

1. 若要統計垃圾件數，需要什麼輸出？
2. 若要估計垃圾覆蓋面積，需要什麼標註？
3. 如何依拍攝日期或場景切分，避免相似照片洩漏？
4. 交付任務定義、標註樣例與兩項評估指標。

離堂檢核

- 預訓練權重為何要搭配自己的 transforms ?
- IoU 很高是否代表類別一定正確 ?
- 重複框為何會影響 precision ?
- 語意分割能否直接回答「有幾個人」 ?

課後程式與延伸閱讀

- 作者第 12 章 Notebook (`12_deep_computer_vision_with_cnns.ipynb`)：先執行 Setup，再定位本課指定區段。

執行前確認資料、套件與運算資源。

Notebook 導讀：可執行的機制與驗收

實驗	驗收證據
IoU、NMS、逐框配對	手算 3/7；重複框算 FP；AP@0.5
FCN、分割、轉置卷積	像素類別／實例 ID；內積轉置關係
上採樣與 skip	尺寸可接合，細節來自較早特徵
前處理、固定骨幹、追蹤	張量形狀、權重不變、ID 配對

AP 範例是單類全點插值，不能直接標成 COCO mAP。

玩具前向不等於訓練 YOLO、U-Net 或預訓練視覺模型。