

自然語言處理：詞嵌入與注意力

字元生成、情感分析與序列翻譯

書本第 14 章

學習重點與成果

- 字元語言模型與 embeddings。
- tokenizer、情感分類與預訓練。
- 翻譯、beam search 與 attention。

成果：能對齊輸入與標籤，解釋 tokenizer、padding 與注意力的作用。


 **配套 Notebook**： `programs/notebooks/17_自然語言處理_詞嵌入與注意力.ipynb`。本檔提供公式驗算、機制實驗與結果圖；框架片段及完整模型案例另依頁面說明閱讀。

程式實驗與實際輸出

```
scores = Q @ K.T / sqrt(d)
weights = softmax(scores)
```

觀察：每列代表一個 query 對各 key 的權重，總和為 1；高權重不是因果證明。

參考程式：`programs/notebooks/17_自然語言處理_詞嵌入與注意力.ipynb`



字元語言模型的任務


給定前面的字元，預測下一個字元的機率分布。

例：「機器學」後面可能接「習」。

訓練目標來自文字本身，不需逐字額外人工標註，但資料選擇仍影響結果。

生成時，把已產生的字元放回模型，逐步延長序列。

輸入與目標相差一個位置



每個輸入視窗對應向右位移一格的目標；最後一個字元也有下一步標籤。


字元視窗手算

原始序列：A B C D E，視窗長度 4。

位置	1	2	3	4
輸入	A	B	C	D
目標	B	C	D	E

分類頭在每個位置輸出 vocab_size 個 logits。

Embedding 是可學習的查表



token ID 只用來查位置；數字 ID 的大小不代表語意遠近。

Embedding 的輸入與輸出

```
import torch
from torch import nn
embed = nn.Embedding(5, 3)
ids = torch.tensor([[3, 2], [0, 2]])
E = embed(ids)
print(E.shape) # 預期 [2, 2, 3]
```

五個 token，各自對應三維向量；重複 ID 會查到同一列參數。

One-hot、詞袋與詞向量

表示	保留什麼
單一 token 的 one-hot	token 身分
文件的 bag-of-words	詞頻，通常忽略順序
序列 embeddings	每個位置的稠密向量

Word2Vec 的 CBOW 與 Skip-gram 利用上下文學詞向量；本章也會端到端學 embeddings。

Char-RNN 的模型結構

```
# X: [B,T] 的 token IDs
embedding = nn.Embedding(vocab_size, 10)
gru = nn.GRU(10, 128, num_layers=2, batch_first=True)
head = nn.Linear(128, vocab_size)
outputs, states = gru(embedding(X))
logits = head(outputs).permute(0, 2, 1)
```

logits [B,V,T]，可搭配 [B,T] 目標使用 CrossEntropyLoss。

Temperature 與抽樣

$$p_i = \frac{\exp(z_i/T)}{\sum_j \exp(z_j/T)}, \quad T > 0$$

- 較小的 T 讓高分 token 更集中。
- 較大的 T 使分布更平坦。
- Greedy 每次選最大值，與隨機抽樣是不同策略。

溫度提高可能增加多樣性，也可能降低連貫性。

Stateful RNN 的資料順序

跨 batch 延續 hidden state 時，每個 batch 位置須接續同一段序列。

- 不任意 shuffle 連續批次。
- 狀態需適時 `detach()`，限制反向傳播範圍。
- 換文件或獨立序列時，重設狀態。

一般獨立視窗訓練則可打亂視窗，兩種做法不可混用。

情感分類的標籤單位

IMDB 範例對每篇評論預測正面或負面。

同一句出現「好」不必然代表正面，例如「好失望」。

先建立詞袋基準，再比較能利用順序的模型。

評估時檢查否定、反諷、長評論與領域轉移。

三種子詞 tokenizer

方法	核心想法	閱讀重點
BPE／byte-level BPE	反覆合併常見相鄰片段	位元組基底可處理更廣字元
WordPiece	依訓練準則建立子詞表	特殊token與子詞延續記號
Unigram	從候選子詞機率模型縮減詞表	可有不同切分可能

Tokenizer 必須搭配預訓練模型

```
from transformers import AutoTokenizer
tokenizer = AutoTokenizer.from_pretrained("bert-base-uncased")
batch = tokenizer(["A good movie", "Not good"],
                  padding=True, truncation=True,
                  max_length=128, return_tensors="pt")
print(batch["input_ids"].shape)
print(batch["attention_mask"])
```

英文模型僅作介面示範；中文任務須另選適合語言的模型與評估資料。

Padding 與截斷

- Padding 讓同一 batch 的序列長度一致。
- Attention mask 標出真正 token 與補值位置。
- 截斷會丟掉文字，可能連否定或結論也一起刪掉。
- `padding_idx` 停止某列 embedding 更新，不等於 RNN 自動忽略 padding。

Packed sequence 避免讀入尾端補值

```
from torch.nn.utils.rnn import pack_padded_sequence
lengths = batch["attention_mask"].sum(dim=1)
E = embedding(batch["input_ids"])
packed = pack_padded_sequence(
    E, lengths.cpu(), batch_first=True, enforce_sorted=False)
outputs, h_n = gru(packed)
```

此用法假設有效 token 在前、右側 padding，且各長度大於 0。


情感分類頭的損失與形狀

GRU 的句子表示接一個線性輸出，得到每句的正面 logit。

```
# logits 與 labels 都是 [B,1]
loss_fn = nn.BCEWithLogitsLoss()
loss = loss_fn(logits, labels.float())
proba_positive = logits.sigmoid()
```

訓練損失接原始 logits；只有要解讀機率時才做 Sigmoid。

雙向 RNN 的上下文



已知完整評論時可讀左右兩側；即時逐步預測未來時不能偷讀尚未到來的內容。

POS tagging 的逐 token 標籤

範例句：The quick brown fox jumps。

token	The	quick	brown	fox	jumps
Penn 標籤	DT	JJ	JJ	NN	VBZ

一個詞拆成多個子詞後，要約定標籤如何對齊與哪些位置忽略損失。

Stemming、lemmatization 與任務需求

- Stemming 以規則裁切字形，結果未必是字典詞。
- Lemmatization 常結合詞性還原詞元。
- 預訓練語言模型通常使用配套 tokenizer，不任意先做 stemming。

討論：若先刪除所有標點，情感或對話任務可能失去哪些訊號？

預訓練表示的兩個層次

表示	同一 token 在不同句子
靜態 embedding	通常查到同一向量
上下文表示	隨上下文改變

可凍結預訓練模型當特徵抽取器，也可微調部分或全部參數。

Task-specific class、Trainer 與 pipeline


工具	幫忙處理什麼
AutoModelForSequenceClassification	預訓練主幹與分類頭
Trainer	訓練、評估、儲存與紀錄
pipeline	封裝前處理與推論

方便的介面仍需正確標籤、資料切分與評估指標。

偏差與公平性檢查

- 把人名、性別或地區詞替換後，比較預測是否不合理改變。
- 分群檢查錯誤率，不只看總準確率。
- 確認模型支援的語言與訓練領域。
- 將測例、結果與限制一起記錄，避免把分數當作人的評價。

Encoder-decoder 翻譯



Encoder 摘要來源句；decoder 依來源表示與已產生的目標文字預測下一詞。

Teacher forcing 的位移

目標句： <bos> I am a student <eos> 。

訓練角色	token 序列
Decoder 輸入	<bos> I am a student
監督標籤	I am a student <eos>

推論沒有標準答案可餵入，必須使用先前產生的 token 。


翻譯的固定向量瓶頸

長句的許多資訊若都壓在一個固定向量，可能難以保留。

先改進資料分桶、遮罩與解碼，再比較 attention。

翻譯評估可用自動指標輔助，仍需檢查漏譯、專有名詞與否定語意。

Beam search 保留多條候選



每步保留若干較高分的部分句子；寬度越大，計算與記憶體成本越高。


Greedy 不一定選到整句高機率

自編例：第一步 $A=0.6$ ， $B=0.4$ 。

- A 後面最佳續接的條件機率為 0.5，路徑機率 $0.6 \times 0.5 = 0.30$ 。
- B 後面最佳續接為 0.9，路徑機率 $0.4 \times 0.9 = 0.36$ 。

Greedy 先選 A，可能錯過 B 路徑；beam search 也不保證全域最佳。

Attention 動態讀取來源序列



每個輸出時間步對來源位置分配不同權重，再組合成當步 context。

注意力的三個步驟

$$e_{tj} = \text{score}(h_t, s_j), \quad \alpha_{tj} = \text{softmax}_j(e_{tj})$$

$$c_t = \sum_j \alpha_{tj} s_j$$

1. 比較目前 decoder 狀態與各來源狀態。
2. 沿來源位置做 Softmax。
3. 用權重加總來源 value。

注意力加權平均手算

若權重為 $[0.2, 0.3, 0.5]$ ，values 為 $[1, 0], [0, 2], [2, 2]$ ：

$$c = 0.2[1, 0] + 0.3[0, 2] + 0.5[2, 2] = [1.2, 1.6]$$

注意力權重是本次計算的分配；高權重不能單獨證明因果重要性。

程式導讀：Luong attention

作者 Notebook (`14_nlp_with_rnn_and_attention.ipynb`) : Cells 210–214。

- 找到 decoder outputs 與 encoder outputs 的矩陣乘法。
- 說明 Softmax 沿哪一軸計算。
- 檢查來源 padding 是否被遮罩。
- 追蹤 context 與 decoder 表示串接後的維度。

課堂活動：可重現的情感分類比較

練習：設計詞袋與 GRU 的比較表。

固定切分，記錄 tokenizer、長度、padding 與評估方式。

交付：兩種表示的資料形狀，以及包含否定、長句、領域差異的 6 個測例。

課後選讀：POS tagging 或英西翻譯，說明標籤對齊方式的差異。

離堂檢核

- token ID 的數字大小能表示語意距離嗎？
- `padding_idx` 是否讓 RNN 自動跳過補值？
- 訓練與推論的 decoder 輸入有何差異？
- Attention 為何不必只依賴最後一個 encoder state？

課後程式與延伸閱讀

- 作者第 14 章 Notebook (`14_nlp_with_rnn_and_attention.ipynb`)：先執行 Setup，再定位本課指定區段。

執行前確認資料、套件與運算資源。

Notebook 導讀：可執行的機制與驗收

對照內容	程式證據
Token 位移、embedding、padding	lookup=one-hot 乘表；有效長度
Char-RNN、雙向與 stateful	序列軸、反向上下文、跨批狀態
Teacher forcing、greedy／beam	輸入標籤位移；路徑機率 0.30／0.36
Luong attention	來源遮罩、加權和 [1.2, 1.6]、串接維度

第一個範例是手工詞向量的 self-attention；第二個是 encoder-decoder 的 cross-attention。
小詞表／一輪 BPE 與分組表不等於預訓練 tokenizer 或公平性研究。