

大型語言模型：生成與聊天系統

Decoder、SFT、偏好學習與工具整合

書本第 15 章

建議 180 分鐘，含活動與休息

學習成果與課堂安排

- 0–50 分：自迴歸生成、GPT 與提示。
- 60–110 分：SFT、RLHF、DPO 與程式導讀。
- 120–180 分：RAG、工具與完整聊天系統。

成果：分辨模型訓練與應用系統，設計有證據的回答評估。


 **配套 Notebook**： `programs/notebooks/19_大型語言模型_生成與聊天系統.ipynb` 。程式片段、實際圖表與表格可由此檔重現。

程式實驗與實際輸出


```
p = softmax(logits / temperature)
token = sample_top_k(p, k=3)
```

觀察：較低溫度讓分布更集中；greedy 與抽樣回答的是不同生成策略。

參考程式：`programs/notebooks/19_大型語言模型_生成與聊天系統.ipynb`



Decoder-only 逐 token 生成



下一個 token 依賴既有前綴；訓練時同時學每個位置的下一步。

語言模型的機率分解

$$p(x_1, \dots, x_T) = \prod_{t=1}^T p(x_t \mid x_{<t})$$

訓練最大化真實 token 的對數機率；生成則依模型分布選 token。

語句流暢只表示接續合理，不保證事實正確。

GPT-1、GPT-2、GPT-3 的閱讀重點

世代	本章用來說明的概念
GPT-1	語言預訓練後做任務微調
GPT-2	較大模型與提示式任務表達
GPT-3	大規模模型與in-context learning

依書中的歷史案例學方法；不用歷史模型尺寸推定今日服務能力。

小模型生成：明確限制輸出長度

```
from transformers import AutoTokenizer, AutoModelForCausalLM
tok = AutoTokenizer.from_pretrained("gpt2")
lm = AutoModelForCausalLM.from_pretrained("gpt2").eval()
inputs = tok("Machine learning is", return_tensors="pt")
with torch.no_grad():
    ids = lm.generate(**inputs, max_new_tokens=30,
                      do_sample=False, pad_token_id=tok.eos_token_id)
print(tok.decode(ids[0], skip_special_tokens=True))
```

需先 `import torch`，首次下載權重需網路；英文 GPT-2 用於理解生成介面。

作者程式：Cells 70–73（簡化）（`15_transformers_for_nlp_and_chatbots.ipynb`）

生成參數的效果

參數	控制內容
max_new_tokens	最多新增多少token
do_sample	是否依分布抽樣
temperature	分布集中程度
top_k/top_p	抽樣候選集合

固定模型、提示與種子，才能比較單一設定的影響。

Prompting 與微調

- Zero-shot：用任務指示與必要背景說明需求。
- Few-shot：在上下文中提供少量輸入／輸出示例。
- 微調：以訓練改變參數，成本與資料需求不同。

Few-shot 在一般推論中不更新權重；也會占用上下文空間。

可檢查的提示範例

請依下列課程規則回答學生問題。列出支持答案的規則編號。若資料不足，指出缺少的資訊。輸出含「答案」與「依據」兩欄。

- 提供明確任務與來源範圍。
- 設定輸出格式與資料不足時的行為。
- 準備一組固定問題評估，不只看一次成功案例。

模型載入與資源估算

書中另使用 Mistral-7B 說明較大模型與對話。

70 億參數若只用每參數 2 bytes 儲存，權重約需 14 GB。

這還不含 KV cache、activation、runtime 與訓練狀態。

模型存取條件與套件介面可能變動，先閱讀對應模型頁與 Notebook Setup。

Base model 與聊天模型


模型	主要學到什麼
Base model	大量文字中的接續分布
Instruction／chat model	回答指示與對話格式

聊天需要角色、輪次邊界與訓練相容的模板；不能只把任何模型包成聊天室。

對話歷史與 context window

- 每一輪需要組成模型能理解的輸入。
- 上下文長度是有限資源；歷史與新回答都占空間。
- 摘要或截斷可能移除必要條件。
- 重新整理歷史後，仍需保留問題與引用來源的關係。

聊天模型的訓練階段



預訓練先學語言分布，再透過監督微調與偏好學習調整回答行為。

SFT：用示範回答教模型

訓練樣本包含 prompt 與示範答案。

常將 prompt 與 padding 的 loss 遮掉，聚焦答案 token。

- 檢查角色標記與答案邊界。
- 去除重複或矛盾標註。
- 驗證集不要出現同題不同包裝的近重複資料。

RLHF 與 DPO 的差異

方法	偏好資料如何進入訓練
RLHF常見流程	先學reward model，再用RL更新policy
DPO	直接用chosen／rejected回答計算損失

兩者都需要清楚的偏好準則，並關注對參考模型的偏離。

DPO 損失的意義

$$\delta(y) = \log p_{\theta}(y \mid x) - \log p_{ref}(y \mid x)$$

$$L = -\log \sigma(\beta[\delta(y_c) - \delta(y_r)])$$

y_c 是偏好回答， y_r 是較不偏好的回答。

相對於參考模型，增加 chosen 的相對優勢，會讓此損失下降。

DPO 手算

設 $\delta(y_c) = 0.4, \delta(y_r) = -0.2, \beta = 1$ 。

差值為 0.6， $L = -\log \sigma(0.6) \approx 0.437$ 。

若兩者沒有相對差異， $L = -\log 0.5 \approx 0.693$ 。

偏好是標註準則的選擇，不能一律視為客觀真理。

答案 log probability 的位移

```
import torch.nn.functional as F
next_ids = input_ids[:, 1:]
logp = F.log_softmax(logits[:, :-1], dim=-1)
chosen_logp = logp.gather(-1, next_ids.unsqueeze(-1)).squeeze(-1)
answer_logp = (chosen_logp * answer_mask[:, 1:]).sum(dim=-1)
```

answer_mask 需排除 prompt 與 padding，並與位移後 target 對齊。

作者程式：Cells 117-124（教學改寫）（`15_transformers_for_nlp_and_chatbots.ipynb`）

TRL 訓練流程導讀

作者 Notebook (`15_transformers_for_nlp_and_chatbots.ipynb`) : Cells 133–151。

1. 檢查 SFT 資料欄位與文字模板。
2. 定位 SFTConfig／SFTTrainer 的設定。
3. 檢查偏好資料的 chosen、rejected 與 prompt。
4. 說明 DPO 使用哪個參考模型。

完整訓練是課後 GPU 選做；先完成資料檢查再啟動。

完整聊天系統的組成

模型之外，還需要：

- 對話與提示的組織。
- 檢索、計算與其他工具。
- 工具結果的驗證與錯誤處理。
- 可追溯的資料來源與評估紀錄。

回答失敗可能發生在任一環節，不一定只靠更大模型解決。

RAG 的工作流程

1. 將問題轉成可檢索的查詢。
2. 從文件找出相關片段。
3. 把片段與來源放入模型上下文。
4. 生成回答並檢查引用是否支持說法。

檢索到不相關或過期片段，仍可能得到流暢的錯誤答案。

工具呼叫與程式執行的邊界

模型可以提出結構化工具請求；應用程式檢查後才執行。

步驟	應用程式負責的檢查
接收請求	工具名稱、參數型別
執行前	使用者授權與資料範圍
回傳後	錯誤、單位、來源與可信度

工具輸出或文件文字不是新的系統指令。

MCP 與結構化生成

MCP 提供工具與資料能力的連接方式；實際能力由 server 與應用程式決定。

結構化生成限制輸出的格式，例如 JSON 欄位與型別。

格式正確不等於事實正確，也不等於工具執行已獲授權。

框架與執行環境的分工

層次	書中列舉	用途
應用流程	LangChain／LangGraph等	組合模型、狀態與工具
使用介面	LM Studio／Ollama等	載入與互動
推論後端	llama.cpp等	執行模型計算

Encoder-decoder 的 text-to-text 任務

T5 把翻譯、摘要與分類都表示成文字輸入與文字輸出。

模型／變體	教材重點
T5	片段遮蔽與統一文字任務
mT5／ByT5	多語言／位元組表示
FLAN-T5／UL2	指令調整／混合預訓練目標
BART	去噪式encoder-decoder預訓練

課堂活動：課程規則問答

20 分鐘，以教師提供的兩頁規則設計 RAG 測試。

- 4 題可直接查到，2 題需跨段整合，2 題資料不足。
- 每題列出正確答案、支持片段與可接受的拒答。
- 比較無檢索與有檢索，分開評估檢索與生成錯誤。

交付：8 題測試表；不以回答長度當品質指標。

離堂檢核

- Few-shot 與 SFT 哪個會更新權重？
- DPO 的參考模型扮演什麼角色？
- JSON 格式正確為何仍需檢查內容？
- RAG 失敗應先查哪些環節？

課後程式與延伸閱讀

- 作者第 15 章 Notebook (`15_transformers_for_nlp_and_chatbots.ipynb`)：先執行 Setup，再定位本課指定區段。
- 舊稿 `LLM.pptx` 與 `機器學習-10-執行大型語言模型.pptx`：token、prompt、BERT／T5／GPT 與幻覺案例。

程式來源依教材核對版本標示；執行前確認資料、套件與運算資源。