

視覺與多模態 Transformer

ViT、CLIP 與圖文生成

書本第 16 章

建議 180 分鐘，含活動與休息

學習成果與課堂安排

- 0–50 分：影像 token、ViT 與視覺架構。
- 60–110 分：自監督表示、CLIP 與對比學習。
- 120–180 分：多模態融合、圖片描述與評估。

成果：能追蹤 patch 形狀，分辨圖文比對與圖文生成。


 **配套 Notebook**： [20_視覺與多模態Transformer.ipynb](#)。程式片段、實際圖表與表格可由此檔重現。

程式實驗與實際輸出

```
similarity = normalize(image_emb) @ normalize(text_emb).T
```

觀察：圖文嵌入先正規化，再以餘弦相似度比較；分數只在同一模型空間內有意義。

[開啟完整 Notebook](#)




視覺注意力的早期脈絡

圖片描述可用 CNN 取得影像區域特徵，再由 RNN 逐詞生成。

Attention 讓不同詞讀取不同區域，而非只用一個固定向量。

視覺化有助觀察行為，但不能只看熱區就認定模型推理正確。

DETR：用集合預測做偵測



影像特徵與 object queries 共同產生一組物件預測，訓練需配對預測與標註。


DETR 的配對概念

一張圖可能只有三個物件，模型卻有固定數量的輸出槽。

- 以一對一配對決定哪些輸出負責哪些標註。
- 其餘槽學「沒有物件」。
- 分類損失與框損失共同訓練。

Object query 是可學習的查詢，不是預先知道的物件名稱。

ViT 把影像切成 token 序列



每個 patch 先映射成向量，加入位置資訊，再交給 Transformer encoder。

Patch 數量手算

224×224 的 RGB 影像，patch 為 16×16。

- 每邊 14 個 patch，共 $14^2 = 196$ 個。
- 每個 patch 攤平為 $16 \times 16 \times 3 = 768$ 維。
- 加上 CLS token 後，序列長度為 197。

Patch 的原始維度與模型 embedding 維度可相同，也可不同。

以 Conv2d 完成 patch embedding

```
import torch
from torch import nn
patchify = nn.Conv2d(3, 192, kernel_size=16, stride=16)
X = torch.randn(2, 3, 224, 224)
tokens = patchify(X).flatten(2).transpose(1, 2)
print(tokens.shape) # 預期 [2, 196, 192]
```

kernel 與 stride 相同，產生不重疊 patches；需先處理不能整除的影像尺寸。

作者程式：Cell 20（簡化）

ViT 的模型結構導讀


作者 Notebook：Cells 20–22。

找到 patch embedding、CLS token、position embedding、encoder 與分類頭。

若影像解析度改變，patch 數與位置表也會改變，不能只修改輸入大小。


課堂先做隨機張量的形狀檢查，微調則使用作者後續 pretrained 範例。

DeiT 的蒸餾 token




以教師模型提供額外監督；蒸餾讓學生能利用教師行為改善資料使用。

PVT 的金字塔表示



逐層改變空間解析度，產生適合密集預測的多尺度特徵。

Swin 的視窗注意力



先限制在局部視窗內，再透過位移視窗讓不同區域交換資訊。


全域與視窗注意力的成本

設影像共有 N 個 token，每個視窗有 M 個 token。

注意力方式	分數矩陣元素總數量級
全域	N^2
固定大小局部視窗	NM

固定視窗大小時，局部注意力的分數成本隨 token 數近似線性增加。

DINO 的自蒸餾



不同視角的學生與教師輸出互相對齊；教師通常以學生參數的移動平均更新。

自監督表示與 attention 圖

作者 DINO 範例：Cells 40–45。

讀取 attention tensor 前，先確認 query 與 key 軸。

作者 Cell 44 使用 patch-to-CLS 的切片；不能直接標成 CLS-to-patch。

熱區是分析線索，不等於經過像素標註評估的完整分割器。

其他視覺 Transformer 的路線

路線	教材例子
遮蔽影像學習	BEiT、MAE、SimMIM
大規模自監督表示	DINO系列、iBOT
減少token計算	合併、裁剪、選取patch
擴大訓練	模型、資料與訓練配方共同調整

模型名稱很多，先辨認改的是資料、目標或架構。

多模態的四種關係

問題	例子
對齊	找出與句子最相符的圖片
融合	同時看圖片與問題作答
生成	依圖片產生描述
條件生成	依文字產生影像


模態不同，不代表所有任務都需要同一種模型。

VideoBERT 與 ViLBERT

- VideoBERT 把影片與語言轉成可共同建模的序列。
- ViLBERT 分別處理視覺與文字，再以 co-attention 交換資訊。
- 預訓練可包含遮蔽 token 與跨模態配對目標。

讀圖時找出：哪些層只處理單一模態？哪些層讓兩者互動？

CLIP 的圖文對比學習



同一 batch 中，真實圖文配對拉近；其他配對作為對比訊號。

CLIP 的相似度矩陣

三張圖與三段配對文字，產生 3×3 相似度矩陣。

對角線是正配對；每列做圖找文，每欄做文找圖。

$$s_{ij} = \frac{u_i^\top v_j}{\tau}$$

此處 u, v 已做長度正規化；溫度影響分數差異。

Zero-shot 分類依賴候選文字

把類別寫成文字描述，再與影像向量比較。

「這是一張貓的照片」與「這是一張狗的照片」形成候選。

- 模板和語言會影響結果。
- 加入或刪除候選類別，正規化分數可能改變。
- 分數最高不表示模型能可靠辨認所有未知類別。

CLIP 推論介面

```
from transformers import pipeline
classifier = pipeline("zero-shot-image-classification",
                      model="openai/clip-vit-base-patch32")
result = classifier(image, candidate_labels=["cat", "dog", "bird"],
                    hypothesis_template="This is a photo of a {}.")
```

image 是已載入的 PIL RGB 影像；需下載模型。先比較不同文字模板，不重新訓練。

作者程式：Cell 49（改寫）


DALL·E 與 DALL·E 2 的差異

教材以這兩個模型說明文字生成影像的不同路線：

- DALL·E：把文字與離散影像碼放入生成模型。
- DALL·E 2：利用 CLIP 表示連接文字條件與影像生成。

圖文對齊提供語意條件，生成器仍需學影像分布。

Perceiver 的 latent bottleneck



大量輸入先透過 cross-attention 進入較短的 latent 序列，再在 latent 中計算。


Perceiver IO 的輸出查詢

Perceiver IO 再利用 output queries 從 latent 讀出所需結果。

同一個 latent 表示可對應不同輸出形狀，例如類別或密集預測。

- 輸入長度與 latent 長度不必相同。
- 輸出位置可以用查詢指定。
- 成本仍含跨輸入與 latent 的注意力運算。

Flamingo 的交錯圖文輸入



用視覺表示與語言模型互動，處理文字與圖片交錯的上下文。


BLIP 與 BLIP-2 的銜接

BLIP 結合圖文理解與生成，也用 captioning／filtering 改善圖文配對資料。

BLIP-2 進一步重用凍結的視覺與語言主幹，用 Q-Former 學兩者之間的連接。

兩者都處理圖文任務，但資料處理與可訓練模組的設計不同。

BLIP-2 的 Q-Former



以較小的連接模組把視覺資訊整理成語言模型可使用的表示。

BLIP-2 的兩階段學習

1. 先讓可學習 query 與視覺特徵互動，學會有用的圖文表示。
2. 再將 query 表示映射至語言模型輸入空間。

凍結大型主幹可減少要更新的參數，但前向計算仍需要資源。

作者 Cells 73–75 提供讀圖生成文字範例，完整模型需較多記憶體。

舊稿圖片描述程式的閱讀路線

11_Image Captioning.pptx s.14-25 提供：

部分	要追蹤的資料
Vocabulary／Dataset	token字典、影像與caption配對
CNN encoder	區域特徵或整張圖特徵
RNN decoder	位移後的文字、hidden state
Attention	每一步對影像區域的加權

與 BLIP-2 比較哪些部分預訓練、哪些部分需任務資料。

其他多模態任務的分類

任務方向	書中例子
文件與版面	LayoutLM
視覺定位與問答	GLIP、LLaVA、PaLI、Qwen-VL
多模態對齊	ImageBind
語音翻譯	SeamlessM4T
動作或影片	RT-2、EMO

此表定位研究問題，不將書中的版本或能力描述當即時排名。

多模態評估：看得見與推測的差別

同一張桌面照片可能讓模型「補出」不存在的物件。

- 分開評估物件、數量、空間關係與文字辨識。
- 把遮擋、低解析度與看不清楚的情況列入測試。
- 讓回答指出可見證據與不確定部分。

照片中的文字也可能是惡意指令，應當作待分析內容。

課堂活動：圖片檢索與描述

20 分鐘，使用教師提供的 6 張圖片與 6 段描述。

1. 設計 CLIP 圖文配對的正確答案表。
2. 加入一段容易混淆的描述，說明評估方法。
3. 為生成式描述另定「捏造物件」與「漏掉物件」檢查。

交付：兩種任務的輸出與指標，不能只比較文字是否好看。

離堂檢核

- 224×224 、patch16 的 token 數是多少？
- CLIP 是否會直接產生完整描述句？
- 短 latent 序列為何有助降低成本？
- 為何 attention 熱區不能取代完整正確性驗證？

課後程式與延伸閱讀

- 作者第 16 章 Notebook：先執行 Setup，再定位本課指定區段。
- 舊稿 11_Image Captioning.pptx 與 機器學習-08-Image Captioning.pptx：CNN／RNN 圖片描述與 attention。

程式連結固定於教材核對的版本；執行前確認資料、套件與運算資源。