

視覺與多模態 Transformer

ViT、CLIP 與圖文生成

書本第 16 章

建議 180 分鐘，含活動與休息

學習成果與課堂安排

- 0–50 分：影像 token、ViT 與視覺架構。
- 60–110 分：自監督表示、CLIP 與對比學習。
- 120–180 分：多模態融合、圖片描述與評估。

成果：能追蹤 patch 形狀，分辨圖文比對與圖文生成。


 **配套 Notebook**： `programs/notebooks/20_視覺與多模態Transformer.ipynb`。本檔提供公式驗算、機制實驗與結果圖；框架片段及完整模型案例另依頁面說明閱讀。

程式實驗與實際輸出

```
similarity = normalize(image_emb) @ normalize(text_emb).T
```

觀察：圖文嵌入先正規化，再以餘弦相似度比較；分數只在同一模型空間內有意義。

參考程式：`programs/notebooks/20_視覺與多模態Transformer.ipynb`




視覺注意力的早期脈絡

圖片描述可用 CNN 取得影像區域特徵，再由 RNN 逐詞生成。

Attention 讓不同詞讀取不同區域，而非只用一個固定向量。

視覺化有助觀察行為，但不能只看熱區就認定模型推理正確。

DETR：用集合預測做偵測



影像特徵與 object queries 共同產生一組物件預測，訓練需配對預測與標註。


DETR 的配對概念

一張圖可能只有三個物件，模型卻有固定數量的輸出槽。

- 以一對一配對決定哪些輸出負責哪些標註。
- 其餘槽學「沒有物件」。
- 分類損失與框損失共同訓練。

Object query 是可學習的查詢，不是預先知道的物件名稱。

ViT 把影像切成 token 序列



每個 patch 先映射成向量，加入位置資訊，再交給 Transformer encoder。

Patch 數量手算

224×224 的 RGB 影像，patch 為 16×16。

- 每邊 14 個 patch，共 $14^2 = 196$ 個。
- 每個 patch 攤平為 $16 \times 16 \times 3 = 768$ 維。
- 加上 CLS token 後，序列長度為 197。

Patch 的原始維度與模型 embedding 維度可相同，也可不同。

以 Conv2d 完成 patch embedding

```
import torch
from torch import nn
patchify = nn.Conv2d(3, 192, kernel_size=16, stride=16)
X = torch.randn(2, 3, 224, 224)
tokens = patchify(X).flatten(2).transpose(1, 2)
print(tokens.shape) # 預期 [2, 196, 192]
```

kernel 與 stride 相同，產生不重疊 patches；需先處理不能整除的影像尺寸。

作者程式：Cell 20（簡化）（`16_vision_and_multimodal_transformers.ipynb`）

ViT 的模型結構導讀


作者 Notebook (`16_vision_and_multimodal_transformers.ipynb`) : Cells 20–22 。

找到 patch embedding、CLS token、position embedding、encoder 與分類頭。

若影像解析度改變，patch 數與位置表也會改變，不能只修改輸入大小。


課堂先做隨機張量的形狀檢查，微調則使用作者後續 pretrained 範例。

DeiT 的蒸餾 token




以教師模型提供額外監督；蒸餾讓學生能利用教師行為改善資料使用。

PVT 的金字塔表示



逐層改變空間解析度，產生適合密集預測的多尺度特徵。

Swin 的視窗注意力



先限制在局部視窗內，再透過位移視窗讓不同區域交換資訊。


全域與視窗注意力的成本

設影像共有 N 個 token，每個視窗有 M 個 token。

注意力方式	分數矩陣元素總數量級
全域	N^2
固定大小局部視窗	NM

固定視窗大小時，局部注意力的分數成本隨 token 數近似線性增加。

DINO 的自蒸餾



不同視角的學生與教師輸出互相對齊；教師通常以學生參數的移動平均更新。

自監督表示與 attention 圖

作者 DINO 範例 (`16_vision_and_multimodal_transformers.ipynb`) : Cells 40–45。

讀取 attention tensor 前，先確認 query 與 key 軸。

作者 Cell 44 使用 patch-to-CLS 的切片；不能直接標成 CLS-to-patch。

熱區是分析線索，不等於經過像素標註評估的完整分割器。

其他視覺 Transformer 的路線

路線	教材例子
遮蔽影像學習	BEiT、MAE、SimMIM
大規模自監督表示	DINO系列、iBOT
減少token計算	合併、裁剪、選取patch
擴大訓練	模型、資料與訓練配方共同調整

模型名稱很多，先辨認改的是資料、目標或架構。

多模態的四種關係

問題	例子
對齊	找出與句子最相符的圖片
融合	同時看圖片與問題作答
生成	依圖片產生描述
條件生成	依文字產生影像


模態不同，不代表所有任務都需要同一種模型。

VideoBERT 與 ViLBERT

- VideoBERT 把影片與語言轉成可共同建模的序列。
- ViLBERT 分別處理視覺與文字，再以 co-attention 交換資訊。
- 預訓練可包含遮蔽 token 與跨模態配對目標。

讀圖時找出：哪些層只處理單一模態？哪些層讓兩者互動？

CLIP 的圖文對比學習



同一 batch 中，真實圖文配對拉近；其他配對作為對比訊號。

CLIP 的相似度矩陣

三張圖與三段配對文字，產生 3×3 相似度矩陣。

對角線是正配對；每列做圖找文，每欄做文找圖。

$$s_{ij} = \frac{u_i^\top v_j}{\tau}$$

此處 u, v 已做長度正規化；溫度影響分數差異。

Zero-shot 分類依賴候選文字

把類別寫成文字描述，再與影像向量比較。

「這是一張貓的照片」與「這是一張狗的照片」形成候選。

- 模板和語言會影響結果。
- 加入或刪除候選類別，正規化分數可能改變。
- 分數最高不表示模型能可靠辨認所有未知類別。

CLIP 推論介面

```
from transformers import pipeline
classifier = pipeline("zero-shot-image-classification",
                      model="openai/clip-vit-base-patch32")
result = classifier(image, candidate_labels=["cat", "dog", "bird"],
                    hypothesis_template="This is a photo of a {}.")
```

image 是已載入的 PIL RGB 影像；需下載模型。先比較不同文字模板，不重新訓練。

作者程式：Cell 49（改寫）（`16_vision_and_multimodal_transformers.ipynb`）


DALL·E 與 DALL·E 2 的差異

教材以這兩個模型說明文字生成影像的不同路線：

- DALL·E：把文字與離散影像碼放入生成模型。
- DALL·E 2：利用 CLIP 表示連接文字條件與影像生成。

圖文對齊提供語意條件，生成器仍需學影像分布。

Perceiver 的 latent bottleneck



大量輸入先透過 cross-attention 進入較短的 latent 序列，再在 latent 中計算。


Perceiver IO 的輸出查詢

Perceiver IO 再利用 output queries 從 latent 讀出所需結果。

同一個 latent 表示可對應不同輸出形狀，例如類別或密集預測。

- 輸入長度與 latent 長度不必相同。
- 輸出位置可以用查詢指定。
- 成本仍含跨輸入與 latent 的注意力運算。

Flamingo 的交錯圖文輸入



用視覺表示與語言模型互動，處理文字與圖片交錯的上下文。


BLIP 與 BLIP-2 的銜接

BLIP 結合圖文理解與生成，也用 captioning／filtering 改善圖文配對資料。

BLIP-2 進一步重用凍結的視覺與語言主幹，用 Q-Former 學兩者之間的連接。

兩者都處理圖文任務，但資料處理與可訓練模組的設計不同。

BLIP-2 的 Q-Former



以較小的連接模組把視覺資訊整理成語言模型可使用的表示。

BLIP-2 的兩階段學習

1. 先讓可學習 query 與視覺特徵互動，學會有用的圖文表示。
2. 再將 query 表示映射至語言模型輸入空間。

凍結大型主幹可減少要更新的參數，但前向計算仍需要資源。

作者 Cells 73–75 提供讀圖生成文字範例，完整模型需較多記憶體。

舊稿圖片描述程式的閱讀路線

11_Image Captioning.pptx s.14-25 提供：

部分	要追蹤的資料
Vocabulary／Dataset	token字典、影像與caption配對
CNN encoder	區域特徵或整張圖特徵
RNN decoder	位移後的文字、hidden state
Attention	每一步對影像區域的加權

與 BLIP-2 比較哪些部分預訓練、哪些部分需任務資料。

其他多模態任務的分類

任務方向	書中例子
文件與版面	LayoutLM
視覺定位與問答	GLIP、LLaVA、PaLI、Qwen-VL
多模態對齊	ImageBind
語音翻譯	SeamlessM4T
動作或影片	RT-2、EMO

此表定位研究問題，不將書中的版本或能力描述當即時排名。

多模態評估：看得見與推測的差別

同一張桌面照片可能讓模型「補出」不存在的物件。

- 分開評估物件、數量、空間關係與文字辨識。
- 把遮擋、低解析度與看不清楚的情況列入測試。
- 讓回答指出可見證據與不確定部分。

照片中的文字也可能是惡意指令，應當作待分析內容。

課堂活動：圖片檢索與描述

20 分鐘，使用教師提供的 6 張圖片與 6 段描述。

1. 設計 CLIP 圖文配對的正確答案表。
2. 加入一段容易混淆的描述，說明評估方法。
3. 為生成式描述另定「捏造物件」與「漏掉物件」檢查。

交付：兩種任務的輸出與指標，不能只比較文字是否好看。

離堂檢核

- 224×224 、patch16 的 token 數是多少？
- CLIP 是否會直接產生完整描述句？
- 短 latent 序列為何有助降低成本？
- 為何 attention 熱區不能取代完整正確性驗證？

課後程式與延伸閱讀

- 作者第 16 章 Notebook (`16_vision_and_multimodal_transformers.ipynb`) : 先執行 Setup，再定位本課指定區段。
- 舊稿 `11_Image Captioning.pptx` 與 `機器學習-08-Image Captioning.pptx` : CNN／RNN 圖片描述與 attention。

程式來源依教材核對版本標示；執行前確認資料、套件與運算資源。

Notebook 導讀：可執行的機制與驗收

模型設計	小型程式的對照範圍
ViT／PVT／Swin	Patch 投影、token 合併、視窗及位移遮罩
DETR／CLIP／DINO	一對一成本、雙向對比損失、EMA 教師
Perceiver／Q-Former／Flamingo	查詢讀圖、latent 瓶頸、視覺門控

原圖是完整架構；Notebook 只重做列出的構件與資料流。

手工／隨機向量沒有辨識語意，不用其相似度或 attention 宣稱模型看懂影像。