

生成模型：自編碼器、GAN 與擴散

表示學習、潛在空間與影像生成

書本第 18 章

學習重點與成果

- 表示學習、AE、去噪、稀疏與 VAE。
- 離散表示、GAN、擴散與條件生成。

成果：能區分重建與生成，寫出主要損失，解讀生成失敗的原因。


 **配套 Notebook**： `programs/notebooks/22_生成模型_自編碼器GAN與擴散.ipynb`。本檔提供公式驗算、機制實驗與結果圖；框架片段及完整模型案例另依頁面說明閱讀。

程式實驗與實際輸出

```
Z = encoder(X)
X_hat = decoder(Z)
```

觀察：線性欠完備自編碼器的教學對照使用 PCA；重建誤差揭示壓縮會捨棄資訊。

參考程式：[programs/notebooks/22_生成模型_自編碼器GAN與擴散.ipynb](#)



重建與生成的差別

任務	輸入	輸出
重建	一筆真實資料	對原資料的近似
去噪	受干擾資料	乾淨資料的近似
生成	潛在樣本或噪聲	新的資料樣本

重建誤差很小，不代表隨便抽一個潛在向量也能得到合理樣本。

Autoencoder 的表示學習


$$z = f_{\theta}(x), \quad \hat{x} = g_{\phi}(z)$$

Encoder 壓縮或轉換資料；decoder 從表示重建輸入。

需要瓶頸、噪聲或其他限制，避免只學會沒有用途的複製。

標籤可以就是輸入本身，但評估仍須使用未參與訓練的資料。

線性 Autoencoder 與 PCA



適當條件下，線性瓶頸模型學到與 PCA 相同的主要子空間；座標軸不必相同。

與本地 PCA 程式的連結

延伸練習：用本章 Notebook 比較線性投影與自編碼器重建。

- 找到中心化／標準化、協方差矩陣、特徵分解與投影。
- 線性 AE 使用 MSE、沒有非線性，瓶頸維度設為相同。
- 必須在相同前處理與資料尺度下比較重建誤差。

PCA 主成分可變號，AE 也可能使用不同基底；不要直接要求 latent 值逐格相同。

SVD 程式的可用部分與限制

延伸練習：用本章 Notebook 檢查 SVD 的投影方向、重建誤差與限制。

可讀 `fit()` 的中心化與主方向、`transform()` 的投影。

協方差特徵值的平方根可表示主成分標準差；資料矩陣的奇異值為 $\sqrt{(n-1)\lambda}$ 。

兩者數值不同，實作時要區分協方差矩陣的特徵分解與資料矩陣的 SVD。

線性 AE 的最小結構

```
import torch
from torch import nn
encoder = nn.Linear(3, 2)
decoder = nn.Linear(2, 3)
autoencoder = nn.Sequential(encoder, decoder)
X = torch.randn(8, 3)
loss = nn.MSELoss()(autoencoder(X), X)
```

這只示範模型與損失；需訓練收斂後才能與 PCA 比較。

Stacked AE 的瓶頸

多層非線性 encoder 與 decoder 可學彎曲的低維表示。

書中 Fashion MNIST 使用 784 維像素與 32 維編碼。

若用 Sigmoid 輸出，資料與目標應配合 0 到 1 的範圍。

瓶頸太小可能丟失重要細節，太大則容易記住輸入。

重建圖要與原圖成對檢查



觀察哪些細節消失、哪些類別重建較差；平均 MSE 無法完整描述視覺品質。

AE 異常偵測的假設

用正常資料訓練後，異常資料可能出現較大的重建誤差。

但模型也可能把某些異常重建得很好。

- 用獨立驗證資料選閾值。
- 分別評估漏報與誤報。
- 在新領域重新檢查誤差分布。

重建誤差閾值活動

正常驗證資料的重建誤差為 0.01、0.02、0.02、0.03。

自編異常測例為 0.025、0.08。

若閾值設 0.04，會漏掉哪個異常？

答案：0.025。調低閾值也可能把正常樣本誤報，應比較完整代價。

表示視覺化與無監督預訓練

- 先用 encoder 產生 latent，再用 t-SNE 等方法視覺化。
- 視覺上分群漂亮，不保證分類或生成品質。
- 可重用 encoder 做下游任務，再以少量標籤微調。
- 比較隨機初始化與預訓練，使用相同資料切分。

Tied weights 與逐層預訓練

Tied weights 讓 decoder 使用 encoder 權重的轉置，減少自由參數。

Greedy layerwise pretraining 每次先學一層，再堆疊微調。

現代訓練不一定需要逐層預訓練；本節用來理解表示學習的歷史與限制。


卷積 Autoencoder

影像 encoder 用卷積與下採樣，decoder 用上採樣或轉置卷積。

需核對最後輸出的通道與高寬是否等於重建目標。

轉置卷積不是資訊的逆運算，下採樣時遺失的細節只能由模型估計。

Denoising AE 的訓練配對



輸入加入噪聲或 dropout，目標仍是乾淨的原始影像。

去噪任務的實作檢查

```
noisy = (clean + 0.2 * torch.randn_like(clean)).clamp(0, 1)
pred = autoencoder(noisy)
loss = nn.MSELoss()(pred, clean)
```

若把 noisy 同時當目標，模型學的任务就變了。

訓練噪聲的型態不一定涵蓋真實感測器的噪聲。

稀疏 AE 的約束

即使 latent 維度較大，也可限制多數神經元平均活化很低。

常見做法：L1 活化懲罰，或對平均活化加 KL 懲罰。

目標活化率 ρ 與觀測平均 $\hat{\rho}_j$ 應使用一致定義。


稀疏懲罰的 KL 形式

$$KL(\rho \parallel \hat{\rho}_j) = \rho \log \frac{\rho}{\hat{\rho}_j} + (1 - \rho) \log \frac{1 - \rho}{1 - \hat{\rho}_j}$$

把各 latent 單元的懲罰加總，再乘權重加入重建損失。

程式需避免平均活化正好為 0 或 1，否則對數可能無限大。

VAE 學習潛在分布



Encoder 輸出平均與變異數，再抽樣 latent；decoder 用 latent 重建。

Reparameterization trick

$$z = \mu(x) + \sigma(x) \odot \epsilon, \quad \epsilon \sim \mathcal{N}(0, I)$$

把隨機性放在 ϵ ，保留對 μ, σ 的可微運算。

通常輸出 $\log \text{variance}$ ，再用 $\exp(0.5 \log \text{var})$ 得到標準差。

VAE 的抽樣

```
def sample_codings(mean, logvar):  
    std = torch.exp(0.5 * logvar)  
    noise = torch.randn_like(std)  
    return mean + std * noise
```

把 log variance 當標準差直接使用會改變分布。此函式的輸出形狀與 mean 相同。

VAE 的重建與 KL 平衡

$$L = L_{recon} + \beta D_{KL}(q_{\phi}(z | x) || p(z))$$

- 重建項鼓勵保留輸入資訊。
- KL 項讓 latent 分布靠近先驗。
- 各項按 pixel、latent 或 batch 加總／平均會改變相對尺度。

比較 β 前，先固定 reduction 的方式。

標準常態先驗的 KL

$$KL = \frac{1}{2} \sum_j (\mu_j^2 + \sigma_j^2 - \log \sigma_j^2 - 1)$$

當 $\mu = 0, \sigma = 1$ ，KL 為 0。

自編一維例： $\mu = 1, \sigma = 1$ 時，KL=0.5。

KL 越小不表示重建必然越好。

從先驗生成與重建的不同

重建：先經 encoder 得到與特定輸入有關的 latent。

生成：從先驗抽樣，再交給 decoder。

```
with torch.no_grad():  
    z = torch.randn(8, latent_dim, device=device)  
    images = vae.decode(z)
```

Latent interpolation



在兩個潛在向量之間插值，再解碼成影像；效果取決於學到的空間結構。

離散 VAE 與 Gumbel-Softmax

離散 latent 可表示為 code IDs，便於與 token 模型串接。

直接 `argmax` 不可微；Gumbel-Softmax 用平滑近似提供梯度。

`hard=True` 可讓前向採離散 one-hot，反向使用近似梯度。

程式函式名是 `F.gumbel_softmax`。


VQ-VAE 的 codebook

Encoder 產生連續表示，選最近的 codebook 向量交給 decoder。

訓練需處理 codebook 學習、encoder commitment 與不可微選取。

之後可把影像轉成離散 token，再用 Transformer 學 token 序列分布。

GAN 的兩個模型



Generator 產生樣本，discriminator 分辨真實與生成資料；兩者交替更新。

GAN 的訓練目標

令 D 輸出「真實」機率：

$$L_D = -\mathbb{E}_x \log D(x) - \mathbb{E}_z \log(1 - D(G(z)))$$

$$L_G = -\mathbb{E}_z \log D(G(z))$$

第二式採常用 non-saturating generator loss，避免初期梯度過弱。

訓練 D 時隔開 generator 梯度

```
fake = generator(z).detach()
p_real = discriminator(real)
p_fake = discriminator(fake)
loss_d = bce(p_real, torch.ones_like(p_real)) + bce(
    p_fake, torch.zeros_like(p_fake))
optimizer_d.zero_grad()
loss_d.backward()
optimizer_d.step()
```

此片段假設 D 已含 Sigmoid、bce=nn.BCELoss()；改用 logits 時搭配 BCEWithLogitsLoss。


訓練 G 時仍須通過 D

更新 generator 時，loss 必須能經由 discriminator 回傳到 generator。

不能對 `generator(z)` 做 detach，也不能把整段 D 放在 `no_grad`。

可暫時停止 D 參數的梯度，但要保留 D 對輸入的運算圖。

Mode collapse




生成器可能反覆產生少數樣式；單張看起來逼真，整體仍缺乏多樣性。

GAN 的不穩定與 DCGAN

- G 與 D 強弱失衡，會改變彼此的學習訊號。
- 損失上下波動不一定直接等於影像品質。
- DCGAN 用卷積結構適應影像生成。
- 固定一組 latent，比較不同 epoch 的樣本與多樣性。

擴散模型的正向與反向過程




正向逐步加入噪聲；模型學習反向去噪，生成時從噪聲開始。

任意時間步的加噪公式

$$x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1 - \bar{\alpha}_t}\epsilon$$
$$\alpha_t = 1 - \beta_t, \quad \bar{\alpha}_t = \prod_{s=1}^t \alpha_s$$

一次抽出 ϵ 就能取得指定時間步的含噪樣本，不需逐步模擬所有前序步驟。

噪聲排程與剩餘訊號



排程決定每個時間步有多少訊號與噪聲； $\bar{\alpha}_t$ 越小，原圖成分越少。

擴散訓練的輸入與標籤

```
def forward_diffusion(x0, alpha_bar):  
    eps = torch.randn_like(x0)  
    xt = alpha_bar.sqrt() * x0 + (1 - alpha_bar).sqrt() * eps  
    return xt, eps  
# 訓練目標：loss = mse(model(xt, t), eps)
```

alpha_bar 須可broadcast至影像，例如 `[B,1,1,1]`；標籤是未縮放的 eps。

去噪網路需要知道時間

同樣的像素值，在輕微噪聲與幾乎純噪聲階段有不同意義。

U-Net 類架構結合下採樣、上採樣與跨尺度跳接，再加入 time embedding。

輸出形狀通常與輸入影像相同，用來預測噪聲。

DDPM 與 DDIM 取樣

方法	閱讀重點
DDPM	依反向排程逐步更新，通常含隨機噪聲
DDIM	可採較少步數，調整隨機程度

少步數與品質之間的取舍要實際量測。跳步取樣需使用相容的係數，不能只跳過迴圈。

Latent diffusion 與條件生成

先以 autoencoder 壓縮影像，再在 latent 空間做擴散。

文字或影像表示可作條件，引導生成內容。

應用包含文字生圖、inpainting 與 outpainting。

生成品質同時受到壓縮器、去噪器、條件與取樣設定影響。

生成程式的閱讀路線

作者 Notebook (`18_autoencoders_gans_and_diffusion_models.ipynb`)

- Cells 91–113：VAE 與離散 latent。
- Cells 114–123：GAN／DCGAN。
- Cells 124–152：加噪、U-Net、取樣與 Diffusers。
- Cells 153 起：flow matching，屬 Notebook 額外選讀。

完整影像生成可能需要下載大型權重；先用小張量檢查資料流。

課堂活動：生成模型比較

從 AE、VAE、GAN 與 diffusion 各選一種方法比較。

建立表格：訓練輸入、目標、主要損失、生成起點與一種失敗模式。

交付兩份評估：單張品質，以及整批樣本的多樣性。

資料與生成圖片需標註來源，避免把合成結果當真實觀測。

離堂檢核

- 線性 AE 何時能與 PCA 子空間比較？
- VAE 為何要控制潛在分布？
- 訓練 G 時為何不能切斷經過 D 的梯度？
- 擴散訓練的噪聲目標與含噪輸入有何不同？

課後程式與延伸閱讀

- 作者第 18 章 Notebook (`18_autoencoders_gans_and_diffusion_models.ipynb`)：先執行 Setup，再定位本課指定區段。
 - PCA／SVD 與神經網路是本章的先備知識。
 - 本章 Notebook：比較 PCA、SVD 投影與非線性表示。
- 執行前確認資料、套件與運算資源。

Notebook 導讀：可執行的機制與驗收

類型	Notebook 的可執行範圍
AE／去噪	train-only PCA、測試重建、noisy→clean 配對
VAE／VQ	重參數化、KL、PCA latent 插值、最近 code
GAN	一維交替更新、梯度邊界、刻意構造的 collapse
擴散	加噪排程、解析高斯去噪器的 DDPM／DDIM

重建、抽樣公式與訓練好的影像生成模型分開解讀。

VAE／GAN／擴散架構圖用於整體設計閱讀；小型程序驗證機制，不宜稱能重現大型模型品質。