

強化學習：策略、價值與深度 RL

Gymnasium、Q-learning、DQN 與 PPO

書本第 19 章

學習重點與成果

- 互動、Gymnasium、回報與 policy gradient。
- MDP、Q-learning、DQN、actor-critic 與 PPO。

成果：能手算回報與 Q 更新，區分 episode 結束與 bootstrap 條件。


 **配套 Notebook**： `programs/notebooks/23_強化學習_策略價值與深度RL.ipynb`。本檔提供公式驗算、機制實驗與結果圖；框架片段及完整模型案例另依頁面說明閱讀。

程式實驗與實際輸出

```
Q[a] += (reward - Q[a]) / count[a]
```

觀察：epsilon-greedy 保留探索；移動平均獎勵逐步接近較佳動作的期望值。

參考程式：`programs/notebooks/23_強化學習_策略價值與深度RL.ipynb`



Agent 與環境的互動

在每一步，agent 依 observation 選 action，環境回傳新 observation 與 reward。

策略 $\pi(a \mid s)$ 決定行為，學習目標是提高長期回報。

環境有資料與回饋，只是正確動作未必事先標好。

Reward、return 與 policy

名稱	意義
Reward	某一步收到的回饋
Return	從某一步起的折扣累積回饋
Policy	根據狀態選動作的方法
Value	在特定策略下的預期return

短期獎勵高，不一定代表長期結果最好。

Policy search 與神經網路策略


策略可由規則、參數化機率模型或神經網路表示。

Policy search 在策略參數空間尋找較好的行為。

神經網路可輸出各動作的 logits，再轉成分布抽樣。

訓練前先用簡單規則作基準，確認環境與獎勵理解正確。

CartPole 的任務



觀測描述小車與桿子的狀態；動作控制往左或往右施力。

Gymnasium 的一步互動

```
import gymnasium as gym
env = gym.make("CartPole-v1")
obs, info = env.reset(seed=42)
action = env.action_space.sample()
next_obs, reward, terminated, truncated, info = env.step(action)
env.close()
```

reset 回傳 observation 與 info ; step 回傳五個項目。

Terminated 與 truncated

訊號	常見原因
terminated	任務中的終止狀態，例如跌倒
truncated	外部時間或步數限制

兩者都可能需要 reset，但價值學習不一定都停止 bootstrap。

若任務本身有有限時域，剩餘時間也應納入狀態設計。


折扣回報

$$G_t = r_t + \gamma r_{t+1} + \gamma^2 r_{t+2} + \dots$$

γ 決定較遠回饋的相對權重。

在有限 episode 可從尾端反向算： $G_t = r_t + \gamma G_{t+1}$ 。

Credit assignment 的回報分配



後來得到的結果，會影響先前動作的評價；距離越遠，折扣通常越多。

回報手算：10、0、−50

設 $\gamma = 0.8$ ，從最後一步往前：

步驟	計算	Return
3	−50	−50
2	$0 + 0.8 \times (-50)$	−40
1	$10 + 0.8 \times (-40)$	−22

第一步立刻得到10，仍可能有負的長期回報。

折扣回報的小函式

```
def returns(rewards, gamma):  
    result = []  
    G = 0.0  
    for reward in reversed(rewards):  
        G = reward + gamma * G  
        result.append(G)  
    return list(reversed(result))  
assert returns([10, 0, -50], 0.8) == [-22.0, -40.0, -50.0]
```

此例為完整有限 episode，不另外加末端 bootstrap。

REINFORCE 的更新方向

$$L_{\pi} = -\frac{1}{N} \sum_t G_t \log \pi_{\theta}(a_t | s_t)$$

高回報動作的 log probability 受到增加的壓力。

回報作為權重，不對環境或抽到的動作本身微分。

減去與動作無關的 baseline 可降低梯度估計變異。

Policy gradient 程式導讀

作者 Notebook (`19_reinforcement_learning.ipynb`) : Cells 40–50 。

- PolicyNetwork 產生動作 logits 。
- choose_action 同時保存 action 與 log probability 。
- 收集 episode 後計算 return 。
- 使用 log probability 與 return 更新 policy 。

若只存整數 action，之後無法從它恢復原本的梯度圖。


Markov 性與 observation

Markov 狀態包含預測下一步所需的資訊，不必回看完整歷史。

環境的 observation 未必就是完整 state。

例如單一影格看不出速度，可用多影格或記憶模型補充。

Markov decision process



狀態、可選動作、轉移機率與回饋，定義一個可做長期決策的問題。

Value iteration 與 Bellman 最優性

$$V^*(s) = \max_a \sum_{s'} P(s' \mid s, a) [r(s, a, s') + \gamma V^*(s')]$$

已知環境轉移模型時，可反覆更新價值估計。

Q-value 把「先採取哪個動作」也納入價值的輸入。

TD learning 用樣本更新

$$\delta = r + \gamma V(s') - V(s)$$

$$V(s) \leftarrow V(s) + \alpha \delta$$

使用一步樣本與下一狀態的估計，不必等待整段 episode 才更新。

這種以估計值作目標的一部分，稱為 bootstrap。

Q-learning 的更新式

$$Q(s, a) \leftarrow Q(s, a) + \alpha \left[r + \gamma \max_{a'} Q(s', a') - Q(s, a) \right]$$

更新的是這次實際走過的 (s, a) 。

目標使用下一狀態的最大 Q ，行為策略卻可包含隨機探索。

Q-learning 手算：一般移動

先設定一般移動的局部數例：

$$Q = 0.5, \alpha = 0.1, \gamma = 0.9, r = 0, \max Q_{next} = 0.8 \circ$$

$$Q_{new} = 0.5 + 0.1(0 + 0.9 \times 0.8 - 0.5) = 0.522$$

這是本例的獎勵設定；其他例題以各頁明列的尺度為準。

Q-learning 手算：抵達終點

設 $Q = 0.2$, $\alpha = 0.1$, $r = 1$ ，且下一狀態為 terminal。

$$Q_{new} = 0.2 + 0.1(1 - 0.2) = 0.28$$

終點沒有下一步可累積的回報，因此不再加下一狀態的估計。

若只是時間限制中斷，需要先確認任務的終止定義。

Q-learning 手算：碰牆但尚未終止

設 $Q = 0.1, \alpha = 0.1, \gamma = 0.9, r = -0.1, \max Q_{next} = 0.4$ 。

$$Q_{new} = 0.1 + 0.1(-0.1 + 0.9 \times 0.4 - 0.1) = 0.116$$

立即回饋為負，Q 值仍可能上升，因為更新同時考慮未來。

探索與利用

ϵ -greedy 以機率 ϵ 隨機探索，其他時候挑最高 Q 。

選擇	可能的問題
太早停止探索	沒發現更好的路徑
一直大量隨機	已學到的策略難以穩定展現

可逐步調低 ϵ ，也可使用依不確定性或新奇程度設計的探索。

DQN 用網路近似 Q 函數

CartPole 有兩個離散動作，網路可輸出 $[Q(\text{left}), Q(\text{right})]$ 。

輸出是預期回報，不是總和等於 1 的機率。

因此不需要對 Q 值加 Softmax 再做 Q-learning。

DQN 的兩個動作輸出

```
import torch
from torch import nn
q_net = nn.Sequential(
    nn.Linear(4, 32), nn.ReLU(),
    nn.Linear(32, 32), nn.ReLU(),
    nn.Linear(32, 2))
q_values = q_net(torch.randn(8, 4))
```

預期形狀 `[8,2]` ；每筆資料的狀態有4個特徵。

Replay buffer 與 target network

Replay buffer 保存 $(s, a, r, s', terminated, truncated)$ ，抽樣後更新。

Target network 以較慢速度更新，降低目標跟著參數快速移動的問題。

兩者用途不同：一個改資料取樣，一個穩定 bootstrap 目標。

DQN 的 TD target

```
# 此例把時間限制視為可bootstrap的截斷，使用終止前next_state
with torch.no_grad():
    next_q = target_net(next_states).max(dim=1).values
    target = rewards + gamma * (~terminated).float() * next_q
    current = q_net(states).gather(1, actions[:, None]).squeeze(1)
    loss = nn.functional.mse_loss(current, target)
```

所有向量均以 batch 對齊；自動 reset 的環境要保留真正 final observation。

DQN 的常見改善

方法	要處理的問題
Target network	學習目標快速變動
Double DQN	max操作造成的過度估計
Prioritized replay	提高重要經驗的取樣機會
Dueling network	分開估計state value與action advantage

Actor-critic 的兩個角色

Actor 產生 policy ; critic 估計 value , 協助評估動作。

$$A(s, a) = Q(s, a) - V(s)$$

Advantage 表示動作比該狀態的平均水準好多少。

簡單版本可用 TD error 近似 advantage。

Actor loss 與 critic loss 分開

```
td_error = target_value - state_value
actor_loss = -(log_prob * td_error.detach()).mean()
critic_loss = nn.functional.mse_loss(state_value, target_value)
loss = actor_loss + critic_weight * critic_loss
```

target_value 應是已停止梯度的bootstrap目標；actor權重detach，避免錯走critic梯度。

PPO 限制策略一次改太多


$$r_t(\theta) = \frac{\pi_{\theta}(a_t \mid s_t)}{\pi_{old}(a_t \mid s_t)}$$

$$L^{clip} = \mathbb{E}[\min(r_t A_t, \text{clip}(r_t, 1 - \epsilon, 1 + \epsilon) A_t)]$$

PPO 最大化這個代理目標，實作最小化損失時須改符號。

Clipping 限制過度更新的誘因，不是硬性保證每個比率都在區間內。

Atari 的影格前處理



縮小、灰階與堆疊影格，可降低輸入成本並提供運動資訊。

Stable-Baselines3 的小型介面示例

```
from stable_baselines3 import PPO
agent = PPO("MlpPolicy", "CartPole-v1", verbose=0, seed=42)
agent.learn(total_timesteps=10_000)
agent.save("ppo_cartpole_demo")
```

改用小型 CartPole 示範；一萬步只作介面練習，不保證收斂。

Atari 完整實驗的閱讀路線

作者 Notebook (`19_reinforcement_learning.ipynb`) : Cells 102–118。

讀取 vectorized environments、frame stack、PPO 設定與評估。

原筆記本提供作者訓練模型的下載方式；其訓練步數與結果屬作者實驗。

課堂不把預訓練回放當作現場重新訓練成功。

演算法比較

家族	學什麼	本課例子
Value-based	狀態或動作價值	Q-learning、DQN
Policy gradient	策略分布	REINFORCE
Actor-critic	策略與價值	A2C、PPO
連續動作方法	連續動作策略與價值	DDPG、TD3、SAC（選讀）

On-policy、off-policy 與環境模型

比較軸	含義
On-policy	主要使用目前策略收集的資料更新
Off-policy	可利用其他行為策略的資料
Model-based	使用或學習環境轉移／回饋模型來規劃
Model-free	直接學價值或策略

這是兩組不同的分類軸，不應放在同一個互斥清單。

連續動作與其他演算法（選讀）

連續動作空間無法簡單列出所有動作再取最大 Q 。

- DDPG 使用決定性 actor 提供動作，critic 評估動作。
- TD3 以雙 critic 等設計減少過度估計與不穩定。
- SAC 的目標包含熵，鼓勵保留策略多樣性。

另可閱讀 model-based RL、模仿學習與 offline RL，比較互動資料如何取得。

RL 實驗的評估方式

- 分開訓練探索策略與測試策略。
- 多個隨機種子與多個 episode，報告分布或不確定性。
- 固定環境版本、步數限制與獎勵設定。
- 除了 return，也檢查行為是否符合任務目的。

高 reward 可能反映鑽獎勵設計漏洞，而非完成真正需求。

課堂活動：迷宮與 CartPole

練習：

1. 手填迷宮的兩次 Q 更新，標出 terminal。
2. 比較規則策略與小型 PPO 的評估設計。
3. 寫一個「獎勵變高但行為不合目的」的例子。

交付：狀態／動作／回饋定義、更新計算與評估表。

離堂檢核

- Reward 與 return 是否相同？
- Q-learning 的行為與目標策略可以不同嗎？
- DQN 輸出為何不是機率？
- truncated 為何不一定代表下一狀態價值為零？

課後程式與延伸閱讀

- 作者第 19 章 Notebook (`19_reinforcement_learning.ipynb`)：先執行 Setup，再定位本課指定區段。
 - 三個 Q-learning 手算分別示範一般移動、抵達終點與碰牆。
- 執行前確認資料、套件與運算資源。

Notebook 導讀：可執行的機制與驗收

實驗	可檢查的證據
Return 與 Q 更新	$[-22, -40, -50]$ ；0.522／0.28／0.116
LineWorld／Bellman／DQN	終止條件、表格與網路動作、replay／target
REINFORCE／actor-critic／PPO	更新方向、優勢、clipped objective
影格與種子	合成 $4 \times 84 \times 84$ 張量；五種子回報摘要

Bandit 不等於 MDP；時間中斷與真正終止分開處理。

CartPole 圖驗算觀測角色，Atari 圖對照前處理；未宣稱完成其基準訓練。