

附錄 A：自動微分與計算圖

手算、有限差分、前向與反向模式

書本附錄 A

建議 90 分鐘，含活動與休息

學習成果與使用時機

可在深層網路、LoRA 或自訂損失之前補充。

- 0–25 分：手算導數與有限差分。
- 25–55 分：計算圖、前向模式與對偶數。
- 55–90 分：反向模式、autograd 與梯度檢查。

成果：解釋 backward 如何工作，辨識梯度中斷與累積。


 **配套 Notebook**： `programs/notebooks/24_附錄A_自動微分與計算圖.ipynb` 。程式片段、實際圖表與表格可由此檔重現。

程式實驗與實際輸出

$$\text{dfd}x = (f(x+\text{eps}) - f(x-\text{eps})) / (2 * \text{eps})$$

觀察：有限差分的步長太大有近似誤差，太小則受浮點相消影響。

參考程式：`programs/notebooks/24_附錄A_自動微分與計算圖.ipynb`



同一函式的三種求導方式

以書中 $f(x, y) = x^2y + y + 2$ 為例。

方法	做法
手算微分	使用符號規則推導
有限差分	微小改變輸入再比較函式值
自動微分	沿計算圖套用局部導數與鏈鎖律

自動微分仍受浮點誤差影響，但不靠小步長近似導數。

手算梯度

$$\frac{\partial f}{\partial x} = 2xy, \quad \frac{\partial f}{\partial y} = x^2 + 1$$

在 $(x, y) = (3, 4)$:

$f = 42$, $\partial f / \partial x = 24$, $\partial f / \partial y = 10$ 。

請指出 y 透過幾條路徑影響輸出。

有限差分與步長

$$\frac{\partial f}{\partial x} \approx \frac{f(x + \epsilon, y) - f(x - \epsilon, y)}{2\epsilon}$$

ϵ 太大，近似誤差較大；太小，浮點相減可能失去有效位數。

中央差分常作梯度檢查，但高維參數逐一擾動成本很高。

有限差分的可執行小例子

```
def f(x, y):  
    return x*x*y + y + 2  
eps = 1e-5  
dx = (f(3 + eps, 4) - f(3 - eps, 4)) / (2 * eps)  
dy = (f(3, 4 + eps) - f(3, 4 - eps)) / (2 * eps)  
print(dx, dy) # 預期接近 24、10
```

函式不含下載或模型依賴，可與手算結果比較。

作者程式：Cells 6、17-23（改寫）（[Appendix_A_autodiff.ipynb](#)）


計算圖與中間變數

把函式拆成：

變數	運算	$x=3$ 、 $y=4$ 時
a	$x \times x$	9
b	$a \times y$	36
c	$b + y$	40
f	$c + 2$	42

每個節點只需知道自己的局部導數。

前向模式沿計算順序傳遞導數



選定一個輸入方向，讓值與該方向的導數一起往前走。

前向模式手算

對 x 微分，初始方向為 $\dot{x} = 1, \dot{y} = 0$ 。

節點	方向導數
$a=x^2$	$2x\dot{x} = 6$
$b=ay$	$\dot{a}y + a\dot{y} = 24$
$c=b+y$	$24 + 0 = 24$
$f=c+2$	24

改求 y 方向時，要換初始方向。


對偶數的表示

以 $a + b\varepsilon$ 表示值與方向導數，且 $\varepsilon^2 = 0$ 。

$$(a + b\varepsilon)(c + d\varepsilon) = ac + (ad + bc)\varepsilon$$

乘法自然出現乘法微分法則；程式可把值與導數存成一對資料。

反向模式由輸出往回傳



先算所有中間值，再從輸出導數 1 出發，沿反向路徑累積梯度。

反向模式手算

由 $\partial f / \partial f = 1$ 開始：

節點	累積的梯度
c、b	各為1
y	直接路徑1，加上乘法路徑a=9，共10
a	y=4
x	$4 \times 2x = 24$

同一變數出現在多條路徑時，梯度必須相加。

前向與反向模式的選擇

問題	通常較合適的方向
少量輸入、多個輸出	前向模式
大量參數、一個scalar loss	反向模式

前向模式計算 Jacobian-vector product；反向模式計算 vector-Jacobian product。

神經網路訓練常以一個 scalar loss 對很多參數求梯度。

PyTorch autograd 驗算

```
import torch
x = torch.tensor(3., requires_grad=True)
y = torch.tensor(4., requires_grad=True)
f = x*x*y + y + 2
f.backward()
print(f.item(), x.grad.item(), y.grad.item())
# 預期 42.0、24.0、10.0
```

此例可直接執行；backward 對scalar輸出預設使用上游梯度1。

作者程式：Cells 85–86 (`Appendix_A_autodiff.ipynb`)

梯度累積與計算圖生命週期

- `.grad` 會累積，更新前應依訓練設計清空。
- `backward` 後，圖中部分中間資訊通常已釋放。
- `.detach()` 切斷目前的梯度路徑。
- `.item()` 取得 Python 數值，不能再當可微損失接回圖。

不要為了消除錯誤而到處加 `retain_graph=True`。

與手刻反向傳播程式對照

MachineLearning2025：ANN from scratch

(`programs/upstream/MachineLearning2025/06_ANN_from_Scratch_MNIST.py`)

找出 Linear 與 activation 的 `backward`，對照：

- 上游梯度乘上局部導數。
- batch 與廣播軸的梯度如何加總。
- 權重梯度與輸入梯度的形狀。

autograd 把這套工作系統化，仍需正確的前向運算。

課堂活動：梯度檢查

15 分鐘。

1. 手算 $f(3, 4)$ 的兩個偏導數。
2. 用有限差分與 autograd 比較。
3. 把 `x*x` 改成 `(x*x).detach()`，預測哪些梯度消失。

交付三種結果與差異原因；不要只貼執行畫面。

離堂檢核

- 自動微分是否就是有限差分？
- 共享參數的多條路徑為何要加總？
- scalar loss 對百萬參數為何適合反向模式？
- `.item()` 放進 loss 建構過程可能造成什麼問題？

課後程式與延伸閱讀

- 作者附錄 A Notebook (`Appendix_A_autodiff.ipynb`)：先執行 Setup，再定位本課指定區段。
- 主教材附錄 A 與作者的 Toy Computation Graph；不需大型模型或資料集。
- 本地手刻 ANN (`programs/upstream/MachineLearning2025/06_ANN_from_Scratch_MNIST.py`)：逐層 backward 對照。

程式來源依教材核對版本標示；執行前確認資料、套件與運算資源。