

附錄 B：混合精度與量化

數值格式、AMP、PTQ 與 QAT

書本附錄 B

學習重點與成果

- 數值格式、範圍與精度。
- 混合精度與量化手算。
- PTQ、QAT、模型載入與比較。

成果：估算儲存需求，說明低位元如何改變誤差與執行成本。


 **配套 Notebook**： `programs/notebooks/25_附錄B_混合精度與量化.ipynb` 。本檔提供公式驗算、機制實驗與結果圖；框架片段及完整模型案例另依頁面說明閱讀。

程式實驗與實際輸出


```
q = round(weight / scale).astype(int8)
weight_hat = q * scale
```

觀察：對稱 int8 量化大幅縮小表示範圍，但反量化後仍會留下離散化誤差。

參考程式：`programs/notebooks/25_附錄B_混合精度與量化.ipynb`



數值格式的位元分配



浮點格式把位元分配給符號、指數與有效數字；範圍與精細程度是不同特性。

FP32、FP16 與 BF16

格式	指數位元	小數位元	教學重點
FP32	8	23	常用完整精度基準
FP16	5	10	較窄範圍，較易溢位或下溢
BF16	8	7	較寬範圍，精細程度較低

表中另各有1個符號位元；硬體支援決定實際速度。

模型權重大小估算

10 億參數，只計權重：


每參數儲存	約略大小
FP32，4 bytes	4 GB
FP16／BF16，2 bytes	2 GB
INT8，1 byte	1 GB
4-bit，半 byte	0.5 GB

量化還有 scale／zero point 等額外資訊；以上不是完整執行記憶體。

降低精度的不同位置

- 權重儲存格式。
 - 乘法與加總的計算格式。
 - Activation 與梯度格式。
 - Optimizer 狀態與主權重副本。
- 「4-bit 模型」通常不代表所有步驟都以4-bit計算。

混合精度訓練



不同運算採不同精度；保留必要的高精度操作，降低其他部分的成本。

AMP 與 loss scaling

Autocast 依運算與 backend 選擇精度，避免手動把所有 tensor 轉成半精度。

FP16 小梯度可能下溢；loss scaling 先放大 loss，再在更新前處理尺度。

BF16 因範圍較寬，通常不需要同樣的 scaling，但仍需硬體與套件支援。

CUDA FP16 的 AMP 訓練步驟

```
scaler = torch.amp.GradScaler("cuda")
optimizer.zero_grad()
with torch.autocast(device_type="cuda", dtype=torch.float16):
    loss = criterion(model(X), y)
scaler.scale(loss).backward()
scaler.step(optimizer)
scaler.update()
```

模型與資料須在 CUDA；此例不適用時保留 FP32 流程，不強制切到 FP16。

AMP 與梯度裁切的順序

若同時使用 loss scaling 與梯度裁切：

```
scaler.scale(loss).backward()  
scaler.unscale_(optimizer)  
torch.nn.utils.clip_grad_norm_(model.parameters(), max_norm=1.0)  
scaler.step(optimizer)  
scaler.update()
```

應在 unscale 後裁切，才能使用原本梯度尺度的門檻。

線性量化與反量化

$$q = \text{clip}(\text{round}(x/s) + z, q_{\min}, q_{\max})$$

$$\hat{x} = s(q - z)$$

s 是 scale， z 是 zero point；四捨五入與裁切都可能產生誤差。


量化手算

設 $s = 0.1, z = 0$ ，整數範圍足以容納資料。

x	q	還原值	誤差
0.26	3	0.3	+0.04
-0.44	-4	-0.4	+0.04
0	0	0	0

若數值超過整數範圍，裁切誤差可能遠大於半個刻度。

對稱量化



以零為中心安排整數刻度；適合某些近似對稱的權重分布。

對稱、非對稱與粒度

選項	影響
對稱／非對稱	是否以零為中心，zero point如何設定
Per-tensor	整個tensor共用scale
Per-channel	不同通道有不同scale
Per-group	每組權重共用量化參數

細粒度可降低部分誤差，也增加metadata與kernel複雜度。

對稱 INT8 權重量化

```
import torch
w = torch.tensor([0.0, -0.94, 0.92, 0.93])
scale = max(w.abs().max().item() / 127, 1e-12)
qw = torch.quantize_per_tensor(w, scale=scale,
                                zero_point=0, dtype=torch.qint8)

print(qw.int_repr())
print(qw.dequantize())
```

這是張量量化示例；把完整模型變成高效整數運算，還需相容算子與backend。

PTQ 與 QAT

方法	何時考慮量化誤差
Post-training quantization	訓練完成後轉換
Quantization-aware training	訓練時模擬量化效果

PTQ 成本較低；QAT 可讓參數適應量化，但需資料與額外訓練。

動態與靜態量化

方法	Activation 的量化設定
動態量化	執行時依輸入範圍計算
靜態量化	以代表性校準資料估計

校準資料應涵蓋部署分布，並保持測試集獨立，避免反覆利用測試結果調設定。

靜態 PTQ 的工作流程

1. 準備已訓練且在 eval 模式的模型。
2. 依 backend 融合適合的算子並插入 observers。
3. 用代表性 calibration data 前向計算。
4. 轉換成量化模型，重測品質與延遲。

量化前後要用同一批測試樣本與同一硬體比較。

量化 API 的版本相容性

作者附錄 B Notebook (`Appendix_B_mixed_precision_and_quantization.ipynb`) : Cells 48–66。

教材使用 `torch.ao.quantization` 的 `dynamic`、`prepare`／`convert` 與 QAT 介面。

先核對 Notebook 環境、官方 API 與執行 backend；不同版本的部署流程可能不同。

CPU、CUDA、MPS 支援的量化算子不同。

QAT 的 fake quantization

訓練期間模擬四捨五入與裁切造成的效果，通常仍用浮點 tensor。

真正的 round 幾乎處處導數為0；訓練可採 straight-through estimator 近似梯度。

完成後還需 convert 與部署 backend，不能把 fake quant 模型直接當整數加速結果。

BitsAndBytes 與低位元 LLM

作者範例以 4-bit NF4 載入權重，並指定 BF16 計算格式。

低位元權重可減少儲存；反量化、矩陣乘法與 runtime 仍有成本。

搭配 LoRA 的 QLoRA 概念是凍結量化主幹，再訓練小型 adapter。

量化設定與計算精度分開指定

```
from transformers import BitsAndBytesConfig
config = BitsAndBytesConfig(
    load_in_4bit=True, bnb_4bit_quant_type="nf4",
    bnb_4bit_compute_dtype=torch.bfloat16)
# 已選定的相容模型：from_pretrained(..., quantization_config=config)
```

此處只展示設定；完整載入需支援的 bitsandbytes／硬體與足夠記憶體。

預先量化模型與格式

書中介紹可直接取得的量化權重與 GGUF 等格式。

- 檢查格式是否符合推論後端。
- 核對 tokenizer、聊天模板與模型來源。
- 比較不同量化程度對自己的任務造成的誤差。

檔案較小，不代表所有裝置上的延遲都較低。

課堂活動：精度比較表

設計 FP32、AMP 與 INT8 的比較：

每欄填入：權重大小、峰值記憶體、延遲、任務指標與硬體。

固定 batch 與輸入長度，區分載入時間與暖機後推論。

交付：預期取捨與實測欄位；尚未測量的數字留空。

離堂檢核

- FP16 與 BF16 的範圍與精度差在哪裡？
- Loss scaling 為何不能改變有效學習率？
- Calibration data 與 test data 為何應分開？
- 4-bit 權重是否表示所有運算都是4-bit？

課後程式與延伸閱讀

- 作者附錄 B Notebook (`Appendix_B_mixed_precision_and_quantization.ipynb`)：先執行 Setup，再定位本課指定區段。
 - 主教材附錄 B；與第 17 章的 LoRA、記憶體估算與加速實驗一起閱讀。
- 執行前確認資料、套件與運算資源。

Notebook 導讀：可執行的機制與驗收

實驗	驗收證據
FP16／BF16、loss scaling	可表示範圍、下溢、先 unscale 再 clip
線性與每通道量化	手算誤差、零張量、INT32 累加還原
PTQ／動態範圍／QAT	校準與測試分離；STE 與飽和限制

BF16 是位元模擬；NumPy 不執行 CUDA AMP 或低位元加速核心。

圖表呈現數值誤差與介面，速度／顯存需在實際硬體另量測。