


深度學習中的強化學習

入門與概述



簡報大綱

- 強化學習基本介紹
- 核心要素：代理人、環境與獎勵
- 深度學習與強化學習的結合
- 常見演算法與應用



強化學習基本介紹

- 透過與環境互動，以試錯方式學習最大化累積獎勵的策略。
- 範例：訓練狗狗坐下




強化學習基本介紹

- 透過與環境互動，以試錯方式學習最大化累積獎勵的策略。
- 理論模型



Q-learning 運作流程：狀態、動作與獎勵的循環



這個循環不斷重複，代理人透過與環境互動和接收獎勵來學習最佳策略。

Q-learning 詳解

- 理論：是一種基於價值 (Value-based) 的方法，目標是學習一個 Q 表格 (Q-table)，告訴我們在特定狀態下採取特定動作的預期未來總獎勵。

公式

$$\underbrace{Q(S_t, A_t)}_{\substack{Q(S_t, A_t) \\ \text{舊的 Q 值}}} \leftarrow Q(S_t, A_t) + \underbrace{\alpha}_{\substack{\alpha \\ \text{學習率}}} \left[\underbrace{R_{t+1} + \gamma \max_a Q(S_{t+1}, a)}_{\substack{\gamma \\ \text{折扣因子} \\ \text{TD 目標 / 實際獎勵}}} - \underbrace{Q(S_t, A_t)}_{\substack{\max_a Q(S_{t+1}, a) \\ \text{下一狀態最大 Q 值}}} \right] \quad \text{TD 誤差}$$

- 變數：
 - $Q(S_t, A_t)$: 在狀態 S_t 採取動作 A_t 的價值。
 - α : 學習率 (0-1)，決定新訊息覆蓋舊訊息的程度。
 - R_{t+1} : 在 $t+1$ 時刻獲得的即時獎勵。
 - γ : 折扣因子 (0-1)，決定未來獎勵的重要性。
 - $\max_a Q(S_{t+1}, a)$: 在下一狀態 S_{t+1} 能獲得的最大預期未來獎勵。


以強化學習解決迷宮尋路問題 (Maze Navigation with Q-Learning)

內容重點

- 問題類型：序列決策 (Sequential Decision Making)
- 任務目標：讓智能體 (Agent) 在迷宮中從起點移動至終點
- 使用方法：
 - 強化學習 (Reinforcement Learning)
 - Q-Learning (表格式方法)
- 實作工具：
 - Python、NumPy
 - PyGame (環境視覺化)

講解說明

- 此問題屬於典型的「離散狀態 × 離散動作」RL 問題
- 適合用來理解 Q-Learning 的核心概念與學習行為



強化學習 (Reinforcement Learning)


核心元素

內容重點

- Agent (智能體)
- Environment (環境)
- State (狀態)
- Action (動作)
- Reward (回饋)
- Policy (策略)

講解說明

- 強化學習的本質是「互動式學習」
- Agent 透過不斷嘗試行動，從環境回饋中修正策略



迷宮環境 (Maze Environment)


建模方式

內容重點

- 狀態空間 (State Space) : Agent 的位置 (x, y)
- 動作空間 (Action Space) : 上 / 下 / 左 / 右 (4 個動作)
- 隨機障礙物
- 起點 (0,0) 、終點 (N-1, N-1)

講解說明

- 使用二維陣列表示迷宮
- 1 代表障礙物，0 代表可行走區域
- 狀態為完全可觀測 (Fully Observable)



0 = 可行走區域

1 = 障礙物

回饋設計 (Reward Design)


回饋函數如何影響學習行為

內容重點

- 撞到障礙物：-50
- 每走一步：-1
- 抵達終點：+100

講解說明

- 負步進懲罰鼓勵「最短路徑」
- 大幅懲罰避免撞牆
- 明確終點獎勵有助於收斂



Q-Learning 理論基礎


Q-Learning 的核心思想

內容重點

- Q-value : $Q(s, a)$ 表示在狀態 s 採取動作 a 的價值
- 更新公式：
$$Q(s,a) \leftarrow Q(s,a) + \alpha [r + \gamma \max_{Q(s',a')} Q(s',a') - Q(s,a)]$$
- 參數意義：
 - α (Learning Rate)
 - γ (Discount Factor)

講解說明

- Q-Learning 是 off-policy 方法
- 不需要已知環境模型
- 透過 bootstrap 方式更新價值估計



Q-Table 結構設計


Q-Table 的維度與索引方式

內容重點

- Q-Table 維度： $[\text{maze_x}, \text{maze_y}, \text{action}]$
- 每一格儲存 4 個動作的 Q-value
- 使用 $\text{tuple}(\text{state})$ 作為索引

講解說明

- NumPy 中直接使用 array 當索引會觸發 advanced indexing
- 轉為 tuple 可確保正確對應到 (x, y) 位置
- 此細節是實務中常見錯誤來源



$\text{state} = (x, y)$

$\text{Q_table}[\text{tuple}(\text{state})]$




$\text{Q_table}[\text{array}(\text{state})]$



advanced indexing
(可能錯誤)

Q-Table 更新範例 1：基本移動

場景：Agent 從狀態 (1,1) 向右移動到 (1,2)，獲得獎勵 0，且非終止狀態。



初始設定： $\alpha=0.1, \gamma=0.9, Q((1,1), \text{Right}) = 0.5,$
 $\max_a Q((1,2), a) = 0.8$

$$Q(s,a) \leftarrow Q(s,a) + \alpha [r + \gamma \max_a Q(s',a') - Q(s,a)]$$

$$Q((1,1), \text{Right}) \leftarrow 0.5 + 0.1 [0 + 0.9 * 0.8 - 0.5]$$


$$Q((1,1), \text{Right}) \leftarrow 0.5 + 0.1 [0.72 - 0.5]$$

$$Q((1,1), \text{Right}) \leftarrow 0.5 + 0.1 * 0.22$$

$$Q((1,1), \text{Right}) \leftarrow 0.522$$

Q-Table 更新範例 2：到達目標狀態

場景：Agent 從狀態 (2,3) 向下移動到目標狀態 (3,3)，獲得獎勵 1，且為終止狀態。



初始設定： $\alpha=0.1, \gamma=0.9, Q((2,3), \text{Down}) = 0.2,$
 $\max Q((3,3), a') = 0$ (終止狀態)

$$Q(s,a) \leftarrow Q(s,a) + \alpha [r + \gamma \max_{a'} Q(s',a') - Q(s,a)]$$

$$Q((2,3), \text{Down}) \leftarrow 0.2 + 0.1 [1 + 0.9 * 0 - 0.2]$$


$$Q((2,3), \text{Down}) \leftarrow 0.2 + 0.1 [1 - 0.2]$$

$$Q((2,3), \text{Down}) \leftarrow 0.2 + 0.1 * 0.8$$

$$Q((2,3), \text{Down}) \leftarrow 0.28$$

Q-Table 更新範例 3：撞到牆壁/障礙

場景：Agent 從狀態 (0,1) 嘗試向上移動，撞到牆壁，獲得獎勵 -0.1，停留在原狀態 (0,1)。



初始設定： $\alpha=0.1, \gamma=0.9, Q((0,1), Up) = 0.1,$
 $\max Q((0,1), a') = 0.4$

$$Q(s,a) \leftarrow Q(s,a) + \alpha [r + \gamma \max_{a'} Q(s',a') - Q(s,a)]$$

$$Q((0,1), Up) \leftarrow 0.1 + 0.1 [-0.1 + 0.9 * 0.4 - 0.1]$$

$$Q((0,1), Up) \leftarrow 0.1 + 0.1 [-0.1 + 0.36 - 0.1]$$

$$Q((0,1), Up) \leftarrow 0.1 + 0.1 * 0.16$$

$$Q((0,1), Up) \leftarrow 0.116$$

探索與利用 (Exploration vs Exploitation)


ϵ -greedy 策略

內容重點

- 初期：高探索率 ($\epsilon = 1.0$)
- 後期：逐步衰減至最小值 ($\epsilon \rightarrow 0.01$)
- 行為決策：
 - 機率 ϵ ：隨機探索
 - 機率 $1-\epsilon$ ：選擇最大 Q-value

講解說明

- 避免過早陷入次佳解
- 探索率衰減有助於最終穩定策略



整體訓練流程說明



講解說明

- 每一回合代表一次完整嘗試
- 回饋總和 (Total Reward) 可作為學習成效指標


學習過程中的行為演化

內容重點


- 初期：隨機走動、頻繁撞牆
- 中期：開始避開障礙物
- 後期：快速找到接近最短路徑



初期 (Early)



中期 (Mid)



後期 (Late)

講解說明

- Total Reward 隨 Episode 增加而上升
- 行為逐漸穩定，策略趨於收斂


最終學習策略的路徑展示

內容重點

- 使用已訓練完成的 Q-Table
- 每一步選擇最大 Q-value 對應動作
- 視覺化 Agent 從起點到終點的完整路徑

講解說明

- 顯示學習成果是否符合預期
- 可用於檢查是否陷入局部最優



方法限制與未來擴充

方法限制 (Limitations)

- Q-Table 在大狀態空間下不可擴展
- 無法處理連續狀態

未來擴充 (Future Extensions)

- 可延伸方向：
 - Deep Q-Network (DQN)
 - 加入狀態特徵
 - 動態迷宮或移動障礙物